



## F01 计算资源、私有缓存与共享带宽池





私有容量按核心独立；带宽由全部核心共享；只读L2仅在Q3启用

硬件约束示意；连线表示资源可达，不是算法步骤。


(a) 输入：操作—张量二部DAG




(b) 划分 g: 原操作恰好归入一个子图

(c) 分核 a 与核序  $\pi$ : 相同子图、不同核心队列


F03 100张计算图的规模与计算组成



每点/每列对应一张图；非COPY工作量按 $\max(1, \text{cycles})$ 。




F04 单张量大小与私有缓存容量



最大单张量不是运行时驻留峰值；零值保留。


(a) 场景A：两个Task



同核边界仍需一次写出、一次读入

**边界COPY: 2b**

(b) 场景B：同一Task



私有缓存允许保留  $t$


**驻留且无Spill时：边界COPY为0**

相同片段： $u_0$ 产生  $b$  字节中间张量， $u_1$ 消费；无其他消费者、非最终输出

场景B消除该同核边界，不代表容量足够或不会Spill

单生产者、单消费者、非最终输出的示意；不含Spill。

(a) 合法核序



核心0: S0, S3

核心1: S1, S2

依赖边与核序边的并图仍无环




数据依赖



核心队列约束

(b) 核序造成等待环




核心0: S3, S0

核心1: S1, S2

 $S0 \rightarrow S1 \rightarrow S3 \rightarrow S0$


## F07 场景A：核数扩展与参考性能




100图逐例比值算术平均；C3并非等搜索预算。

## F08 场景A：全量性能变化与退化定位

(a) 全部400格；红框额外标记退化，不改变色标





(b) 全部9个退化配置，逐项可定位





保留全部400格和完整色标；退化单列，不以平均优势掩盖负例。

F09 场景A：最终Task粒度分布




每核数组100图；箱体为四分位范围，不是置信区间。

## F10 场景A：新增COPY的来源




MiB=1048576 bytes; 算术均值, 不是每图都同向变化。

## F11 场景A：静态计算负载均衡




静态M+V工作量，不等于实际Pipe利用率或Makespan。

# F12 困难案例case\_087：五核执行时间线




原始官方时间线；仅合并相接忙区间，保留空闲。

(a) 逻辑活跃区间：仍有后续使用



示意顺序索引（非实测cycles）

(b) 两者不能同时留在L1




每张量单独可容纳  
不等于二者同时可驻留

逻辑活跃  $\neq$  物理常驻：需换出再读入，或选择不同的合法顺序

此图仅解释容量冲突；不指定替换策略，不推断实测Spill字节数

概念例，非实测活期或Spill量；逻辑活跃不等于物理驻留。

(a) 原依赖：每条链  $A_i$  在  $B_i$  之前，无跨链依赖



所有  $A_i$  读取同一大输入  $tA$ ；所有  $B_i$  读取同一大输入  $tB$

(b) 交替顺序

核心0；横向为顺序，不是持续时间



(c) 同核局部重排


核心0；横向为顺序，不是持续时间



下排同输入连续使用；原始依赖与核心归属不变，但实际收益仍须完整评价


示意前提为  $A_i \rightarrow B_i$ ，无跨链依赖；不保证实际Spill或Makespan改善。

F15 场景B：核数扩展与参考性能





标准一核点为1；实际优化B1另列；非等搜索预算。

## F16 优化B1：相对固定单核的逐图变化




按收益排序展示全部100图；不是标准曲线的一核点。

## F17 场景B：边界COPY与Spill分解



官方模拟前COPY记账；每个核数100图。


## F18 五核B: 非零Spill细节与全量集中度




左侧 $\log_{10}$ 轴仅显示非零值并披露零值数; 右侧保留全部100图。

## F19 五核B: 同次请求的阶段增量

(a) 纵轴局部放大; 标明实际增量




(b) 全部100个请求为分母





100个同次请求阶段配对; 不是等预算独立消融。

## F20 五核B：执行时间与COPY的权衡



相对C3的逐例变化；非等搜索预算；不称全局Pareto前沿。

## F21 微批阶段：两个实际改善案例的配对结果



展示全部2个进一步改善例；其余98例未进一步改善，非等预算独立消融。

## F22 FIFO状态快照与在途读取

概念例：每个键256 KiB；FIFO容量1 MiB；左端最早插入



$t_0 < t_1 < t_2$  仅表示先后；缓存键被逐出，不撤销已发射读取的带宽池选择

按官方语义构造的概念例；不是缓存实测时间线。

## F23 方案×配置：两种比较的实验结构



**配置效应：固定方案**

$$R_{hw} = T_B(P_B)/T_L(P_B)$$

**综合效应：允许另选**


$$R_{select} = T_B(P_B)/T_L(P_L)$$

先逐图求比值，再对100图取算术均值；不能用两条均值曲线相除


仅使用三项已有评分；空白对照不补值，先逐图求比再汇总。

## F24 L2: 三条方案曲线与两种配置比

(a) 三类真实方案；图例末列为五核值




(b) 两种比值；纵轴局部放大




每点100图；右侧直接逐图求比再平均，不用左侧均值相除。

## F25 L2收益：完整长尾与五核典型区间



左图保留500对全范围；右图为五核100对ECDF的局部视窗，分母不变。


## F26 五核：命中字节率与配置收益




100个观测配对；散点关系不是容量或带宽的因果分解。

# F27 case\_073: 缓存事件与共同观察窗口

(a) 真实占用; 阴影与F28使用同一窗口




(b) 同一事件定位: t=1,143,536 cycles




e为全局缓存日志序号; 净占用变化不等于驱逐字节, 更不是Pipe瓶颈归因。


(a) 无L2: 固定PB; T = 2,034,983 cycles




(b) 有L2: 同一PB; T = 1,806,253 cycles



(c) 无L2 / 核心0 / 局部




(d) L2 / 核心0; 红线e2428见F27




阴影为共同绝对时间窗; 红线是L2全局缓存事件, 不指定某Pipe的因果关系。

## F29 五核：不同最终方案的选择解效应




仅列28对方案哈希不同的实例；其余72对方案相同。

# F30 全部同方案L2退化记录




完整8对；横轴放大；低于1表示退化。

# F31 跨场景：相对C3的逐例胜平负





14组各100图；非等搜索预算，仅描述终点解质量。

# F32 求解墙钟与预算长尾




含构造、评价和I/O；非模拟cycles；保留4个1800秒补跑。


(a) 安全链：源出度=1，目标入度=1




(b) 链块深度分带： $\text{band}(C) = \lfloor \text{depth}(C)/2 \rfloor$




(c) 子图结果：带内按弱连通分量合并，不把整带强行并为一个Task



(a) 同一候选日历：ready=5，duration=5，gap=1



(b) 增强索引：用子树摘要排除不可能容纳任务的区间



$t = \max(\text{ready}, \text{low})$ ;  $t + \text{duration} + \text{gap} \leq \text{high}$ . t=14即1400代理cycles。

概念树形，非实际Treap快照；只索引候选日历，不改变官方时刻或评分。