

通用神经网络处理器下的多核调度问题

摘要

多核 NPU 调度要同时决定切图、分核与核内子图次序；操作的开始时刻、核内顺序与 Spill 插入都由官方评价程序决定，Makespan 没有闭式表达式。本文据此建立以官方评价器为目标、以 (Makespan, 新增搬运量) 为字典序的统一优化模型，证明问题在忽略搬运的特例下已是 NP 难的，并给出与方案无关的计算下界；在此基础上设计“结构化候选生成—下界剪枝—整机评价—字典序择优”的求解框架 R12，在 100 张计算图、三个场景共 1400 个配置格上完成全量实验。

针对问题一，场景 A 每个子图独立成 Task，代价集中在边界搬运与启动等待。模型以 $P=(g,a,\pi)$ 为决策，约束含联合无环、Task 释放规则与活跃集合容量。算法收缩两端独占的安全链，按依赖深度分带（宽度 4、8、2、16）取带内弱连通分量得到候选粒度，以尾长优先的追加式分核放置，用官方时间线做划分不变的反馈重排，以 Treap 区间索引加速插入式候选；当前解不超过下界 1.03 倍即判定近优并停止。2 至 5 核平均加速比为 1.855、2.561、3.197、3.743，400 格无一慢于整图单核；相对固定构造基线 C3，逐图耗时平均降低 25.01% 至 43.48%。

针对问题二，同核子图合并为一个 Task 后，代价转向核内驻留与容量溢出。在问题一框架上增加活动核数与驻留组织候选、沿官方关键链的局部移动，以及只在确有 Spill 时启动的局部微批，并证明微批保持核归属不变、因而 Spill 前的边界搬运严格不变。2 至 5 核平均加速比为 1.993、2.801、3.521、4.131，五核最小 1.812，相对 C3 降低 34.49%；五核仅 22 张图发生 Spill，前 10 张占全部 Spill 字节的 93.84%。

针对问题三，按官方实现建立“发射时命中、完成时插入”的 FIFO 只读缓存与两个独立带宽池模型，提出同方案配置比与分别选优比及逐例分解恒等式，把硬件配置效应与选解效应分开。L2 下独立选优的五核平均加速比为 4.219；同方案配置比随核数由 1.001978 升至 1.016766，五核中位数仅 1.000546，分别选优比为 1.027400。命中率与收益不单调对应，500 对同方案对照中 8 对开启 L2 后反而更慢，计划新增搬运由 8.217 MiB 升至 9.403 MiB。

模型检验表明，相对 C3 的优势在 14 个场景-核数组的配对检验中均显著 ($p < 10^{-22}$)；1400 个配置格无一慢于整图单核，并行效率随核数平稳下降；图规模与加速比几乎不相关，结果对核数与规模稳健。

关键词：多核 NPU 调度；计算图切分；字典序优化；可证下界；Spill 触发微批；只读缓存；配置效应分解

1 问题重述

1.1 问题背景

神经网络模型的规模仍在快速增长，单个 AI 核心受制造成本、功耗和散热的约束，难以独立提供所需算力，多核 NPU 因此成为提升并行能力与能效的主流架构。深度神经网络加速器的研究早已表明，片上缓存的数据复用与片外存储的访问次数在很大程度上决定了执行效率和能耗[1,2]。多核化以后，这一问题又多了一层：一张完整的计算图需要被划分为若干子图，分配到不同核心上执行，核内要尽量复用私有缓存中的数据，核间依赖则要经过共享主存或同步机制传递。

多核调度的关键，是在多核并行度、核内缓存容量和共享主存带宽三者之间取得平衡。切得越细，可并行的机会越多，但跨子图的数据要反复经主存中转；切得越粗，搬运越少，但并行度下降、单个子图的缓存压力上升。好的调度方案要在给定硬件和给定计算图上同时照顾这三方面，缩短总体执行时间，并控制额外的数据搬运。

1.2 平台、计算图与方案形式

硬件平台。 平台由 k 个同构 AI 核心和共享的核外主存 DDR 组成。每个核心有 Cube 矩阵计算单元 (PIPE_M)、Vector 向量计算单元 (PIPE_V)、两类数据搬运单元 (PIPE_MTE2 负责搬入，PIPE_MTE3 负责搬出) 以及私有的 L1 与 UB 缓存。四条 Pipe 各自串行、彼此可以并行；全部核心对 DDR 的读写共同竞争固定的总带宽。固定配置下，L1 为 524288 bytes，UB 为 131072 bytes，DDR 总带宽为 60 bytes/cycle。

计算图。 待调度对象是一张操作—张量二部有向无环图 $G=(V,E)$ ， $V=V_T \cup V_O$ 。张量节点带有逻辑位置 (DDR、L1 或 UB) 与字节数；操作节点带有操作类型、执行 Pipe 与周期数，其中 COPY_IN、COPY_OUT 负责 DDR 与核内缓存之间的搬运，其余为核内计算。边只连接张量与操作，本身不携带通信量：依赖跨越子图或 Task 时，搬运字节数由对应张量的大小决定。题目给出的 100 张正式计算图保证每个 DDR 输入只搬入一次、每个最终结果只搬出一次，且单个计算操作的输入输出总量不超过相应缓存容量。

方案形式。 算法输出两部分：切图方案 `node_to_subgraph`，把每个非 COPY 操作映射到一个子图编号；子图调度方案 `core_schedules`，为每个核心给出一条子图执行序列。每个子图必须且只能出现一次，子图依赖图必须无环，同核顺序不得违反依赖。

评价流程。 官方评估程序[3]读入方案后分三步给出结果：按场景规则构造 Task 并补充跨 Task 边界搬运；用题面附录 C 的核内调度算法确定每个 Task 内部的操作顺序，容量不足时自动插入换出与换入；在统一事件时间轴上模拟全部核心、Pipe 与共享带

宽的并行执行。所有操作结束时刻的最大值即为 Makespan，这是最重要的指标；次要指标为总额外数据搬运量，即调度后全部 DDR 搬运量扣除原始计算图已有搬运量后的字节数；问题三另报告只读 Cache 的字节命中率。

1.3 两种硬件场景与共享 L2

场景 A（无核间同步机制）。 一个 Task 只能包含一个子图。同一核上多个 Task 串行执行时核内缓存被清空，因此所有跨子图数据都必须经 DDR 中转，即使相邻两个 Task 位于同一核心也不例外。Task 的激活受两类等待约束：同核前一 Task 完成后至少等待 100 cycles，每个跨核前驱 Task 完成后至少等待 1000 cycles。

场景 B（有核间同步机制）。 同一核心上的全部子图合并为一个 Task，前序子图的数据可以留在 L1/UB 中供后续子图直接使用；跨核依赖由源核写入 DDR 并发出同步信号，目标核的 COPY_IN 在源 COPY_OUT 完成并经过 500 cycles 后才能进入就绪判定。同核复用减少了搬运，但跨多个子图的驻留数据会持续占用缓存，可能压缩其他子图的可用空间。

共享只读 L2。 在场景 B 基础上增加一块由全部核心共享的只读 L2 Cache，容量 1 MiB，读带宽 250 bytes/cycle，与 DDR 带宽相互独立。COPY_IN 在发射时按逻辑张量编号查询 Cache，命中则走 L2 读带宽池，未命中则访问 DDR 并在完成后写入 Cache，容量不足时按先进先出淘汰。

1.4 需要解决的问题

问题一 在场景 A 下建立多核切图与调度模型并设计求解算法：为每个非 COPY 操作分配子图编号，确定各核心上的子图执行顺序；以缩短总体执行时间为主要目标，兼顾总额外数据搬运量，并在 2 至 5 核范围内稳定、高效地给出高质量结果。需提交 1 至 5 核的平均加速比折线图（单核基准为整图单核核内调度的 Makespan，单核加速比定义为 1），附录逐例列出 Makespan 与总额外数据搬运量，附件提供可复现的 Python 程序。

问题二 在问题一的基础上，建立适用于场景 B 的切图与调度模型并设计求解算法，在严格满足 L1/UB 容量约束的前提下进一步缩短总体执行时间、减少额外数据搬运，同样适应 2 至 5 核的变化。需提交场景 B 下 1 至 5 核的平均加速比折线图（定义同问题一）、逐例的 Makespan 与总额外数据搬运量，以及可复现程序。

问题三 在场景 B 的基础上引入共享只读 L2，研究其容量和带宽对多核切图与调度的影响，建立相应模型并设计求解算法。需在正文给出 1 至 5 核下无 L2 与只读 Cache 两种配置的对比曲线，并报告相同核数下只读 Cache 相对无 L2 基线的加速比（无 L2 的 Makespan 除以只读 Cache 配置的 Makespan）；附录逐例列出两种配置的 Makespan、总额外数据搬运量与 Cache 命中率。

三问的结果都必须由使用固定配置的官方评估程序给出，不得修改评估程序与配置。

2 问题分析

2.1 多核调度的核心矛盾

题目要求同时确定三件事：每个计算操作属于哪个子图（切图），每个子图放在哪个核心（分核），每个核心上子图的先后次序（核序）。三者彼此牵制。切图决定了子图规模、并行空间和通信边界；分核决定负载是否均衡、哪些依赖变成跨核依赖；核序决定依赖等待的长短、张量在缓存里驻留多久，以及核内调度是否被迫插入换出与换入。减少切分可以降低通信，却会压缩并行度、增大单个子图的缓存压力；增加切分提供更多并行机会，却会带来重复读取和更多 DDR 搬运。任何一个环节单独做到最好，都不能保证总体执行时间最短。

还有一层困难来自评分方式本身。方案只规定 (g, a, π) ，每个操作何时开始、核内按什么顺序执行、何时插入 Spill，全部由官方评价程序按其确定性规则决定；搬运耗时又取决于同一时刻有多少搬运在争用共享带宽。这意味着我们无法写出 Makespan 关于决策变量的闭式表达式，只能通过完整评价得到它。求解思路因此自然落在“构造合法候选—官方评价—择优”的闭环上，问题的关键变成：候选从哪里来，怎样在有限的评价次数内覆盖有希望的区域，以及怎样判断当前解已经足够好、可以停止搜索。

2.2 输入数据普查

题目给定 100 张正式计算图，统计结果见表 2-1。

表 2-1 100 张正式计算图的规模统计

统计量	最小值	下四分位	中位数	上四分位	最大值
非 COPY 操作数	552	1098	3720.5	7008	35705
张量数	816	1555	4590.5	7953	40287
边数	1841	3348	11187	20378	108272
PIPE_M 计算周期 W_M	0	62556	256920	1334492	58915232
PIPE_V 计算周期 W_V	9988	55496	144314.5	344076	7714975

注：四分位数取经验最近秩；周期数按 $\max(1, \text{cycles})$ 计。

从这张表可以读出三点，它们直接影响方法设计。

规模跨度大。 最大图的非 COPY 操作数是最小图的约 65 倍，操作数不超过 1000 和不少于 10000 的图各有 19 张。固定的切分粒度不可能同时适合两端，粒度必须由图

的结构决定。大图单次官方评价的耗时也更长，在固定预算下能尝试的候选更少，这会反映在求解墙钟的长尾上（5.5.5 节）。

M/V 组成分化。 72 张图以矩阵计算为主，28 张以向量计算为主，其中 7 张没有矩阵计算（图 2-1）。同一核心内 Cube 与 Vector 可以并行，所以一个子图的执行时间更接近两条计算 Pipe 负载的较大者，而不是两者之和。切图时若只按操作数均分，就会漏掉这层结构；本文在分核代理时长中取两条 Pipe 负载与搬运时间的最大值（5.2.3 节）。




图 2-1 100 张计算图的规模与计算组成

单张量不大，容量压力来自重叠。 全部图的最大单张量都不超过对应缓存容量的 0.5625 倍，73 张图不到十分之一（图 2-2）。容量不足因而不是“某个张量放不下”，而是多个张量生命周期重叠造成的，这在场景 B 同核合并 Task 以后尤其明显。




图 2-2 单张量大小与私有缓存容量

2.3 问题一的分析

场景 A 的规则最直接：每个子图独立成为一个 Task，跨 Task 数据一律经 DDR 中转，同核相邻 Task 之间还有 100 cycles 的切换等待，跨核依赖有 1000 cycles 的等待。于是全部额外代价都由切分粒度和 Task 的放置决定。切得太细，边界搬运、重复读取和启动等待成倍增加；切得太粗，并行空间不足，单个 Task 的缓存压力也会上升。

合理的切分应该避开两类没有收益的边界：一是非分支的链，切开它只会凭空增加一次写出与读入；二是依赖深度上相距很近又彼此相连的操作，把它们拆到不同 Task 会引入等待。反过来，同一依赖深度区间内彼此没有连接的部分，天然可以并行放到不同核心。据此，问题一的求解按“安全链收缩—依赖带分组—沿拓扑序追加分核—官方评价择优”展开，并用官方返回的实际 Task 时长做反馈重排，最后用区间索引加速插入式候选的生成（第 5 章）。

2.4 问题二的分析

场景 B 只改了一条规则：同核的全部子图合并为一个 Task。同核子图之间的数据可以留在 L1/UB 中，场景 A 里那部分同核边界搬运随之消失；跨核依赖改为写出、同步 500 cycles、再读入。但“数据留在缓存里”是有代价的：一个张量若被相隔很远的子图使用，它就要在整段时间里占据缓存，挤压其间其他张量的空间，官方核内调度在容量不足时会插入换出与换入。代价的重心由此从边界搬运转向容量溢出，核内执行顺序第一次成为独立的优化对象。

因此问题二不能由问题一替换同步常数得到。本文在问题一框架的候选生成层增加两类机制：一是枚举活动核数与驻留组织，权衡跨核边界与并行度；二是只在当前解确实发生 Spill 时，诊断引起反复换入的大张量，在局部窗口内重排操作顺序，同时保持每个操作的核心归属不变，使 Spill 之前的边界搬运严格不变（第 6 章）。

2.5 问题三的分析

问题三在场景 B 上增加一块共享只读 L2。它服务的是多个核心对同一输入的重复读取：命中的读取走独立的 250 bytes/cycle 读带宽，不再与其他搬运争用 60 bytes/cycle 的 DDR。缓存采用 FIFO：命中在读取发射时判定，插入在读取完成时发生，命中不刷新次序。于是命中率受三类因素影响：张量是否大于容量、两次使用之间插入了多少其他张量、多个核心是否在首次读取完成前就同时发射了同一读取。

问题三真正困难的地方在于测量。开启 L2 以后测得的性能变化混合了两种效应：同一个方案在新硬件上跑得更快（配置效应），以及求解器在新配置下选出了另一个方案（选解效应）。如果只报告一个比值，就会把后者算到缓存头上。本文为此设计“方案×配置”的对照：固定无 L2 下选出的方案，在两种配置下各评价一次，得到纯配置

效应；再与 L2 下独立选优的结果比较，得到选解效应；两者由逐例恒等式联系起来（第 7 章）。

2.6 三问的递进关系与技术路线

三问共享同一决策结构 $P=(g,a,\pi)$ 、同一类评价机制和同一套求解框架，差别在于 Task 的组织方式带来的代价结构：问题一的代价主要是 Task 边界搬运与启动等待，问题二转向核内驻留与容量溢出，问题三又叠加了缓存状态与两条带宽路径。全文技术路线如图 2-3 所示：第 4 章建立统一模型并给出复杂性与下界；第 5 至 7 章在同一框架上分别增加场景专属机制；第 8 章用加速比分布、配对检验、核数与规模的稳健性分析、最终方案来源的白盒统计与求解预算的灵敏度分析对模型进行检验。




图 2-3 全文技术路线

2.7 相关方法与本文定位

有向无环任务图在多处理器上的静态调度是经典问题，NP 难已为人熟知，常用的是按优先级逐个放置任务的构造型启发式及其各种变体[4,5,6]。深度学习编译与加速器领域则更关注数据流与存储层次：加速器研究强调片上缓存复用对能效的决定作用[1,2]，编译器通过算子融合、图划分与并行策略搜索降低访存与通信开销[7,8,9,10]。

与本题的联合无环约束直接相关的是有向无环划分，即要求划分后的商图仍然无环，已有多层划分算法[11]；有限容量下数据搬运量的下界问题，则可以追溯到红蓝卵石博弈[12]。

本题有两个特点使这些方法不能直接照搬。第一，目标由一个带启发式核内调度和共享带宽事件模拟的官方程序给出，任务时长不是常数，而是随切分、放置和并发状态变化；第二，三个场景的 Task 组织方式不同，同一种代价代理在一个场景合理，换到另一个场景就可能失效（6.4.1 节给出了实例）。本文的定位是：以官方评价器为唯一目标，用结构化方法生成覆盖不同粒度与放置的合法候选，用与方案无关的下界做剪枝和近优认证，并对三个场景分别说明哪些机制需要增加、哪些应当舍弃。

3 模型假设与符号说明

3.1 模型假设

本文的假设分两类。第一类是与题面和官方评价程序一致的建模约定，它们不是为了简化而人为引入的，而是评分口径本身的规定，写成假设是为了让后文每一步推导都有明确的出发点；第二类是本文在方法上的选择，需要单独说明理由。

（一）与题面及官方评价程序一致的建模约定

假设 1（评价确定性） 同一计算图 G 、同一方案 P 、同一固定配置 θ 在同一版本的官方评价程序下给出唯一的 Makespan 与搬运统计。 *依据*：题面附录 C 的核内拓扑排序按操作类型、预计算深度和 id 的固定优先级排列，题面附录 D 的离散事件循环按固定次序推进，评价过程中不含随机因素。

假设 2（输入不可改） 原始计算图的操作、周期数、张量大小以及 config.txt 中的全部参数在实验中保持不变；算法只输出 node_to_subgraph 与 core_schedules 两个字段。 *依据*：题面附录 B.1 规定论文中的算法评估结果必须由使用统一配置的评估脚本给出，不得修改。

假设 3（零周期计算） 周期数为零的计算操作按 $\max(1, \text{cycles})$ 计时。 *依据*：这是当前原版实现的实际行为；本文按实现而非文字理解建模，以免估计值与评分出现系统偏差。

假设 4（容量约束的作用对象） L1/UB 容量约束作用于某一时刻核内实际活跃的驻留张量集合，而不是一个子图涉及的全部张量。 *依据*：题面附录 C.3 规定输入张量在最后一次使用完成后释放，题面附录 D.4 规定操作完成后递减引用、最后一次使用完成即释放空间。

假设 5（等待的计费方式） 场景 A 中，同核前一 Task 完成后的 100 cycles 切换等待只对同核前一 Task 计一次；1000 cycles 跨核等待只在前驱与后继分属不同核心時計

入；场景 B 与 L2 场景中，跨核 COPY_IN 须在对应 COPY_OUT 完成 500 cycles 后才进入就绪判定。依据：题面附录 D.2 对问题 1 与问题 2、3 的 Task 激活条件的描述。

假设 6（边界搬运的计数方式） 边界搬运按张量的生产单元与消费单元计数，而不是按操作依赖边计数：场景 A 中，生产 Task 对跨 Task 使用的张量写出一次，其他每个消费 Task 各读入一次；场景 B 中，每一对“生产核心→消费核心”的跨核连接各计一次写出与一次读入。同一张量被同一远端单元多次使用只计一次。依据：题面 1.2 节“边本身不设置通信量，搬运字节数由关联张量的大小决定”，以及官方评估程序重建边界 COPY 的实现（4.4.5 节）。

假设 7（COPY 记账时点） 新增 COPY 字节数在事件模拟之前记账，模拟阶段的只读 Cache 命中不回减该量。依据：官方问题 3 评估程序在模拟前完成 added_copy_bytes 统计；第 7 章的同方案对照中，固定方案在两种配置下的边界与 Spill 新增字节完全一致，与这一记账方式相符。

假设 8（带宽池独立） DDR 带宽池（60 bytes/cycle）与只读 L2 读带宽池（250 bytes/cycle）各自由全部核心共享，两池之间互不占用；池内在途搬运公平分享带宽。依据：题面 1.5 节与附录 D.5。

（二）本文的方法学假设

假设 9（黑箱目标） 把官方评价程序当作确定性的黑箱目标函数，不为其建立代理模型，候选之间的优劣一律以完整官方评价结果判定。理由：评价过程中 Task 释放、Pipe 串行、内存申请次序与带宽公平分配以事件推进方式耦合，写不出闭式目标；代理模型的偏差无法事先界定（4.4.2 节）。

假设 10（有限预算） 每个求解请求在 600 秒软预算内完成候选生成与评价，预算用尽时输出已评价的最好方案；个别用例若在该预算内没有得到任何成功方案，单独放宽预算补跑并如实报告。理由：题面要求在“合理时间内”生成方案，但没有给出具体时限；600 秒使 100 张图、1400 个配置格可在有限机时内全部完成，同时给大图保留多次完整评价的余地。本文不声称结果为全局最优。

假设 11（测试集代表性） 结论只对题目给定的 100 张正式计算图与固定配置成立；向其他图结构或其他硬件参数外推时须另行验证。理由：本文所有统计都是这 100 张图上的描述；第 9 章讨论了外推边界。

3.2 符号说明

全文通用符号列于表 3-1，只在某一章使用的符号在首次出现处另行定义。

表 3-1 主要符号说明

符号	含义	单位或取值
$G=(V,E)$	操作—张量二部有向无环计算图， $V=V_T \cup V_O$	—
U	非 COPY 计算操作集合（方案需要覆盖的对象）	—

符号	含义	单位或取值
S	非空子图集合	—
k	核心数	场景 A 取 2-5；场景 B 与 L2 取 1-5
g	操作划分 $g:U \rightarrow S$ ，即 node_to_subgraph	—
a	核心分配 $a:S \rightarrow \{0, \dots, k-1\}$	—
π_c	核心 c 上的子图执行顺序，即 core_schedules[c]	排列
$P=(g, a, \pi)$	多核切图与调度方案	—
θ	固定硬件配置（容量、带宽、等待常数）	见表 3-2
$\text{Eval}_A, \text{Eval}_B, \text{Eval}_L$	问题 1、2、3 的官方评价算子	—
$T_A(P), T_B(P), T_L(l)$	三种评价下的 Makespan	cycles
$T_{\text{REF},i}$	第 i 张图整图单核的原版核内调度结果（加速比基准）	cycles
D_{added}	新增 COPY 字节数， $D_{\text{added}} = D_{\text{partition}} + D_{\text{spill}}$	bytes
$D_{\text{partition}}$	Spill 之前的 Task 边界新增字节（下文简称“边界新增”）	bytes
D_{spill}	核内容量不足时插入的换出与换入字节（“Spill 新增”）	bytes
F_A, F_B	满足方案规则且官方执行成功的方案集合	—
f_p, r_s	Task p 的完成时刻；Task s 的必要释放时刻	cycles
$\text{Pred}(s)$	子图 s 的数据前驱集合	—
C_m	私有缓存 $m \in \{L1, \text{UB}\}$ 的容量	bytes
$L_{c,m}(\tau)$	时刻 τ 核心 c 上缓存 m 的活跃驻留张量集合	—
b_t	张量 t 的字节数	bytes
W_M, W_V	全图 PIPE_M、PIPE_V 计算周期总和	cycles
L_{CP}	只计算周期的最长依赖路径长度	cycles
LB_k	k 核下与方案无关的计算下界（4.5 节）	cycles
$\bar{S}_k$	k 核下 100 张图逐例加速比的算术平均	—
ρ_i	相对 C3 的逐例耗时降幅	%
$Q(t), H(t)$	只读 L2 的 FIFO 键序列及其字节占用（第 7 章）	—/bytes
h_i	第 i 张图的按字节命中率（第 7 章）	%
$R_{\text{hw}}, R_{\text{select}}$	同方案配置比、分别选优综合比（第 7 章）	—

表 3-2 固定配置参数（全部实验不变）

参数	取值	适用范围
L1 容量 C_{L1}	524288 bytes	每核私有，三问
UB 容量 C_{UB}	131072 bytes	每核私有，三问
DDR 总带宽	60 bytes/cycle	全部核心共享，三问
同核 Task 切换等待	100 cycles	问题 1
跨核前驱等待	1000 cycles	问题 1
跨核拷贝同步延迟	500 cycles	问题 2、3
只读 L2 容量	1048576 bytes (1 MiB)	问题 3
只读 L2 读带宽	250 bytes/cycle	问题 3，独立于 DDR

文中 1 MiB = 1048576 bytes，1 KiB = 1024 bytes。加速比、配置比等无量纲比值在正文一般保留四位有效数字，表格保留六位小数；贴近 1 的配置比在正文也保留六位小数，原因见 7.3.1 节。

4 多核计算图的统一建模


三个问题共享同一组决策变量、同一套可行性条件和同一个评价机制，差别只在 Task 的组织方式以及由此决定的通信代价。本章把这部分公共骨架一次讲清：资源与规模、决策结构、目标与评价口径、评价语义下的时序与资源约束、问题的计算复杂性与下界、三个场景的关系，以及求解框架的总体形态。第 5 至 7 章不再重复推导，只写各场景新增的代价结构和相应的求解机制。

把公共部分单独立章，还有一个比节省篇幅更重要的用处：三个场景之间的差异由此可以被准确定位。从问题一到问题三，改变的究竟是哪几处，每一处改变又为什么会让最优策略随之改变，读者可以逐条对照。

4.1 资源与问题规模

4.1.1 硬件资源的归属

计算单元与私有缓存按核心独立配置，每个核心拥有各自的 L1（524288 bytes）与 UB（131072 bytes）；DDR 带宽则不同，60 bytes/cycle 由全部核心共同竞争。图 4-1 画出了这一归属关系：纵向的核心之间互不干扰，横向的 DDR 通道是唯一的公共资源（结构示意，图中画出三个核心仅作参考，不表示核数固定为三）。



私有容量按核心独立；带宽由全部核心共享；只读L2仅在Q3启用

图 4-1 计算资源、私有缓存与共享带宽池（示意图）

这条不对称性是全文所有权衡的物理根源：**核心数可以增加，带宽不会**。并行度提高以后，只要搬运量随之上升，带宽就会成为新的瓶颈，加速比因此不可能随核数等比例增长。

三个场景共用这套硬件。只有问题三额外增加一块 1 MiB、250 bytes/cycle 的共享只读 L2，它独立于 DDR，构成第二条读路径。

4.1.2 输入规模的异质性

实验使用题目给定的 100 张正式计算图。图与图之间的规模差异很大：非 COPY 操作数从 552 到 35705，最大与最小相差约 65 倍，中位数为 3720.5；每张图 M 计算与 V 计算的工作量占比也明显分化，72 张图以矩阵计算为主，28 张以向量计算为主（图 2-1，每点与每列各对应一张图）。

这一异质性直接决定了求解策略的形态。**任何固定的切分尺度都不可能对所有 100 张图都合理**：对五百操作量级的图合适的粒度，用在三万操作量级的图上会产生过多的子图与边界搬运。因此本文的切图不采用固定阈值，而由图自身的结构（链的分布与依赖深度）决定粒度，细节见 5.2 节。

全文共产生 1400 个配置结果：场景 A 的 400 格（100 图×2 至 5 核），场景 B 与 L2 场景各 500 格（100 图×1 至 5 核）。**这不是 1400 个独立样本**：同一张图在不同核数、不同场景下反复出现，因此涉及分布的陈述均按场景与核数分组给出，不做跨组汇总。

4.2 决策结构与可行性

4.2.1 决策三元组

方案由三项决策构成：


$$P=(g,a,\pi), g:U \rightarrow S, a:S \rightarrow \{0,\dots,k-1\}, \pi_c \text{ 为核心 } c \text{ 的子图顺序} \quad (4-1)$$

g 把每个非 COPY 操作分配到一个子图， a 把每个子图分配到一个核心， π_c 给出核心 c 上的子图执行次序。提交文件只含 node_to_subgraph 与 core_schedules 两个字段。


算法能控制的只有这三项。 操作的具体开始时刻由官方评价流程确定，不由方案指定。这一点在建模上是决定性的，4.3.2 节会展开它的后果。

图 4-2 把同一个概念 DAG 分别画成操作—张量视图、子图划分视图与核心队列视图，三者中的对象一一对应，可以直观区分三项决策各自作用在哪一层；图中核心队列给出的是队列序号而非执行时刻（结构示意，非实际选解）。

(a) 输入：操作—张量二部DAG



(b) 划分 g: 原操作恰好归入一个子图



(c) 分核 a 与核序 π : 相同子图、不同核心队列




图 4-2 调度方案的三种视图：操作划分、核心映射与核序（概念示例）

4.2.2 可行性条件

方案合法需同时满足三条。前两条是覆盖性与唯一排布：

$$\bigcup_{c=0}^{k-1} \bigcup_{s \in \pi_c} g^{-1}(s) = U, \text{ 任意两 } g^{-1}(s) \text{ 互不相交, 每个 } s \text{ 仅在一条队列中出现一次} \quad (4-2)$$

即每个非 COPY 操作恰好归入一个子图，每个子图恰好在一條核心队列中出现一次。

第三条是**联合无环**。记 $u < u'$ 表示原图中存在经张量传递的依赖。子图依赖边与核心队列顺序边分别为

$$E_{\text{dep}} = \{(s, s') : s \neq s', \exists u \in g^{-1}(s), u' \in g^{-1}(s'), u < u'\}, E_{\text{ord}} = \bigcup_c \{(\pi_c(j), \pi_c(j+1))\} \quad (4-3)$$

方案可执行要求有向图 $H(P) = (S, E_{\text{dep}} \cup E_{\text{ord}})$ 无环。这一条容易被忽略，因为原始计算图本身无环；但核序引入的顺序边会与数据依赖边叠加成一个新的有向图，完全可能形成等待环。也就是说，原 DAG 无环不足以保证方案可执行。

联合无环是必要条件而非充分条件：它排除了顺序死锁，但不代替容量与带宽层面的可行性，后者由评价流程在执行中落实。

三个场景共用这一整套决策结构与可行性条件。场景之间的差别不在这里，而在 4.3 节的评价算子与 4.6 节的 Task 组织方式。

4.3 目标函数与评价口径

4.3.1 目标与择优规则

总体执行时间由官方评价器统一计算：

$$T_A(P) = \text{Makespan}\left(\text{Eval}_A^{\text{orig}}(G, P; \theta)\right) \quad (4-4)$$

场景 B 为同一形式，只替换评价算子：

$$T_B(P) = \text{Makespan}\left(\text{Eval}_B^{\text{orig}}(G, P; \theta)\right) \quad (4-5)$$

问题三使用加载了只读 L2 配置的同一套评价流程，记为 $T_L(P)$ 。三者单位均为 cycles。

择优采用字典序：

$$\text{lex min}_{P \in F} (T(P), D_{\text{added}}(P)) \quad (4-6)$$

先比较 Makespan，相同时再比较新增 COPY 字节数；两者都相同时按候选的确定性名称排序，保证结果唯一。

选择字典序而非加权和，是因为加权和需要一个把 cycles 与 bytes 通约的权重，而题目没有给出这个兑换率。任何自定权重都会把评分标准的一部分替换成我们的假设；字典序则严格对应题目“以缩短总体执行时间为主要目标，并兼顾总额外数据搬运量”的主次关系，不引入额外自由度。代价是无法表达“稍慢但搬运大幅减少”这类偏好，而这种偏好本来就不在评分标准里。

4.3.2 把评价器当作黑箱目标的取舍

一个自然的想法是把问题写成混合整数规划或约束规划，交给成熟求解器。本文没有走这条路，理由分三层，三层的性质各不相同。

可写性：目标函数是官方评价器，不是闭式表达式。Task 释放、Pipe 串行、内存申请次序、共享带宽的公平分配这四件事在评价流程内部以事件推进的方式耦合（4.4 节），核内顺序和 Spill 插入还由题面附录 C 的启发式确定，写不出一个能交给求解器的目标函数。

可信性：即便构造代理模型近似评价器，代理与真实评价之间的偏差也会直接转化为解质量的偏差，而这个偏差**无法事先界定**。在评分标准已由评价器唯一确定的场合，用代理模型优化，等于在优化一个与评分无关的量。

规模：题目要求在合理时间内给出方案，而最大图有 35705 个非 COPY 操作；即使只保留操作到核心的分配，决策空间也随操作数指数增长，4.5.1 节进一步说明问题在很弱的特例下已是 NP 难的。

三条求解路线的对比见表 4-1。

表 4-1 三条求解路线的比较

路线	目标与评分的一致性	大规模可行性	最优性信息	可复现性
精确规划 (混合整数 规划、约束 规划)	需近似评价语义，存在建 模偏差	最大图 35705 个 非 COPY 操作， 决策空间指数增 长	可解时给出最优 或间隙	高
代理目标 + 元启发式 (遗传、模 拟退火等)	优化的是代理量，偏差无 法事先界定	可行，但每一步 都依赖代理评估	无	依赖随机种子
本文：结构 化候选 + 官 方评价闭环	完全一致，官方评价器即 目标	可行，成本由官 方评价次数决定	下界剪枝与近优 认证 (4.5.2 节)	高：无随机种 子，结果与方案 哈希绑定

三层之中第二层是决定性的：即使时间无限，代理偏差的问题也不会消失。若把遗传、模拟退火等方法直接接在官方评价器上以消除代理偏差，又会受评价成本约束：大图的一次完整评价就要消耗可观的预算（case_087 的场景 A 四格在 600 秒内没有得到成功方案，5.5.5 节），而这类方法通常需要成百上千次评价才能收敛。因此本文选择“合法候选构造 + 真实评价反馈”的闭环，**牺牲解析意义上的最优性保证，换取报告值与评分口径的严格一致**。4.5.2 节给出的与方案无关的计算下界，则用于剪枝和判断何时可以停止搜索。

4.3.3 基准与对照

基准 REF 取原版核内调度算法在整图单核上的结果。按题目要求，不使用各方法自行优化后的单核结果作为分母，因此单核加速比按定义为 1。逐核平均加速比为

$$\bar{S}_{A,k} = \frac{1}{100} \sum_{i=1}^{100} \frac{T_{\text{REF},i}}{T_{A,i,k}}, \bar{S}_{A,1} = 1 \quad (4-7)$$

先逐图求比值再取算术平均，不用“平均耗时之比”替代。场景 B 与 L2 场景同形式。REF 本身来自启发式核内调度而非最优调度，因此个别图的多核加速比超过核数在原理上是可能的，8.2 节给出了实际计数。

对照基线 C3 是本文构造的可复现固定基线：合并安全链、按就绪层平衡计算负载、用场景 A 的等待与边界代理分核，一次成型后不再迭代。它与本文方法使用相同输入、相同官方评分口径。

C3 的性质需要先说明，以免后续章节的相对降幅被误读。C3 不是随机调度或朴素贪心，而是一个**自身即可独立运行的完整构造方法**；选这样一条基线，本文报告的相对改进就不会因基线过弱而虚高。另一方面，C3 是一次性完成的构造，本文方法是利用官方反馈的多候选搜索，两者搜索成本不同，因此 **C3 是事后同口径对照，不是等搜索预算的消融实验**，两者的终点性能差不能解释为等成本下的算法效率差。相对 C3 的逐例比较口径为

$$\rho_i = 1 - \frac{T_{R12,i}}{T_{C3,i}}, \bar{\rho} = \frac{1}{100} \sum_{i=1}^{100} \rho_i \quad (4-8)$$

同样是逐图先计算再平均，不是求解程序的墙钟降幅。

4.4 评价语义下的时序、容量与带宽约束

本节把题面附录 C、D 描述的评价语义写成约束的形式。需要强调，这些约束刻画的是“任何一次合法执行都必须满足的条件”，具体的开始时刻由评价流程按其确定性规则给出，并不是本文的决策变量。

4.4.1 操作级依赖与 Pipe 串行

记 s_v 、 f_v 为操作 v 的开始与完成时刻， p_v 为其周期数（计算操作按假设 3 取 $\max(1, \text{cycles})$ ）， $\text{pipe}(v)$ 与 $\text{core}(v)$ 为其所在流水线与核心。数据依赖与同一 Pipe 上的串行分别为

$$s_v \geq f_u, \forall (u \rightarrow v), t \in V_T \quad (4-9)$$

$$f_u \leq s_v \text{ 或 } f_v \leq s_u, \forall u \neq v, \text{core}(u) = \text{core}(v), \text{pipe}(u) = \text{pipe}(v) \quad (4-10)$$

计算操作满足 $f_v = s_v + p_v$ ；搬运操作的完成时刻由 4.4.4 节的带宽共享规则决定。不同 Pipe、不同核心之间可以并行，同一核心内的 Cube 与 Vector 单元也因此可以同时工作，这正是题目提示的“核内矩阵单元与向量单元自动并行”。

4.4.2 Task 的释放时刻

记 f_p 为 Task p 的完成时刻。同核前一 Task 带来固定的切换等待：

$$r_s^{\text{seq}} = f_{\text{prev}(s)} + 100 (\text{存在同核前一Task}), r_s^{\text{seq}} = 0 \text{ 否则} \quad (4-11)$$

数据前驱带来的释放约束为

$$r_s^{\text{dep}} = \max(\{0\} \cup \{f_p + 1000 \cdot 1_{\{a(p) \neq a(s)\}} : p \in \text{Pred}(s)\}) \quad (4-12)$$

两者取大得到必要释放时刻：

$$r_s = \max(r_s^{\text{seq}}, r_s^{\text{dep}}) \quad (4-13)$$

两处计费细节直接影响代价估计的正确性：100 周期的切换等待**只对同核前一 Task 计一次**，不在每条数据边上重复；1000 周期的跨核等待**只在前驱与后继分属不同核心时计入**。并集中的 0 使无前驱的 Task 也有定义。 r_s 只是必要条件，Task 内部的操作还须满足式(4-9)式(4-10)与内存申请次序。

场景 B 与 L2 场景的跨核传输另有一条同步约束：

$$s(\text{COPY_IN}_e) \geq f(\text{COPY_OUT}_e) + 500 \quad (4-14)$$

e 为一条实际跨核传输。这同样是必要释放条件，源端写出完成加 500 周期并不意味着目标端立即发射。

4.4.3 私有容量约束

$$\sum_{t \in L_{c,m}(\tau)} b_t \leq C_m, m \in \{L1, UB\} \quad (4-15)$$

这条约束最容易被误读的是它的作用对象： $L_{c,m}(\tau)$ 是时刻 τ 核心 c 上缓存 m 的**实际活跃驻留集合**，不是该子图的全部张量集合。两者的区别直接影响对切图粒度上限的判断：从子图的张量总量推不出容量意义上的操作数上限。容量不足时，官方核内调度从未来仍会使用的驻留张量中换出下一次使用最晚者，这正是 Belady 最远未来使用策略[13]；换出与换入的字节计入 D_{spill} 。

图 2-2 给出了输入尺度的证据：100 张图的最大单张量与对应容量之比全部落在 1.0 以内（最大为 0.5625），73 张图不到容量的十分之一（零值保留）。也就是说，**容量压力不来自单个张量装不下，而来自多个张量的生命周期重叠**。这正是式(4-15)必须约束活跃集合的原因，也解释了 Spill 为什么在切分粒度较粗时才成为主要代价（详见第 6 章）。最大单张量只描述输入尺度，不能由此推断运行时的驻留峰值。

4.4.4 共享带宽的公平分配

访问 DDR 的搬运以“独占全部带宽时尚需的周期数”记录剩余工作量 w_j 。设带宽池 p 的总带宽为 B_p 、时刻 t 的在途搬运集合为 $A_p(t)$ ，则

$$w_j(t_j^{\text{issue}}) = \frac{b_j}{B_p}, \frac{dw_j}{dt} = -\frac{1}{|A_p(t)|}, f_j = \min\{t : w_j(t) = 0\} \quad (4-16)$$

即每个在途搬运分得 $B_p/|A_p(t)|$ 的速率；有搬运加入或完成时，评价器先按原并发数结算上一时段，再重算各搬运的预计完成时刻。三问的 DDR 池 $B_{\text{DDR}} = 60$ bytes/cycle；问题三另有只读 L2 读池 $B_{L2} = 250$ bytes/cycle，两池互不占用（第 7 章）。

式(4-16)说明了搬运时间为什么不能在切图阶段预先算定：同一次 COPY 的耗时取决于它执行期间有多少别的搬运在争用同一池，而这又取决于全部核心的执行进度。这是 4.3.2 节“写不出闭式目标”的具体来源之一。

4.4.5 边界搬运的计账

新增 COPY 由两部分组成：切图产生的 Spill 前边界搬运，以及核内容量不足时插入的换出与换入，

$$D_{\text{added}}(P) = D_{\text{partition}}(P) + D_{\text{spill}}(P), D_{\text{partition}}(P) = \sum_{t \in V_T} D(t) - D_{\text{orig}} \quad (4-17)$$

其中 D_{orig} 为原始计算图已有的 COPY 字节。记张量 t 的生产单元集合为 P_t 、消费单元集合为 C_t ，只统计非 COPY 操作所在的单元：场景 A 的单元是子图（即 Task），场景 B 的单元是核心；图输入张量由原有的 COPY_IN 产生，其 $P_t = \emptyset$ 。记 φ_t 表示 t 是最终输出或没有消费者。按官方评估程序重建边界 COPY 的实现，

$$D^A(t) = b_t \left(|C_t \setminus P_t| + \sum_{p \in P_t} 1[\varphi_t \vee C_t \setminus \{p\} \neq \emptyset] \right) \quad (4-18)$$

$$D^B(t) = b_t \left(|C_t| \cdot 1[P_t = \emptyset] + |P_t| \cdot 1[\varphi_t] + 2 \sum_{p \in P_t} |C_t \setminus \{p\}| \right) \quad (4-19)$$

场景 A 中，生产 Task 把跨 Task 使用的张量写出一次，其他每个消费 Task 各读入一次；图输入被几个 Task 使用就要读入几次，这正是题面所说的“重复读取”。场景 B 中，同核消费不产生搬运，每一条跨核连接各对应一次写出与一次读入。两式直接给出两条后文要用的推论：

- 场景 A 的 $D_{\text{partition}}$ 只由划分 g 决定，与核心分配 a 、核序 π 无关，所以“保持划分不变的反馈重排”不会改变边界搬运（5.2.3 节）；
- 场景 B 的 $D_{\text{partition}}$ 只由每个操作的核心归属 $a \circ g$ 决定，与核内子图划分和次序无关，所以保持核归属不变的局部微批不会改变边界搬运（6.2.4 节）。

两式都不含 Spill，也不扣除问题三中只读 Cache 的命中，因此 D_{added} 是计划中的搬运请求量，而不是物理 DDR 的净流量（7.4.6 节）。

4.4.6 模型汇总

综合 4.2 至 4.4 节，三问共用的多核切图与调度模型为

$$\begin{aligned} \text{lex } \min_{P=(g,a,\pi)} (T(P), D_{\text{added}}(P)) \text{ s.t. } & \begin{cases} \text{覆盖、唯一与无环：式 (4-2) 式 (4-3)} \\ \text{依赖与Pipe串行：式 (4-9) 式 (4-10)} \\ \text{释放与跨核同步：式 (4-11) 至式 (4-14)} \\ \text{活跃集合容量：式 (4-15)} \\ \text{带宽公平共享：式 (4-16)} \\ \text{搬运记账：式 (4-17) 至式 (4-19)} \end{cases} \end{aligned} \quad (4-20)$$

三个场景在这一模型中只有三处不同：Task 的组织（场景 A 为“一个子图一个 Task”，场景 B 与 L2 为“一个核心一个 Task”），释放规则（场景 A 用式(4-11)至式(4-13)，场景 B 与 L2 用式(4-14)），以及评价算子与带宽池（场景 A、B 为 T_A 、 T_B 与 DDR 单池，L2 另加只读读池与 FIFO 状态，见第 7 章）。决策变量只有 (g, a, π) ，各操作的开始时刻、核内顺序与 Spill 由评价语义唯一确定，所以式(4-20)不是一个可以直接交给求解器的规划模型，而是对“评价器作为目标”这一问题的完整数学描述。

4.5 问题的计算复杂性与下界

4.5.1 NP 难性

命题 4.1 即使令全部张量大小为 0（从而不产生任何搬运耗时）、全部计算操作两两独立，在 $k=2$ 时求场景 A 或场景 B 的最小 Makespan 仍是 NP 难问题。

证明 取 n 个相互独立、均在 PIPE_V 上执行的计算操作，周期为正整数 $p_1, \dots, p_n$ 。场景 B 中每个核心的全部子图合并为一个 Task，同核操作在 PIPE_V 上串行（式(4-10)），而不同核心互不影响，故 Makespan 等于两核 PIPE_V 周期和的较大者。场景 A 中，把同核的全部操作放入同一个子图可以得到同一数值，而把它们拆成多个子图只会额外引入同核切换等待（式(4-11)），不会更短。因此在两种场景下，“是否存在

Makespan 不超过 $1/2 \sum_j p_j$ 的方案”都等价于判定 $\{p_j\}$ 能否划分为和相等的两部分，即 PARTITION 问题，它是 NP 完全的[14]。□

命题 4.1 给出了本文放弃精确求解的另一个理由：一般情形还叠加了依赖、共享带宽与容量，只会更难。它也说明，对大规模实例能做的是在有限预算内给出好的可行解，并判断何时已经不值得继续搜索，这正是下一小节下界的用处。

4.5.2 与方案无关的计算下界

记 W_M 、 W_V 为全图 PIPE_M 与 PIPE_V 计算周期之和， L_{CP} 为只计计算周期的最长依赖路径长度，定义

$$LB_k = \max \left\{ \lceil \frac{W_M}{k} \rceil, \lceil \frac{W_V}{k} \rceil, L_{CP} \right\} \quad (4-21)$$

命题 4.2 对任意核数 k 下的任意可行方案 P ，三种评价下都有 $T(P) \geq LB_k$ 。

证明 每个核心只有一条 PIPE_M，同一核心的矩阵计算在其上串行（式(4-10)），全部 W_M 周期分布在 k 条 PIPE_M 上，至少有一条承担不少于 W_M/k 周期；周期为整数，故可取上整。 W_V 同理。沿任一依赖路径，计算操作须依次完成（式(4-9)），搬运耗时与各类等待均非负，故 Makespan 不小于 L_{CP} 。计算操作的实际耗时 $\max(1, \text{cycles})$ 不小于其周期数，下界仍然成立。□

把“开始不早于某时刻、结束后还须接续一段计算”的操作放在一起看，可以得到更紧的窗口下界。记 r_v 为只计计算周期时操作 v 的最早开始时刻， q_v 为其全部后继链上计算周期的最大值， c_v 为其周期数。对任一流水线类型 $p \in \{M, V\}$ 与阈值 $\alpha, \beta \geq 0$ ，集合 $U(\alpha, \beta, p) = \{v: \text{pipe}(v) = p, r_v \geq \alpha, q_v \geq \beta\}$ 中的操作只能在 $[\alpha, T - \beta]$ 内执行，且全图共有 k 条该类流水线，于是

$$T(P) \geq \alpha + \beta + \frac{1}{k} \sum_{v \in U(\alpha, \beta, p)} c_v \quad (4-22)$$

取 $\alpha = \beta = 0$ 即回到式(4-21)的前两项。求解器用区间最大值线段树在全部阈值组合上取式(4-22)的最大值作为窗口下界，它同样与方案无关。

LB_k 与划分、分核、核序都无关，因此可以同时用于两件事：在求解中判断当前解是否已足够接近最优（4.7.3 节的停止准则），以及作为全部官方结果的一致性检验（任何评价结果若低于它，说明实现或记录有误）。它忽略了共享带宽、跨核等待和边界搬运，在核数较多、搬运较重时会变松，因此只用于剪枝与停止判断，不用来比较候选之间的优劣。

4.6 三个场景的关系

三个场景共用 4.2 至 4.5 节的全部结构，差别集中在 Task 的组织方式与由此引出的代价结构上。

表 4-2 三个场景的对照

维度	场景 A (问题一)	场景 B (问题二)	L2 场景 (问题三)
Task 组织	每个子图独立成 Task	每核全部子图合并为一个 Task	同场景 B
同核跨子图数据	必须经 DDR 中转	留在 L1/UB 中直接复用	同场景 B
跨核同步	前驱完成后 + 1000 cycles	写出完成后 + 500 cycles	同场景 B
主要代价	Task 边界搬运	核内驻留与容量溢出	缓存交互 (命中与逐出)
评价配置	$Eval_A$	$Eval_B$	$Eval_B + 1 \text{ MiB}$ 只读 L2、250 bytes/cycle
求解策略差异	不使用局部微批	可用 Spill 触发的局部微批	同场景 B，另做配置效应与选解效应的分离分析

从 A 到 B 只改动了一条规则，即同核子图是否合并；但这一条改动使代价结构整体转向：同核边界搬运消失，跨子图驻留带来的容量溢出取而代之，核内执行顺序第一次成为独立的优化对象。从 B 到 L2 的改动更局部，只增加一条独立读路径；正因为效应微小，它带来了一个前两问不会遇到的问题：如何确认测到的究竟是硬件的效应，还是求解器行为变化的效应。

这里先点明两条边界，细节分别在第 6、7 章展开：**场景 B 不能由场景 A 替换同步常数平移得到**；**L2 的收益必须把硬件配置效应与求解器选解效应分开报告**。

4.7 求解框架总览

4.7.1 三层结构

本文的求解框架记为 R12，由三层构成。

候选生成层从原图产生结构合理的合法方案，包含安全链收缩、依赖带分带与追加式分核；**筛选剪枝层**在送评价之前排除不可能更优的候选，包含覆盖性与联合无环检查、有效资源下界，以及用于加速插入位置查找的区间索引；**评价择优层**调用官方评价器，按式(4-6)的字典序保留最优解。

三层之间只有一个接口，即候选方案，因此任何一层都可以在不改动其余两层的前提下替换。**三个场景的专属机制全部加在第一层**，这是同一套框架能够适配三种代价结构的结构原因。

4.7.2 组件清单

各组件的设计依据与实现细节分别见 5.2、6.2、7.2 节，此处只交代职责。一次请求内，各组件按下列顺序依次运行，共用同一软预算：

1. **控制链**：先运行基础构造器得到首个可行解；再尝试至多 6 个“减少活动核心”的候选；场景 A 随后生成依赖带候选（宽度 4、8、2、16）。依赖带候选由安全

链收缩、依赖带弱连通分组与追加式分核构成，追加式分核沿统一的合法拓扑序推进，不会由构造自身引入等待环。

2. **反馈重排**：利用官方评价返回的时间线修正代理时长后重新安排。场景 A 为“划分 g 不变、按实测 Task 时长重新分核与排序”，划分不变意味着边界搬运结构不变；场景 B 与 L2 场景为沿官方时间线上关键链的至多 4 个局部移动。
3. **分量家族**：对活动核数 $m \leq k$ 与驻留组织参数枚举候选，至多评价 6 个新候选（场景 B 与 L2 场景的主要结构候选；场景 A 同样运行，但以 Task 激活下界剪枝）。
4. **跨配置重评价**（仅 L2 场景）：在同一请求内独立求解一个场景 B 方案，并按 L2 配置重新评价，成本计入该请求。
5. **插入式候选**：用确定性区间索引加速“最早可行位置”的查找。它只加快同一条插入规则的执行，不改变判定结果。
6. **Spill 触发的局部微批**：仅当当前解确有容量溢出时才诊断并重排（场景 B 与 L2 场景；场景 A 因不存在驻留复用收益而不使用）。

第 1 至 4 项的每个阶段在开始前都检查近优认证条件式(4-23)（基础构造在评价每个候选之前检查），成立即跳过；第 5、6 项不受这一门控，只受剩余预算约束。每个组件产生的候选都走同一条处理链：覆盖与联合无环检查、哈希去重、下界剪枝、官方评价、字典序择优。执行顺序与门控条件如图 4-3 所示，各组件的参数汇总于表 4-3，全部取自求解器源码，在 1400 个配置格的实验中保持不变。




图 4-3 R12 一次求解请求的流程

表 4-3 R12 算法参数一览

模块	参数	取值	说明
全局	单请求软预算	600 s	case_087 的场景 A 四格补跑用 1800 s
全局	近优认证阈值	$T \leq 1.03 \cdot LB$	满足即跳过其余改进阶段
控制链	基础构造的单次评价 上限	120 s	同时做下界剪枝
控制链	减少活动核心的候选	至多 6 个	三个场景
控制链 (A)	依赖带宽度 w	4、8、2、16	四种粒度

模块	参数	取值	说明
控制链 (A)	分组软目标	2048 个操作	粒度控制参数，不是容量上限
反馈重排 (B/ L2)	关键链局部移动	至多 4 个	仅用于不超过 10000 个操作的图
分量家族	活动核数 m ；驻留 组织 target	$m \leq k$ ； 0、512、2048	至多评价 6 个新候选，单次 30 s
插入式候选 局部微批 (B/ L2)	生成时限；评价上限 触发条件	30 s；120 s Spill 新增>0；张量 不小于容量的 1/4； 前后使用距离不超过 8	场景 A 的日历间隔为 100 见式(6-4)
局部微批 (B/ L2)	窗口	4、8 个子图；至多 16 个窗口；每窗至 多 128 个原计算操 作；至多 2 个候选	见式(6-5)
局部微批 (B/ L2)	诊断时限；单候选评 价上限	40 s；45 s	诊断在独立进程中进行
跨配置重评价 (L2)	B 方案求解时限；评 价上限	至多 180 s；40 s	成本计入同一请求

4.7.3 停止准则与两条性质

停止准则。 请求在三种情况下结束：预算用尽；全部候选枚举完毕；当前最好解已被下界认证为近优，即

$$T(P^*) \leq 1.03 \cdot LB \quad (4-23)$$

此时最优性间隙不超过 3%，后续改进阶段直接跳过（LB 取式(4-21)或同性质的窗口下界）。这条准则把节省下来的预算让给确实还有改进余地的大图，而不会让近优的小图空耗评价次数。

同次请求内不变差。 候选只有通过官方评价且字典序严格更优才会替换当前解，因此最终输出不会劣于流程起点得到的控制解。该性质成立于同一次请求、同一版本、同一机器、同一超时设置之下，不跨请求成立。

确定性与可复现。 索引的平衡优先级由固定的整数散列生成，候选按确定性名称排序，全流程不使用随机种子；每个结果都绑定方案、官方结果与输入的 SHA256 哈希。需要说明的是，各阶段受墙钟预算约束：预算未截断时，同一输入重复运行得到相同方案；若某阶段因预算或超时被截断，被评价的候选数可能随机器负载变化，最终方案也可能随之不同。本文全部结果均保留了实际运行的方案哈希，复查以存档方案为准。

4.8 小结

本章确立了三问共享的建模骨架：决策三元组 $P=(g,a,\pi)$ 、含联合无环在内的三条可行性条件、以官方评价器为黑箱目标的字典序择优、评价语义下的依赖、Pipe、释放、容量与带宽约束，以及问题的 NP 难性与一个与方案无关的计算下界。三个场景在

这套骨架上只改变 Task 的组织方式与评价算子，求解框架相应地只在候选生成层增加场景专属机制。

有两处建模取舍决定了全文结论的形态。其一，把评价器当作黑箱目标，换来报告值与评分口径的零偏差，代价是放弃最优性的解析保证，本文以与方案无关的下界支撑剪枝与近优认证；其二，选择一条完整构造方法而非弱基线作为对照，使相对改进的数值更保守，也更可信。

按此框架，三个场景在五核下相对基准的平均加速比分别为 3.743、4.131、4.219，相对 C3 的逐图耗时降幅平均分别为 43.48%、34.49%、31.41%。这些结果的完整分布、代价分解、退化记录与边界条件，分别在第 5、6、7 章给出。

5 问题一：场景 A 下的多核切图与调度

场景 A 要求把计算图切成若干子图，每个子图独立成为一个 Task，再把 Task 分配到多个核心并确定核内次序。本章把官方评价器作为确定性的黑箱目标函数，给出“结构化候选生成—下界剪枝—整机评价—字典序择优”的求解框架，并在 100 张计算图、2 至 5 核共 400 个配置格上给出完整结果。五核相对整图单核的平均加速比为 3.743，中位数 4.130，最小值 1.202；相对固定构造对照基线 C3，五核逐图耗时平均下降 43.48%。

5.1 问题分析与数学模型

5.1.1 问题分析

第 4 章已经确立了三问共享的决策结构与评价机制。场景 A 是三者中约束最直接的一个：每个子图独立成为一个 Task，跨 Task 数据一律经 DDR 中转，因此全部额外代价都由切分粒度与 Task 的放置决定。本章在这一最简结构上给出完整的求解路径与实验结果，后两章在此基础上替换代价模型。

难在哪。 子图独立成 Task 这条规则带来两个后果：跨 Task 的数据即使落在同一核心上也必须经 DDR 中转，Task 之间还存在启动等待。于是“把操作数量平均分到各核”不是一个有意义的目标。切分变细会同时增加重复读取、边界搬运与启动次数；切分变粗则压缩并行空间，单个 Task 的驻留压力上升，官方核内调度被迫插入更多换出与换入。两个方向各有代价，最优粒度不在任何一端。资源归属使这个矛盾无法靠增加核心来回避：核心可以增加，DDR 带宽不会（4.1.1 节）。

为什么不能直接套用现成方法。 目标函数是官方评价器，不是闭式表达式（4.3.2 节）；即使在忽略搬运的特例下，问题也已是 NP 难的（命题 4.1）。以精确规划为路线的方法在这里没有入口，基于代理模型的方法又会引入无法事先界定的偏差。

我们的切入点。 用图自身的结构信息生成合法候选，再用官方评价的真实反馈筛选与改进；评价器既是目标也是唯一的裁判，全程不引入代理目标函数。代理量只用于构造候选和剪枝，不参与最终择优。

本章产出。 100 张计算图在 2 至 5 核下的 400 个配置格全部得到完整结果，并给出加速比分布、新增 COPY 的两类来源分解、全部退化配置与预算例外的完整记录。

5.1.2 场景 A 的模型

场景 A 的决策变量、可行域与目标完全沿用第 4 章：方案 $P=(g,a,\pi)$ 见式(4-1)，覆盖性、唯一排布与联合无环见式(4-2)式(4-3)，目标为式(4-4)的 $T_A(P)$ ，择优按式(4-6)的字典序， F_A 为满足方案规则且官方执行成功的方案集合。场景 A 特有的约束是 Task 的释放规则式(4-11)至式(4-13)：同核前一 Task 完成后等待 100 cycles，跨核前驱完成后等待 1000 cycles，并且每个 Task 开始执行时核内缓存为空，其全部输入都要从 DDR 读入。问题一的模型因此是式(4-20)在场景 A 下的实例：

$$\text{lex min}_{P=(g,a,\pi)} \left(T_A(P), D_{\text{added}}^A(P) \right) \text{ s.t. } \begin{cases} \text{式 (4-20) 的全部约束组} \\ \text{Task} \equiv \text{子图, 释放按式 (4-11) 至式 (4-13)} \\ \text{边界记账按式 (4-18)} \end{cases} \quad (5-1)$$

联合无环这一条在场景 A 中尤其要紧，因为一个核心上往往排着几十乃至上千个 Task。当核心 0 的队列写成 S_3 先于 S_0 时， $S_0 \rightarrow S_1 \rightarrow S_3 \rightarrow S_0$ 就形成了等待环，尽管每条数据依赖本身都没有问题（图 5-1 的反例，结构示意）。核序合法性必须在式(4-3)定义的并图上检验。




图 5-1 数据依赖与核心队列的联合无环约束（合法例与反例）

场景 A 中每个 Task 独立占用缓存，容量约束式(4-15)在每个 Task 内部分别起作用。开始时刻、核内顺序、Spill 插入全部由官方 Step1/Step2/Step3 决定，算法能控制的只有 (g, a, π) ；这正是本文把评价器当作黑箱目标的原因。这样做的收益是报告数值与官方口径完全一致，代价是无法对最优性给出解析保证。

5.2 求解算法

5.2.1 求解路径与方法选择

本章的求解路径分三步。第一步用图的结构信息确定切分粒度：先收缩不该被切开的链，再按依赖深度分带成组。第二步把子图沿合法拓扑序追加到各核心队列，使构造本身不产生等待环。第三步把得到的方案交官方评价器打分，用真实反馈筛选并改进，直到预算耗尽或当前解被下界认证为近优。框架的三层结构见 4.7.1 节，每次请求都从原图开始，不读取历史结果中的优胜方案。

方法选择上有一处需要单独说明：**为什么安全链要求两端独占**。出度为 1 且入度为 1 是使合并必不劣成立的最弱条件。若源操作出度大于 1，合并会使其余消费者变成跨 Task 访问；若目标操作入度大于 1，合并会把其余生产者拉进同一依赖前沿。只有两端都独占时，合并才不改变该边之外的任何边界关系，强行切开只会凭空增加一次边界搬运。放宽这一条件可以得到更大的链块，但合并收益不再有保证，只能逐个送评价验证。

5.2.2 安全链收缩与依赖带分带

第一步是识别不该被切开的结构。沿拓扑序扫描，若一条边的源操作出度为 1、目标操作入度为 1，就把两端并入同一链块，直到遇到分支为止；每个非 COPY 操作恰好属于一个链块 C ，链块是后续切分的最小单位。由于被收缩的每条边都满足两端独占，收缩不会在商图中制造新的环。

链块按依赖深度分带：

$$\text{depth}(C) = 1 + \max(\{-1\} \cup \{\text{depth}(C') : C' \in \text{Pred}(C)\}), \text{band}(C) = \lfloor \text{depth}(C) / w \rfloor \quad (5-2)$$


无前驱的链块深度为 0。宽度 w 依次取 4、8、2、16，生成四种粒度的候选。带内不是把整条带并成一个 Task，而是只沿同带链块之间的依赖做图遍历，求出带内的弱连通分量；过大的分量再按原链块拓扑顺序切成连续段，每段不超过 2048 个操作（粒度控制的软目标，不是物理容量上限）。

这样构造保证了三件事：跨带依赖只指向后续带，带内不同弱连通分量之间无依赖，连续拓扑段之间也只向前。图 5-2 以 $w=2$ 的概念例展示完整流程：带 2 含两个互不相连的分量，因此形成 S_2 与 S_3 两个独立子图而非一个（结构示意，示意规模不触发 2048 操作的软分组目标）。

(a) 安全链：源出度=1，目标入度=1



(b) 链块深度分带：band(C)=⌊depth(C)/2⌋



(c) 子图结果：带内按弱连通分量合并，不把整带强行并为一个Task




图 5-2 安全链与依赖带如何形成子图（示意图）

5.2.3 追加式分核与反馈重排

得到子图之后，用一个与场景 A 规则一致的代理时长来决定分核。记子图 s 的矩阵、向量计算周期为 $W_M(s)$ 、 $W_V(s)$ ，子图内部只计计算周期的最长路径为 $L_{\text{int}}(s)$ ，从外部读入与向外写出的字节为 B_s^{in} 、 B_s^{out} ，则代理时长为

$$d_s = \max \left\{ W_M(s), W_V(s), L_{\text{int}}(s), \frac{B_s^{\text{in}} + B_s^{\text{out}}}{60} \right\} \quad (5-3)$$

取最大值而不是求和，对应的是核内 Cube、Vector 与搬运 Pipe 可以并行（4.4.1 节），题目提示的“两个计算单元之间的负载均衡”由此进入代理。子图的尾长定义为

$$\text{tail}(s) = d_s + \max \left\{ \{0\} \cup \{1000 + \text{tail}(s') : s' \in \text{Succ}(s)\} \right\} \quad (5-4)$$

它估计从 s 开始到图结束至少还要多久。算法维护就绪集合，每次取出尾长最大的子图 s （平局依次比较代理时长与编号），对每个核心 c 估计 s 的最早开始时刻

$$\hat{r}_c(s) = \max \left\{ \ell_c + 100 \cdot 1_{\{\pi_c \neq \emptyset\}}, \max_{p \in \text{Pred}(s)} \left(\hat{f}_p + 1000 \cdot 1_{\{a(p) \neq c\}} \right) \right\} \quad (5-5)$$

其中 ℓ_c 为核心 c 当前队尾的估计完成时刻， $\hat{f}_p$ 为前驱的估计完成时刻；然后把 s 追加到使 $\hat{r}_c(s) + d_s$ 最小的核心队尾（平局取负载较小、编号较小者），并更新 $\hat{f}_s$ 与 ℓ_c 。

式(5-5)与式(4-11)式(4-12)的释放规则一一对应，只是用代理时长代替了真实时长。这一构造不会由自身引入等待环：

命题 5.1 (追加式分核的联合无环性) 若划分 g 的子图依赖图无环（依赖带候选满足这一点，见 5.2.2 节），则按式(5-5)逐个追加得到的核序 π 满足联合无环条件式(4-3)。

证明 记子图的追加次序为 σ 。子图只在全部前驱都已放置后才进入就绪集合，所以每条子图依赖边 (s', s) 都满足 $\sigma(s') < \sigma(s)$ ；每个核心的队列按追加先后排列，所以每条核序边 (s, s^+) 也满足 $\sigma(s) < \sigma(s^+)$ 。并图中的每条边都指向 σ 值更大的顶点，沿任何路径 σ 严格增加，不可能回到起点，因此并图无环。□

反馈重排沿用同一追加过程，只替换代理时长，命题 5.1 对它同样成立；分量家族、插入式候选等其他构造不在命题范围内，仍逐个显式检查并图无环。

拿到成功方案后，官方评价器返回的不只是 Makespan 数值，还有每个 Task 的实际时间段。**反馈重排**用这份反馈修正代理：保持划分 g 不变，把每个子图的 d_s 替换为其实测时长（分别取核内排布时长与多核执行时长两种口径），再按式(5-4)式(5-5)重新分核与排序。划分不变意味着边界搬运结构不变，这一轮的改进收益完全来自负载与等待的重新安排，与搬运量解耦。

5.2.4 插入式候选与 Treap 区间索引

剩余预算用于构造插入式候选。它以 5.2.2 节的安全链链块为子图，沿用静态 DAG 调度中“优先级排序 + 插入式最早完成”的构造规则[6]。链块 u 的优先级为

$$\text{rank}(u) = d_u + \max \left(\{0\} \cup \left\{ \sigma + \frac{2b_{uv}}{60} + \text{rank}(v) : v \in \text{Succ}(u) \right\} \right) \quad (5-6)$$

其中 d_u 按式(5-3)计算， σ 为跨核同步常数（场景 A 取 1000，场景 B 与 L2 场景取 500）， b_{uv} 为 u 流向 v 的张量字节， $2b_{uv}/60$ 估计一次写出加一次读入的 DDR 时间。链块按优先级从大到小依次放置：对每个核心，先由跨核前驱的完成时刻加 σ 与搬运估计求出就绪时刻 ready ，再在该核心的候选日历上找满足就绪时刻与持续时间的最早可行位置，最后放到完成最早的核心。场景 A 的日历在相邻 Task 之间保留 $\text{gap} = 100$ 的切换间隔，场景 B 与 L2 场景取 0。在起点为 low 、终点为 high 的空闲区间中，判定式为


$$t = \max(\text{ready}, \text{low}), t + \text{duration} + \text{gap} \leq \text{high} \quad (5-7)$$

朴素做法是按时间顺序逐个扫描区间；当日历中区间数量增长时，这种扫描会反复检查大量明显放不下的短空隙。算法改用确定性 Treap[15]维护空闲区间，每个节点额外记录子树内的最大可用跨度 span 与最右边界 rightmost ，据此整体跳过不可能命中的子树：

$$\text{span} + 16 \text{ulp}(\cdot) < \text{need} \text{ 或 } \text{rightmost} + 16 \text{ulp}(\cdot) < \text{ready} + \text{need} \Rightarrow \text{剪枝}, \text{need} = \text{duration} + \text{gap} \quad (5-8)$$

容差按机器精度给出，避免浮点误差造成错误剪枝。剪枝条件是必要条件：被跳过的子树确实不可能容纳该任务，通过剪枝的候选仍由式(5-7)最终判定。在精确算术下该索引与顺序扫描第一个可行空隙等价，浮点实现另有包内等价性测试。图 5-3 给出一个 $\text{ready}=5$ 、 $\text{duration}=5$ 、 $\text{gap}=1$ 的例子：左子树最大空隙为 3、小于所需的 6，可整体跳过，首个可行起点落在 I_3 的 $t=14$ （结构示意，查询的是候选构造用的虚拟日历，最终执行时刻仍由官方评价器给出）。

(a) 同一候选日历: $\text{ready}=5$, $\text{duration}=5$, $\text{gap}=1$



(b) 增强索引: 用子树摘要排除不可能容纳任务的区间




图 5-3 Treap 区间索引：相同插入规则，更少无效搜索（示意图）

这里有一处刻意的取舍：场景 A 不使用场景 B 与 L2 场景的局部微批策略。那类策略的收益来自操作级细分后的核内驻留复用，而场景 A 每个子图独立成 Task、跨 Task 数据一律经 DDR，驻留收益并不存在，平移过来只会增加边界搬运。

5.2.5 求解流程与停止准则

算法 5-1 R12 场景 A 求解流程

输入：计算图 G ；固定硬件配置 θ ；核心数 k ；总软预算 B （600 秒）

输出：方案 P^* 及其官方评价结果；或失败标志

- 1 构造依赖索引与张量索引，计算与方案无关的下界 LB（式(4-21)式(4-22)）；
- 2 从原图运行控制链的基础构造器，得到首个成功方案 P^* ；若失败则返回失败标志；
- 3 **for** 阶段 $\in$ （减少活动核心候选；依赖带候选 $w \in \{4, 8, 2, 16\}$ ；反馈重排；分量家族）**do**
- 4 **if** $T(P^*) \leq 1.03 \cdot \text{LB}$ **then** 跳过其余改进阶段（近优认证，式(4-23)）；
- 5 生成该阶段候选，检查覆盖性式(4-2)与联合无环式(4-3)，按哈希去重；
- 6 对每个候选计算其 Task 激活下界，若大于 $T(P^*)$ 则剪枝；
- 7 其余候选送官方评价（单次上限 30 至 120 秒，因阶段而异，并受剩余预算约束）；
- 8 **if** 候选完整成功且 $(T, D_{\text{added}}, \text{名称})$ 字典序优于 P^* **then** $P^* \leftarrow$ 该候选；
- 9 **end for**
- 10 用至多 30 秒构造 Treap 插入候选（式(5-7)式(5-8)），按第 5—8 行检查、评价与更新；
- 11 输出 P^* 的两字段方案文件；若无成功解，明确返回失败而不输出占位方案。

终止条件：预算耗尽、候选枚举完毕或近优认证成立，以先到者为准。

第 6 行的 Task 激活下界是对固定方案的松弛：把每个 Task 的时长换成式(5-3)那样的下限，再按式(4-11)至式(4-13)推进激活时刻。它只承担剪枝职责；实现中还对每个官方结果检查“不得低于该下界”，一旦违反即中止请求，全部成功请求中这一检查从未触发。

5.2.6 结构性质、确定性与复杂度

不变差性质。 同一次请求内，候选只有通过官方评价且字典序严格更优才会替换当前解，因此最终输出不会劣于第 2 行得到的控制解。该性质成立于同一次请求、同一版本、同一机器、同一超时设置之下。

确定性。 Treap 的平衡优先级由固定整数散列生成，候选按确定性名称排序，全流程不使用随机种子；预算未截断时同一请求重复运行得到相同方案，受预算截断的阶段则可能随机器负载评价到不同数量的候选（4.7.3 节）。

核数的边界。 核数增加时允许添加空核心，形式上 k 核的可行域包含 $k-1$ 核的可行域，但有限预算下的启发式搜索不因此具备逐例单调性，5.5.2 节的 case_062 就是反例。此外，命题 5.1 的无环保证只覆盖追加式分核与反馈重排；其他候选仍显式检查并图无环。

求解成本。 一次请求的墙钟成本可分解为

$$C_{\text{solve}} = C_{\text{index}} + C_{\text{generate}} + C_{\text{bound}} + \sum_{j=1}^K C_{\text{official}}(G, P_j, A) + C_{\text{IO}} \quad (5-9)$$

K 为实际评价过的候选数。记计算图的非 COPY 操作数为 $|U|$ 、边数为 $|E|$ 、子图数为 $|S|$ 、子图间依赖数为 $|E_s|$ 、日历中空闲区间数为 m 。单个候选的构造成本按步骤为：安全链收缩与链块深度都是沿拓扑序的一次遍历， $O(|U|+|E|)$ ；带内弱连通分量的图遍历为 $O(|U|+|E|)$ ，按拓扑秩切段另需一次排序， $O(|U|\log|U|)$ ；追加式分核的就绪堆操作为 $O(|S|\log|S|)$ ，每次对 k 个核心按式(5-5)扫描前驱，合计 $O(k(|S|+|E_s|))$ ；Treap 的期望深度为 $O(\log m)$ [15]，带剪枝的最早可行查询每次访问的节点数不超过顺序扫描的 $O(m)$ ，在区间数较多时通常远少于它。因此单个候选的构造复杂度为

$$O((|U|+|E|)\log|U|+k(|S|+|E_s|)+|S|\cdot q_m), q_m \leq m \quad (5-10)$$

其中 q_m 为单次插入查询访问的节点数。各部件的复杂度汇总于表 5-1。

表 5-1 R12 各部件的时间复杂度

部件	复杂度	说明
安全链收缩与链块深度	$O(U + E)$	沿拓扑序一次遍历、一次动态规划
带内弱连通分量与切段	$O(U + E + U \log U)$	同带图遍历，按拓扑秩排序后切段
尾长优先的追加式分核	$O(S \log S +k(S + E_s))$	就绪堆，逐核估计最早开始时刻
Treap 插入候选	$O(S \cdot q_m), q_m \leq m$	Treap 期望深度 $O(\log m)$
下界计算	$O(U + E)$ ；窗口下界另加线段树维护	与方案无关，每请求算一次
官方评价	C_{eval} ，随图规模增长	主导项，一次请求共 K 次

但这不是求解的总复杂度。由式(5-9)，总成本由 K 次官方评价主导：每次官方评价都要对全部 Task 完整运行核内调度与多核事件模拟。 K 由剩余预算与单次评价上限共同决定，在预算固定时随单次评价成本反向变化。本测试集的非 COPY 操作数范围为 552 至 35705，大图评价一次就要消耗可观的预算，能试的候选数自然少；case_087 是这一机制的极端情形（5.5.5 节）。Treap 索引优化的是候选构造项，主导项是官方评价求和项，因此不能用某个子模块的复杂度代表整套算法。

5.3 实验设置

实验在题目给定的 100 张正式测试计算图上进行，核数取 2 至 5，共 400 个配置格。硬件参数全部使用官方配置（表 3-2），单次请求软预算 600 秒。加速比按式(4-7)以 REF 为分母逐图计算后取平均，单核加速比按定义为 1；相对 C3 的比较按式(4-8)逐图计算，C3 的定义与性质见 4.3.3 节，本章及后两章沿用。

5.3.1 对比实验的设计

调度类问题的性能对比容易出现两类失真：一是对照基线过弱，使相对改进虚高；二是把不同来源的改进混算成一个数字，使读者无法判断收益归属。本文用四条相互独立的对照轴来规避这两点。

轴一：题目基准 REF。 原版核内调度算法在整图单核上的结果，由题目指定，不含任何本文的设计。它回答“相对于不做多核切分，我们快了多少”。

轴二：独立构造对照 C3。 C3 是一个自身即可独立运行的完整构造方法：合并安全链、按就绪层平衡计算负载、用等待与边界代理分核。选择这样一条基线，本文报告的相对降幅（五核 43.48%）就不会因基线过弱而虚高。同时，C3 是一次性完成的构造而本文方法是多候选搜索，两者搜索成本不同，因此 C3 是事后同口径对照，不是等搜索预算的消融实验。

轴三：同请求阶段对照。 在同一次请求内记录控制链、插入后、微批后三个阶段的方案质量（6.4.4 节），回答“框架内部各机制各自保留了多少收益”。该轴在场景 B 五核上给出的结论是控制链单独已达到最终水平的 98.6%。三阶段共享同一预算，这是增量对照而非等预算消融，结论相应限定。

轴四：跨场景对照。 同一框架在场景 A、场景 B、L2 场景下的表现（7.6 节），回答“代价结构改变时，同一套方法如何响应”。

5.4 主要结果

表 5-2 场景 A 逐核主结果（每格 100 图）

核数	平均加速比	中位加速比	最小加速比	均值新增 COPY/MiB	其中边界/MiB	其中 Spill/MiB	墙钟中位/s	墙钟 P95/s
2	1.855274	1.963848	1.045561	13.2023	11.9502	1.2521	25.6756	376.9549
3	2.560587	2.768124	1.113337	14.5546	13.1640	1.3906	20.8955	399.0524
4	3.197302	3.459641	1.171898	14.8736	14.4942	0.3794	18.8994	465.8099
5	3.743282	4.130239	1.202340	14.7913	13.5574	1.2340	21.4839	470.6481

注：加速比为逐图比值的算术平均；1 MiB = 1048576 bytes；P95 为经验最近秩；墙钟含候选构造、评价与 I/O。表中保留完整精度，正文取四位有效数字。

题目要求的 1 至 5 核平均加速比折线见图 5-4，一核点按定义取 1。平均加速比随核数单调上升，从两核的 1.855 增至五核的 3.743。每增加一核的边际增量在缩小，依次为 0.705、0.637、0.546，方向与共享带宽的物理限制一致；本章未做带宽敏感性实验，不把递减完全归因于带宽。




图 5-4 问题一：场景 A 下 1 至 5 核平均加速比折线图（R12 完整流程与 C3 基线）

中位数在各核数上都高于均值（五核 4.130 对 3.743），说明存在少数低加速比用例拉低均值；这些用例的最小值在 2 至 5 核都来自同一张图 case_064。最小加速比一列给出分布下沿：五核最差的一张图仍有 1.202，400 个配置格中没有出现比单核参考更慢的情况。

核数扩展趋势与 C3 的差距随核数拉大（图 5-4）。C3 曲线是相同输入与评分口径下的事后对照，两者搜索成本不同。

5.5 结果分析

5.5.1 与 C3 的逐例比较

平均曲线的差距需要落到逐例层面。按式(4-8)逐图计算耗时降幅，结果见表 5-3。

表 5-3 场景 A 相对 C3 的逐例对照（每格 100 图）

核数	加速比均值	逐图降幅均值	更快 / 持平 / 更慢	更快但 COPY 更高
	T_{C3}/T_{R12}			
2	1.398926	25.0121%	92 / 7 / 1	4
3	1.622964	32.9501%	91 / 7 / 2	2
4	1.828961	38.9334%	92 / 4 / 4	3
5	2.053093	43.4760%	93 / 5 / 2	2

注：C3 为同输入、同评分口径的事后对照，非等搜索预算消融；时间为官方 cycles，非求解墙钟。

五核逐图降幅均值 43.48%。这是逐图先算降幅再平均的结果，不是求解程序的墙钟下降率；依赖带、反馈重排、分量家族与插入式候选在同一次请求中共同竞争预算，该数值不能归因于其中某一个模块。

胜负分布比均值更有信息量：五核为 93 例更快、5 例持平、2 例更慢。平均优势不等于逐例必胜，这在任何核数上都成立。8.3 节对这组配对结果做了符号检验。

5.5.2 退化配置与 case_062

400 个配置格中有 9 个相对 C3 更慢：case_062 在 2 核为+22.97%、3 核为 +40.94%；case_085 在 3 核为+0.997%；case_016、case_024、case_051、case_082 在 4 核分别为+0.25%、+0.24%、+0.24%、+0.21%；case_028 与 case_090 在 5 核分别为 +0.60%、+0.16%。

除 case_062 外的 7 个退化幅度均在 1%以内，属于小幅退化。case_062 是唯一的显著退化，且幅度随核数从 2 增到 3 不降反升，而在 4 核与 5 核未进入退化清单。

逐例数据可以部分检验这一现象的来源（表 5-4）。

表 5-4 case_062 在场景 A 各核数下的最终方案

核数	Makespan/ cycles	C3 Makespan/ cycles	Task 数	每 Task 操 作数中位	新增 COPY/bytes	C3 新增 COPY/bytes
2	1976451	1607247	4361	8	13393920	13393920
3	1593547	1130638	4361	8	13393920	13393920
4	764940	889045	293	71	897024	13393920
5	619333	746374	293	71	897024	13393920

注：Task 数与每 Task 操作数来自最终方案；C3 的 Task 数未记录。

两组核数的最终方案属于完全不同的粒度。2 核与 3 核时 R12 选中的方案有 4361 个 Task，每个 Task 中位只有 8 个操作，新增 COPY 与 C3 完全相同；4 核与 5 核时选中的是 293 个 Task 的粗粒度方案，新增 COPY 降为 897024 bytes，只有前者的约十五分之一，并反过来比 C3 快。细粒度方案的代价可以从释放规则直接估出下限：2 核时最忙的核心至少排有 2181 个 Task，按式(4-11)仅同核切换等待就不少于 218000 cycles，约占该方案 Makespan 的 11.0%；293 个 Task 的方案在 4 核时这一下限只有 7300 cycles。

据此可以把原先的假设收紧为一个有数据支持的判断：case_062 在低核数的退化，来自求解在预算内没有选到那个粗粒度划分，细粒度划分下的启动等待与边界搬运吞掉了并行收益；与 C3 相比，两者搬运量相同而 R12 更慢，差距来自 Task 的放置与次序。至于低核数下为什么没有评价到 293 个 Task 的候选，现有记录不足以回答，本章不作推断。场景 B 取消了同核 Task 边界，该图只在五核出现+0.502%的轻微退化（6.4.6 节），与上述判断方向一致。

全部 400 格的对数比值热力图与 9 个退化配置的逐项定位见图 5-5；该图保留了完整色标与全部负例，避免用均值掩盖。




图 5-5 场景 A：全量性能变化与退化定位

5.5.3 新增搬运的构成

新增 COPY 由两个来源合成：切图产生的 Task 边界搬运，以及官方核内调度阶段因容量不足插入的 Spill，两者之和等于官方报告的新增 COPY 字节字段。

边界搬运在各核数上都是主导项，占比在九成以上。五核平均新增 14.79 MiB，其中边界 13.56 MiB、Spill 1.234 MiB。四核的 Spill 均值明显更低 (0.3794 MiB)，而边界均值在四核最高 (14.49 MiB)。这一组合在数值上自洽：切分更细时单个 Task 的驻留压力下降，Spill 随之减少，代价是边界搬运上升。不过这只是四个观测点上的一次共变，样本不足以支撑一般性结论。

图 5-6 把两类来源分开堆叠，并统计各核数下实际发生 Spill 的图数：2 至 5 核分别为 25、25、20、26 张。Spill 不是普遍现象，而是集中在部分用例上，因此均值里那 1 MiB 多的 Spill 并不代表典型用例。




图 5-6 场景 A：新增 COPY 的来源

5.5.4 并行与搬运的权衡

字典序目标先比 Makespan 再比 COPY，意味着算法会接受“更快但搬运更多”的方案。五核下有 2 例在比 C3 更快的同时增加了官方 COPY 记账，因此不能把全部加速解释为通信量下降。

表 5-5 并行—搬运权衡案例（五核）

用例	Makespan/cycles	新增 COPY/bytes
case_002	58180	82944
case_005	69060	2483610

注：两例均比 C3 更快且 COPY 更高；展示的是最终选解的终点值，非控制单一变量的对照。

两例 Makespan 相差不到两成，新增 COPY 却相差近三十倍。同一目标函数在不同图结构上会落到很不一样的权衡点：case_002 的结构允许在几乎不增加搬运的前提下取得并行收益，case_005 则必须用大量边界搬运换取并行度。

5.5.5 预算例外

case_087 是唯一在 600 秒软预算内没有产生顶层成功结果的用例，A2 至 A5 四个配置全部如此；该组单独使用 1800 秒预算重跑后均告成功。

表 5-6 预算例外完整记录

用例	场景/核数	首次预算	补跑预算	补跑墙钟/s	Makespan/cycles
case_087	A2	600 s 首次无成功	1800 s	819.1333	2093249
case_087	A3	600 s 首次无成功	1800 s	752.9736	1483711
case_087	A4	600 s 首次无成功	1800 s	910.7309	1204070

用例	场景/核数	首次预算	补跑预算	补跑墙钟/s	Makespan/ cycles
case_087	A5	600 s 首次无成功	1800 s	1036.1133	1038529

注：首次 600 秒的失败结果予以保留，不以补跑结果替换来源记录；仅本组使用 1800 秒预算。

四次补跑的墙钟在 753.0 至 1036.1 秒之间，全部超过 600 秒，说明 600 秒对该用例确实不足而非偶发失败。1800 秒约为五核请求中位墙钟的 84 倍。补跑方案的五核执行时间线见图 5-7：画面中的空白保留了真实空闲，不自动解释为某一种原因。




图 5-7 困难案例 case_087：五核执行时间线

整体墙钟分布高度右偏：五核请求中位数 21.48 秒、P95 为 470.6 秒、最大 1036.1 秒。绝大多数图在半分钟内完成，少数大图会用满预算。题目要求在合理时间内生成方案而未规定具体时限，本文以 600 秒作为单请求软预算；除 case_087 外，全部 396 个场景 A 请求都在该预算内得到结果。

5.5.6 校验范围

全部输出方案均通过官方评价器执行，并在覆盖性、周期数、核心归属、依赖关系、Pipe 占用与 COPY 记账等方面完成核查；全部 400 个结果均不低于式(4-21)的下界。本章未另行独立重建全部带宽与容量的活期状态，相关校验属于内部自检。

5.6 小结

联合选择 Task 粒度、核心归属与执行顺序，可以在全部 400 个配置格上取得稳定的多核加速：五核平均加速比 3.743、中位 4.130、最小 1.202，相对 C3 的逐图耗时平均下降 43.48%。三项决策必须联合选择，任何一项单独最优都不能保证总体执行时间最短。

本章的做法是先用安全链收缩与依赖带分带构造结构合理的候选粒度，再用尾长优先的追加式分核放置，借助官方评价反馈在划分不变的前提下改进分核与排序，最后用 Treap 区间索引加速插入式候选的生成；当前解一旦被下界认证为近优即停止，把预算留给仍有改进余地的大图。

同时需要如实记录三点边界：平均优势不代表逐例必胜，五核仍有 2 例慢于对照，400 格中有 9 个退化配置，其中 case_062 的低核数退化源于未选到粗粒度划分；加速并不总伴随搬运下降，字典序目标会接受更快但搬运更多的方案；600 秒预算对 case_087 不足，该组使用了 1800 秒补跑。全部结论限定在这 100 张图、题目给定的固定配置与已披露的预算设置之内。

6 问题二：场景 B 下的同核驻留与多核调度

场景 B 把同一核心上的全部子图合并为一个 Task。这条规则改变的不只是通信常数：相邻子图之间不再必然经 DDR 交换数据，但张量跨多个子图驻留会持续占用 L1/UB，容量溢出（Spill）因此取代边界搬运成为新的主要代价。本章给出场景 B 的差异化建模，设计以实际 Spill 事件为触发条件的局部重排方法，并在 100 张计算图、1 至 5 核的全部配置上给出结果。五核相对固定整图单核的平均加速比为 4.131，中位数 4.447，最小值 1.812；相对 C3 的逐图耗时降幅平均为 34.49%。

6.1 问题分析与建模差异

6.1.1 问题分析

场景 B 相对场景 A 只改动一条规则：同核的全部子图合并为一个 Task。但这一条改动使第 5 章的代价结构整体失效：同核边界搬运消失，取而代之的是跨子图驻留带来的容量溢出。切分粒度不再是唯一的调节变量，核内执行顺序第一次成为独立的优化对象。

难在哪。 减少跨核边界、保持双 Pipe 负载均衡、减少驻留冲突这三件事可能互相竞争。合并 Task 换来的驻留复用有代价：张量若跨越多个子图被使用，就要在整段区间内占据私有缓存，压缩其间其他张量的可用空间。“同核数据永不换出”是一个不成立的假设。

为什么第5章的办法不够用。 场景 A 的代价代理量在场景 B 下失去意义。最直接的证据来自对照基线本身：C3 沿用场景 A 的等待与边界代理构造方案，放到场景 B 的单核配置下评价，平均 REF 加速比只有 0.9487，小于 1，即构造出的方案平均慢于不切分的原版基准。仅替换同步常数无法完成场景迁移。

我们的切入点。 在第 5 章框架的候选生成层增加两类针对驻留问题的机制：活动核数与驻留组织候选族，以及以实际发生的容量溢出为触发条件的局部微批。其余两层不变。

本章产出。 100 张计算图在 1 至 5 核下的 500 个配置格完整结果，新增 COPY 按边界与 Spill 两类来源的分解，以及同一次请求内三个阶段的收益归因。

6.1.2 沿用与替换


方案表示与可行性条件与场景 A 相同：仍记 $P=(g,a,\pi)$ ，三项决策的定义、覆盖性条件与联合无环条件见式(4-1)式(4-2)式(4-3)。固定参数 θ 同样包括 $L1=524288$ bytes、 $UB=131072$ bytes 与全部核心共享的 60 bytes/cycle。目标函数形式不变，只换用场景 B 的评价算子 $T_B(P)$ (式(4-5))，择优仍按式(4-6)的字典序，可行集记为 F_B 。问题二的模型是式(4-20)在场景 B 下的实例：

$$\underset{P=(g,a,\pi)}{\text{lex min}} \left(T_B(P), D_{\text{added}}^B(P) \right) \text{s.t.} \begin{cases} \text{式 (4-20) 的全部约束组} \\ \text{Task} \equiv \text{核心, 跨核同步按式 (4-14)} \\ \text{边界记账按式 (4-19)} \end{cases} \quad (6-1)$$

瞬时容量由官方展开过程与容量复用依赖控制，不能用子图全部张量之和代替。合并 Task 后驻留窗口被显著拉长，这一区分在场景 B 比在场景 A 更关键。

6.1.3 Task 边界的消失与不消失

第一处实质差异在 Task 边界。设操作 u_0 产生 b 字节的中间张量、 u_1 消费它，无其他消费者且非最终输出。场景 A 中若两者分属不同子图，即便调度到同一核心也要一次写出加一次读入，共 $2b$ 字节；场景 B 中两者落在同核的同一个 Task 里，只要不发生 Spill，这 $2b$ 字节就不产生。图 6-1 并排给出两种情形（结构示意）：场景 B 消除的是“同核跨 Task”这一类边界搬运，前提是“驻留且无 Spill”，消除边界不等于容量足够。



相同片段: u_0 产生 b 字节中间张量, u_1 消费; 无其他消费者、非最终输出

场景B消除该同核边界, 不代表容量足够或不会Spill

图 6-1 同一计算片段在场景 A 与场景 B 下的 Task 边界 (示意图)

跨核情形则按连接计费。按官方评估程序的实现 (式(4-19)), 场景 B 对每一对“生产核心→消费核心”的跨核连接各插入一次 COPY_OUT 与一次 COPY_IN。对单生产者、非最终输出的中间张量, 设字节数为 b 、不同远端消费核心数为 r , Spill 前的边界记账为

$$D_{\text{边界}}^B(t) = \begin{cases} 2rb, & r > 0 \\ 0, & r = 0 \end{cases} \quad (6-2)$$

即每个远端消费核心各对应一次写出与一次读入; $r=0$ 表示所有消费者都在生产核上, 不产生这一项。同样的张量在场景 A 中若分布在 r 个其他 Task 上, 计为一次写出加 r 次读入, 即 $(r+1)b$ 。两者在 $r=1$ 时相同, $r \geq 2$ 时场景 B 的跨核扇出反而更贵, 这可能是场景 B 的边界新增随核数上升较快 (6.4.2 节) 的原因之一。该特例不含 Spill、原始输入的重复读入与最终输出。


跨核传输另有一条时序约束式(4-14): 目标核的 COPY_IN 要在源核 COPY_OUT 完成 500 周期后才进入就绪判定。这是必要释放条件, 目标操作还须满足 Pipe FIFO、本地前驱与内存申请次序, 源端完成加 500 周期不等于目标端立即发射。

6.1.4 逻辑活期不等于物理驻留

合并 Task 换来的驻留复用有代价。张量若跨越多个子图被使用, 它在整段区间内都要占据私有缓存, 压缩其间其他张量的可用空间。

这里需要区分两个概念: **逻辑活跃**指张量从产生到最后一次使用之间的区间, **物理驻留**指它实际占据缓存的字节。两个张量的逻辑活期重叠, 不能直接换算成占用量

或 Spill 量。320 KiB 与 256 KiB 两个张量各自都能放进 512 KiB 的 L1，合计 576 KiB 却超出容量，无法同时常驻（图 6-2，概念例）。容量冲突必须按活跃集合判断。



逻辑活跃 ≠ 物理常驻：需换出再读入，或选择不同的合法顺序
此图仅解释容量冲突；不指定替换策略，不推断实测Spill字节数

图 6-2 逻辑活跃、物理驻留与容量冲突（示意图）

至此场景 B 的权衡结构清楚了：减少跨核边界、保持双 Pipe 负载均衡、减少驻留冲突这三件事可能互相竞争；核心归属与可表达的操作顺序是能优化的对象，而“同核数据永不换出”是一个不成立的假设。

6.2 求解算法

6.2.1 求解路径概述

本章沿用第 5 章的三层框架，改动集中在候选生成层。求解路径分四步。第一步仍从原图生成并评价控制链，得到首个可行解。第二步枚举活动核数与驻留组织的候选族：减少活动核心会减少跨核边界但牺牲并行度，净效果无法预先判断，因此每个候选都要完整评价。第三步用区间索引生成插入候选。第四步只在当前解确有容量溢出时才启动微批诊断与窗口重排，无溢出则跳过。四步共用同一预算，择优规则与第 5 章相同。

6.2.2 活动核数与驻留组织候选

从原图得到当前可行解后，在剩余预算与质量界允许时枚举一族候选：

$$C_{family} = \{ (m, target) : m \leq k, target \in \{0, 512, 2048\} \}, \text{补空队列使输出始终含 } k \text{ 条核心队列}$$

(6-3)

m 为活动核心数， $target$ 控制驻留排序的组织粒度；该扩展阶段最多评价六个新候选。

枚举 $m < k$ 的意义在于：减少活动核心会减少跨核边界，但同时牺牲并行度。两个方向的净效果无法预先判断，因此每个候选都要完整评价，而不是用代理分数筛掉。

6.2.3 Spill 触发的局部微批

第二类机制只在确有 Spill 时启动。仅当当前成功结果的 Spill 新增字节大于零，才进行微批诊断；诊断在独立子进程中观察原版 Step2 返回的 Spill 事件，并核对诊断中的搬运分解与成功结果一致，正式评分在未插桩的新进程中进行，不修改原版仿真。

诊断关注满足下列条件的大张量事件：


$$size(t_b) \geq 1/4 C_m, dist(s_{before}, s_{after}) \leq 8 \quad (6-4)$$

即张量大小至少为相应容器容量的四分之一，且前后两次使用所在子图的距离不超过 8。两个阈值是启发式候选规则。候选窗口参数为

$$w \in \{4, 8\}, |[窗口]| \leq 16 (\text{互不重叠}), |[原计算操作]| \leq 128 (\text{每窗口}) \quad (6-5)$$

窗口内细化到操作级子图，用稳定 Kahn 顺序[16]优先复用最近使用的大型外部输入，平局时沿原位置与 ID 确定；窗口外的顺序不改变。设计动机见图 6-3：四条 $A_i \rightarrow B_i$ 依赖链共享两份大输入 t_A 与 t_B ，交替顺序会让两份输入反复换入，成组顺序则让同一输入连续使用（结构示意）。窗口重排改变的只是同核内部的执行次序，中间张量的活期可能因此被拉长，实际收益仍须完整评价确认。


(a) 原依赖：每条链 A_i 在 B_i 之前，无跨链依赖



所有 A_i 读取同一大输入 tA ；所有 B_i 读取同一大输入 tB


(b) 交替顺序

核心0；横向为顺序，不是持续时间



(c) 同核局部重排

核心0；横向为顺序，不是持续时间



下排同输入连续使用；原始依赖与核心归属不变，但实际收益仍须完整评价

图 6-3 局部微批：依赖不变，共享输入成组使用（示意图）

6.2.4 微批的不变量：能推出什么，不能推出什么

微批重排满足核心归属不变式：

$$a_{\text{new}}(g_{\text{new}}(u)) = a_{\text{old}}(g_{\text{old}}(u)), \forall u \in U \quad (6-6)$$

场景 B 下每个核心只有一个 Task，核心归属不变意味着每个张量的生产核心集合与消费核心集合都不变，于是 Spill 前的边界 COPY 记账严格保持：

$$D_{\text{partition,new}}^B = D_{\text{partition,old}}^B \quad (6-7)$$

这条推论的适用范围需要划清，它是本章分析中最容易被误用的一步。式(6-7)只覆盖 Spill 前的边界 COPY；执行顺序改变了，Spill 量可以改变，Makespan 当然也可以改变。因此不能由它推出“微批不改变总时间”或“微批不改变总搬运”。该结论也不适用于场景 A：A 中一个核心上有多个 Task，核心归属不变并不保证 Task 边界集合不变。

同样，局部 Kahn 顺序只保证窗口内部的原依赖被满足；与窗口外顺序、跨核释放及内存复用边的组合是否合法，由完整方案检查与官方评价决定。只有完整成功且 (Makespan, 新增COPY, 名称) 更优的候选才替换当前解。

6.2.5 求解流程与预算分配

算法 6-1 R12 场景 B 求解流程

输入：原图 G ；固定 B 配置 θ ；核心数 k ；单请求软预算 B （600 秒）

输出：通过原版评价的最佳已得方案 P^* ，及诊断与失败记录

- 1 从原图生成并评价控制链（基础构造、减少活动核心候选、沿官方时间线关键链的局部移动），保存当前最好解 P^* ；
- 2 **if** $T(P^*) > 1.03 \cdot LB$ **then** 按式(6-3)生成分量家族、活动核心数与驻留组织候选，去重、下界剪枝后至多评价 6 个；
- 3 用区间索引生成插入候选，完整评价后按字典序更新 P^* ；
- 4 **if** P^* 的 Spill 新增字节 $D_{\text{spill}}(P^*) > 0$ 且预算尚有剩余 **then**
- 5 在独立进程中观察原版 Step2 的 Spill 事件，按式(6-4)筛选大张量事件；
- 6 按式(6-5)生成至多两个固定窗口的微批候选，逐个检查合法性并送官方评分，按字典序更新 P^* ；
- 7 **end if**
- 8 输出两字段方案；未产生成功方案则明确返回失败，不补 0、不删图以伪造完整均值。

各阶段共用总软预算 600 秒，其中快速生成上限 30 秒、插入候选评分 120 秒、Spill 诊断 40 秒、每个微批候选评分 45 秒，均受剩余预算约束，控制链已消耗的预算同样计入。

第 4 行的条件顺序决定了微批的触发面：它不是无条件执行的优化，而是“先看有没有 Spill，再决定是否诊断”，见 6.4.4 节。

场景 B 的候选构造复杂度与场景 A 同阶（式(5-10)）。新增的分量家族枚举为常数规模，该扩展阶段最多评价六个新候选；微批重排本身的规模由窗口参数式(6-5)限定（每份候选最多 16 个互不重叠的窗口、每个窗口不超过 128 个原计算操作），附加的构造成本很小；Spill 诊断需要在独立进程中运行一次带观测的核内调度，成本与一次核内排布同阶，并受 40 秒上限约束。总成本仍由官方评价次数主导。

6.2.6 与 C3 对照的可比性

C3 在场景 B 中的构造沿用 4.3.3 节的定义：合并安全链，按就绪层平衡计算负载，用场景 A 的等待与边界代理分核，再在场景 B 的真实规则下评价。两者输入与官方配置相同，搜索成本结构不同，终点性能比较不能解释为等成本下的算法效率比较。

6.3 实验设置与主要结果

6.3.1 口径：一核的两种含义

场景 B 的实验里“一核”出现两次，含义不同：标准参考曲线的一核点按原题定义取 1，是加速比的分子定义；优化 B1 则是把 R12 框架实际作用在单核配置上得到的结果，平均 REF 加速比 1.061。两者不可混用，也不能用后者替换曲线上的参考点。

6.3.2 逐核主结果

表 6-1 场景 B 逐核主结果（每格 100 图）

核数	平均加速比	中位加速比	最小加速比	均值新增 COPY/MiB	其中边界/MiB	其中 Spill/MiB	有 Spill 图数	墙钟中位/s	墙钟 P95/s
1	1.06136 6	1.00887 2	1.00000 0	8.7090	0.0000	8.7090	50	13.8222	183.098 5
2	1.99252 2	1.99411 1	1.42476 0	9.1437	2.7091	6.4346	36	9.8964	105.632 0
3	2.80110 9	2.92598 2	1.35526 4	8.7155	3.9676	4.7479	23	10.1644	94.2155
4	3.52104 6	3.72410 9	1.73610 4	7.7976	4.5703	3.2273	23	9.9414	86.0755
5	4.13107 7	4.44679 2	1.81181 8	8.2173	5.5112	2.7062	22	7.9157	77.4654

注：一核行为优化 B1 实测均值，标准参考曲线的一核点按原题定义为 1，两者不可混用；1 MiB = 1048576 bytes；P95 为经验最近秩；“有 Spill 图数”分母为 100。表中保留完整精度，正文取四位有效数字。

平均加速比从两核的 1.993 升到五核的 4.131，五核最小值 1.812，100 张图全部快于固定整图单核。五核请求墙钟中位 7.916 秒、P95 为 77.47 秒、最大 127.1 秒，全部 500 个请求在 600 秒预算内完成。

两处非单调需要指出。其一是最小加速比列：两核与三核的最小值都来自同一张图 case_064，它在三核下的加速比（1.355）低于两核（1.425），四核与五核的最小值换成了其他图并恢复上升。case_064 也是场景 A 全部核数下的最小值（5.4 节），是本测试集里最难并行化的一张图。其二是新增 COPY 总量列既不单调增也不单调减，成因见 6.4.2 节。

核数扩展趋势与 C3 的差距随核数扩大（图 6-4）；该图同时提示一核参考点按定义取 1、优化 B1 另行报告。




图 6-4 问题二：场景 B 下 1 至 5 核平均加速比折线图（R12 完整流程与 C3 基线）

6.3.3 优化 B1

单核配置下 R12 框架仍能在原版结果之上改进：平均 REF 加速比 1.061，其中 55 图改善、45 图相同，没有变慢的用例。中位数 1.009 显著低于均值，改善集中在少数图上而非普遍分布（图 6-5，纵轴为加速比超出 1 的幅度，不是耗时降低率）。




图 6-5 优化 B1：相对固定单核的逐图变化

单核是一个干净的对照点：此时不存在跨核边界，表 6-1 一核行的边界项为 0.0000，全部 8.709 MiB 新增 COPY 都来自 Spill。这从口径上确认了两类来源的划分是互斥的。

6.4 结果分析

6.4.1 与 C3 的逐例对照

逐图耗时降幅定义同式(4-8)，五核结果为

$$\bar{\rho}_B = \frac{1}{100} \sum_{i=1}^{100} \left(1 - \frac{T_{R12,i}}{T_{C3,i}} \right) = 34.4910\% \tag{6-8}$$

表 6-2 场景 B 相对 C3 的逐例对照（每格 100 图）

核数	加速比均值		更快 / 持平 / 更慢	更快但 COPY 更高	C3 平均加速比
	T_{C3}/T_{R12}	逐图降幅均值			T_{REF}/T_{C3}
1	1.138380	10.8752%	82 / 18 / 0	15	0.948680
2	1.227637	16.3835%	90 / 10 / 0	20	1.670220
3	1.357801	22.6021%	92 / 7 / 1	11	2.163389
4	1.498911	28.1411%	93 / 7 / 0	5	2.514776
5	1.718822	34.4910%	94 / 5 / 1	4	2.668780

注：C3 为同输入、同评分口径的事后对照，非等搜索预算消融；时间为官方 cycles，非求解墙钟。

最后一列有一个值得单独说明的现象：C3 在单核配置下的平均 REF 加速比为 0.9487，小于 1，即它的固定构造在单核上平均慢于原版整图单核基准。单核时不存在

跨核边界，C3 按场景 A 代理切出的子图次序改变了核内的执行与驻留顺序，结果反而不如不切分。这一观察支持 6.1.1 节的判断：场景 B 不能靠替换同步常数从场景 A 平移过来。

五核下 R12 为 94 例更快、5 例持平、1 例更慢。“更快但 COPY 更高”一列在两核达到峰值（一核 15 例、两核 20 例），此后随核数递减（11、5、4），提示核数较多时主次目标的冲突较少；这是五个观测点上的趋势，未做机制层面的验证。

6.4.2 边界与 Spill 的反向变化

表 6-1 中两个分解项走向完全相反。边界项随核数单调上升：
0、2.709、3.968、4.570、5.511 MiB；Spill 项随核数单调下降：
8.709、6.435、4.748、3.227、2.706 MiB。总量因此非单调，在四核取到最低的 7.798 MiB。

两条走向各有直接的机制解释。核数增加意味着更多依赖跨核，边界搬运必然上升；同时每个核心承担的计算量减少，单个 Task 的驻留压力下降，Spill 减少。总量是两条相反趋势的合成，本身不携带机制信息：只报告总量会把这个结构完全掩盖。

发生 Spill 的图数同样随核数下降：50、36、23、23、22（表 6-1 末列，另见图 6-6 的字节分解）。这条计数与 Spill 字节的下降方向一致，说明减少的不只是溢出的量，也包括发生溢出的用例范围。




图 6-6 场景 B：边界 COPY 与 Spill 分解

6.4.3 Spill 的集中度

五核 B 的 100 张图中有 Spill 的只有 22 图，其余 78 图为零。在这 22 张图内部分布同样极不均匀：按 Spill 降序排列的前 10 图贡献了全部 Spill 字节的 93.84%。

因此表 6-1 五核行那 2.706 MiB 的平均 Spill 并不代表典型用例。对四分之三以上的图，同核合并已经完全消除了容量溢出；剩余的容量代价高度集中在少数困难实例上。

图 6-7 用对数轴展示 22 个非零值并标明零值图数，右侧的累计贡献曲线以完整 100 图作为分母：保留全部图作分母是为了避免用非零子集冒充整体典型情况。




图 6-7 五核 B：非零 Spill 细节与全量集中度

6.4.4 同次请求的阶段增量

为观察各机制各自保留了多少收益，记录同一次请求内三个阶段的方案质量：

$$\bar{S}_{\text{stage}} = \frac{1}{100} \sum_{i=1}^{100} \frac{T_{\text{REF},i}}{T_{\text{stage},i}}, \text{stage} \in \{\text{control}, \text{indexed}, \text{full}\} \quad (6-9)$$

表 6-3 五核 B 同次请求的三阶段结果

相对 REF 平均加速比 / 原		
阶段	始 cycles	较前阶段严格改善
控制	4.073198	(基准)
插入后	4.111995	12 / 100
微批后	4.131077	2 / 100
case_067 (明细)	15,255,427 → 13,798,191 → 13,054,159	—
case_073 (明细)	3,210,135 → 3,046,190 → 2,034,983	—

注：三阶段共享同一总软预算，不是等预算独立消融；未改善含相同、未触发或未完成三种情况。

严格改善的计数定义为

$$N_j = \left| \left\{ i : T_{\text{stage}_{j+1},i} < T_{\text{stage}_j,i} \right\} \right|, (N_{\text{插入}}, N_{\text{微批}}) = (12, 2) \quad (6-10)$$

这组数据最值得说的一点是量级：控制链单独就达到了最终水平的 98.6%（4.0732 对 4.1311），插入与微批两阶段合计贡献余下的 1.4%。也就是说，本方法的绝大部分

收益来自 5.2 节的结构化候选构造与反馈重排，而不是后续的精微机制。把这一点直说出来，比含糊地把三个阶段并列更接近事实。

改善面同样很窄：插入阶段 12/100，微批阶段 2/100（图 6-8，纵轴局部放大，标注的两段增量为+0.038797 与+0.019083）。“未改善”包含三种不同情况（候选评价后未更优、诊断条件未触发、预算耗尽未完成），因此 2/100 既不是触发率也不是成功率。三阶段共享同一总预算，后面的阶段用的是前面剩下的时间，这组数据不构成等预算的独立消融。




图 6-8 五核 B：同次请求的阶段增量

6.4.5 微批阶段的两个改善实例

微批阶段全部两个进一步改善的实例是 case_067 与 case_073（图 6-9 给出配对结果，其余 98 例未进一步改善）。case_067 从插入后到微批后耗时降低 5.39%、对该阶段加速比增量贡献 13.82%；case_073 对应为 33.20%与 86.18%。




图 6-9 微批阶段：两个实际改善案例的配对结果

也就是说，微批阶段那+0.019083 的平均增量里，86.18%来自 case_073 一张图。

表 6-4 开发诊断案例终点值 (case_073, B 五核)

指标	数值
Makespan/cycles	2034983
边界新增/bytes	21712384
Spill 新增/bytes	15489024

R12 提出窗口排序的依据是“两份大输入交替使用可能造成反复换入”这一有源码依据的机制推测，case_073 正是一个 Spill 量级很高的实例。本章把它作为设计动机的来源记录下来，而不把这组终点值当作微批有效性的因果证据：要做因果论证需要等预算的独立消融，本章没有做。

6.4.6 退化配置

500 个 B 配置格中相对 C3 更慢的只有两个：case_089 在 3 核为+0.038%，case_062 在 5 核为+0.502%。两者幅度都在 1%以内，属于小幅退化。

case_062 在场景 A 的低核数上有显著退化 (+22.97%、+40.94%)，5.5.2 节的逐例数据显示其根源是低核数下选中了 4361 个 Task 的细粒度划分，启动等待与边界搬运吞掉了并行收益。场景 B 取消了同核 Task 边界，这一代价随之消失：该图在 B 的 1 至 4 核都快于 C3，只在五核出现+0.502%的轻微退化，幅度比场景 A 三核低约两个数量级。

6.4.7 主次目标的权衡

五核下有 4 图比 C3 更快而新增 COPY 更高（图 6-10 给出执行时间与 COPY 的散布关系）。主指标改善不等于逐例搬运下降，也不构成每个用例上的双目标 Pareto 支配。




图 6-10 五核 B：执行时间与 COPY 的权衡

这类用例数随核数下降（1 核 15 例、2 核 20 例、3 核 11 例、4 核 5 例、5 核 4 例），两核为峰值。这一形态与 6.4.2 节的分解一致：核数较低时 Spill 占主导，减少 Spill 所需的顺序调整可能同时增加别处的搬运；核数升高后 Spill 本身已经很小，冲突随之减少。这是对已有数据的一种解释，不是实验验证的结论。

6.4.8 求解成本与校验

表 6-1 显示墙钟 P95 随核数单调下降（183.1 → 105.6 → 94.22 → 86.08 → 77.47 秒），全部 500 个请求在 600 秒预算内完成，原图、配置与评分代码未作修改。这一形态与场景 A 相反：场景 A 的 P95 随核数上升且出现了需要 1800 秒补跑的例外（见表 5-2 与 5.5.5 节）。一个与数据相容的解释是场景 B 的候选空间更受约束：每核只有一个 Task，不需要在 Task 划分与 Task 间排序之间反复权衡。本章未做求解成本的分解实验，故不作为结论。

既有核查覆盖原操作计数、周期、核心归属、原依赖、Pipe 与 COPY 分解，并核对了官方记录的容量峰值；完整的动态容量与共享带宽未用第二套实现全量重建，相关校验属于内部自检。

6.5 小结

场景 B 的结论可归为四点。

同核合并并没有消除容量代价，只是把它从普遍现象变成了少数用例的集中负担：五核下 78 图完全无溢出，而剩余 22 图中前 10 图就占了 93.84% 的溢出字节。代价改变的是形态与分布，不是总量意义上的消失。

边界与 Spill 随核数反向变化，总量掩盖机制。 报告新增 COPY 时必须分开列出两类来源，否则四核那个最低的总量 7.798 MiB 会被误读成“四核搬运最省”。

收益的主体来自结构化候选构造，而非精细机制。 控制链单独达到最终水平的 98.6%，插入与微批合计 1.4%；微批阶段在 100 个五核请求中只有 2 例进一步改善，其中一例贡献该阶段 86.18% 的增量。这个机制有明确的源码依据与合理动机，但现有数据只支持“在特定结构的实例上有效”。

场景 B 不能由场景 A 平移得到。 C3 在单核上 0.9487 的平均加速比是最直接的证据：把场景 A 的等待与边界代理照搬到场景 B，构造出的方案会劣于不切分。

全部结论限定在这 100 张图、题目给定的固定配置与 600 秒软预算之内。

7 问题三：共享只读 L2 下的调度与性能影响

问题三在场景 B 的硬件基础上增加一块 1 MiB 的共享只读 L2，读带宽 250 bytes/cycle，独立于 DDR。

如果把本章的任务理解成“测出这块缓存能提速多少”，得到的会是一个不大的数字：五核下同方案配置比均值 1.016766。但这个数字本身并不是本章的主要产出，甚至单独看还具有误导性：它的中位数只有 1.000546，500 对配置对照中还有 8 对开启 L2 后反而更慢。

本章真正要回答的是**如何正确测量一块缓存对调度的影响**。为此做了三件事：按官方实现重建 FIFO 缓存的状态语义，明确命中、插入与逐出的时点关系；设计一套能把“硬件配置效应”与“求解器选解效应”分开的对照实验，因为常规报告方式会把两者合并成一个数字；在此基础上给出三个与直觉相反的事实：命中率与性能不成对应、只读缓存也可能造成退化、开启缓存后计划中的搬运量反而上升。这三条结论对后续的调度设计比那 1.68% 更有价值。

第 6 章的代价结构在本章保持不变，新增的只有一条独立读路径。正因为改动如此局部，它反而暴露出一个前两章不会遇到的问题：当改动的效应很小时，如何确认测到的究竟是硬件的效应，还是求解器行为变化的效应。本章因此先建立测量框架，再谈优化结果。

7.1 缓存模型

7.1.1 沿用与新增

方案表示、可行性条件、Spill 与驻留规则、跨核同步约束式(4-14)全部沿用场景 B（见 6.1 节）；每核的全部子图仍合成一个 Task，L1 与 UB 容量不变。本章新增的只有一条读路径与随之而来的状态规则。

记同一方案在无 L2、有 L2 两种配置下的官方 Makespan 分别为 $T_B(P)$ 与 $T_L(P)$ 。主目标是最小化 T_L ，主指标相同时比较新增 COPY。方案不增加任何额外的计算、复制、预热或等待指令，也不改变 FIFO 策略：能优化的仍然只有 (g, a, π) 。问题三的模式为

$$\underset{P=(g,a,\pi)}{\text{lex min}} \left(T_L(P), D_{\text{added}}^B(P) \right) \text{ s.t. } \begin{cases} \text{式 (6-1) 的全部约束组} \\ \text{FIFO容量式 (7-2)} \\ \text{双带宽池式 (7-4)} \end{cases} \quad (7-1)$$

新增 COPY 的记账与场景 B 相同（假设 7），只读 Cache 只改变读取走哪一个带宽池。

7.1.2 FIFO 语义：命中在发射时，插入在完成时

令 $Q(t)$ 为按插入先后排列的逻辑张量 FIFO， $H(t)$ 为其字节占用：

$$H(t) = \sum_{\tau \in Q(t)} b_{\tau} \leq 1048576 \quad (7-2)$$

正字节且键有效的读入操作在**发射时**查询缓存：命中则进入独立 L2 读池，未命中进入 DDR 池；写出操作始终走 DDR。命中不刷新已有键的 FIFO 次序，即这是先进先出而非最近最少使用。

插入发生在**完成时**：每个读入完成都会尝试插入，若无键、超容量或键仍存在则不插入，否则逐出最早的键直至能够容纳。

两个时点的分离带来一个容易被忽略的情形：一次命中读取在途期间，其对应的键可能被别的插入挤出，等该读取完成时缓存里已无此键，于是它会重新插入。图 7-1 用每键 256 KiB、容量 1 MiB 的概念例走完整个过程： t_0 发射读取 A 时命中并进入 L2 读池， t_1 另一读取 E 完成并插入、最早的 A 被逐出， t_2 读取 A 完成时 A 已不在缓存，于是逐出 B 后重新插入 A（结构示意，按官方语义构造）。键被逐出不会撤销已发射读取的带宽池选择，这两个时点必须分开理解。

概念例：每个键256 KiB；FIFO容量1 MiB；左端最早插入




图 7-1 FIFO 状态快照与在途读取（示意图）

逐图按字节命中率定义为

$$h_i = \frac{B_{\text{hit},i}}{B_{\text{hit},i} + B_{\text{miss},i}}, B_{\text{hit},i} + B_{\text{miss},i} > 0; \text{分母为零时沿原版约定 } h_i = 0 \quad (7-3)$$

零字节读取不进入正字节命中统计。本章报告的命中率均为 100 图逐图计算式(7-3)后的算术平均，不是把全部命中字节池化后计算的总体命中率。

7.1.3 两个互不占用的带宽池

$$\sum_{j \in A_p(t)} v_j(t) \leq B_p, B_{\text{DDR}} = 60, B_{L2} = 250 \text{ bytes/cycle} \quad (7-4)$$

$A_p(t)$ 为池 p 中的在途传输集合。每个池由全部核心共享，两池之间互不占用，这是 L2 可能带来收益的结构原因：命中的读取不再与未命中读取、写出争抢那 60 bytes/cycle。

忽略取整与并发时，单次搬运的理想参考延迟为

$$d_{\text{DDR}}^{\text{isolated}} = b/60, d_{L2}^{\text{isolated}} = b/250 \quad (7-5)$$

两者相差约 4.17 倍。这个比值只用于说明独立读池的量级：局部传输时间缩短不等于整图同比加速，关键计算、Pipe 占用、跨核释放与其他搬运都可能成为瓶颈。

7.1.4 未命中的三类来源

未命中至少有三类不同来源，终点统计无法区分它们：单条数据超过 1 MiB 容量，永远无法缓存；数据能够缓存，但在两次使用之间被其他张量挤出；多个核心在首次读取尚未完成时同时发射同一输入，此时缓存中还没有这个键，它们会全部未命中。

第三类的存在意味着低命中率既可能反映容量不足，也可能只反映并发时序。本轮实验固定了容量与带宽，未做参数扫描，因此识别的是该指定 L2 配置的**联合净效应**，无法为容量增加与带宽增加分别指定因果贡献。

7.2 实验设计：分离配置效应与选解效应

这是本章的方法学核心。

本章的分析分为两个层次。层次一回答“固定同一个方案，这块缓存值多少”，对应同方案配置比；层次二回答“允许求解器重新选择方案后，总共值多少”，对应分别选优比。两个层次使用同一个分子、不同的分母，不能互换。本章先把测量框架建立在层次一上，再用层次二说明二者的差额来自何处。

之所以必须这样拆，是因为开启 L2 后测得的性能提升实际混合了两件事：同一个方案在更好的硬件上跑得更快；以及求解器在新配置下可能选出另一个方案。前者是硬件配置的效应，后者是搜索行为的变化。合并报告会高估“加上这块缓存能带来多少”。


7.2.1 两种比值

记图 i 在 k 核下由 B 场景与 L2 场景分别选定的方案为 $P_{B,i,k}$ 与 $P_{L,i,k}$ 。同方案配置比与分别选优综合比分别为

$$R_{\text{hw},i,k} = \frac{T_B(P_{B,i,k})}{T_L(P_{B,i,k})} \quad (7-6)$$

$$R_{\text{select},i,k} = \frac{T_B(P_{B,i,k})}{T_L(P_{L,i,k})} \quad (7-7)$$

前者分子分母是同一个方案，差异只来自配置；后者的分母换成了 L2 场景自己选出的方案，因此包含选解变化，不能称为纯硬件收益。图 7-2 用方案×配置的 2×2 矩阵给出两种比较的结构（结构示意）：固定方案 P_B 在两个配置下的两格构成配置效应，右下角 $T_L(P_L)$ 参与的是综合效应，左下角“ P_L 在无 L2 配置下”这一格未纳入本比较。两个比值共用同一分子但分母不同，互换会改变结论的含义。



先逐图求比值，再对100图取算术均值；不能用两条均值曲线相除

图 7-2 方案×配置：两种比较的实验结构（示意图）

7.2.2 分解恒等式及其使用边界

两个比值之间有一条逐例成立的恒等式：

$$R_{select,i,k} = R_{hw,i,k} \cdot \frac{T_L(P_{B,i,k})}{T_L(P_{L,i,k})} \quad (7-8)$$

右侧第二项即选解效应：同在 L2 配置下，换用 P_L 相对沿用 P_B 的比值。

恒等式逐例成立，但不能推广到均值。配置比的均值按

$$\bar{R}_{hw,k} = \frac{1}{100} \sum_{i=1}^{100} R_{hw,i,k} \quad (7-9)$$

计算，是 100 个逐图比值的算术平均；三个量各自取算术均值后不再满足乘积关系。因此不能用 $\bar{R}_{select}/\bar{R}_{hw}$ 去估计平均选解效应。本章严格避免这一操作，选解效应的量级另行用逐例配对数据给出（7.4.4 节）。同理，两条主性能曲线各自用同一个整图 REF 归一化，配置比则另行对 100 个逐图比值取平均，不能用两条均值曲线相除得到。

7.2.3 对照的构造

配置对照通过图、核数、配置、评估器与方案哈希五项匹配。500 对中 430 对的 B/L2 最终方案本来就相同；其余 70 对方案不同，其中 62 对复用了同哈希的既有候选评分，8 对只补做官方 L2 评分，均不重跑求解器。对照补评分不反向参与既有主方案的选型，主实验的选解来源保持不变，本章只新增读表分析。

一项与官方实现相符的观察可作交叉校验：固定 P_B 时，两个配置下的边界与 Spill 新增 COPY 字节完全一致。这是因为官方在事件模拟之前就完成了新增 COPY 的记账，缓存命中发生在模拟阶段，不会回减该量。

7.2.4 求解路径

L2 求解从原图生成基础可行解，尝试不同的活动核心数与驻留组织；预算允许时独立生成 B 场景候选并按 L2 配置重新评价：这部分成本计入同一请求，不免费读取另一批次已选出的 B 方案。随后尝试快速插入与实际 Spill 触发的至多两个局部微批，按官方 Makespan 与新增 COPY 的字典序保留成功结果。完整流程见算法 7-1。

算法 7-1 R12 共享只读 L2 场景求解流程

输入：原图 G ；L2 配置 θ_L ；核心数 k ；单请求软预算 B （600 秒）

输出：L2 下选出的方案 P_L 及其官方评价结果

- 1 从原图生成并评价控制链（基础构造、减少活动核心候选、关键链局部移动），得到当前最好解 P^* ；
- 2 **if** $T_L(P^*) > 1.03 \cdot LB$ **then** 生成分量家族候选，下界剪枝后至多评价 6 个；
- 3 **if** 预算允许且仍未近优 **then** 在同一请求内独立求解一个场景 B 方案（至多 180 秒），并按 L2 配置评价（至多 40 秒）；
- 4 用区间索引生成插入候选（生成至多 30 秒，评价至多 120 秒）；
- 5 **if** P^* 的 Spill 新增字节 $D_{\text{spill}}(P^*) > 0$ **then** 诊断 Spill 事件，生成至多两个局部微批候选并逐个评价；
- 6 每一步都只在候选完整成功且 $(T_L, D_{\text{added}}, \text{名称})$ 字典序更优时更新 P^* ；最后输出 $P_L = P^*$ 。

同次请求内的择优不变差性质不能推广到两个独立请求：两次请求的最终方案谁优谁劣没有保证，7.4.4 节给出了实例。

L2 场景在同一请求内额外独立求解一个 B 方案（至多 180 秒）并按 L2 配置重新评价，官方评价次数 K 因此多于场景 B。五核请求的墙钟 P95 从场景 B 的 77.47 秒升至 197.70 秒，与这一额外成本方向一致；由于各请求的评价次数没有单独汇总，这里不对两者作定量归因（复杂度分解见式(5-9)式(5-10)）。

7.3 主要结果

7.3.1 本章五个五核指标的口径

本章涉及五个含义不同的五核数字，混用会得出相反结论，先集中辨析（表 7-1）。

表 7-1 本章五个五核指标的口径

指标	数值	含义
同方案配置比（均值/中位）	1.016766 / 1.000546	固定 P_B ，开关 L2 的耗时比， 纯配置效应
分别选优比（均值）	1.027400	分母换成 P_L ，含选解变化
固定 P_B ，L2 相对 REF	4.187457	主性能曲线，方案固定
L2 独立选优相对 REF	4.218978	主性能曲线，方案可变
逐图命中字节率均值	23.4614%	式(7-3)逐图计算后取平均

后两条曲线的定义为

$$\bar{S}_{L2}^{\text{fixed}} = \frac{1}{100} \sum_{i=1}^{100} \frac{T_{\text{REF},i}}{T_L(P_{B,i})} = 4.187457 \quad (7-10)$$

$$\bar{S}_{L2}^{\text{select}} = \frac{1}{100} \sum_{i=1}^{100} \frac{T_{\text{REF},i}}{T_L(P_{L,i})} = 4.218978 \quad (7-11)$$

关于数值精度：配置比这类贴近 1 的比值在本章保留六位小数，因为四舍五入到常规精度会抹掉退化记录（如 0.999831 与 0.999991）之间的差别，使数据失去意义。其余量按四位有效数字报告。

7.3.2 L2 独立选优的逐核主结果

表 7-2 L2 逐核主结果（每格 100 图，L2 独立选优方案）

核数	平均加速比	中位加速比	最小加速比	均值新增 COPY/MiB	其中边界/MiB	其中 Spill/MiB	墙钟中位/s	墙钟 P95/s
1	1.063807	1.011370	1.000000	8.4131	0.0000	8.4131	17.3699	193.1206
2	2.002948	1.995712	1.424760	8.1986	2.7611	5.4375	18.9794	193.8599
3	2.834798	2.939286	1.356033	9.0377	4.2787	4.7590	21.7490	201.4150
4	3.581091	3.742978	1.815040	8.2813	4.6212	3.6601	22.2803	189.8324
5	4.218978	4.470774	1.932301	9.4032	5.8467	3.5565	20.7454	197.7045

注：本表为 L2 配置下独立选优的结果，与“同一 B 方案开关 L2”的配置对照（表 7-3）口径不同。

场景 B 的结构特征在这里重现：一核的边界项为 0.0000，全部新增 COPY 都是 Spill；边界项随核数上升，Spill 项随核数下降。最小加速比在三核处仍有小幅回落（1.356，低于二核的 1.425），与场景 B 形态一致。

值得一提的是，两核最小加速比在场景 B 与 L2 场景下完全相同（均为 1.424760）。逐例数据确认两者来自同一张图 case_064，三核的最小值（B 为 1.355264，L2 为 1.356033）也来自该图，即同一张困难图在开启 L2 后几乎没有得到配置收益，三核回落是这一张图的现象而非普遍规律。case_064 同时是场景 A 全部核数下的最小值（5.4 节）。

7.3.3 三条方案曲线

图 7-3 左侧给出三条相对同一 REF 归一化的曲线：无 L2 的 P_B 、有 L2 的同一 P_B 、有 L2 另选 P_L ，五核值分别为 4.131、4.187、4.219。中间那条才是固定方案的配置效应，最上面那条已经包含了选解变化：两类平均收益不能混为纯硬件收益。三条曲线在 1 至 3 核几乎重合，从 4 核起才明显分离。右侧给出两种比值随核数的变化（纵轴围绕 1 局部放大）。




图 7-3 问题三：无 L2 与只读 Cache 两种配置下的 1 至 5 核平均加速比对比曲线 (a) 与两种配置比 (b)

7.3.4 逐核配置比与选优比

表 7-3 同核数 L2 配置比与选优比（每行 100 图）

核数	同方案配置比均值	同方案配置比中位	分别选优比均值	改善 / 相同 / 退化	逐图命中率均值	最终方案不同对数
1	1.001978	1.000000	1.002364	31 / 69 / 0	6.0886%	3
2	1.004765	1.000174	1.005591	57 / 39 / 4	16.0858%	5
3	1.011799	1.000210	1.013423	55 / 43 / 2	21.6492%	13
4	1.015729	1.000200	1.020292	55 / 45 / 0	19.6118%	21
5	1.016766	1.000546	1.027400	61 / 37 / 2	23.4614%	28

注：配置比与选优比口径不同，不可互换；一核配置比为实测值，不能强设为 1。配置比随核数单调上升，从一核的 1.001978 到五核的 1.016766。核数越多，同一块 L2 服务的并发读取越多，单位时间内可卸载到独立读池的字节也越多，方向与式(7-4)的池共享结构一致。

改善计数的分布值得单看：一核下 69 图完全没有变化，只有 31 图改善；即便到五核也仍有 37 图保持相同。在大多数核数下，超过三分之一的图对这块缓存没有任何可观测响应。

一核配置比是实测值 1.001978 而非按定义设定的 1：单核同样会发射重复读取，同样可能命中。这与加速比曲线的一核参考点（按原题定义取 1）性质不同。

7.4 结果分析

7.4.1 收益的分布形态

五核同方案配置比均值 1.016766，中位数 1.000546，相差一个数量级以上。收益在用例之间极不均匀：超过一半的图提升不到千分之一，均值被少数大幅受益的用例抬起。图 7-4 左侧保留全部 500 对的箱线与完整长尾，右侧是五核 100 对的 ECDF 局部视窗（视窗虽截取横轴，分母仍是完整 100 图，视窗之外还有 16 图）。




图 7-4 L2 收益：完整长尾与五核典型区间

表 7-3 的中位数一列进一步印证：五个核数的中位配置比全部贴近 1（最高者为五核的 1.000546）。只报均值会给出“普遍提速约 1.7%”的印象，只报中位数会给出“几乎没有效果”的印象：两个数字都真实，必须同时给出。

7.4.2 命中率与性能不成对应

这是本章最重要的负面结论，有两条独立证据。

核数维度上的反向变化。 命中字节率随核数为 6.09%、16.09%、21.65%、19.61%、23.46%，四核处出现回落，而同期的配置比仍在上升（1.011799→1.015729）。命中率下降、收益上升，两者并非同向。

退化记录内部的无关联。 表 7-4 中配置比第二差的是 case_090 在两核的 0.995638，而它的命中率是全表最高的 36.29%；命中率最低的 case_049（1.83%）配置

比反而最接近 1 (0.999991) 。八条记录内部，命中率与退化幅度看不出任何对应关系。五核下命中率与配置收益的散点同样不呈一一对应（图 7-5）。




图 7-5 五核：命中字节率与配置收益

机制上这并不矛盾。命中只决定这次读取走哪个带宽池，而更早完成的读取会改变后续操作的发射时刻，进而改变 FIFO 状态、改变后续读取的命中情况，也改变两个池各自的并发数。整条事件轴都被重排了，终点的 Makespan 由重排后的关键路径决定，与命中字节总量之间没有单调关系。

结论是：把命中率当作优化目标的代理不安全。 本章的算法没有这样做：选解依据始终是官方 Makespan 与新增 COPY 的字典序。

7.4.3 全部退化记录

表 7-4 全部同方案 L2 退化记录（8 条）

用例	核数	同方案配置比	同方案命中字节率
case_014	2	0.999863	23.8602%
case_049	2	0.999991	1.8294%
case_053	2	0.999831	11.6049%
case_090	2	0.995638	36.2899%
case_092	3	0.998346	11.1234%
case_094	3	0.999572	13.0478%
case_026	5	0.993980	16.4131%
case_092	5	0.997391	20.3016%

注：低于 1 表示退化。

500 对中有 8 对退化，最差为 case_026 在五核的 0.993980，相当于慢了约 0.6%。八条记录中有四条集中在两核，case_092 在三核与五核各出现一次。图 7-6 完整保留这八条记录并放大横轴：放大是为了读出小差异，不意味着退化幅度很大。




图 7-6 全部同方案 L2 退化记录

为什么只读缓存也可能造成退化。L2 是只读的，命中走独立池，直觉上不应拖慢任何事情。但命中改变的是完成时刻，完成时刻改变发射顺序，发射顺序又改变后续的命中与池内并发；整个事件轴被重新排列后，新的关键路径完全可能比原来更长。这解释了退化在原理上为何可能，但不构成对任何一条具体记录的归因：逐事件的因果追踪本章未做。

7.4.4 选解效应的量级

表 7-3 中配置比与选优比的差随核数扩大：

0.000386、0.000826、0.001624、0.004563、0.010634（对表内两列逐差得到）。同期最终方案不同的对数为 3、5、13、21、28，两组数字同向增长。核数越多，求解器在 L2 配置下找到另一个方案的机会越多，选解效应在综合比中占的份额也越大。

因此五核下 1.027400 与 1.016766 之间的差距不能全部记在 L2 头上：其中有 28 对的最终方案本身就换了。按 7.2.2 节的说明，这里也不能用两个均值相除来估计平均选解效应。

图 7-7 给出五核 28 对方案不同的配对结果：在同一 L2 配置中，另选方案较 P_B 有 26 例更快、1 例相同、1 例更慢。




图 7-7 五核：不同最终方案的选择效应

那个“1 例更慢”值得单独留意。它正是 7.2.4 节所预告情形的实例：两个独立请求各自在自己的配置下择优，同次请求内的不变差性质并不跨请求成立，因此 L2 请求选出的方案在 L2 配置下反而可能劣于 B 请求选出的方案。观察到这一例，说明该限定不是纸面上的谨慎措辞。

7.4.5 case_073：一个收益实例的事件轴

表 7-5 五核异质性案例

用例	无 L2 P_B /cycles	有 L2 同一 P_B /cycles	L2 独立选优/cycles
case_073 (5 核)	2034983	1806253	1805392
case_026 (5 核)	33518	33721	33721

注：case_026 为同方案配置比最小的五核用例。

两个案例形态完全相反。case_073 固定方案后开启 L2，Makespan 从 2034983 降到 1806253 cycles；再让求解器在 L2 下独立选优，只进一步降到 1805392，这一例的提升基本全部来自配置。case_026 则相反：开启 L2 后从 33518 升到 33721，而 L2 独立选优的结果与固定方案完全相同，说明求解器在该图上没有找到更好的替代方案。

case_073 完整 4252 条缓存事件的 FIFO 占用与累计命中率演化见图 7-8：缓存占用在早期迅速逼近 1 MiB 容量上限后长期维持高位，共同观察窗口内出现最大的一次占

用净降，即事件 e2428 (1143536 cycles) 处由 986880 降至 762624 bytes，净降 219 KiB。这里必须注明，占用的净变化不等于该次逐出的字节量。




图 7-8 case_073：缓存事件与共同观察窗口

图 7-9 把同一方案在两个配置下的多核时间线并排（固定 P_B 时两配置 Makespan 分别为 2034983 与 1806253 cycles），L2 视图中读入通道的密集段整体前移；红线只是全局缓存日志的事件定位，不指定给核心 0 的任何具体操作，也不建立 Pipe 层面的因果关系。




图 7-9 case_073：同方案时间线与缓存事件定位

选择 case_073 作展示，是因为它在第 6 章已作为微批机制的开发诊断案例出现过，Spill 量级较高、重复读取特征明显，用同一实例贯穿两章便于对照。两个案例合起来只能说明异质性的存在，不代替全部 100 图的分布。

7.4.6 新增 COPY 反而更高

表 7-6 五核 L2 独立选优的 COPY 与请求成本

五核 L2 独立选优指标	数值
平均新增 COPY/MiB	9.4032
其中边界/MiB	5.8467

五核 L2 独立选优指标	数值
其中 Spill/MiB	3.5565
请求墙钟中位/s	20.7454
请求墙钟 P95/s	197.7045
请求墙钟最大/s	423.6723

一个反直觉的结果：L2 独立选优的五核平均新增 COPY 为 9.403 MiB，高于场景 B 独立选优的 8.217 MiB（见表 7-10）。开启缓存之后，计划中的搬运量反而更多了。

原因有两层。**记账时点**：官方在事件模拟之前就完成新增 COPY 的记账，之后的缓存命中不会回减该量，所以这个数字反映的是计划中的搬运请求，不是物理 DDR 净流量。**目标结构**：字典序先比 Makespan，当 L2 使某些读取变得廉价时，求解器会接受那些搬运更多但时间更短的方案，这正是前两章反复出现的主次目标权衡，在这里以更明显的形式出现。

因此不能因为开了 L2 就说“搬运减少了”。要衡量物理流量，需要模拟阶段的实际 DDR 字节统计，本章没有这项数据。

7.4.7 相对 C3 的对照

表 7-7 L2 最终方案相对 C3 的逐例对照（每格 100 图）

核数	加速比均值 T_{C3}/T_{L2}	逐图降幅均值	更快 / 持平 / 更慢	更快但 COPY 更高
1	1.136025	10.6912%	81 / 19 / 0	14
2	1.222827	16.2115%	91 / 9 / 0	21
3	1.336165	21.8332%	92 / 7 / 1	16
4	1.454170	26.4412%	93 / 7 / 0	7
5	1.621458	31.4081%	94 / 5 / 1	7

注：C3 与 R12 的 L2 方案在本表中均按 L2 配置评价；C3 为同输入、同评分口径的事后对照，非等预算消融。

五核下为 94 例更快、5 例持平、1 例更慢，逐图降幅均值 31.41%，其中 7 个更快的实例 COPY 更高。

这个 31.41% 低于场景 B 的 34.49%：开启 L2 之后，本方法相对 C3 的**相对优势反而缩小了**。原因在于对照基线同步抬升：C3 在本表中同样按 L2 配置评价，因而也获得了配置收益，分子分母同时变小，比值随之收敛。这一现象不说明方法在 L2 场景下变弱，而说明 L2 的收益对固定构造方案与搜索方案都是普遍的。若要衡量本方法在 L2 场景下的“净增量”，正确的口径是 7.3.4 节的配置比与选解效应分解，而不是与 C3 的相对差。

7.4.8 求解成本与校验

L2 请求的墙钟 P95 在各核数上都接近 190 至 200 秒区间，五核最大值 423.7 秒，全部在 600 秒软预算内完成。这一水平高于场景 B（五核 P95 为 77.47 秒，见表 7-10），与 7.2.4 节的描述一致。

三问的选解与各类对照共检查 1470 组输出：1400 组为逐格选解（场景 A 的 400 格、场景 B 与 L2 场景各 500 格），另 70 组是最终方案与 L2 主方案不同的同方案对照（62 组复用同哈希的既有候选评分、8 组新补官方 L2 评分；其余 430 对两场景最终方案本来相同，无需另查）。核查覆盖执行计数、周期、原依赖、核心归属、Pipe 与 COPY 分解，全量结果与同方案对照保留了图、方案、官方结果及哈希绑定。本章未另写独立的缓存与带宽模拟器，相关校验属于内部自检。

7.5 方法的通用性与泛化性

参赛方法的价值不只在能否在给定测试集上取得好结果，还在于它在多大范围内成立。本节从三个层次分析。

7.5.1 测试规模提供的泛化证据

本文在 100 张官方计算图上完成全部实验，三个场景共 1400 个配置格，全部结果无筛选保留。这一规模使泛化性可以用分布而非个例来论证。

表 7-8 三场景五核结果的分布形态

场景	五核加速比 均值 / 中位 / 最小	是否全部优于基准	退化配置数
A	3.743 / 4.130 / 1.202	是	9 / 400
B	4.131 / 4.447 / 1.812	是	2 / 500
L2	4.219 / 4.471 / 1.932	是	8 / 500 (同方案配置对照)

注：退化配置的含义按场景而异：A、B 为相对 C3 更慢的配置格，L2 为同方案开启缓存后更慢的配置对；三者不可直接相加。

三个场景中没有任何一个配置格的结果劣于题目基准，最小加速比分别为 1.202、1.812、1.932。这比任何单点结果都更能说明方法的适用范围：它说的不是“平均表现好”，而是“在全部 1400 个配置格上都不慢于整图单核”。唯一的例外发生在求解阶段而非结果上：case_087 的场景 A 首次请求在 600 秒内没有得到成功方案，放宽到 1800 秒后才完成（5.5.5 节）。

与此同时，最小值与中位数之间的差距（场景 A 为 1.202 对 4.130）说明收益的分布高度右偏：方法的下限有保证，上限依图结构而变。这一形态在三个场景中一致。

7.5.2 框架层面的通用性

方法的通用性来自部件的可替换结构，而非参数调优。表 7-9 按求解器源码列出了各部件在三个场景中的启用情况。决策与择优、下界剪枝与近优认证、安全链收缩、基础构造器、反馈重排、活动核数与驻留组织候选、Treap 插入这些部件三个场景共用；依赖带分带与尾长优先的追加式分核只在场景 A 启用，因为只有场景 A 的代价几乎完

全由 Task 粒度与放置决定；Spill 触发的局部微批只在 B 与 L2 启用；跨配置重评价只在 L2 启用。每一项场景专属机制都对应代价结构中一个明确的新增维度：

- 场景 A 的代价由 Task 粒度决定 → 引入依赖带分带与追加式分核；
- 场景 B 新增容量溢出 → 引入 Spill 触发的局部微批；
- L2 场景新增缓存状态 → 引入跨配置候选重评价。

反过来，场景 A 因不存在驻留复用收益而不引入微批（5.2.4 节）。主动放弃一个机制并说明理由，与引入一个机制同样需要对代价结构的判断。

表 7-9 框架部件与场景专属机制

#	部件	作用	A	B	L2	出处
1	决策变量与可行性	方案三元组及其覆盖、唯一排布、联合无环约束	●	●	●	式(4-1)式(4-2)
2	字典序择优与下界	先 Makespan、相同时比新增 COPY；下界剪枝与 3%近优认证	●	●	●	式(4-6)式(4-23)
3	安全链收缩	合并非分支链为链块，避免凭空增加边界	●	●	●	5.2.2
4	基础构造器	弱连通分量打包、链块波次；B/L2 另含链块迁移	●	●	●	4.7.2
5	依赖带分带	按链块深度分带成组，构造合理粒度	●	○	○	5.2.2
6	追加式分核	尾长优先、沿合法拓扑序追加，构造不引入等待环	●	○	○	5.2.3
7	反馈重排	用官方时间线修正代理：A 为划分不变重排，B/L2 为关键链局部移动	●	●	●	4.7.2、5.2.3
8	活动核数与驻留组织候选	枚举 $m \leq k$ 与驻留排序粒度，权衡跨核边界与并行度	●	●	●	式(6-3)
9	Treap 区间索引插入	加速最早可行位置的查找，不变判定规则	●	●	●	5.2.4
10	Spill 触发局部微批	仅确有溢出时诊断并做窗口重排	●	●	●	式(6-4)式(6-5)
11	跨配置候选重评价	同一请求内按 L2 配置重新评价 B 方案	○	○	●	7.2.4

注：● 启用；○ 未启用；◐ 经分析后不使用（5.2.4 节）。启用情况按求解器源码核对。

这一结构意味着：若将本方法迁移到新的硬件配置，需要替换的是通信代价模型与场景专属机制，核心部件可以沿用。

7.5.3 通用性的边界

以下三点限制了结论的外推范围。

测试集边界。 全部结论基于题目给定的 100 张计算图，其非 COPY 操作数范围为 552 至 35705。对结构差异极大的计算图（例如深度远大于宽度的长链图，或分支因子极高的图），本文没有观测数据。

参数边界。 只读 L2 的容量（1 MiB）与读带宽（250 bytes/cycle）本轮固定未扫描，因此 7.4 节识别的是该指定配置的联合净效应。若容量或带宽变化，命中率与收益之间的关系可能改变。

预算边界。 全部结果在 600 秒软预算下取得（case_087 除外，该组使用 1800 秒补跑）。预算与解质量之间存在阈值效应：1800 秒约为场景 A 五核请求中位墙钟的 84 倍，说明预算的充分性依赖于图的规模。

7.5.4 一条可迁移的方法学结论

除去具体算法，本文有一条结论不依赖于本问题的硬件设定：**在时序耦合的系统中，标量累计指标只能用于剪枝，不能用于择优**（见 7.4.2 节与本章小结）。命中率、搬运总量、瞬时占用都是标量累计量，而性能由重排后的事件轴决定。本文在三个场景中一以贯之地遵循了这条区分：有效资源下界只用于排除候选，从不用于比较候选之间的优劣；亲和度、命中率、Spill 减少量都不参与选解；最终择优一律使用完整的官方评价结果。

这条认识对任何以缓存命中率或以通信总量为优化目标的调度设计都构成直接的提示，其适用范围超出本题的硬件设定。

7.6 小结与跨场景对照

表 7-10 跨场景五核对照（A / B / L2）

场景	平均加速比	边界/MiB	Spill/MiB	墙钟 P95/s
A	3.743282	13.5574	1.2340	470.6481
B	4.131077	5.5112	2.7062	77.4654
L2	4.218978	5.8467	3.5565	197.7045

注：三场景的搜索预算各不相同；C3 对照为事后同评分口径，非等预算消融。本表侧重代价构成的转移，分布形态与退化计数见表 7-8。

三个场景的五核结果连起来看，可以读出一条清晰的**代价转移路径**。从 A 到 B，边界搬运从 13.56 降到 5.511 MiB，降幅接近六成，这是同核 Task 合并消除跨 Task 边界的直接效果；同时 Spill 从 1.234 升到 2.706 MiB，驻留压力接管了一部分原本由边界搬运承担的代价。从 B 到 L2，边界与 Spill 都小幅上升（5.847 与 3.556 MiB），加速比却继续提高到 4.219，这正是 7.4.6 节所说的情形：字典序目标接受了搬运更多但时间更短的方案。三个场景的最优策略因此各不相同，单纯替换同步常数无法完成场景间的迁移。

本章自身的结论可归为三点。

L2 带来的是正向但高度不均的收益：五核同方案配置比均值为 1.016766，中位数却只有 1.000546，超过三分之一的图没有可观测变化，500 对配置对照中还有 8 对反而更慢。

命中率不能代替 Makespan。 命中率在核数维度上非单调（四核 19.61% 低于三核 21.65%）而收益仍在上升；退化记录中命中率最高的 case_090（36.29%）恰是退化第二严重的一例。以命中率为优化代理不安全。

配置效应与选解效应必须分开报告。 五核综合比 1.027400 中包含 28 对最终方案的变化，其中还有 1 例换了方案反而更慢。分解恒等式式(7-8)逐例成立，但不能用于均值相除。

全部结论限定在这 100 张图、1 MiB 与 250 bytes/cycle 的指定 L2 配置以及 600 秒软预算之内。本轮未做容量与带宽的参数扫描，识别的是该配置的联合净效应。

8 模型检验与算法分析

第 5 至 7 章从“结果好不好”的角度报告了三问。本章回答另外几个同样必须回答的问题：结果是否可信，优于对照是否只是偶然，核数与计算图规模变化时是否稳定，以及预算的大小会不会改变结论。本章的全部统计只读取存档的实验结果与校验记录，不新增任何求解与评分。

8.1 检验框架与证据矩阵

表 8-1 把每一类检验的手段、覆盖范围、结果与尚存的缺口放在一起，便于逐项核对。

表 8-1 模型检验的证据矩阵

检验对象	手段	覆盖范围	结果	尚存缺口
方案合法性	官方评价器执行；覆盖、周期、核归属、原依赖、Pipe、COPY 分解核查	1400 格选解 + 70 组同方案对照，共 1470 组	全部通过	未用第二套实现重建带宽与容量活期
数值与来源一致性	方案、官方结果与输入的 SHA256 绑定；全文数字由存档数据重算核对	全部表、图与正文数字	一致	属作者自检
下界一致性	命题 4.2 的 LB_k 与官方 Makespan 比较；求解中的运行时断言	1400 格	0 格低于下界	下界不含带宽与等待项
相对对照的显著性	符号检验、Wilcoxon 符号秩检验	14 个场景-核数组	全部 $p < 10^{-22}$	C3 不是等预算对照
稳健性	逐组最小值、退化计数、规模相关性	1400 格	无一格慢于 REF；规模与加速比弱相关	测试集之外无数据
组件作用	最终方案来源的白盒统计	1400 格	改进阶段产生	不是等预算消融

检验对象	手段	覆盖范围	结果	尚存缺口
预算灵敏度	首次失败与补跑、同请求阶段增量	case_087 四格；五核 B 三阶段	35.6%至 40.0% 的最终方案 600 秒对 1 张图不足	无等预算消融
L2 配置效应	同方案配对、分解恒等式	500 对	8 对退化，全部列出	未扫描容量与带宽

8.2 加速比分布、并行效率与超线性现象

表 8-2 加速比分布与并行效率（每组 100 图）

场景-核数	平均加速比	并行效率 $\bar{S}_k/k$	最小（用例）	最大（用例）	加速比超过核数的图数
A2	1.8553	0.9276	1.0456 (case_064)	2.4751 (case_084)	26
A3	2.5606	0.8535	1.1133 (case_064)	3.2877 (case_084)	14
A4	3.1973	0.7993	1.1719 (case_064)	4.4784 (case_059)	14
A5	3.7433	0.7487	1.2023 (case_064)	5.5011 (case_059)	8
B1	1.0614	—	1.0000 (case_001)	1.9726 (case_044)	55
B2	1.9925	0.9963	1.4248 (case_064)	3.4125 (case_044)	40
B3	2.8011	0.9337	1.3553 (case_064)	3.5503 (case_083)	27
B4	3.5210	0.8803	1.7361 (case_069)	4.8234 (case_083)	20
B5	4.1311	0.8262	1.8118 (case_071)	5.9116 (case_092)	14
L2-1	1.0638	—	1.0000 (case_001)	1.9726 (case_044)	71
L2-2	2.0029	1.0015	1.4248 (case_064)	3.4128 (case_044)	43
L2-3	2.8348	0.9449	1.3560 (case_064)	3.7727 (case_090)	30
L2-4	3.5811	0.8953	1.8150 (case_064)	4.8234 (case_083)	21
L2-5	4.2190	0.8438	1.9323 (case_005)	5.8962 (case_092)	17

注：并行效率为平均加速比除以核数；最后一列统计加速比大于核数的图数（单核组即大于 1 的图数）。

并行效率定义为平均加速比与核数之比，

$$E_k = \frac{\bar{S}_k}{k} \tag{8-1}$$

它衡量每增加一个核心换来多少加速。**并行效率随核数下降。**场景 A 从两核的 0.9276 降到五核的 0.7487，场景 B 从两核的 0.9963 降到五核的 0.8262，L2 场景从两核的 1.0015 降到五核的 0.8438。同样是五个核心，场景 B 与 L2 的效率明显高于场景 A，差距来自 Task 边界搬运与启动等待（5.5.3 节）；而三个场景的效率都随核数下降，这是共享 DDR 带宽与跨核等待不随核数扩展的体现（4.1.1 节）：共享 DDR 带宽相当于 Roofline 模型中的带宽上限[17]，跨核等待则类似 Amdahl 定律中不随核数缩短的串行部分[18]。

超线性加速比的来源。场景 A 两核有 26 张图的加速比超过 2，场景 B 五核有 14 张、L2 五核有 17 张图超过 5，最大值为场景 B 五核 case_092 的 5.9116。这并不违背物理约束：加速比的分母 REF 是原版启发式核内调度在整图单核上的结果，而不是单核最优。本文的单核方案在 55 张图上优于 REF，最多达到 1.9726 倍（case_044），说明 REF 离单核最优还有相当距离。多核加速比因此同时包含“并行收益”与“相对原版调度的质量收益”两部分，个别图超过核数是后者叠加的结果。题目规定的加速比口径保持不变，这里只说明其构成。

困难实例集中在少数图上。13 个多核组中有 9 个组的最小加速比来自同一张图 case_064，它只有 906 个非 COPY 操作、以向量计算为主，在场景 A 的 2 至 5 核都是最小值，在场景 B 的两核、三核与 L2 场景的两至四核也是最小值。小图可供并行的计算量有限，跨核通信与等待更难被计算掩盖，这与 5.4 节、6.3.2 节的观察一致。

方案并非简单均分。场景 A 最终方案的 Task 数中位数在 2 至 5 核依次为 8、10.5、33.5、27.5，最少的只有 2 至 3 个 Task，最多达 4361 个（图 8-1）；静态计算负载的不均衡度定义为




图 8-1 场景 A：最终 Task 粒度分布

$$B = \frac{\max W_c}{\frac{1}{k} \sum_{c=0}^{k-1} W_c}, W_c = \sum_{u: a(g(u))=c} \max(1, \text{cycles}_u) \quad (8-2)$$

$B=1$ 表示各核计算量完全均衡；它忽略通信、双 Pipe 重叠与等待，不等于实际利用率。场景 A 最终方案的 B 中位数为 1.013 至 1.079，最大到 2.727（图 8-2）。五核时还有 7 张图的最终方案只使用了不到 5 个核心。这些都说明，算法在不同图上选择了差异很大的粒度与放置，并会在并行收益不抵通信代价时主动少用核心，而不是把图机械地切成 k 块。




图 8-2 场景 A：静态计算负载均衡

8.3 相对对照基线 C3 的配对检验

第 5 至 7 章报告了 R12 相对 C3 的胜平负与平均降幅。为判断这种优势是否可能出于偶然，对每个场景-核数组把 100 张图按图配对，做两种非参数检验。符号检验只看每张图的胜负方向，剔除持平后，

$$p = 2 \sum_{j=0}^{\min(n_+, n_-)} \binom{n_+ + n_-}{j} 2^{-(n_+ + n_-)} \quad (8-3)$$

其中 n_+ 、 n_- 为 R12 更快与更慢的图数。Wilcoxon 符号秩检验[19]同时利用差异的大小：取 $d_i = \ln(T_{C3,i}/T_{R12,i})$ ，剔除 $d_i=0$ 后按 $|d_i|$ 取平均秩 rk_i ，

$$W_+ = \sum_{d_i > 0} rk_i, z = \frac{W_+ - n(n+1)/4}{\sqrt{n(n+1)(2n+1)/24 - \sum_g (t_g^3 - t_g)/48}} \quad (8-4)$$

n 为非零差异的配对数， t_g 为第 g 组并列值的个数。结果见表 8-3，逐组胜平负的全貌见图 8-3。




图 8-3 跨场景：相对 C3 的逐例胜平负

表 8-3 R12 相对 C3 的配对检验（每组 100 图）

场景-核数	更快/持平/更慢	符号检验 $\log_{10} p$	Wilcoxon z	有效配对数
A2	92/7/1	-25.72	8.29	93
A3	91/7/2	-24.05	8.28	93
A4	92/4/4	-22.06	8.47	96
A5	93/5/2	-24.64	8.45	95
B1	82/18/0	-24.38	7.87	82
B2	90/10/0	-26.79	8.24	90
B3	92/7/1	-25.72	8.37	93
B4	93/7/0	-27.69	8.37	93
B5	94/5/1	-26.31	8.46	95
L2-1	81/19/0	-24.08	7.82	81
L2-2	91/9/0	-27.09	8.28	91
L2-3	92/7/1	-25.72	8.37	93
L2-4	93/7/0	-27.69	8.37	93
L2-5	94/5/1	-26.31	8.46	95

注：符号检验为精确双侧检验，列出 $\log_{10} p$ ；Wilcoxon 检验取正态近似并做并列校正。

14 个组的符号检验 p 值全部小于 10^{-22} （最大的一组为场景 A 四核， $\log_{10} p = -22.06$ ），Wilcoxon 统计量 z 在 7.82 至 8.47 之间。R12 的最终方案在这 100 张图上系统性地快于 C3，这一点不依赖于均值是否被少数图拉动。

检验的含义需要限定。第一，C3 与 R12 的搜索预算不同（4.3.3 节），检验说明的是“终点方案的差异不是偶然”，不是“等成本下算法效率更高”。第二，14 个组共用同一

批图，组与组之间并不独立，不能把 14 个 p 值再合并成一个更小的数。第三，结论以这 100 张图为条件，推广到其他计算图需要另行验证。

8.4 稳健性分析：核数与计算图规模

题目要求算法“在 2 至 5 核范围内均能稳定地、高效地生成高质量结果”。从核数维度看，证据有四条：1400 个配置格没有一格慢于 REF（表 8-2 最小值列）；场景 A 的最小加速比随核数单调上升，从两核的 1.0456 升到五核的 1.2023；每个组相对 C3 的更快图数都不少于 81 张，多核组都不少于 90 张；相对 C3 更慢的配置在场景 A 为 9/400、场景 B 为 2/500、L2 场景为 2/500，除 case_062 在场景 A 两核、三核外，幅度都在 1% 以内。求解成本方面，各组请求墙钟的中位数在 7.916 秒至 25.68 秒之间。

从规模维度看，用非 COPY 操作数衡量图的规模，计算它与加速比、与求解墙钟的 Spearman 秩相关系数[20]，结果见表 8-4。

表 8-4 计算图规模与结果、成本的秩相关

场景-核数	规模与加速比的 Spearman r_s	规模与求解墙钟的 Spearman r_s
A2	0.107	0.901
A5	0.158	0.905
B2	-0.051	0.924
B5	0.192	0.879
L2-5	0.185	0.844

规模与加速比的相关系数在 -0.051 至 0.192 之间，几乎不相关：大图并没有因为评价更慢、可试候选更少而系统性地得到更差的加速比。规模与墙钟的相关系数在 0.844 至 0.924 之间，高度正相关，与式(5-9)“总成本由官方评价主导”的分析一致，因为单次评价的成本随图规模增长。相关不等于因果，这里只作描述。

8.5 白盒统计：最终方案由哪个组件产生

R12 在一次请求内按固定顺序运行多个组件（4.7.2 节，图 4-3）。每个配置格最终输出的方案，都能追溯到首次给出它的组件：该组件的候选在当时字典序最优，而此后运行的组件都没有找到更优的候选。表 8-5 按场景统计了 1400 个配置格最终方案的来源。

表 8-5 最终方案的来源组件（配置格数）

产生最终方案的 组件	场景 A (400 格)	场景 B (500 格)	L2 场景 (500 格)
基础构造	240	322	311
减少活动核心	4	5	4
依赖带候选	39	—	—
反馈重排	97	52	49
分量家族	18	8	3
跨配置重评价	—	—	3
插入式候选	2	107	123

产生最终方案的 组件	场景 A (400 格)	场景 B (500 格)	L2 场景 (500 格)
局部微批	—	6	7
改进阶段合计 (占比)	160 (40.0%)	178 (35.6%)	189 (37.8%)

注：场景 A 为 2 至 5 核，场景 B 与 L2 场景为 1 至 5 核；“—”表示该组件在此场景不启用。基础构造包括分量打包、链块波次、分量批次，场景 B 与 L2 另有链块迁移；反馈重排在场景 A 为划分不变的重排，在场景 B 与 L2 为关键链局部移动。来源按选中方案的官方结果文件所在的阶段目录判定；五核 B 中来源为插入式候选或局部微批的图，与 6.4.4 节同请求阶段记录中“后两个阶段有改善”的图逐一对应。

这是存档运行记录的读表统计，不是等预算消融：某组件“产生了最终方案”，说明它在该请求中给出了字典序更优的候选，但不能说明去掉它以后其余组件补不上这一改进。在这一限定下，表中可以读出三点。

基础构造给出约六成的最终方案，改进阶段贡献其余约四成。 三个场景由改进阶段产生最终方案的配置格分别为 160、178、189 格，占 40.0%、35.6%、37.8%。基础构造本身包含分量打包、链块波次等多种构造，在规模小、结构简单的图上直接胜出在意料之中；各改进阶段的作用集中在其余配置格上。

场景专属组件在各自的场景中都产生了最终方案。 场景 A 中，反馈重排产生 97 格，约占四分之一，依赖带候选产生 39 格，在两核、三核分别为 7 格与 4 格，在四核、五核各为 14 格；插入式候选只产生 2 格，这与场景 A 的代价主要由 Task 粒度与放置决定（5.1.1 节）相符。场景 B 与 L2 场景中，插入式候选分别产生 107 格与 123 格，是最大的改进来源；关键链局部移动分别产生 52 格与 49 格；局部微批只产生 6 格与 7 格，这与它“只在确有 Spill 时启动”的设计以及 Spill 集中在少数图上的事实（6.4.3 节）一致。

来源随核数变化。 场景 B 的插入式候选在一核时产生 28 格，五核时只有 10 格；关键链局部移动则从一核的 0 格增至五核的 17 格。L2 场景的趋势相同，插入式候选从 27 格降到 15 格，关键链局部移动从 0 格增到 16 格。核数少时改进主要来自核内次序，核数多时越来越多地来自沿跨核关键链的调整。

参数层面的观察。 依赖带的四种宽度中，宽度 4、8、16 分别产生 18、14、7 格，宽度 2 没有产生任何最终方案；场景 A 的反馈重排有两种时长口径，按整机时间线实测时长重排的产生 70 格，按 Task 核内局部时长重排的产生 27 格。前者提示宽度 2 的候选在本测试集上边际作用很小，后者与“计入等待和带宽争用的实测时长更能反映 Task 真实代价”的直觉一致。两条同样是来源统计，不是控制变量的参数扫描。

8.6 灵敏度分析：求解预算与求解成本

三个场景的求解墙钟分布见图 8-4，它们都高度右偏：多数请求在半分钟内结束，少数大图用满预算。预算对结论的影响集中在两处。




图 8-4 求解墙钟与预算长尾

预算阈值。 case_087 是本测试集第 5 大的图（27556 个非 COPY 操作），场景 A 的四个配置在 600 秒内都没有得到成功方案，改用 1800 秒后全部成功，补跑墙钟在 753.0 至 1036.1 秒之间（5.5.5 节）。这说明对最大的一批图，600 秒接近完成一次完整搜索所需的下限。其余 1396 个配置格都在 600 秒内得到结果，场景 B 与 L2 全部请求的墙钟最大值分别为 265.0 秒与 423.7 秒。

预算在机制间的分配。 五核 B 的同请求阶段数据（6.4.4 节）显示，控制链阶段结束时的平均加速比已达 4.0732，是最终值的 98.6%；插入与微批阶段分别只在 12 张与 2 张图上进一步改善。也就是说，即使后两个阶段完全没有机会运行，五核 B 的平均加速比也不会低于 4.0732。这是同一请求内的增量记录，不是等预算的独立消融，但它说明本文的主要收益并不依赖于把预算耗尽。

8.7 小结

本章的检验支持四条结论。第一，R12 相对 C3 的优势在 14 个组中都通过了配对检验， p 值全部小于 10^{-22} ，但这是终点方案的比较，不是等预算的算法效率比较。第二，结果对核数与图规模是稳健的：没有一格慢于 REF，并行效率随核数平稳下降，规模与加速比几乎不相关，规模只显著影响求解墙钟。第三，各组件都实际产生过最终方案：改进阶段在三个场景中产生了 35.6%至 40.0%的最终方案，场景 A 以反馈重排与依赖带为主，场景 B 与 L2 场景以插入式候选与关键链局部移动为主。第四，600 秒预算对绝大多数图足够，对最大的一批图接近下限，case_087 需要 1800 秒。此外，全部 1470 组输出都通过了合法性核查，1400 个官方结果无一低于 4.5.2 节的计算下界。尚未完成的检验是等预算的单模块消融与 L2 容量、带宽的参数扫描，第 9 章把它们列为不足与改进方向。

9 模型评价与推广

9.1 主要认识

把三个场景放在一起，本文得到三条不依赖具体数字的认识。

三项决策必须联合选择。 切图、分核、核序中任何一项单独做到最好，都不能保证 Makespan 最短。case_062 在场景 A 的表现说明了这一点：同一张图，4361 个 Task 的细粒度划分在两核、三核下慢于对照，293 个 Task 的粗粒度划分在四核、五核下反而比对照快，耗时分别低 13.96% 与 17.02%。粒度的好坏只能在与分核、核序一起评价时才看得出来。

同核合并转移而非消除容量代价。 从场景 A 到场景 B，五核平均边界新增由 13.56 MiB 降到 5.511 MiB，Spill 新增却由 1.234 MiB 升到 2.706 MiB，而且高度集中在少数图上（前 10 张图占五核 B 全部 Spill 字节的 93.84%）。优化的对象从“少切几刀”变成了“驻留谁、何时驻留”。

标量累计指标只能用于剪枝，不能用于择优。 命中率、搬运总量、瞬时占用都是标量，而 Makespan 由重排后的事件轴决定。第 7 章中命中率最高的退化记录恰是退化第二严重的一例，五核 L2 独立选优的新增 COPY 反而高于场景 B。本文始终只用完整官方评价择优，下界与代理量只用于排除候选。

9.2 模型的优点

1. **评价一致。** 以官方评价器为唯一目标函数，报告值与评分口径零偏差；公式、代理与下界只服务于候选构造与剪枝，不会把代理误差带进结果。
2. **下界辅助的搜索。** 与方案无关的计算下界用于剪枝与近优认证停止，把预算留给仍有改进余地的大图；全部官方结果无一低于下界，同时充当了一项独立的一致性检验。
3. **结构化而非随机的搜索。** 安全链收缩、依赖带分组、尾长优先分核、反馈重排、Treap 插入、Spill 触发微批各有明确的结构依据，候选数量有界、全流程无随机种子，结果与方案哈希绑定，可以复查。
4. **全量无筛选的实验纪律。** 1400 个配置格与 500 对同方案对照全部保留，退化记录、预算例外、首次失败全部披露；相对 C3 的优势在 14 个组中都通过了配对检验。
5. **方法学上的区分。** 把 L2 的收益拆成同方案配置效应与选解效应，并给出逐例成立的分解恒等式，避免把求解器行为的变化记在硬件头上。
6. **框架可迁移。** 三个场景共用决策结构、择优规则与多数候选部件，场景专属机制只加在候选生成层，每一项都对应代价结构中一个明确的新增维度。

9.3 模型的不足

1. **一般情形下没有最优性保证。** 黑箱目标建模只能给出可行解；计算下界忽略了共享带宽与等待，在高核数下偏松，只能用于剪枝与停止判断，不足以刻画解与最优之间的距离。
2. **缺少等预算的单模块消融。** 依赖带、反馈重排、分量家族与插入候选在同一请求内竞争预算，相对 C3 的 43.48% 降幅不能归因到具体模块；8.5 节的来源统计说明每个组件都产生过最终方案，五核 B 的三阶段记录给出了增量，但二者都不是等预算消融。
3. **没有做 L2 的参数扫描。** 容量与带宽在全部实验中固定，第 7 章识别的是该配置的联合净效应，不能分别给容量与带宽分配贡献。
4. **个别实例的机制没有完全查清。** case_062 在低核数下没有选到粗粒度划分，逐例数据说明了后果，但没有回答搜索为何没有评价到那类候选；case_026 等 L2 退化记录同样只确认了事实，未做逐事件的因果追踪。
5. **验证属于自检。** 全部核查由作者完成，没有用第二套独立实现重建带宽与容量的动态过程。

9.4 改进方向

1. **做等预算的独立消融。** 固定预算、依次关闭依赖带、反馈重排、分量家族、插入与微批，把增量对照升级为可归因的比较；8.5 节发现依赖带宽度 2 从未产生最终方案，可优先检验去掉它、把预算让给其余候选的效果。
2. **收紧下界。** 在计算下界之外加入跨 Task 边界搬运的必然字节与跨核等待，得到在高核数下更紧的下界，使剪枝与近优认证在更多实例上起作用。
3. **按图规模分配预算。** 规模与墙钟的秩相关达到 0.844 至 0.924，可以在请求开始时按图规模动态分配预算，把节省下来的时间给 case_087 这类大图。
4. **L2 参数扫描与缓存感知的候选。** 对容量与带宽做二维扫描以分离两者的作用；在候选生成中考虑共享输入的首次读取时序，减少多个核心同时未命中的情况。
5. **引入关键路径信息的粒度选择。** case_062 提示，粒度候选应同时覆盖“粗”和“细”两端，并按关键路径上的等待累计量排序送评价，避免在低核数下错过粗粒度划分。

9.5 模型的推广

本文的框架对三类问题有直接的借鉴意义。第一，目标由仿真器或评价程序给出、写不出闭式表达式的调度问题，例如带共享总线或网络的多处理器任务映射，可以沿用“结构化候选—下界剪枝—真实评价—字典序择优”的闭环。第二，编译器中的算子融合与切分决策，本质上也是粒度、放置与次序的联合选择，安全链收缩与依赖带分组

可以直接作为候选生成手段。第三，任何“开启一项硬件特性后性能变化”的评估，都可以用同方案配置比与分别选优比的分解，把硬件效应与软件行为变化分开报告。迁移时需要替换的是通信代价模型与场景专属机制，决策结构、择优规则与下界思路可以保留。

10 结论

本文把多核 NPU 上的切图与调度写成以官方评价器为目标的字典序优化问题，证明其在忽略搬运的特例下已是 NP 难的，给出与方案无关的计算下界；在此基础上设计了“结构化候选生成—下界剪枝—整机评价—字典序择优”的 R12 框架，在 100 张正式计算图、三个场景、1400 个配置格上完成了全量实验。三问的核心结果汇总于表 10-1。

表 10-1 三问核心结果汇总（每格 100 图，逐例比值的算术平均）

核数	问题一 场景 A	问题二 场景 B	问题三 无 L2 (P_B)	问题三 只读 Cache (P_L)	同方案配置比 $\bar{R}_{hw}$	分别选优比 $\bar{R}_{select}$
1	1 (定义)	1 (定义)	1.0614	1.0638	1.001978	1.002364
2	1.8553	1.9925	1.9925	2.0029	1.004765	1.005591
3	2.5606	2.8011	2.8011	2.8348	1.011799	1.013423
4	3.1973	3.5210	3.5210	3.5811	1.015729	1.020292
5	3.7433	4.1311	4.1311	4.2190	1.016766	1.027400

注：问题一、问题二的一核点按题目定义为 1；问题三两条曲线的一核点为实测值（无 L2 列即优化后的 B1）。同方案配置比固定无 L2 下选出的方案 P_B ，分别选优比的分母换成 L2 下独立选出的方案 P_L 。

问题一（场景 A）。以安全链收缩与依赖带弱连通分组构造 Task 粒度，以尾长优先的追加式分核放置，以官方时间线做划分不变的反馈重排，并用 Treap 区间索引加速插入式候选。2 至 5 核的平均加速比为 1.855、2.561、3.197、3.743，五核中位 4.130、最小 1.202，400 个配置格无一慢于整图单核；相对固定构造基线 C3，2 至 5 核的逐图耗时平均降低 25.01%、32.95%、38.93%、43.48%。新增 COPY 以边界搬运为主，五核平均 14.79 MiB。1 至 5 核平均加速比折线见图 5-4，逐例 Makespan 与总额外数据搬运量见附录 A。

问题二（场景 B）。同核合并 Task 以后，代价由边界搬运转向核内驻留与 Spill。在问题一框架上增加活动核数与驻留组织候选、沿官方关键链的局部移动，以及只在确有 Spill 时启动的局部微批，并证明核归属不变可保证 Spill 前的边界 COPY 严格不变。2 至 5 核平均加速比为 1.993、2.801、3.521、4.131，五核最小 1.812；一核按定义为 1，优化后的单核方案平均为 1.061。五核相对 C3 的逐图耗时平均降低 34.49%；五核只有 22 张图发生 Spill，其中前 10 张图占全部 Spill 字节的 93.84%。折线见图 6-4，逐例结果见附录 A。

问题三（共享只读 L2）。按官方语义建立“发射时命中、完成时插入”的 FIFO 模型与两个互不占用的带宽池，用同方案配置比与分别选优比把硬件配置效应与选解效应分开，并给出逐例分解恒等式。L2 下独立选优的 1 至 5 核平均加速比为 1.064、2.003、2.835、3.581、4.219；同方案配置比随核数从 1.001978 升至 1.016766，五核中位数只有 1.000546，分别选优比五核为 1.027400。收益高度不均：500 对同方案对照中 8 对退化，命中率与收益不单调对应，开启 L2 后计划中的新增 COPY 反而由 8.217 MiB 升至 9.403 MiB。两种配置的对比曲线与配置比见图 7-3，逐例两配置的 Makespan、新增 COPY 与命中率见附录 A。

模型检验。相对 C3 的优势在 14 个场景-核数组的配对检验中都显著 ($p < 10^{-22}$)；1400 个配置格无一慢于整图单核，并行效率随核数平稳下降；图规模与加速比几乎不相关，只与求解墙钟强相关。

本文的主要创新。第一，**评价一致的建模与可证下界**：把官方评价语义写成依赖、Pipe、释放、容量、带宽与边界计账六组约束，以 (Makespan, 新增搬运量) 为字典序目标；证明问题在忽略搬运时已是 NP 难的，并用与方案无关的下界做剪枝与 3% 近优认证。第二，**按代价结构组织的结构化候选族**：场景 A 以安全链收缩、依赖带弱连通分组、尾长优先分核与划分不变的反馈重排控制边界搬运；场景 B 与 L2 场景以驻留组织候选和只在确有 Spill 时启动的局部微批处理容量溢出，并以核归属不变式保证 Spill 前的边界 COPY 严格不变。第三，**配置效应与选解效应的分解**：同方案配置比、分别选优比与逐例分解恒等式把 L2 的硬件收益与求解器行为变化分开，得到“命中率高不等于收益大”“只读缓存也会使个别方案变慢”“开启 L2 后新增 COPY 反而上升”三条可检验的结论。第四，**全量、可复查的实验**：1400 个配置格与 500 对同方案对照全部报告，方案与官方结果以 SHA256 绑定，退化与预算例外逐项披露。

需要说明的边界是：结论限于这 100 张图、题目给定的固定配置与 600 秒软预算 (case_087 的场景 A 四格为 1800 秒补跑)；C3 是事后同口径对照，不是等预算消融；L2 的容量与带宽没有分别扫描，报告的是指定配置的联合净效应。

参考文献

- [1] Sze V, Chen Y H, Yang T J, et al. Efficient processing of deep neural networks: a tutorial and survey[J]. Proceedings of the IEEE, 2017, 105(12): 2295-2329.
- [2] Chen Y H, Krishna T, Emer J S, et al. Eyeriss: an energy-efficient reconfigurable accelerator for deep convolutional neural networks[J]. IEEE Journal of Solid-State Circuits, 2017, 52(1): 127-138.
- [3] 2026 年中国研究生数学建模竞赛组委会. 2026 年中国研究生数学建模竞赛 A 题：通用神经网络处理器下的多核调度问题（赛题、附录与评估程序）[Z]. 2026.
- [4] Graham R L. Bounds on multiprocessing timing anomalies[J]. SIAM Journal on Applied Mathematics, 1969, 17(2): 416-429.
- [5] Kwok Y K, Ahmad I. Static scheduling algorithms for allocating directed task graphs to multiprocessors[J]. ACM Computing Surveys, 1999, 31(4): 406-471.
- [6] Topcuoglu H, Hariri S, Wu M Y. Performance-effective and low-complexity task scheduling for heterogeneous computing[J]. IEEE Transactions on Parallel and Distributed Systems, 2002, 13(3): 260-274.
- [7] Chen T, Moreau T, Jiang Z, et al. TVM: an automated end-to-end optimizing compiler for deep learning[C]//13th USENIX Symposium on Operating Systems Design and Implementation (OSDI 18). Carlsbad: USENIX Association, 2018: 578-594.
- [8] Xing Y, Liang S, Sui L, et al. DNNVM: end-to-end compiler leveraging heterogeneous optimizations on FPGA-based CNN accelerators[EB/OL]. arXiv:1902.07463, 2019.
- [9] Zheng L, Li Z, Zhang H, et al. Alpa: automating inter- and intra-operator parallelism for distributed deep learning[C]//16th USENIX Symposium on Operating Systems Design and Implementation (OSDI 22). Carlsbad: USENIX Association, 2022: 559-578.
- [10] Shi Y, Yang Z, Xue J, et al. Welder: scheduling deep learning memory access via tile-graph[C]//17th USENIX Symposium on Operating Systems Design and Implementation (OSDI 23). Boston: USENIX Association, 2023.
- [11] Popp M, Schlag S, Schulz C, et al. Multilevel acyclic hypergraph partitioning[EB/OL]. arXiv:2002.02962, 2020.
- [12] Hong J W, Kung H T. I/O complexity: the red-blue pebble game[C]//Proceedings of the 13th Annual ACM Symposium on Theory of Computing. New York: ACM, 1981: 326-333.
- [13] Belady L A. A study of replacement algorithms for a virtual-storage computer[J]. IBM Systems Journal, 1966, 5(2): 78-101.
- [14] Garey M R, Johnson D S. Computers and intractability: a guide to the theory of NP-completeness[M]. San Francisco: W. H. Freeman, 1979.
- [15] Seidel R, Aragon C R. Randomized search trees[J]. Algorithmica, 1996, 16(4-5): 464-497.

- [16] Kahn A B. Topological sorting of large networks[J]. Communications of the ACM, 1962, 5(11): 558-562.
- [17] Williams S, Waterman A, Patterson D. Roofline: an insightful visual performance model for multicore architectures[J]. Communications of the ACM, 2009, 52(4): 65-76.
- [18] Amdahl G M. Validity of the single processor approach to achieving large scale computing capabilities[C]//Proceedings of the AFIPS Spring Joint Computer Conference. New York: ACM, 1967: 483-485.
- [19] Wilcoxon F. Individual comparisons by ranking methods[J]. Biometrics Bulletin, 1945, 1(6): 80-83.
- [20] Spearman C. The proof and measurement of association between two things[J]. The American Journal of Psychology, 1904, 15(1): 72-101.

附录

附录 A 逐例结果（官方评估程序输出）

以下各表由脚本从存档结果表直接生成，数值即官方评估程序输出，未作任何取舍。Makespan 单位为 cycles，新增 COPY（总额外数据搬运量）单位为 bytes，命中率为按字节计算的百分比。场景 A 的 case_087 四个配置为 1800 秒补跑结果（5.5.5 节），其余均为 600 秒软预算结果。

A.1 问题一：场景 A

表 A-1 问题一逐例 Makespan（REF 为整图单核基准）

用例	REF 单核	2 核	3 核	4 核	5 核
case_001	233110	116868	78545	58984	47502
case_002	261945	140236	98023	76865	58180
case_003	602212	393827	321535	287598	276507
case_004	392357	199074	134043	104188	88341
case_005	95618	80999	72553	70248	69060
case_006	82837	43033	30917	27895	27679
case_007	1012562	507494	338094	254398	203834
case_008	487605	244266	163359	123060	100603
case_009	153261	92198	92198	81530	73571
case_010	86969	45626	30856	27800	24563
case_011	184697	92646	69625	46880	46880
case_012	59088	30094	21894	17853	14212
case_013	263949	132198	88351	66982	54363
case_014	17698626	8759857	5865918	4447779	3614837
case_015	177362	92321	61168	51205	42955
case_016	7715523	4646180	3793761	3592965	3306411
case_017	162810	84055	58959	48848	35470
case_018	1004367	503411	339838	258063	202636
case_019	81144	43224	30852	24099	22228
case_020	532746	266580	177950	133704	107650
case_021	6567937	3156352	2106282	1550324	1250168
case_022	56780	28881	19370	14641	11813
case_023	122614	61424	41720	30522	24965
case_024	2555343	1539668	1256817	1189845	1095663
case_025	4863026	2434032	1624426	1219420	975282
case_026	99203	58112	41276	41219	41219
case_027	2363952	1120962	837049	559196	558753
case_028	43836040	20541851	14076015	10461460	8605530
case_029	37555	19740	12743	11028	9383
case_030	2808034	1394193	931629	698657	560814
case_031	1414369	706033	485202	392550	306307
case_032	41443	21706	15674	12763	10415
case_033	1774196	904907	607519	461610	373638
case_034	842996	415383	287578	230925	184639
case_035	169571	95406	95406	90516	82052
case_036	931510	466068	311345	233584	187182
case_037	210001	105374	74038	53320	43800
case_038	1364555	681518	461018	345206	283932
case_039	1435262	708561	485565	392896	395297
case_040	253454	143799	110105	98759	93219
case_041	6003957	2965113	1976739	1484401	1192525
case_042	1686740	835375	571947	435238	363428
case_043	677656	355614	268777	261670	232286
case_044	154407	78699	78699	78699	78699
case_045	125614	63059	42601	31878	26164
case_046	276455	158876	142176	124612	124612
case_047	326508	245880	187273	171560	158050
case_048	222220	169359	145022	145292	145490
case_049	196276	148351	124128	115314	108297
case_050	149690	108121	85329	74902	70368
case_051	607628	367112	299245	282785	261214
case_052	180301	91267	65207	50125	43641

用例	REF 单核	2 核	3 核	4 核	5 核
case_053	1472686	770010	546106	492232	492699
case_054	815051	515425	391890	331031	298043
case_055	118835	57941	43655	31823	26800
case_056	277285	213386	180659	166455	157566
case_057	59726	32042	21762	16879	14055
case_058	4539717	2200935	1532101	1184895	1004819
case_059	829473	369318	254768	185216	150782
case_060	888789	458745	308169	232466	185331
case_061	77191	39298	28342	27170	22059
case_062	2854809	1976451	1593547	764940	619333
case_063	1070397	558373	377834	290167	237375
case_064	19116	18283	17170	16312	15899
case_065	53068	26972	17918	14288	11235
case_066	359070	226476	185361	167785	159869
case_067	63834834	32438342	22543931	16545997	13961132
case_068	362095	260340	221224	197091	189541
case_069	25144	21197	19700	18866	19032
case_070	117300	58234	45660	34658	28840
case_071	18919	16232	14889	14434	14220
case_072	23897828	11713796	7870089	5945430	4779968
case_073	10081626	5304875	4427074	3646155	3315864
case_074	1682239	832726	548347	415984	345470
case_075	1441809	844156	639599	552334	506598
case_076	6185113	3046650	2033956	1526939	1230399
case_077	495320	250735	178739	144734	121081
case_078	2296143	1080972	763089	619540	536429
case_079	31052251	14738594	9939977	7495240	5998948
case_080	292138	145926	100325	100325	100325
case_081	151795	76860	51943	39588	30943
case_082	721041	450921	355841	311867	290998
case_083	1057993	537673	414361	390026	370632
case_084	2507412	1013056	762658	629028	503472
case_085	3187899	2105594	1593477	1291419	1216812
case_086	118403	99674	92319	84701	83340
case_087	3974071	2093249	1483711	1204070	1038529
case_088	243623	173654	146818	131635	127073
case_089	693092	346832	243614	178160	147432
case_090	1178363	513438	397500	346678	346678
case_091	9186769	4529311	3036878	2288314	1857417
case_092	4815554	2498492	1841420	1465901	1384732
case_093	74205	37827	25103	19779	15876
case_094	94892	49398	39889	27461	23564
case_095	2084853	1042890	695775	524422	420852
case_096	84194	47089	30832	26980	26930
case_097	11491509	5161740	3577028	2626908	2102348
case_098	177430	89551	82660	69258	64165
case_099	1622999	811243	544403	405655	336496
case_100	151223	82771	57566	57566	51287

表 A-2 问题一逐例总额外数据搬运量 (bytes)

用例	2 核	3 核	4 核	5 核
case_001	1152	2304	3456	4608
case_002	82944	82944	82944	82944
case_003	6729464	6729464	6729464	6729464
case_004	110592	221184	331776	442368
case_005	2049178	2483610	2483610	2483610
case_006	56200	91264	664560	664560
case_007	27648	55296	82944	110592
case_008	0	0	0	0
case_009	0	0	928212	928212
case_010	48384	48384	715508	715508
case_011	180224	1081344	540672	540672
case_012	28800	20160	21888	31104
case_013	8192	16384	24576	32768
case_014	71556024	71375016	75533208	81189384
case_015	224536	290056	1081932	342528
case_016	119566328	119566936	119567544	119568152
case_017	161280	175104	260352	343296
case_018	2835456	4075904	4914944	5136384
case_019	27168	24576	51744	608920
case_020	0	0	0	0
case_021	5427200	6707200	4608000	11431936
case_022	6912	13824	13824	6912

用例	2核	3核	4核	5核
case_023	84096	196896	207552	197472
case_024	39331088	39331288	39331488	39331688
case_025	248832	304128	304128	110592
case_026	288	217872	217872	217872
case_027	1744896	3686400	3317760	5529600
case_028	99676800	98668800	103033728	105408000
case_029	0	0	0	0
case_030	7370752	8237056	9418752	10398720
case_031	4379136	7348224	14062336	8059392
case_032	6216	12360	129188	12360
case_033	6645792	6972480	12826272	7816320
case_034	1998336	2645504	6690304	3581952
case_035	0	0	469248	1007048
case_036	1152	2304	3456	4608
case_037	204800	1064960	614400	1925120
case_038	6790656	7045632	9295872	9667584
case_039	11067392	14323712	16388096	16388096
case_040	53760	0	2075814	2075814
case_041	22579200	25559040	26910720	28502016
case_042	6967584	8251680	7876896	8598528
case_043	556040	233480	5285512	5285512
case_044	2014560	2014560	2014560	2014560
case_045	0	0	0	0
case_046	6512800	4021280	4513952	4513952
case_047	3820950	3820950	3820950	3820950
case_048	853830	1253562	1253562	1253562
case_049	1784066	1784066	2743324	2743324
case_050	3456	1219726	1219726	1219726
case_051	9046218	9046264	9046310	9046356
case_052	102912	181248	259584	854016
case_053	7237216	5882944	6360992	6918912
case_054	6850874	6850874	6850874	6850874
case_055	57856	115712	115712	198656
case_056	2922520	2922520	2922520	2922520
case_057	70272	70272	70272	70272
case_058	43794432	32858112	45551616	32104448
case_059	360448	2748416	1081344	4325376
case_060	8150032	8150032	8150032	3641728
case_061	34560	43008	62208	382558
case_062	13393920	13393920	897024	897024
case_063	337920	337920	337920	337920
case_064	65662	65662	131982	131982
case_065	13968	27936	41760	55728
case_066	1953158	2890070	2890070	2890070
case_067	272726272	298754304	282468608	298754304
case_068	2598030	2598030	2598030	2598030
case_069	532364	532364	532364	532364
case_070	129536	259072	360960	462848
case_071	375274	375274	375274	375274
case_072	99330848	177263132	177263132	177263132
case_073	98703232	100065536	144435968	102790144
case_074	5910536	7626752	7790592	8392712
case_075	8130090	8130090	8130090	8130090
case_076	33976320	33654784	33742848	35696640
case_077	57344	114688	172032	172032
case_078	15039360	15825792	15039360	15825792
case_079	47714304	43948032	44257280	45352960
case_080	2191360	3047424	3047424	3047424
case_081	0	0	0	0
case_082	4435418	8998170	9580494	10097280
case_083	13151840	14082240	15012640	15943040
case_084	30190464	30190464	0	0
case_085	40692846	43297606	42980512	46542906
case_086	2656640	2656640	3103172	3103172
case_087	35193224	35193224	35193224	35193224
case_088	1860972	1860972	1860972	1860972
case_089	238720	477440	716160	954880
case_090	4145280	6293760	8442240	8442240
case_091	56506336	55158080	59109376	61130752
case_092	56912480	57842880	58773280	59703680
case_093	8192	16384	24576	32768
case_094	106272	212544	318816	259200
case_095	0	0	0	0
case_096	66240	67392	719180	661824

用例	2核	3核	4核	5核
case_097	14483456	29818880	14221312	21311488
case_098	0	1602190	1602190	2065850
case_099	7319552	8798208	9764864	9703424
case_100	763960	534528	534528	1877578

A.2 问题二：场景 B

表 A-3 问题二逐例 Makespan

用例	1核	2核	3核	4核	5核
case_001	233110	116868	78545	58984	47502
case_002	261945	137089	94149	73120	59575
case_003	548159	315516	257302	234056	232588
case_004	392357	199074	134043	104188	88341
case_005	83323	60883	52655	52655	52655
case_006	76373	39367	29782	26251	24618
case_007	1012562	507494	338094	254398	203834
case_008	487605	244266	163359	123060	100603
case_009	147061	84436	63747	55563	52311
case_010	86057	42846	30856	26147	26147
case_011	184697	92646	69625	46880	46880
case_012	51532	29730	18114	14886	12712
case_013	263949	132198	88351	66982	54363
case_014	17698626	8864262	5924867	4428315	3605387
case_015	158311	89331	58906	51503	39837
case_016	7715523	4026549	2876720	2238959	2087323
case_017	155189	86334	52489	42924	30495
case_018	1004367	498719	334784	255853	202778
case_019	74026	40392	28195	21744	18640
case_020	532746	266580	177950	133704	107650
case_021	6567937	3194570	2106848	1550324	1250168
case_022	56750	28851	19370	14574	11813
case_023	109495	58216	41720	30522	24793
case_024	2555343	1334769	953408	743027	694207
case_025	4863026	2431840	1622164	1217444	975282
case_026	90235	53208	41132	35520	33518
case_027	2363952	1118352	765280	559196	558753
case_028	41576363	20615674	13848390	10250099	8211965
case_029	37555	19740	12743	11028	9383
case_030	2808034	1403594	933857	700342	561102
case_031	1412792	732205	483567	394466	306307
case_032	34524	17554	11808	11164	10415
case_033	1774196	896676	602408	457602	369453
case_034	825894	440418	280681	252538	173032
case_035	162870	95406	71961	56936	58349
case_036	931510	466068	311345	233584	187182
case_037	210001	105374	74038	53320	43800
case_038	1364555	681518	459530	344898	283188
case_039	1435262	708561	483806	381106	381106
case_040	236131	140145	105923	95952	89745
case_041	6003957	2992480	1991992	1490603	1196379
case_042	1686740	840916	571947	435949	369780
case_043	644058	350868	267919	240597	240597
case_044	78274	45248	45248	45248	45248
case_045	125614	63059	42601	31878	26164
case_046	216726	109740	82826	79918	79918
case_047	291280	166394	136827	125959	119372
case_048	198369	125568	99835	97813	98572
case_049	181681	106107	84225	70510	64305
case_050	142450	78327	67318	59891	58897
case_051	607628	318674	227452	178386	168374
case_052	175278	86843	62309	45500	41994
case_053	1341846	728229	497437	425404	375096
case_054	815051	438618	316491	262542	240647
case_055	106616	56582	40063	31823	26183
case_056	258692	147688	117225	104605	97116
case_057	59056	30025	23294	20957	16538
case_058	4539717	2261085	1554831	1141608	1004819
case_059	738041	369318	254073	185216	150782
case_060	882690	474073	323843	240113	185331
case_061	77191	39298	28342	26678	22283
case_062	2854809	1572635	1083992	838854	703542
case_063	1070397	575202	396695	313176	255854

用例	1核	2核	3核	4核	5核
case_064	17184	13417	14105	10614	8333
case_065	44156	22021	16963	11769	9558
case_066	318124	190462	139098	123721	119141
case_067	63834834	31418001	21034535	16152614	13054159
case_068	328200	200719	167916	147382	141879
case_069	21597	16133	14920	14483	13698
case_070	110849	58234	43439	34658	25840
case_071	15824	12826	10782	10331	10442
case_072	23897828	11836023	7961454	5911772	4831103
case_073	9839163	5587533	4300595	2507770	2034983
case_074	1651943	803673	537857	406099	330183
case_075	1334897	728185	526421	425508	374967
case_076	6185113	3065214	2050028	1540201	1240011
case_077	495320	250735	178739	144734	121081
case_078	2095621	1051374	720770	568228	481517
case_079	31052251	15446486	10140755	7635624	6045667
case_080	292138	145926	100325	100325	100325
case_081	151795	76860	51943	39588	30943
case_082	718790	387499	263881	217255	195543
case_083	851601	433315	298003	219344	191867
case_084	2191327	1168951	836220	629028	503472
case_085	3187899	1810774	1228758	938020	822333
case_086	105557	67521	60328	55557	55557
case_087	3974071	1987606	1371815	1069325	885221
case_088	219593	134265	117498	98539	98539
case_089	659152	329430	229298	165616	133338
case_090	882630	454440	337795	295164	274650
case_091	9186769	4571759	3053553	2290698	1848187
case_092	4373417	2162750	1418789	1033609	814597
case_093	74205	37827	25103	19779	15876
case_094	84874	48430	35024	27182	20297
case_095	2084853	1042890	695775	524422	420852
case_096	75393	41837	30611	26984	25183
case_097	11491509	5617602	3660459	2626908	2102348
case_098	176171	89551	65715	52186	50844
case_099	1622999	811243	544403	405655	324321
case_100	141463	74200	54371	50324	47130

表 A-4 问题二逐例总额外数据搬运量 (bytes)

用例	1核	2核	3核	4核	5核
case_001	0	1152	2304	3456	4608
case_002	0	562176	746496	841728	872448
case_003	24576	6408454	9518568	7733990	9723996
case_004	0	110592	221184	331776	442368
case_005	0	2190534	1728714	1728714	1728714
case_006	166044	614532	841742	913168	411656
case_007	0	27648	55296	82944	110592
case_008	0	0	0	0	0
case_009	327048	1236498	1616024	1890898	2008978
case_010	63892	471500	48384	778932	778932
case_011	0	180224	1081344	540672	540672
case_012	0	461572	20160	21888	31104
case_013	0	8192	16384	24576	32768
case_014	71010720	62154168	46130856	48577944	53128200
case_015	873464	1786394	208128	231168	317952
case_016	0	404192	12200	15864	214900
case_017	0	394974	175104	260352	343296
case_018	1970176	1377280	12853772	3755776	5054464
case_019	315392	814128	24576	359504	327032
case_020	0	0	0	0	0
case_021	4501504	3174400	4710400	4608000	11431936
case_022	0	6912	13824	13824	6912
case_023	1100056	1523296	196896	207552	197472
case_024	0	396848	4040	5256	202660
case_025	0	27648	55296	82944	110592
case_026	0	1301728	1491816	724704	491168
case_027	1400832	1449984	33890304	3317760	5529600
case_028	62779392	82416768	34820352	31777152	30147072
case_029	0	0	0	0	0
case_030	5519360	7644160	9242624	10404864	11479040
case_031	2251776	2139648	3462144	4922880	8059392
case_032	0	6216	12360	12360	12360
case_033	4592640	3391008	4180032	5251680	6509184

用例	1核	2核	3核	4核	5核
case_034	0	1459712	2341888	2979328	3532800
case_035	0	0	1735510	1675904	1602218
case_036	0	1152	2304	3456	4608
case_037	0	204800	1064960	614400	1925120
case_038	5627904	6790656	5534208	6950400	8558592
case_039	7929856	11067392	12414976	13320192	13320192
case_040	0	2475470	3308532	2473682	2634900
case_041	30898176	33490944	34879488	39164928	40630272
case_042	6629376	7262496	8251680	7059744	8045568
case_043	2867036	9505206	7959640	9832918	9832918
case_044	0	930400	930400	930400	930400
case_045	0	0	0	0	0
case_046	0	930400	1860800	2791200	2791200
case_047	0	3012550	4387628	5012946	3409368
case_048	0	391302	1016076	1114512	1132628
case_049	27658	2803330	3516344	1739398	2125062
case_050	702996	1958198	1393486	1620642	1885008
case_051	0	393884	960	1252	198040
case_052	0	102912	181248	259584	333312
case_053	855054	5317152	7442990	11152366	12135050
case_054	0	8276074	6482640	7592222	8940968
case_055	282696	852212	115712	115712	198656
case_056	25618	3622398	1870000	3214102	3574548
case_057	0	416890	549116	288	27936
case_058	28696576	30621696	30400512	32284672	32104448
case_059	0	360448	2162688	1081344	4325376
case_060	1439748	1255552	3290252	3131648	3641728
case_061	0	34560	43008	62208	83712
case_062	0	10856448	10865664	10054656	10626048
case_063	0	3323904	3133440	3538944	3253248
case_064	0	95590	126220	152784	132948
case_065	0	13968	27936	41760	55728
case_066	75272	3937564	3077354	3938934	4419676
case_067	264449408	182202752	187518720	154190976	158705152
case_068	531976	3519186	3536102	4076226	4184738
case_069	0	233732	489770	503470	465362
case_070	0	129536	1523108	360960	462848
case_071	0	208452	235082	329486	317010
case_072	108613680	113724192	82414368	85994272	84918960
case_073	90447872	91806080	93164288	44120192	37201408
case_074	5255176	3747840	4923392	6230016	7118848
case_075	0	7124774	12146060	12171570	12788022
case_076	28280832	31095808	34332672	37442560	40553472
case_077	0	57344	114688	172032	172032
case_078	24576	2148480	8054016	6445440	12822528
case_079	32448512	31780864	33890304	30445568	31907840
case_080	548864	2191360	3047424	3047424	3047424
case_081	0	0	0	0	0
case_082	597130	3234278	2788460	6970608	5194934
case_083	262144	930400	1860800	2791200	3721600
case_084	29453952	28717440	0	0	0
case_085	0	9335690	29372396	29385842	22587672
case_086	155146	1185860	1851498	2269390	2269390
case_087	7902720	10142208	5465088	7133184	8050176
case_088	544128	2582030	2337262	2683862	2683862
case_089	0	238720	477440	716160	954880
case_090	0	2341200	4490496	6514560	8606208
case_091	53947008	57904096	33286976	35909280	39725056
case_092	29294592	16642656	10675392	6788896	4606336
case_093	0	8192	16384	24576	32768
case_094	458752	106272	737860	318816	259200
case_095	0	0	0	0	0
case_096	107552	719692	67392	78336	623148
case_097	10584064	11796480	16031744	14221312	21311488
case_098	852332	0	852966	1249322	1517236
case_099	5484544	7319552	8798208	9764864	7065600
case_100	0	1161942	1640268	1961860	1112288

A.3 问题三：无 L2 与只读 Cache 两种配置

“无 L2”为场景 B 下选出的方案 P_B ；“只读 Cache”为 L2 配置下独立选优的方案 P_L ；
“同方案开 L2”为把 P_B 原样放到 L2 配置下评价的结果，用于计算同方案配置比。

表 A-5 问题三逐例结果 (1 核)

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_001	233110	0	233110	0	0.0000	233110	0.0000
case_002	261945	0	261945	0	0.0000	261945	0.0000
case_003	548159	24576	548159	24576	0.0000	548159	0.0000
case_004	392357	0	392357	0	0.0000	392357	0.0000
case_005	83323	0	83323	0	0.0000	83323	0.0000
case_006	76373	166044	76373	166044	6.4862	76373	6.4862
case_007	1012562	0	1012562	0	0.0000	1012562	0.0000
case_008	487605	0	487605	0	0.0000	487605	0.0000
case_009	147061	327048	146683	327048	7.4819	146683	7.4819
case_010	86057	63892	86057	63892	0.0000	86057	0.0000
case_011	184697	0	184697	0	0.0000	184697	0.0000
case_012	51532	0	51532	0	0.0000	51532	0.0000
case_013	263949	0	263949	0	0.0000	263949	0.0000
case_014	17698626	71010720	17689602	71010720	12.2910	17689602	12.2910
case_015	158311	873464	156783	873464	15.4479	156783	15.4479
case_016	7715523	0	7715523	0	0.0000	7715523	0.0000
case_017	155189	0	155189	0	0.0000	155189	0.0000
case_018	1004367	1970176	1003110	1970176	34.3750	1003110	34.3750
case_019	74026	315392	74026	315392	4.7471	74026	4.7471
case_020	532746	0	532746	0	0.0000	532746	0.0000
case_021	6567937	4501504	6558837	4501504	50.0597	6558837	50.0597
case_022	56750	0	56750	0	0.0000	56750	0.0000
case_023	109495	1100056	109032	1100056	19.1895	109032	19.1895
case_024	2555343	0	2555343	0	0.0000	2555343	0.0000
case_025	4863026	0	4863026	0	0.0000	4863026	0.0000
case_026	90235	0	90235	0	0.0000	90235	0.0000
case_027	2363952	1400832	2359515	1400832	26.8939	2359515	26.8939
case_028	41576363	62779392	41555374	62779392	3.3815	41555374	3.3815
case_029	37555	0	37555	0	0.0000	37555	0.0000
case_030	2808034	5519360	2807891	5519360	25.9868	2807891	25.9868
case_031	1412792	2251776	1412441	2251776	36.2137	1412441	36.2137
case_032	34524	0	34524	0	0.0000	34524	0.0000
case_033	1774196	4592640	1774080	4592640	9.6277	1774080	9.6277
case_034	825894	0	825894	0	0.0000	825894	0.0000
case_035	162870	0	162870	0	0.0000	162870	0.0000
case_036	931510	0	931510	0	0.0000	931510	0.0000
case_037	210001	0	210001	0	0.0000	210001	0.0000
case_038	1364555	5627904	1363312	5627904	17.3617	1363312	17.3617
case_039	1435262	7929856	1435262	7929856	0.0000	1435262	0.0000
case_040	236131	0	236131	0	0.0000	236131	0.0000
case_041	6003957	30898176	6001575	30898176	10.1637	6001575	10.1637
case_042	1686740	6629376	1675633	6629376	31.8692	1675633	31.8692
case_043	644058	2867036	642964	2867036	2.2848	642964	2.2848
case_044	78274	0	78274	0	0.0000	78274	0.0000
case_045	125614	0	125614	0	0.0000	125614	0.0000
case_046	216726	0	216726	0	0.0000	216726	0.0000
case_047	291280	0	291280	0	0.0000	291280	0.0000
case_048	198369	0	198369	0	0.0000	198369	0.0000
case_049	181681	27658	181681	27658	0.0060	181681	0.0060
case_050	142450	702996	141691	372270	12.8892	141872	10.4185
case_051	607628	0	607628	0	0.0000	607628	0.0000
case_052	175278	0	175278	0	0.0000	175278	0.0000
case_053	1341846	855054	1341846	855054	0.0003	1341846	0.0003
case_054	815051	0	815051	0	0.0000	815051	0.0000
case_055	106616	282696	105512	282696	11.0962	105512	11.0962
case_056	258692	25618	258692	25618	0.0077	258692	0.0077
case_057	59056	0	59056	0	0.0000	59056	0.0000
case_058	4539717	28696576	4539717	28696576	0.0000	4539717	0.0000
case_059	738041	0	738041	0	0.0000	738041	0.0000
case_060	882690	1439748	882534	1439748	31.1384	882534	31.1384
case_061	77191	0	77191	0	0.0000	77191	0.0000
case_062	2854809	0	2854809	0	0.0000	2854809	0.0000
case_063	1070397	0	1070397	0	0.0000	1070397	0.0000
case_064	17184	0	17184	0	0.0000	17184	0.0000
case_065	44156	0	44156	0	0.0000	44156	0.0000
case_066	318124	75272	318124	75272	0.0008	318124	0.0008
case_067	63834834	264449408	61875727	197050368	88.5588	63834834	0.0000
case_068	328200	531976	327848	531976	3.5140	327848	3.5140
case_069	21597	0	21597	0	0.0000	21597	0.0000
case_070	110849	0	110849	0	0.0000	110849	0.0000
case_071	15824	0	15824	0	0.0000	15824	0.0000

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_072	23897828	108613680	23890756	108613680	2.6210	23890756	2.6210
case_073	9839163	90447872	8702659	90447872	95.4660	8702659	95.4660
case_074	1651943	5255176	1647335	5255176	23.4920	1647335	23.4920
case_075	1334897	0	1334897	0	0.0000	1334897	0.0000
case_076	6185113	28280832	6183098	28280832	13.3577	6183098	13.3577
case_077	495320	0	495320	0	0.0000	495320	0.0000
case_078	2095621	24576	2095621	24576	0.0000	2095621	0.0000
case_079	31052251	32448512	31052251	32448512	0.0000	31052251	0.0000
case_080	292138	548864	291826	548864	16.8614	291826	16.8614
case_081	151795	0	151795	0	0.0000	151795	0.0000
case_082	718790	597130	717869	597130	8.7058	717869	8.7058
case_083	851601	262144	851601	262144	0.0000	851601	0.0000
case_084	2191327	29453952	2191327	29453952	0.0000	2191327	0.0000
case_085	3187899	0	3187899	0	0.0000	3187899	0.0000
case_086	105557	155146	105557	155146	0.0025	105557	0.0025
case_087	3974071	7902720	3969779	7902720	18.3368	3969779	18.3368
case_088	219593	544128	219539	544128	1.2106	219539	1.2106
case_089	659152	0	659152	0	0.0000	659152	0.0000
case_090	882630	0	882630	0	0.0000	882630	0.0000
case_091	9186769	53947008	9168820	53947008	10.5386	9168820	10.5386
case_092	4373417	29294592	4333631	66000096	79.3550	4358155	5.6952
case_093	74205	0	74205	0	0.0000	74205	0.0000
case_094	84874	458752	84874	458752	3.4469	84874	3.4469
case_095	2084853	0	2084853	0	0.0000	2084853	0.0000
case_096	75393	107552	75393	107552	1.5394	75393	1.5394
case_097	11491509	10584064	11491509	10584064	0.0000	11491509	0.0000
case_098	176171	852332	175431	852332	12.3105	175431	12.3105
case_099	1622999	5484544	1618902	5484544	25.2355	1618902	25.2355
case_100	141463	0	141463	0	0.0000	141463	0.0000

表 A-6 问题三逐例结果（2 核）

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_001	116868	1152	116868	1152	0.0000	116868	0.0000
case_002	137089	562176	137089	562176	0.0000	137089	0.0000
case_003	315516	6408454	314363	6408454	6.1616	314363	6.1616
case_004	199074	110592	199074	110592	0.0000	199074	0.0000
case_005	60883	2190534	60375	2190534	10.3340	60375	10.3340
case_006	39367	614532	39326	614532	26.9994	39326	26.9994
case_007	507494	27648	507494	27648	0.0000	507494	0.0000
case_008	244266	0	244266	0	0.0000	244266	0.0000
case_009	84436	1236498	84423	1236498	18.1690	84423	18.1690
case_010	42846	471500	42721	471500	29.6773	42721	29.6773
case_011	92646	180224	92646	180224	0.0000	92646	0.0000
case_012	29730	461572	29689	461572	11.9454	29689	11.9454
case_013	132198	8192	132198	8192	0.0000	132198	0.0000
case_014	8864262	62154168	8857863	51088824	23.1463	8865476	23.8602
case_015	89331	1786394	87960	1786394	28.6870	87960	28.6870
case_016	4026549	404192	4025717	404192	49.6535	4025717	49.6535
case_017	86334	394974	86028	394974	26.6336	86028	26.6336
case_018	498719	1377280	498614	1377280	43.0650	498614	43.0650
case_019	40392	814128	40392	814128	8.4923	40392	8.4923
case_020	266580	0	266580	0	0.0000	266580	0.0000
case_021	3194570	3174400	3193634	3174400	21.7778	3193634	21.7778
case_022	28851	6912	28851	6912	3.1354	28851	3.1354
case_023	58216	1523296	57260	1523296	21.0907	57260	21.0907
case_024	1334769	396848	1333937	396848	49.8848	1333937	49.8848
case_025	2431840	27648	2431840	27648	0.0000	2431840	0.0000
case_026	53208	1301728	51165	1301728	26.7505	51165	26.7505
case_027	1118352	1449984	1118352	1449984	0.0000	1118352	0.0000
case_028	20615674	82416768	20601621	82416768	3.5459	20601621	3.5459
case_029	19740	0	19740	0	0.0000	19740	0.0000
case_030	1403594	7644160	1403449	7644160	46.3375	1403449	46.3375
case_031	732205	2139648	732205	2139648	42.6581	732205	42.6581
case_032	17554	6216	17554	6216	2.1782	17554	2.1782
case_033	896676	3391008	896372	3391008	35.7219	896372	35.7219
case_034	440418	1459712	440340	1459712	36.0757	440340	36.0757
case_035	95406	0	95319	1195418	20.6213	95406	0.0000
case_036	466068	1152	466068	1152	0.0000	466068	0.0000
case_037	105374	204800	105374	204800	0.0000	105374	0.0000
case_038	681518	6790656	681309	6790656	27.1460	681309	27.1460
case_039	708561	11067392	705615	11067392	37.0172	705615	37.0172

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_040	140145	2475470	139995	2475470	15.9642	139995	15.9642
case_041	2992480	33490944	2987139	33490944	22.3048	2987139	22.3048
case_042	840916	7262496	840258	7262496	41.2962	840258	41.2962
case_043	350868	9505206	348941	9505206	12.5953	348941	12.5953
case_044	45248	930400	45244	930400	0.3432	45244	0.3432
case_045	63059	0	63059	0	0.0000	63059	0.0000
case_046	109740	930400	109740	930400	0.0000	109740	0.0000
case_047	166394	3012550	166346	3012550	7.2543	166346	7.2543
case_048	125568	391302	125568	391302	19.9076	125568	19.9076
case_049	106107	2803330	106108	2803330	1.8294	106108	1.8294
case_050	78327	1958198	76865	1958198	16.9776	76865	16.9776
case_051	318674	393884	317922	394076	49.9727	318334	49.9788
case_052	86843	102912	86703	102912	8.5805	86703	8.5805
case_053	728229	5317152	728352	5317152	11.6049	728352	11.6049
case_054	438618	8276074	438266	8276074	2.2547	438266	2.2547
case_055	56582	852212	55755	852212	20.7220	55755	20.7220
case_056	147688	3622398	147676	3622398	4.5028	147676	4.5028
case_057	30025	416890	29987	416890	35.7464	29987	35.7464
case_058	2261085	30621696	2260689	30621696	8.8310	2260689	8.8310
case_059	369318	360448	369318	360448	0.0000	369318	0.0000
case_060	474073	1255552	472697	1255552	29.8871	472697	29.8871
case_061	39298	34560	39272	34560	5.9731	39272	5.9731
case_062	1572635	10856448	1572635	10856448	0.0000	1572635	0.0000
case_063	575202	3323904	575202	3323904	0.0000	575202	0.0000
case_064	13417	95590	13417	95590	9.6806	13417	9.6806
case_065	22021	13968	22021	13968	4.4528	22021	4.4528
case_066	190462	3937564	189749	3937564	7.5765	189749	7.5765
case_067	31418001	182202752	30483124	148560256	79.4855	30544074	83.7261
case_068	200719	3519186	198360	3519186	10.4518	198360	10.4518
case_069	16133	233732	16094	233732	20.4230	16094	20.4230
case_070	58234	129536	58234	129536	19.1047	58234	19.1047
case_071	12826	208452	12813	208452	28.4446	12813	28.4446
case_072	11836023	113724192	11826643	113724192	12.4176	11826643	12.4176
case_073	5587533	91806080	4270350	36216704	78.7759	4539269	80.9675
case_074	803673	3747840	803065	3747840	25.8573	803065	25.8573
case_075	728185	7124774	727824	7124774	6.7648	727824	6.7648
case_076	3065214	31095808	3063843	31095808	27.8782	3063843	27.8782
case_077	250735	57344	250735	57344	2.6082	250735	2.6082
case_078	1051374	2148480	1051374	2148480	0.0000	1051374	0.0000
case_079	15446486	31780864	15446486	31780864	0.0000	15446486	0.0000
case_080	145926	2191360	145674	2191360	43.6000	145674	43.6000
case_081	76860	0	76860	0	0.0000	76860	0.0000
case_082	387499	3234278	387499	3234278	4.7322	387499	4.7322
case_083	433315	930400	433240	930400	43.9821	433240	43.9821
case_084	1168951	28717440	1168951	28717440	0.0000	1168951	0.0000
case_085	1810774	9335690	1810773	9335690	5.0074	1810773	5.0074
case_086	67521	1185860	67520	1185860	11.4674	67520	11.4674
case_087	1987606	10142208	1984150	10142208	29.5515	1984150	29.5515
case_088	134265	2582030	133573	2582030	10.9573	133573	10.9573
case_089	329430	238720	329430	238720	0.0000	329430	0.0000
case_090	454440	2341200	456431	2341200	36.2899	456431	36.2899
case_091	4571759	57904096	4569395	57904096	17.9865	4569395	17.9865
case_092	2162750	16642656	2161490	16642656	0.8739	2161490	0.8739
case_093	37827	8192	37827	8192	0.0000	37827	0.0000
case_094	48430	106272	48430	106272	18.3989	48430	18.3989
case_095	1042890	0	1042890	0	0.0000	1042890	0.0000
case_096	41837	719692	40991	719692	17.5851	40991	17.5851
case_097	5617602	11796480	5617602	11796480	0.0000	5617602	0.0000
case_098	89551	0	89551	0	0.0000	89551	0.0000
case_099	811243	7319552	807032	7319552	44.1892	807032	44.1892
case_100	74200	1161942	73335	1161942	30.0567	73335	30.0567

表 A-7 问题三逐例结果 (3 核)

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_001	78545	2304	78545	2304	0.0000	78545	0.0000
case_002	94149	746496	94149	746496	0.0000	94149	0.0000
case_003	257302	9518568	247555	9518568	23.5742	247555	23.5742
case_004	134043	221184	134043	221184	0.0000	134043	0.0000
case_005	52655	1728714	52396	1733514	18.7198	52401	18.7537
case_006	29782	841742	27859	841742	37.2060	27859	37.2060
case_007	338094	55296	338094	55296	0.0000	338094	0.0000

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_008	163359	0	163359	0	0.0000	163359	0.0000
case_009	63747	1616024	62869	1616024	27.0609	62869	27.0609
case_010	30856	48384	30856	48384	11.1880	30856	11.1880
case_011	69625	1081344	69625	1081344	46.9697	69625	46.9697
case_012	18114	20160	18114	20160	3.9980	18114	3.9980
case_013	88351	16384	88351	16384	0.0000	88351	0.0000
case_014	5924867	46130856	5896850	57474216	22.4236	5914855	17.5900
case_015	58906	208128	58906	208128	19.0487	58906	19.0487
case_016	2876720	12200	2876720	12200	0.1523	2876720	0.1523
case_017	52489	175104	52439	175104	24.6548	52439	24.6548
case_018	334784	12853772	334589	12853772	26.5243	334589	26.5243
case_019	28195	24576	28195	24576	12.0572	28195	12.0572
case_020	177950	0	177950	0	0.0000	177950	0.0000
case_021	2106848	4710400	2106355	4710400	45.2174	2106355	45.2174
case_022	19370	13824	19370	13824	6.0801	19370	6.0801
case_023	41720	196896	41357	1160938	26.4747	41720	31.2029
case_024	953408	4040	953408	4040	0.0506	953408	0.0506
case_025	1622164	55296	1622164	55296	0.0000	1622164	0.0000
case_026	41132	1491816	37376	1491816	26.6300	37376	26.6300
case_027	765280	33890304	765280	33890304	15.6045	765280	15.6045
case_028	13848390	34820352	13848390	34820352	0.0000	13848390	0.0000
case_029	12743	0	12743	0	0.0000	12743	0.0000
case_030	933857	9242624	933236	9242624	54.6511	933236	54.6511
case_031	483567	3462144	483567	3462144	50.2392	483567	50.2392
case_032	11808	12360	11808	12360	4.2399	11808	4.2399
case_033	602408	4180032	602363	4180032	28.3169	602363	28.3169
case_034	280681	2341888	280601	2341888	44.5326	280601	44.5326
case_035	71961	1735510	71125	1735510	29.9945	71125	29.9945
case_036	311345	2304	311345	2304	0.0000	311345	0.0000
case_037	74038	1064960	74038	1064960	61.5385	74038	61.5385
case_038	459530	5534208	459314	5534208	44.5933	459314	44.5933
case_039	483806	12414976	482552	12414976	31.8462	482552	31.8462
case_040	105923	3308532	103722	3308532	26.3744	103722	26.3744
case_041	1991992	34879488	1991302	34879488	25.6151	1991302	25.6151
case_042	571947	8251680	569347	29111164	19.7565	571429	48.0684
case_043	267919	7959640	265912	8238192	29.1496	266191	29.0864
case_044	45248	930400	45244	930400	0.3432	45244	0.3432
case_045	42601	0	42601	0	0.0000	42601	0.0000
case_046	82826	1860800	82826	1860800	63.8267	82826	63.8267
case_047	136827	4387628	134415	4387628	23.6383	134415	23.6383
case_048	99835	1016076	99785	1016076	13.7738	99785	13.7738
case_049	84225	3516344	80938	3516344	18.6046	80938	18.6046
case_050	67318	1393486	64455	2735846	22.8307	67069	17.5362
case_051	227452	960	227452	960	0.0117	227452	0.0117
case_052	62309	181248	61902	181248	15.8048	61902	15.8048
case_053	497437	7442990	489248	7442990	19.8318	489248	19.8318
case_054	316491	6482640	316308	6482640	13.1293	316308	13.1293
case_055	40063	115712	40063	115712	13.3973	40063	13.3973
case_056	117225	1870000	116861	1870000	14.4754	116861	14.4754
case_057	23294	549116	20872	549116	42.2528	20872	42.2528
case_058	1554831	30400512	1554831	30400512	0.0000	1554831	0.0000
case_059	254073	2162688	254073	2162688	55.1768	254073	55.1768
case_060	323843	3290252	323606	3290252	46.8773	323606	46.8773
case_061	28342	43008	28316	43008	7.3262	28316	7.3262
case_062	1083992	10865664	1083992	10865664	0.0000	1083992	0.0000
case_063	396695	3133440	396695	3133440	0.0000	396695	0.0000
case_064	14105	126220	14097	126220	20.0517	14097	20.0517
case_065	16963	27936	16963	27936	8.5260	16963	8.5260
case_066	139098	3077354	137156	3077354	22.5103	137156	22.5103
case_067	21034535	187518720	20274197	150320896	78.4083	20361960	83.5511
case_068	167916	3536102	160947	5172720	18.4923	165344	25.6883
case_069	14920	489770	14474	489770	23.2645	14474	23.2645
case_070	43439	1523108	41101	1523108	29.0399	41101	29.0399
case_071	10782	235082	10460	235082	33.5518	10460	33.5518
case_072	7961454	82414368	7944880	82414368	14.6043	7944880	14.6043
case_073	4300595	93164288	3223907	93164288	87.8960	3223907	87.8960
case_074	537857	4923392	537389	4923392	32.2975	537389	32.2975
case_075	526421	12146060	524721	12146060	23.0935	524721	23.0935
case_076	2050028	34332672	2047868	34332672	33.6950	2047868	33.6950
case_077	178739	114688	178739	114688	2.5419	178739	2.5419
case_078	720770	8054016	709786	8054016	38.2845	709786	38.2845
case_079	10140755	33890304	10140199	33890304	15.4802	10140199	15.4802
case_080	100325	3047424	100325	3047424	0.0000	100325	0.0000

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_081	51943	0	51943	0	0.0000	51943	0.0000
case_082	263881	2788460	263832	2788460	17.3891	263832	17.3891
case_083	298003	1860800	298003	1860800	30.5440	298003	30.5440
case_084	836220	0	836220	0	0.0000	836220	0.0000
case_085	1228758	29372396	1224333	29372396	17.1512	1224333	17.1512
case_086	60328	1851498	59919	1851498	18.1600	59919	18.1600
case_087	1371815	5465088	1371815	5465088	22.0609	1371815	22.0609
case_088	117498	2337262	112104	4023768	19.8669	114232	27.2380
case_089	229298	477440	229298	477440	27.1191	229298	27.1191
case_090	337795	4490496	312336	4409088	60.3885	324619	54.4626
case_091	3053553	33286976	3070819	64602944	24.4627	3044780	28.4675
case_092	1418789	10675392	1421140	10675392	11.1234	1421140	11.1234
case_093	25103	16384	25103	16384	0.0000	25103	0.0000
case_094	35024	737860	35039	737860	13.0478	35039	13.0478
case_095	695775	0	695775	0	0.0000	695775	0.0000
case_096	30611	67392	30252	934048	26.4862	30611	24.2721
case_097	3660459	16031744	3660338	16031744	21.9721	3660338	21.9721
case_098	65715	852966	64144	1619618	31.0486	64713	31.6733
case_099	544403	8798208	540586	8798208	51.0381	540586	51.0381
case_100	54371	1640268	51556	1640268	36.4561	51556	36.4561

表 A-8 问题三逐例结果（4 核）

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_001	58984	3456	58984	3456	0.0000	58984	0.0000
case_002	73120	841728	73120	841728	0.0000	73120	0.0000
case_003	234056	7733990	229275	7733990	24.0408	229275	24.0408
case_004	104188	331776	104188	331776	0.0000	104188	0.0000
case_005	52655	1728714	50800	2224782	27.8088	52401	18.7537
case_006	26251	913168	24645	913168	33.7919	24645	33.7919
case_007	254398	82944	254398	82944	0.0000	254398	0.0000
case_008	123060	0	123060	0	0.0000	123060	0.0000
case_009	55563	1890898	52843	1890898	30.6073	52843	30.6073
case_010	26147	778932	24135	774836	38.1265	25518	38.0459
case_011	46880	540672	46808	704512	10.5357	46880	0.0000
case_012	14886	21888	14884	21888	4.3258	14884	4.3258
case_013	66982	24576	66982	24576	0.0000	66982	0.0000
case_014	4428315	48577944	4426698	48577944	30.3476	4426698	30.3476
case_015	51503	231168	51503	231168	17.7834	51503	17.7834
case_016	2238959	15864	2238959	15864	0.3031	2238959	0.3031
case_017	42924	260352	42924	260352	32.4397	42924	32.4397
case_018	255853	3755776	255632	3755776	52.6970	255632	52.6970
case_019	21744	359504	21598	359504	23.3655	21598	23.3655
case_020	133704	0	133704	0	0.0000	133704	0.0000
case_021	1550324	4608000	1550324	4608000	0.0000	1550324	0.0000
case_022	14574	13824	14574	13824	6.0801	14574	6.0801
case_023	30522	207552	30522	207552	9.3655	30522	9.3655
case_024	743027	5256	743027	5256	0.1010	743027	0.1010
case_025	1217444	82944	1217444	82944	0.0000	1217444	0.0000
case_026	35520	724704	34962	724704	30.2014	34962	30.2014
case_027	559196	3317760	559196	3317760	0.0000	559196	0.0000
case_028	10250099	31777152	10250076	31777152	26.0089	10250076	26.0089
case_029	11028	0	11028	0	0.0000	11028	0.0000
case_030	700342	10404864	700156	10404864	59.6575	700156	59.6575
case_031	394466	4922880	394388	4922880	40.4330	394388	40.4330
case_032	11164	12360	10764	12360	2.8348	10764	2.8348
case_033	457602	5251680	457038	5251680	32.3248	457038	32.3248
case_034	252538	2979328	252450	2979328	42.7956	252450	42.7956
case_035	56936	1675904	54927	1675904	36.8000	54927	36.8000
case_036	233584	3456	233584	3456	0.0000	233584	0.0000
case_037	53320	614400	53320	614400	0.0000	53320	0.0000
case_038	344898	6950400	344678	9295872	35.6060	344898	45.9622
case_039	381106	13320192	368055	17604608	47.8212	380496	22.6741
case_040	95952	2473682	90709	3717274	29.5439	94060	26.1551
case_041	1490603	39164928	1487676	39164928	34.3802	1487676	34.3802
case_042	435949	7059744	435882	7059744	38.1425	435882	38.1425
case_043	240597	9832918	227159	10019550	32.7617	227480	32.0638
case_044	45248	930400	45244	930400	0.3432	45244	0.3432
case_045	31878	0	31878	0	0.0000	31878	0.0000
case_046	79918	2791200	79918	2791200	0.0000	79918	0.0000
case_047	125959	5012946	118989	5012946	27.0725	118989	27.0725
case_048	97813	1114512	97321	1114512	19.2820	97321	19.2820

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_049	70510	1739398	70332	1743366	21.3067	70450	21.2015
case_050	59891	1620642	58829	1628226	21.1599	58841	21.4086
case_051	178386	1252	178386	1252	0.0234	178386	0.0234
case_052	45500	259584	45216	259584	14.6473	45216	14.6473
case_053	425404	11152366	415932	11152366	23.6495	415932	23.6495
case_054	262542	7592222	262300	7592222	12.5505	262300	12.5505
case_055	31823	115712	31823	115712	11.8780	31823	11.8780
case_056	104605	3214102	103277	3214102	20.3623	103277	20.3623
case_057	20957	288	18687	797094	45.8641	20957	0.0855
case_058	1141608	32284672	1136056	37580800	25.1019	1139266	18.0229
case_059	185216	1081344	185144	1802240	33.2237	185216	0.0000
case_060	240113	3131648	239861	3131648	38.3556	239861	38.3556
case_061	26678	62208	26678	62208	10.2612	26678	10.2612
case_062	838854	10054656	838854	10054656	0.0000	838854	0.0000
case_063	313176	3538944	313176	3538944	0.0000	313176	0.0000
case_064	10614	152784	10532	152784	32.1324	10532	32.1324
case_065	11769	41760	11769	41760	12.2291	11769	12.2291
case_066	123721	3938934	120237	3943030	26.6901	120393	27.1509
case_067	16152614	154190976	15291889	154190976	78.6283	15291889	78.6283
case_068	147382	4076226	138618	4065986	20.7584	138634	19.8884
case_069	14483	503470	12569	503470	33.1777	12569	33.1777
case_070	34658	360960	34658	360960	11.3440	34658	11.3440
case_071	10331	329486	9203	329390	31.0190	9237	27.9135
case_072	5911772	85994272	5901949	85994272	19.1622	5901949	19.1622
case_073	2507770	44120192	2194944	44120192	74.9185	2194944	74.9185
case_074	406099	6230016	406017	6230016	28.4486	406017	28.4486
case_075	425508	12171570	417743	12171570	23.0180	417743	23.0180
case_076	1540201	37442560	1536306	37442560	41.7145	1536306	41.7145
case_077	144734	172032	144734	172032	4.9578	144734	4.9578
case_078	568228	6445440	568228	6445440	0.0000	568228	0.0000
case_079	7635624	30445568	7635624	30445568	0.0000	7635624	0.0000
case_080	100325	3047424	90584	4190208	45.8333	100325	0.0000
case_081	39588	0	39588	0	0.0000	39588	0.0000
case_082	217255	6970608	210359	6970608	26.4094	210359	26.4094
case_083	219344	2791200	219344	2791200	70.1874	219344	70.1874
case_084	629028	0	629028	0	0.0000	629028	0.0000
case_085	938020	29385842	923869	29385842	22.4863	923869	22.4863
case_086	55557	2269390	51263	2266894	32.0400	52040	30.7162
case_087	1069325	7133184	1069325	7133184	22.9131	1069325	22.9131
case_088	98539	2683862	91991	2712598	20.6292	94102	20.0603
case_089	165616	165616	165616	716160	0.0000	165616	0.0000
case_090	295164	6514560	248631	6515328	46.5257	251921	46.5278
case_091	2290698	35909280	2307637	69360288	28.0418	2290222	24.6548
case_092	1033609	6788896	1018349	6788896	27.0236	1018349	27.0236
case_093	19779	24576	19779	24576	0.0000	19779	0.0000
case_094	27182	318816	26940	318816	39.7295	26940	39.7295
case_095	524422	0	524422	0	0.0000	524422	0.0000
case_096	26984	78336	26984	78336	27.1438	26984	27.1438
case_097	2626908	14221312	2626908	14221312	4.1667	2626908	4.1667
case_098	52186	1249322	50584	1806012	32.8177	50721	38.3945
case_099	405655	9764864	403542	9764864	55.4526	403542	55.4526
case_100	50324	1961860	45240	1961860	39.0025	45240	39.0025

表 A-9 问题三逐例结果 (5 核)

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_001	47502	4608	47502	4608	0.0000	47502	0.0000
case_002	59575	872448	59575	872448	0.0000	59575	0.0000
case_003	232588	9723996	212297	9779292	31.0521	212880	31.0114
case_004	88341	442368	88341	442368	0.0000	88341	0.0000
case_005	52655	1728714	49484	2547864	32.7884	52401	18.7537
case_006	24618	411656	21965	710016	28.8795	22707	37.7187
case_007	203834	110592	203834	110592	0.0000	203834	0.0000
case_008	100603	0	100603	0	0.0000	100603	0.0000
case_009	52311	2008978	46342	2008978	33.2497	46342	33.2497
case_010	26147	778932	24724	1011020	31.1386	25518	38.0459
case_011	46880	540672	46777	1622016	62.3106	46880	0.0000
case_012	12712	31104	12622	31104	6.0373	12622	6.0373
case_013	54363	32768	54363	32768	0.0000	54363	0.0000
case_014	3605387	53128200	3592432	53128200	30.9378	3592432	30.9378
case_015	39837	317952	39837	317952	26.4424	39837	26.4424
case_016	2087323	214900	2086359	214900	33.1289	2086359	33.1289

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_017	30495	343296	30495	343296	27.1034	30495	27.1034
case_018	202778	5054464	201337	4681728	61.4323	201472	54.2267
case_019	18640	327032	18640	327032	21.0548	18640	21.0548
case_020	107650	0	107650	0	0.0000	107650	0.0000
case_021	1250168	11431936	1249380	11431936	56.9964	1249380	56.9964
case_022	11813	6912	11813	6912	3.1354	11813	3.1354
case_023	24793	197472	24793	197472	31.1289	24793	31.1289
case_024	694207	202660	693243	202660	33.2644	693243	33.2644
case_025	975282	110592	975282	110592	0.0000	975282	0.0000
case_026	33518	491168	33721	491168	16.4131	33721	16.4131
case_027	558753	5529600	558753	5529600	4.4444	558753	4.4444
case_028	8211965	30147072	8209101	31031808	25.2734	8209252	27.4793
case_029	9383	0	9383	0	0.0000	9383	0.0000
case_030	561102	11479040	560897	11479040	59.5113	560897	59.5113
case_031	306307	8059392	306307	8059392	54.7425	306307	54.7425
case_032	10415	12360	10391	12360	2.8348	10391	2.8348
case_033	369453	6509184	367285	6509184	26.4588	367285	26.4588
case_034	173032	3532800	171529	3532800	50.6998	171529	50.6998
case_035	58349	1602218	56942	1602218	33.7165	56942	33.7165
case_036	187182	4608	187182	4608	0.0000	187182	0.0000
case_037	43800	1925120	43013	1925120	64.2500	43013	64.2500
case_038	283188	8558592	273759	8558592	47.7315	273759	47.7315
case_039	381106	13320192	340476	20480000	37.0893	380496	22.6741
case_040	89745	2634900	81272	3935920	28.2661	86832	27.2525
case_041	1196379	40630272	1193054	40630272	31.7719	1193054	31.7719
case_042	369780	8045568	369723	8045568	42.8201	369723	42.8201
case_043	240597	9832918	215630	11060460	34.5843	227480	32.0638
case_044	45248	930400	45244	930400	0.3432	45244	0.3432
case_045	26164	0	26164	0	0.0000	26164	0.0000
case_046	79918	2791200	79918	2791200	0.0000	79918	0.0000
case_047	119372	3409368	114114	5402776	32.8906	117596	35.7046
case_048	98572	1132628	98551	1132628	19.7987	98551	19.7987
case_049	64305	2125062	63196	2123270	23.8340	63369	23.2890
case_050	58897	1885008	54311	1885008	32.3691	54311	32.3691
case_051	168374	198040	167410	198040	33.3163	167410	33.3163
case_052	41994	333312	41587	333312	27.6295	41587	27.6295
case_053	375096	12135050	362303	12135050	22.5096	362303	22.5096
case_054	240647	8940968	237165	8940968	18.9723	237165	18.9723
case_055	26183	198656	26183	198656	12.3598	26183	12.3598
case_056	97116	3574548	94490	3574548	26.9310	94490	26.9310
case_057	16538	27936	16538	27936	0.0790	16538	0.0790
case_058	1004819	32104448	1004819	32104448	0.0000	1004819	0.0000
case_059	150782	4325376	150736	4325376	73.7879	150736	73.7879
case_060	185331	3641728	184532	3641728	52.9842	184532	52.9842
case_061	22283	83712	22283	83712	12.3158	22283	12.3158
case_062	703542	10626048	703542	10626048	0.0000	703542	0.0000
case_063	255854	3253248	255854	3253248	0.0000	255854	0.0000
case_064	8333	132948	8292	132948	30.0384	8292	30.0384
case_065	9558	55728	9558	55728	15.6782	9558	15.6782
case_066	119141	4419676	110103	4610524	27.4677	113123	25.6030
case_067	13054159	158705152	12257518	158705152	76.4690	12257518	76.4690
case_068	141879	4184738	130386	4177634	22.7867	130785	22.9230
case_069	13698	465362	12569	503470	33.1777	13071	36.0266
case_070	25840	462848	25840	462848	29.6978	25840	29.6978
case_071	10442	317010	9203	329390	31.0190	10229	30.1908
case_072	4831103	84918960	4817940	131343024	19.3648	4826576	16.5441
case_073	2034983	37201408	1805392	74410240	82.9390	1806253	63.4171
case_074	330183	7118848	330183	7118848	26.2029	330183	26.2029
case_075	374967	12788022	355004	12788022	34.0954	355004	34.0954
case_076	1240011	40553472	1232435	40553472	44.6061	1232435	44.6061
case_077	121081	172032	121081	172032	0.0000	121081	0.0000
case_078	481517	12822528	452545	12822528	35.8494	452545	35.8494
case_079	6045667	31907840	6043668	31907840	23.3847	6043668	23.3847
case_080	100325	3047424	86025	4571136	31.8786	100325	0.0000
case_081	30943	0	30943	0	0.0000	30943	0.0000
case_082	195543	5194934	187467	8565908	33.5699	194918	37.5612
case_083	191867	3721600	190890	3721600	18.9588	190890	18.9588
case_084	503472	0	503472	0	0.0000	503472	0.0000
case_085	822333	22587672	813738	40853464	32.5884	817718	35.0246
case_086	55557	2269390	51263	2266894	32.0400	52040	30.7162
case_087	885221	8050176	885221	8050176	21.2111	885221	21.2111
case_088	98539	2683862	91991	2712598	20.6292	94102	20.0603
case_089	133338	954880	133338	954880	0.0000	133338	0.0000

用例	无 L2 Makespan	无 L2 新增 COPY	只读 Cache Makespan	只读 Cache 新增 COPY	只读 Cache 命中率/%	同方案开 L2 Makespan	同方案命中 率/%
case_090	274650	8606208	248631	6515328	46.5257	273577	4.6857
case_091	1848187	39725056	1848050	39725056	24.1690	1848050	24.1690
case_092	814597	4606336	816728	4606336	20.3016	816728	20.3016
case_093	15876	32768	15876	32768	0.0000	15876	0.0000
case_094	20297	259200	20152	259200	12.0242	20152	12.0242
case_095	420852	0	420852	0	0.0000	420852	0.0000
case_096	25183	623148	24363	623148	38.7532	24363	38.7532
case_097	2102348	21311488	2102250	21311488	24.5235	2102250	24.5235
case_098	50844	1517236	46116	1533620	45.6206	46288	45.1468
case_099	324321	7065600	327276	10698752	54.4487	324289	43.6942
case_100	47130	1112288	38158	2170338	40.6034	41936	39.0883

附录 B 复现说明

程序入口。 求解器入口为

reproduction/NPU_R12/round12_src/solve_round12.py (profile 固定为 full)，它在同一次请求内依次调用基础构造器、控制链各阶段 (R6、R7、R10) 与插入、微批模块；这些都是同一请求中的算法模块，不读取任何历史结果。官方评估程序与配置文件原样保存在 official/ 下，未作修改。

环境。 求解器只依赖 CPython 标准库，已完成的实验使用过 Linux/WSL (Ubuntu 24.04, Python 3.12.3)。将 100 个原始 case_*.json 放入

reproduction/NPU_R12/official/data/ 后，单例命令为

```
python3 -B -S round12_src/solve_round12.py
official/data/case_001.json -n 2 --scene A --profile full --budget
600 --out work/repro_case001_A2
```

--scene 取 A、B 或 L2，-n 取核数。输出目录中的

<case>_multicore_res.json 顶层只含 node_to_subgraph 与 core_schedules 两个字段，可直接交官方评估程序复核；report.json 记录各阶段候选、预算、失败与源码哈希。

问题三的同方案对照。 对每个场景 B 最终方案 P_B ，用相同图、核数与配置分别运行问题 2 与问题 3 的评估程序，得到 $T_B(P_B)$ 与 $T_L(P_B)$ ；L2 独立选优方案 P_L 的结果另列。500 对中 430 对两场景最终方案相同，62 对复用哈希一致的已有候选评分，8 对补做了官方 L2 评分，补评分不反向参与选解。

可复现性的限度。 求解受墙钟预算约束，并发与机器负载可能改变预算内评价到的候选数，因此不承诺跨机器每个请求都与存档方案逐字节相同；本文全部数值以存档方案及其官方结果为准，二者以 SHA256 绑定。

附录 C 支撑材料清单

表 C-1 支撑材料清单

材料	位置	说明
求解程序	reproduction/NPU_R12/	R12 求解器与官方评估程序、固定配置
逐例结果表	publication/tables/	Q1/Q2/Q3 逐例 CSV、汇总与 C3 对照
校验记录	publication/sources/ closeout/results/	1470 组核查、下界字段、预算例外、方

材料	位置	说明
图件	figures_v3/、paper_full_v1/ figures/	案哈希 全部图的 PDF、600 dpi PNG、SVG 与作 图数据
论文数值核对	paper_full_v1/qa/	事实总表、全文数字溯源报告

附录 D AI 工具使用说明

【本附录须由队员按当届竞赛关于 AI 工具使用的规定，用自己的语言填写，下列条目为待填框架。】

- 1. 使用的工具：名称、版本或型号、开发机构、版本发布日期（未能核实的项目如实注明“未核实”）。
- 2. 使用环节：例如资料整理、代码辅助、图表绘制、文字润色、数字核对；逐项说明使用范围。
- 3. 未使用 AI 的环节：例如模型的提出、算法设计、实验运行与结果判断（按实际情况填写）。
- 4. 人工核查方式：说明队员如何核对 AI 产出的公式、数值、代码与文字，以及对最终内容负责的声明。