

基于可证下界与结构化搜索的多核 NPU 切图调度

摘要

多核 NPU 调度需要联合决定计算图划分、子图核心归属与核内子图次序，其执行时间还受私有缓存、共享带宽及同步等待制约。针对题目给定的确定性评价流程，本文建立以切图、分核、核序为决策的仿真驱动优化模型，采用 Makespan 优先、额外搬运量次优的字典序选择规则。求解框架 R12 按场景生成结构化候选，以全局下界和固定方案下界分别支持近优判定与候选淘汰，再以官方评估程序确定最终优劣。在 100 张正式计算图的 1400 个场景—核数配置上完成实验，保留全部结果及预算例外。

针对问题一，利用两端独占链收缩与依赖深度分带形成不同粒度的子图，按尾长优先的拓扑次序追加分核，并证明该过程保持依赖边与核序边的联合无环。随后以官方时间线反馈调整分核和次序，使用 Treap 区间索引生成插入候选。2 至 5 核平均加速比分别为 1.8553、2.5606、3.1973、3.7433；五核中位数为 4.1302，最小值为 1.2023，相对固定构造基线 C3 的逐图耗时平均降低 43.48%。

针对问题二，分别刻画同核驻留、跨核边界与容量溢出，枚举活动核数及驻留组织方式，只在当前方案实际出现 Spill 时启动局部微批。证明核心归属不变可保证 Spill 前边界计账不变，但不保证 Spill 量或完成时间不变。2 至 5 核平均加速比分别为 1.9925、2.8011、3.5210、4.1311。五核 22 张图出现 Spill，前 10 张占全部 Spill 字节的 93.84%；微批阶段仅在两张图上进一步改善，表明该机制的收益具有明显的实例依赖性。

针对问题三，按照发射时查询、完成时插入的 FIFO 规则建立共享只读缓存模型，使用同方案配对评价区分配置效应与重新选解效应。五核 L2 独立选优的平均加速比为 4.2190；固定 B 方案时，开关 L2 的耗时比均值为 1.016766，中位数为 1.000546。500 组固定方案对照有 8 组轻微退化。五核命中率与配置收益呈正秩相关，但不存在逐例单调保证。进一步用几何均值给出可乘的总体分解，不用算术均值之比替代逐例效果。

模型检验保留逐例胜平负、非单调扩核记录、组件来源及求解墙钟。相对 C3 的 14 组符号检验在多重比较校正后仍显示方向差异，但该比较不是等预算算法消融。全部最终方案不慢于固定整图单核参考；case_087 的四个场景 A 配置在 600 秒内未成功，另用 1800 秒预算补跑，实际用时 753.0 至 1036.1 秒，超出题面建议时效。

本文的方法贡献集中在三方面：以统一评价口径组织切图、分核与排序的结构化搜索；利用联合无环和核心归属不变量约束候选，并对满足全局下界条件的实例给出 3% 相对最优性间隙证书；通过同方案配对和比值分解区分缓存配置变化与软件选解变化。证书并非覆盖全部实例，结论限于题目给定的 100 张图、固定硬件配置和已披露预算。

关键词：多核 NPU；计算图划分；仿真驱动调度；可证下界；驻留优化；只读缓存

1 问题重述

1.1 问题背景

神经网络模型的规模仍在快速增长，单个 AI 核心受制造成本、功耗和散热的约束，难以独立提供所需算力，多核 NPU 因此成为提升并行能力与能效的主流架构。深度神经网络加速器的研究早已表明，片上缓存的数据复用与片外存储的访问次数在很大程度上决定了执行效率和能耗[1,2]。多核化以后，这一问题又多了一层：一张完整的计算图需要被划分为若干子图，分配到不同核心上执行，核内要尽量复用私有缓存中的数据，核间依赖则要经过共享主存或同步机制传递。

多核化并不自动消除访存瓶颈。细化子图能够增加并行机会，却可能增加重复读取和启动次数；聚合子图能够保留部分复用，却可能压缩并行空间或加重容量压力。本文把这些影响落实到题目提供的评价程序，在相同输入和硬件配置下比较完整方案，而不把某一个局部代价的下降直接等同于整图加速。

1.2 平台、计算图与方案形式

(1) 硬件平台。平台由 k 个同构 AI 核心和共享的核外主存 DDR 组成。每个核心有 Cube 矩阵计算单元 (PIPE_M)、Vector 向量计算单元 (PIPE_V)、两类数据搬运单元 (PIPE_MTE2 负责搬入，PIPE_MTE3 负责搬出) 以及私有的 L1 与 UB 缓存。四条 Pipe 各自串行、彼此可以并行；全部核心对 DDR 的读写共同竞争固定的总带宽。固定配置下，L1 为 524288 bytes，UB 为 131072 bytes，DDR 总带宽为 60 bytes/cycle。

(2) 计算图。待调度对象是一张操作—张量二部有向无环图 $G=(V,E)$ ， $V=V_T \cup V_O$ 。张量节点带有逻辑位置 (DDR、L1 或 UB) 与字节数；操作节点带有操作类型、执行 Pipe 与周期数，其中 COPY_IN、COPY_OUT 负责 DDR 与核内缓存之间的搬运，其余为核内计算。边只连接张量与操作，本身不携带通信量：依赖跨越子图或 Task 时，搬运字节数由对应张量的大小决定。题目给出的 100 张正式计算图保证每个 DDR 输入只搬入一次、每个最终结果只搬出一次，且单个计算操作的输入输出总量不超过相应缓存容量。

(3) 方案形式。算法输出两部分：切图方案 `node_to_subgraph`，把每个非 COPY 操作映射到一个子图编号；子图调度方案 `core_schedules`，为每个核心给出一条子图执行序列。每个子图必须且只能出现一次，子图依赖图必须无环，同核顺序不得违反依赖。

(4) 评价流程。官方评估程序[3]读入方案后分三步给出结果：按场景规则构造 Task 并补充跨 Task 边界搬运；用题面附录 C 的核内调度算法确定每个 Task 内部的操作顺序，容量不足时自动插入换出与换入；在统一事件时间轴上模拟全部核心、Pipe 与共享带宽的并行执行。所有操作结束时刻的最大值即为 Makespan，这是最重要的指标；次要指标为总额外数据搬运量，即调度后全部 DDR 搬运量扣除原始计算图已有搬运量后的字节数；问题三另报告只读 Cache 的字节命中率。

1.3 两种硬件场景与共享 L2

(1) 场景 A (无核间同步机制)。一个 Task 只能包含一个子图。同一核上多个 Task 串行执行时核内缓存被清空，因此所有跨子图数据都必须经 DDR 中转，即使相邻两个

Task 位于同一核心也不例外。Task 的激活受两类等待约束：同核前一 Task 完成后至少等待 100 cycles，每个跨核前驱 Task 完成后至少等待 1000 cycles。

(2) 场景 B（有核间同步机制）。同一核心上的全部子图合并为一个 Task，前序子图的数据可以留在 L1/UB 中供后续子图直接使用；跨核依赖由源核写入 DDR 并发出同步信号，目标核的 COPY_IN 在源 COPY_OUT 完成并经过 500 cycles 后才能进入就绪判定。同核复用减少了搬运，但跨多个子图的驻留数据会持续占用缓存，可能压缩其他子图的可用空间。

(3) 共享只读 L2。在场景 B 基础上增加一块由全部核心共享的只读 L2 Cache，容量 1 MiB，读带宽 250 bytes/cycle，与 DDR 带宽相互独立。COPY_IN 在发射时按逻辑张量编号查询 Cache，命中则走 L2 读带宽池，未命中则访问 DDR 并在完成后写入 Cache，容量不足时按先进先出淘汰。

1.4 需要解决的问题

问题一 在场景 A 下建立多核切图与调度模型并设计求解算法：为每个非 COPY 操作分配子图编号，确定各核心上的子图执行顺序；以缩短总体执行时间为主要目标，兼顾总额外数据搬运量，并在 2 至 5 核范围内稳定、高效地给出高质量结果。需提交 1 至 5 核的平均加速比折线图（单核基准为整图单核核内调度的 Makespan，单核加速比定义为 1），附录逐例列出 Makespan 与总额外数据搬运量，附件提供可复现的 Python 程序。

问题二 在问题一的基础上，建立适用于场景 B 的切图与调度模型并设计求解算法，在严格满足 L1/UB 容量约束的前提下进一步缩短总体执行时间、减少额外数据搬运，同样适应 2 至 5 核的变化。需提交场景 B 下 1 至 5 核的平均加速比折线图（定义同问题一）、逐例的 Makespan 与总额外数据搬运量，以及可复现程序。

问题三 在场景 B 的基础上引入共享只读 L2，研究其容量和带宽对多核切图与调度的影响，建立相应模型并设计求解算法。需在正文给出 1 至 5 核下无 L2 与只读 Cache 两种配置的对比曲线，并报告相同核数下只读 Cache 相对无 L2 基线的加速比（无 L2 的 Makespan 除以只读 Cache 配置的 Makespan）；附录逐例列出两种配置的 Makespan、总额外数据搬运量与 Cache 命中率。

三问均使用固定配置和原版评估程序。题面脚注建议单个用例在 5 至 10 分钟内给出结果，并要求避免暴力迭代搜索。本文采用 600 秒单请求软预算，个别首次失败配置的补跑单列，区分“结果覆盖完整”与“所有请求满足建议时效”。

2 问题分析

2.1 多核调度的核心矛盾

题目要求同时定下三件事：每个计算操作归入哪个子图（切图），每个子图交给哪个核心（分核），每个核心上的子图按什么顺序执行（核序）。三件事互相牵制。切图决定子图的规模、可并行的空间和通信边界；分核决定负载是否均衡、哪些依赖变成跨核依赖；核序决定等待有多长、张量在缓存里要驻留多久、核内调度会不会被迫插入换出与换入。切得粗，搬运少，但并行度下降、单个子图的缓存压力上升；切得细，并行机会多，但同一份数据要反复经 DDR 中转。三件事中任何一件单独做到最好，都保证不了总时间最短。

方案只给定切图、分核与核序；操作开始时刻、Spill 插入及共享带宽竞争由官方流程展开。静态工作量不足以完全描述这种时序耦合。本文没有构造能够直接替代评价器的闭式目标，而是将其作为确定性评价算子，保留候选生成与最终评价之间的区别。

求解分为结构分析、候选生成、下界筛选和官方评价四个环节。结构信息用于选择有针对性的切分与重排；证明成立的下界用于排除不可能更优的候选；所有保留候选均以官方执行结果择优。下界具有明确适用域，未被证明为下界的优先级和亲和度不承担严格剪枝职责。

2.2 输入数据普查

首先统计 100 张正式计算图的规模与资源组成，结果见表 2-1。

表 2-1 100 张正式计算图的规模统计

统计量	最小值	下四分位	中位数	上四分位	最大值
非 COPY 操作数	552	1098	3720.5	7008	35705
张量数	816	1555	4590.5	7953	40287
边数	1841	3348	11187	20378	108272
PIPE_M 计算周期 W_M	0	62556	256920	1334492	58915232
PIPE_V 计算周期 W_V	9988	55496	144314.5	344076	7714975

注：四分位数取经验最近秩；周期数按 $\max(1, \text{cycles})$ 计。

规模数据给出三条直接影响方法设计的信息。

(1) 规模跨度较大。最大图的非 COPY 操作数约为最小图的 65 倍，操作数不超过 1000 和不少于 10000 的图各有 19 张。由此采用多粒度候选，而不是将所有图固定切成相同数量或相同操作数的子图。规模统计并不能唯一确定具体粒度参数；宽度 4、8、2、16 和 2048 操作数目标属于固定的启发式设计。

(2) 计算组成存在差异。72 张图以矩阵计算为主，28 张以向量计算为主，其中 7 张没有矩阵计算（图 2-1）。两类计算 Pipe 可以在依赖允许时并行，故代理时长考虑两类负载的较大值，而不直接把它们相加。该代理仍忽略部分等待、驻留和带宽耦合，不能作为最终执行时间。




图 2-1 100 张计算图的规模与计算组成

(3) 单张量容量比不等于驻留峰值。全部图的最大单张量都不超过对应私有缓存容量的 0.5625 倍，73 张图不到十分之一（图 2-2）。这排除了单张量必然装不下的情况，但多个张量同时驻留仍会引起容量冲突。是否发生 Spill 必须由执行序列中的实际驻留集合判断。




图 2-2 单张量大小与私有缓存容量

规模只说明图有多大，能切出多少并行、数据要驻留多久，还得看依赖结构。我们在操作级依赖图上统计了关键路径、并行宽度与张量复用距离（表 2-2）。

表 2-2 100 张正式计算图的依赖结构与复用特征统计

统计量	最小值	下四分位	中位数	上四分位	最大值
关键路径长度（周期）	400	2484	6140	23904	863040
关键路径上的操作数	5	14	46.5	126	2442
最大分层宽度（操作数）	12	147	270	1374	15921
平均并行度	3.42	18.79	43.13	304.79	6258.78
多用途张量占比	0.001	0.093	0.142	0.210	0.300
每图复用距离中位数（操作数）	1	6	15	44	6080
每图复用距离最大值（操作数）	1	180	2184	5031	28536
每图复用距离中位数（周期）	152	524	1008	23056	5726700
每图复用距离最大值（周期）	300	32628	285877.5	1328670	60412800

注：四分位数按经验最近秩计算，中位数取中间两项平均。操作依赖由同一张量的写入者和读取者建立；关键路径只计原始计算周期，COPY 操作计 0。表中“分层宽度”为按依赖跳数分层后单层操作数的最大值，不是最大反链大小，也不等于运行时并发数。平均并行度为原始计算总周期与计算关键路径长度之比；多用途张量至少被两个操作读取。复用跨度取确定性拓扑序中首末读取位置差及其间累计周期，先逐图统计，再汇总 100 张图。

依赖结构又给出两条信息。

(4) 依赖结构限制可利用的并行空间。关键路径长度为 400 至 863040 周期，中位数 6140；最大分层宽度为 12 至 15921。平均并行度中位数 43.13，最小 3.42 (case_048)，低于 10 的图共 11 张。case_064 的平均并行度为 6.53、分层宽度 62，在 12 个多核组中占据 9 组的最小加速比。第 8.4 节进一步报告相关性，但不将其写成图结构已被独立识别的因果效应。

(5) 多次使用与较长复用跨度同时存在。每图多用途张量占比中位数为 0.142；每图最大复用跨度的中位数为 2184 个操作、285877.5 周期。该统计说明输入可能跨较长序列再次使用，但拓扑跨度并非实际经过时间。场景 A 中，它可能形成多个 Task 的重复读入；场景 B 中，则形成驻留与换入换出的权衡；L2 命中还取决于读取发射时点和中间插入的其他键。

因此，本文从图结构生成多种粒度和活动核数候选，并在问题二中显式处理驻留次序。上述统计用于解释设计动机，不构成对既定阈值最优性的证明。

本节结构统计及第 8 章原有相关性由 AI 辅助脚本完成，历史工具信息由参赛队据实核实。本文新增的命中率、几何分解和扩核计数属于冻结表的只读复算，未重新求解计算图；使用范围与待核验信息见附录 D。

2.3 问题一的分析

场景 A 的每个子图独立成为 Task，跨 Task 数据都经 DDR 中转。切分粒度影响边界搬运、启动次数和单 Task 容量压力；分核与核序决定这些代价如何在全局时间线上叠加。切得更细或更粗都不必然更优，实际取舍需要完整评价。

候选生成优先收缩两端独占的非分支链，再按依赖深度分带，并保留带内互不相连的分量。链收缩的“安全”限定为结构无环，不代表完成时间必不增加。随后沿拓扑序追加分核，用官方 Task 时长反馈修正，并在剩余预算内尝试索引插入。

2.4 问题二的分析

场景 B 将同核全部子图合并为一个 Task，并把跨核同步改为写出完成后等待 500 周期。相较场景 A，同核子图边界不再必然产生 DDR 中转，但驻留数据会与后续操作竞争容量。因此，边界搬运、流水线负载和 Spill 需要共同优化，不能概括为边界代价已经消失。

所以问题二不能靠替换同步常数从问题一平移过来。我们在问题一框架的候选生成层增加两类机制：一是枚举活动核数与驻留组织，在跨核边界与并行度之间权衡；二是只在当前解确实发生 Spill 时，诊断引起反复换入的大张量，在局部窗口内重排执行顺序，同时保持每个操作的核心归属不变，使 Spill 之前的边界搬运严格不变（第 6 章）。

2.5 问题三的分析

问题三在场景 B 上加了一块共享只读 L2，它服务的是多个核心对同一输入的重复读取：命中的读取走独立的 250 bytes/cycle 读带宽，不再与其他搬运争用 60 bytes/cycle 的 DDR。缓存按 FIFO 管理，命中在读取发射时判定，插入在读取完成时发生，命中不刷新次序。命中率因此取决于三件事：张量是否大于容量，两次使用之间插入了多少其他张量，以及多个核心是否在首次读取完成之前就同时发射了同一读取。

开启 L2 后的终点性能差异同时可能包含配置变化和方案变化。本文固定无 L2 下选出的方案，在两种配置中分别评价，以获得同方案配置比；再在同一 L2 配置下比较两种已选方案。两类比值由逐例恒等式联系，既保留正收益，也允许无变化和退化，不把重新选解的全部效果归给缓存。

2.6 三问的递进关系与技术路线

三问使用相同的决策三元组、可行性检查和字典序选择规则。场景 A 重点组织 Task 粒度与释放次序，场景 B 增加驻留相关候选，L2 场景增加缓存状态与跨配置重评价。图 2-3 展示数据、模型、分问求解和结果核验的衔接。统计复算只作用于已冻结结果，不反向替换原实验选解。




图 2-3 全文技术路线

2.7 相关方法与本文定位

有向无环任务图在多处理器上的静态调度是经典问题，NP 难早为人熟知，常用的是按优先级逐个放置任务的构造型启发式及其变体[4,5,6]。深度学习编译与加速器领域更关注数据流与存储层次：加速器研究强调片上缓存复用对能效的决定作用[1,2]，编译器通过算子融合、图划分与并行策略搜索降低访存与通信开销[7,8,9,10]。与本题联合无环约束直接相关的是有向无环划分，即要求划分后的商图仍然无环，已有多层划分算法[11]；有限容量下数据搬运量的下界问题，则可以追溯到红蓝卵石博弈[12]。

上述文献提供了优先级、插入调度、无环划分和数据复用等方法基础。本题的 Task 时长还受官方核内启发式与全局带宽竞争影响，不能直接按静态任务时间解释。本文沿用这些方法中的候选构造思想，另以完整官方评价决定终点；没有把文献算法在本题上的性能视为已测得，也未将 C3 等同于文献中的最强基线。

3 建模约定与符号说明

3.1 题设约定与求解边界

本节区分题设与实现约定、算法设计选择以及结论适用范围。前者用于对齐官方评价，后两者不作为新增的硬件物理假设。

（一）题设与评价实现约定

假设 1（评价确定性） 同一计算图 G 、同一方案 P 、同一固定配置 θ 在同一版本的官方评价程序下给出唯一的 Makespan 与搬运统计。依据：题面附录 C 的核内拓扑排序按操作类型、预计算深度和 id 的固定优先级排列，题面附录 D 的离散事件循环按固定次序推进，评价过程中不含随机因素。

假设 2（输入不可改） 原始计算图的操作、周期数、张量大小以及 config.txt 中的全部参数在实验中保持不变；算法只输出 node_to_subgraph 与 core_schedules 两个字段。依据：题面附录 B.1 规定论文中的算法评估结果必须由使用统一配置的评估脚本给出，不得修改。

假设 3（零周期计算） 周期数为零的计算操作按 $\max(1, \text{cycles})$ 计时。依据：这是当前原版实现的实际行为；本文按实现而非文字理解建模，以免估计值与评分出现系统偏差。

假设 4（容量约束的作用对象） L1/UB 容量约束作用于某一时刻核内实际活跃的驻留张量集合，而不是一个子图涉及的全部张量。依据：题面附录 C.3 规定输入张量在最后一次使用完成后释放，题面附录 D.4 规定操作完成后递减引用、最后一次使用完成即释放空间。

假设 5（等待的计费方式） 场景 A 中，同核前一 Task 完成后的 100 cycles 切换等待只对同核前一 Task 计一次；1000 cycles 跨核等待只在前驱与后继分属不同核心时计入；场景 B 与 L2 场景中，跨核 COPY_IN 须在对应 COPY_OUT 完成 500 cycles 后才进入就绪判定。依据：题面附录 D.2 对问题 1 与问题 2、3 的 Task 激活条件的描述。

假设 6（边界搬运的计数方式） 边界搬运按张量的生产单元与消费单元计数，而不是按操作依赖边计数：场景 A 中，生产 Task 对跨 Task 使用的张量写出一次，其他每个消费 Task 各读入一次；场景 B 中，每一对“生产核心→消费核心”的跨核连接各计一次写出与一次读入。同一张量被同一远端单元多次使用只计一次。依据：题面 1.2 节“边本身不设置通信量，搬运字节数由关联张量的大小决定”，以及官方评估程序重建边界 COPY 的实现（4.4.5 节）。

假设 7（COPY 记账时点） 新增 COPY 字节数在事件模拟之前记账，模拟阶段的只读 Cache 命中不回减该量。依据：官方问题 3 评估程序在模拟前完成 added_copy_bytes 统计；第 7 章的同方案对照中，固定方案在两种配置下的边界与 Spill 新增字节完全一致，与这一记账方式相符。

假设 8（带宽池独立） DDR 带宽池（60 bytes/cycle）与只读 L2 读带宽池（250 bytes/cycle）各自由全部核心共享，两池之间互不占用；池内在途搬运公平分享带宽。 依据：题面 1.5 节与附录 D.5。

（二）算法设计选择与证据边界

约定 9（评价与代理分工） 候选生成可以使用工作量、尾长及驻留信息等代理量；候选最终优劣统一按完整官方评价确定。只有经证明成立且适用域匹配的下界用于严格剪枝。该选择旨在控制代理误差，不否定代理建模或其他搜索路线的可能性。

约定 10（有限预算） 常规单请求预算为 600 秒，全部阶段共用剩余时间。预算内没有顶层成功结果的请求记录失败，另行补跑时注明预算和来源。题面建议单例在 5 至 10 分钟内完成；case_087 的场景 A 四格未达到这一建议时效。

约定 11（测试边界） 结论限于 100 张正式图、固定配置和已披露的搜索预算。未增加独立外部测试集，也未进行等预算单模块消融或 L2 参数扫描，不将测试集内覆盖写成测试集外保证。

3.2 符号说明

全文通用符号列于表 3-1，只在某一章使用的符号在首次出现处另行定义。

表 3-1 主要符号说明

符号	含义	单位或取值
$G=(V,E)$	操作一张量二部有向无环计算图， $V=V_T \cup V_O$	—
U	非 COPY 计算操作集合（方案需要覆盖的对象）	—
S	非空子图集合	—
k	核心数	场景 A 取 2–5；场景 B 与 L2 取 1–5
g	操作划分 $g:U \rightarrow S$ ，即 node_to_subgraph	—
a	核心分配 $a:S \rightarrow \{0,\dots,k-1\}$	—
π_c	核心 c 上的子图执行顺序，即 core_schedules[c]	排列
$P=(g,a,\pi)$	多核切图与调度方案	—
θ	固定硬件配置（容量、带宽、等待常数）	见表 3-2
$\text{Eval}_A, \text{Eval}_B, \text{Eval}_L$	问题 1、2、3 的官方评价算子	—
$T_A(P), T_B(P), T_L(P)$	三种评价下的 Makespan	cycles
$T_{\text{REF},i}$	第 i 张图整图单核的原版核内调度结果（加速比基准）	cycles
D_{added}	新增 COPY 字节数， $D_{\text{added}}=D_{\text{partition}}+D_{\text{spill}}$	bytes
$D_{\text{partition}}$	Spill 之前的 Task 边界新增字节（下文简称“边界新增”）	bytes
D_{spill}	核内容量不足时插入的换出与换入字节（“Spill 新增”）	bytes

符号	含义	单位或取值
F_A, F_B	满足方案规则且官方执行成功的方案集合	—
f_p, r_s	Task p 的完成时刻; Task s 的必要释放时刻	cycles
$Pred(s)$	子图 s 的数据前驱集合	—
C_m	私有缓存 $m \in \{L1, UB\}$ 的容量	bytes
$L_{c,m}(\tau)$	时刻 τ 核心 c 上缓存 m 的活跃驻留张量集合	—
b_t	张量 t 的字节数	bytes
W_M, W_V	全图 PIPE_M、PIPE_V 计算周期总和	cycles
L_{CP}	只计算周期的最长依赖路径长度	cycles
LB_k	k 核下与方案无关的计算下界 (4.5 节)	cycles
$\bar{S}_k$	k 核下 100 张图逐例加速比的算术平均	—
ρ_i	相对 C3 的逐例耗时降幅	%
$Q(t), H(t)$	只读 L2 的 FIFO 键序列及其字节占用 (第 7 章)	—/bytes
h_i	第 i 张图的按字节命中率 (第 7 章)	%
R_{hw}, R_{select}	同方案配置比、分别选优综合比 (第 7 章)	—

表 3-2 固定配置参数 (全部实验不变)

参数	取值	适用范围
L1 容量 C_{L1}	524288 bytes	每核私有, 三问
UB 容量 C_{UB}	131072 bytes	每核私有, 三问
DDR 总带宽	60 bytes/cycle	全部核心共享, 三问
同核 Task 切换等待	100 cycles	问题 1
跨核前驱等待	1000 cycles	问题 1
跨核拷贝同步延迟	500 cycles	问题 2、3
只读 L2 容量	1048576 bytes (1 MiB)	问题 3
只读 L2 读带宽	250 bytes/cycle	问题 3, 独立于 DDR

文中 1 MiB = 1048576 bytes, 1 KiB = 1024 bytes。加速比、配置比等无量纲比值在正文一般保留四位有效数字, 表格保留六位小数; 贴近 1 的配置比在正文也保留六位小数, 原因见 7.3.1 节。

4 多核计算图的统一建模

本章统一定义方案、评价目标、时序约束和搬运记账, 再区分计算下界、窗口下界与固定方案下界。第 5 至 7 章在此基础上给出不同 Task 组织和读取路径下的候选机制。所有公式均用于刻画决策或评价语义, 操作实际时刻仍由原版评估流程确定。

4.1 资源与问题规模

4.1.1 硬件资源的归属

每核独立配置计算单元与 L1/UB 容量；DDR 的 60 bytes/cycle 总带宽由所有核心的读写共同分享。图 4-1 中的三个核心仅作结构示意。问题三另有全局共享的独立 L2 读池，因此跨核执行虽不共享私有计算单元，仍通过全局带宽和同步依赖耦合。




图 4-1 计算资源、私有缓存与共享带宽池（示意图）

增加核心并不增加 DDR 总带宽。若并行化同时增加通信量，共享带宽可能限制后续收益；但带宽是否成为某个实例的主瓶颈，仍需实际时间线或受控比较支持，不能仅从核数推断。

三个场景共用这套硬件。只有问题三额外增加一块 1 MiB、250 bytes/cycle 的共享只读 L2，它独立于 DDR，构成第二条读路径。

4.1.2 输入规模的异质性

实验使用题目给定的 100 张正式计算图。图与图之间的规模差异很大：非 COPY 操作数从 552 到 35705，最大与最小相差约 65 倍，中位数为 3720.5；每张图 M 计算与 V 计算的工作量占比也明显分化，72 张图以矩阵计算为主，28 张以向量计算为主（图 2-1，每点与每列各对应一张图）。

不同规模和依赖形态需要候选粒度具有一定覆盖面。本文用图的链结构和依赖深度确定候选边界，同时采用固定宽度及分组软目标。因而“结构自适应”不等于没有参数，也不意味着这组参数已经在每张图上达到最优。

全文共有 1400 个配置结果：场景 A 400 格（100 图×2 至 5 核），场景 B 与 L2 场景各 500 格（100 图×1 至 5 核）。它们不是 1400 个独立样本，同一张图在不同核数、不同场景下反复出现，所以涉及分布的陈述一律按场景与核数分组给出，不跨组汇总。

4.2 决策结构与可行性

4.2.1 决策三元组

方案由三项决策构成：


$$P=(g,a,\pi), g:U \rightarrow S, a:S \rightarrow \{0,\dots,k-1\} \quad (4-1)$$

g 把每个非 COPY 操作分配到一个子图， a 把每个子图分配到一个核心， π_c 给出核心 c 上的子图执行次序。提交文件只含 node_to_subgraph 与 core_schedules 两个字段。


算法能控制的只有这三项，操作的具体开始时刻由官方评价流程确定。这一点在建模上是决定性的，后果在 4.3.2 节展开。

图 4-2 把同一个概念 DAG 分别画成操作一张量视图、子图划分视图与核心队列视图，三者中的对象一一对应，可以直观区分三项决策各自作用在哪一层；图中核心队列给出的是队列序号而非执行时刻（结构示意，非实际选解）。

(a) 输入：操作—张量二部 DAG



(b) 划分 g ：原操作恰好归入一个子图



(c) 分核 a 与核序 π ：相同子图、不同核心队列




图 4-2 调度方案的三种视图：操作划分、核心映射与核序（概念示例）

4.2.2 可行性条件

方案合法需同时满足三条。前两条是覆盖性与唯一排布：

$$\bigcup_{s \in S} g^{-1}(s) = U, g^{-1}(s) \cap g^{-1}(s') = \emptyset (s \neq s') \quad (4-2)$$

即每个非 COPY 操作恰好归入一个子图，每个子图恰好在一个核心队列中出现一次。

第三条是联合无环。记操作间直接数据依赖经张量投影后得到子图边，另按各核相邻子图生成顺序边。取直接边或其传递闭包都不改变环检测的结论；实现采用邻接结构而非显式枚举全部传递关系。

$$\begin{aligned} E_{dep} &= \{(s, s') : s \neq s', \exists u \in g^{-1}(s), u' \in g^{-1}(s'), u < u'\}, \\ E_{ord} &= \bigcup_c \{(\pi_c(j), \pi_c(j+1))\}. \end{aligned} \quad (4-3)$$

令联合图为 $H(P) = (S, E_{dep} \cup E_{ord})$ ，本文候选要求其无环。仅检查原始计算图无环并不充分，因为核序可能与数据边组成等待环。该条件是本文采用的结构合法性约束；完整执行成功还需要官方展开和资源检查。

联合无环解决顺序冲突，不能代替内存申请、缓存复用边及事件推进的执行检查。本文把格式、结构和完整官方执行都成功的候选纳入可行方案集合，不仅凭结构检查成功就报告性能。

三个场景共用这一整套决策结构与可行性条件，差别在 4.3 节的评价算子和 4.6 节的 Task 组织方式。

4.3 目标函数与评价口径

4.3.1 目标与择优规则

总体执行时间由官方评价器统一计算：

$$T_A(P) = \text{Makespan} \left(\text{Eval}_A^{\text{orig}}(G, P; \theta) \right) \quad (4-4)$$

场景 B 为同一形式，只替换评价算子：

$$T_B(P) = \text{Makespan} \left(\text{Eval}_B^{\text{orig}}(G, P; \theta) \right) \quad (4-5)$$

问题三使用加载了只读 L2 配置的同一套评价流程，记为 $T_L(P)$ 。三者单位均为 cycles。

择优采用字典序：

$$\text{lex min}_{P \in F} (T(P), D_{\text{added}}(P)) \quad (4-6)$$

先比较 Makespan，相同时再比较新增 COPY 字节数；两者都相同时按候选的确定性名称排序，保证结果唯一。

字典序是本文依据主次指标关系采用的选择规则：先最小化 Makespan，在主指标相同的候选中减少额外搬运。它避免设定 cycles 与 bytes 的换算权重，但也可能接受“更快而搬运更多”的方案。题面没有给出唯一的多目标权重，本文不将其他权衡形式一概排除。

4.3.2 把评价器当作黑箱目标的取舍

可以考虑精确规划、代理驱动搜索或直接使用官方评价的候选搜索。本文从评价一致性、实现规模和可用预算三个方面选择当前路线。

(1) 评价语义。Task 释放、流水线、内存申请与共享带宽以事件方式耦合，Spill 和核内次序又由指定启发式生成。将这些规则完整嵌入规划模型需要额外实现和一致性验证；本文没有完成该等价编码，而不是证明其原则上不存在。

(2) 代理偏差。静态代价可用于指导候选，但它与真实 Makespan 的误差会影响候选排序。本文不以未校准的代理代替最终评价，同时保留代理在构造和优先级估计中的作用。

(3) 规模和预算。最大图有 35705 个非 COPY 操作，候选完整评价包含核内展开和多核事件模拟。本文限制候选族及单次评价时限，以控制有限预算内的开销；不把 NP 难性解释为任何具体实例必然无法精确求解。

三条求解路线的对比见表 4-1。

表 4-1 三条求解路线的比较

路线	目标与评分的一致性	大规模可行性	最优性信息	可复现性
精确规划（混合整数规划、约束规划）	完整等价编码需另外实现与验证	取决于规模及具体编码	可解时给出最优或间隙	高
代理目标+元启发式（遗传、模拟退火等）	代理需校准；也可直接接官方评价	取决于评价成本与搜索预算	无	依赖随机种子
本文：结构化候选+官方评价闭环	完全一致，官方评价器即目标	可行，成本由官方评价次数决定	下界剪枝与近优认证（4.5.2 节）	候选确定；预算截断可能改变终点

表 4-1 比较的是路线属性，不是性能排行榜。本文采用有限结构候选与官方反馈相结合的方式，能够直接对齐最终评价口径，但仍可能因候选覆盖和预算不足遗漏更优方案。全局下界提供条件性的近优证书，不能消除一般实例的最优性缺口。

4.3.3 基准与对照

基准 REF 取原版核内调度算法在整图单核上的结果。按题目要求，不使用各方法自行优化后的单核结果作为分母，因此单核加速比按定义为 1。逐核平均加速比为

$$\bar{S}_{A,k} = \frac{1}{100} \sum_{i=1}^{100} \frac{T_{REF,i}}{T_{A,i,k}}, \bar{S}_{A,1} = 1 \quad (4-7)$$

先逐图求比值，再取算术平均，不以总时间比替代。场景 B 的标准曲线同样把一核参考点定义为 1；其优化后 B1 另行报告。问题三的两配置曲线采用各自实际结果，因此一核配置比不强制取 1。REF 来自启发式单核排序而非单核最优，故可能出现多核加速比大于核数。

对照基线 C3 是本文构造的可复现固定基线：合并安全链、按就绪层平衡计算负载、用场景 A 的等待与边界代理分核，一次成型后不再迭代。它与本文方法使用相同输入、相同官方评分口径。

C3 是可独立运行的固定构造对照，R12 则进行多候选搜索，两者使用相同输入和官方口径，但搜索成本不同。C3 的独立可运行性并不证明其代表强基线；本文的相对降幅只比较存档终点方案，不解释为等预算优势。相对 C3 的逐例耗时降幅定义为

$$\rho_i = 1 - \frac{T_{R12,i}}{T_{C3,i}}, \bar{\rho} = \frac{1}{100} \sum_{i=1}^{100} \rho_i \quad (4-8)$$

同样是逐图先计算再平均，不是求解程序的墙钟降幅。

4.4 评价语义下的时序、容量与带宽约束

本节把题面附录 C、D 描述的评价语义写成约束。这些约束刻画的是任何一次合法执行都必须满足的条件；具体的开始时刻仍由评价流程按确定性规则给出，不是本文的决策变量。

4.4.1 操作级依赖与 Pipe 串行

记 s_v 、 f_v 为操作 v 的开始与完成时刻， p_v 为其周期数（计算操作按假设 3 取 $\max(1, \text{cycles})$ ）， $\text{pipe}(v)$ 与 $\text{core}(v)$ 为其所在流水线与核心。数据依赖与同一 Pipe 上的串行分别为

$$s_v \geq f_u, \forall (u \rightarrow t \rightarrow v), t \in V_T \quad (4-9)$$

$$f_u \leq s_v \text{ 或 } f_v \leq s_u, \forall u \neq v, \text{core}(u) = \text{core}(v), \text{pipe}(u) = \text{pipe}(v) \quad (4-10)$$

计算操作满足 $f_v = s_v + p_v$ ；搬运操作的完成时刻由 4.4.4 节的带宽共享规则决定。不同 Pipe、不同核心之间可以并行，同一核心内的 Cube 与 Vector 单元也因此可以同时工作，这正是题目提示的“核内矩阵单元与向量单元自动并行”。

4.4.2 Task 的释放时刻

记 f_p 为 Task p 的完成时刻。同核前一 Task 带来固定的切换等待：

$$r_s^{\text{seq}} = f_{\text{prev}(s)} + 100 (\text{存在同核前一Task}), r_s^{\text{seq}} = 0 \text{ 否则} \quad (4-11)$$

数据前驱带来的释放约束为

$$r_s^{\text{dep}} = \max \left(\{0\} \cup \{f_p + 1000 \cdot 1_{[a(p) \neq a(s)]} : p \in \text{Pred}(s)\} \right) \quad (4-12)$$

两者取大得到必要释放时刻：

$$r_s = \max \{r_s^{\text{seq}}, r_s^{\text{dep}}\} \quad (4-13)$$

有两处计费细节直接影响代价估计：100 周期的切换等待只对同核前一 Task 计一次，不在每条数据边上重复；1000 周期的跨核等待只在前驱与后继分属不同核心时计入。并集中的 0 使无前驱的 Task 也有定义。 r_s 只是必要条件，Task 内部的操作还须满足式(4-9)、式(4-10)与内存申请次序。

场景 B 与 L2 场景的跨核传输另有一条同步约束：

$$s(\text{COPY_IN}_e) \geq f(\text{COPY_OUT}_e) + 500 \quad (4-14)$$

e 为一条实际跨核传输。这同样是必要释放条件，源端写出完成加 500 周期并不意味着目标端立即发射。

4.4.3 私有容量约束

$$\sum_{t \in L_{c,m}(\tau)} b_t \leq C_m, m \in \{L1, \text{UB}\} \quad (4-15)$$

式(4-15)约束每个时刻的实际驻留集合，不是子图曾涉及的全部张量。官方 Step2 选择未来使用较晚、且非当前输入输出的驻留张量进行换出，与 Belady 最远未来使用原则[13]相近；由于张量大小、有效 DDR 副本和执行依赖不同，不能直接套用等大小分页下的最优性结论。换出已有后备副本时不一定复制数据，一次 Spill 也不必然新增两倍张量字节。

最大单张量比只描述输入尺度，无法推出运行时峰值。即使所有单张量均能单独容纳，多份数据的驻留重叠仍可产生 Spill；相反，逻辑活期重叠也不意味着所有数据必须一直物理驻留。第 6 章据实际 Spill 事件而不是仅据张量总量定位局部候选。

4.4.4 共享带宽的公平分配

为说明公平共享，先用连续工作量近似表示访问 DDR 的搬运。设池 p 的总带宽为 B_p ，非空在途集合为 $A_p(t)$ ， w_j 为独占该池时的剩余时间，则

$$w_j(t_j^{\text{issue}}) = \frac{b_j}{B_p}, \frac{dw_j}{dt} = -\frac{1}{|A_p(t)|}, f_j = \min\{t: w_j(t) = 0\} \quad (4-16)$$

即每个在途搬运分得 $B_p/|A_p(t)|$ 的速率；有搬运加入或完成时，评价器先按原并发数结算上一时段，再重算各搬运的预计完成时刻。三问的 DDR 池 $B_{\text{DDR}} = 60$ bytes/cycle；问题三另有只读 L2 读池 $B_{L2} = 250$ bytes/cycle，两池互不占用（第 7 章）。

式(4-16)是解释争用的连续松弛，完整评价还包含原版参考工作量取整、零字节与事件先后处理。本文不以该连续式替代官方执行。某次 COPY 的完成时刻取决于执行期间进入和离开同一带宽池的其他请求，故单次独占延迟不能直接相加得到整图 Makespan。

4.4.5 边界搬运的记账

新增 COPY 由两部分组成：切图产生的 Spill 前边界搬运，以及核内容量不足时插入的换出与换入，

$$D_{\text{added}}(P) = D_{\text{partition}}(P) + D_{\text{spill}}(P), D_{\text{partition}}(P) = \sum_{t \in V_T} D(t) - D_{\text{orig}} \quad (4-17)$$

其中 D_{orig} 为原始图已有 COPY 字节； P_t 、 C_t 分别为非 COPY 生产、消费单元集合。场景 A 的单元为子图，场景 B 为核心。原图输入没有非 COPY 生产者。令 φ_t 表示该张量有原始 COPY_OUT 消费者，或不存在非 COPY 消费者。以下记账按原版逐张量重建规则计算：

$$D^A(t) = b_t \left(|C_t \setminus P_t| + \sum_{p \in P_t} 1[\varphi_t \vee C_t \setminus \{p\} \neq \emptyset] \right) \quad (4-18)$$

$$D^B(t) = b_t \left(|C_t| \cdot 1[P_t = \emptyset] + |P_t| \cdot 1[\varphi_t] + 2 \sum_{p \in P_t} |C_t \setminus \{p\}| \right) \quad (4-19)$$

场景 A 中，生产 Task 把跨 Task 使用的张量写出一次，其他每个消费 Task 各读入一次；图输入被几个 Task 使用就要读入几次，这正是题面所说的“重复读取”。场景 B 中，同核消费不产生搬运，每一条跨核连接各对应一次写出与一次读入。两式直接给出两条后文要用的推论：

场景 A 的 $D_{\text{partition}}$ 只由划分 g 决定，与核心分配 a 、核序 π 无关，所以“保持划分不变的反馈重排”不会改变边界搬运（5.2.3 节）；

场景 B 的 $D_{\text{partition}}$ 只由每个操作的核心归属 $a \circ g$ 决定，与核内子图划分和次序无关，所以保持核归属不变的局部微批不会改变边界搬运（6.2.4 节）。

两式都不含 Spill，也不扣除问题三中只读 Cache 的命中，因此 D_{added} 是计划中的搬运请求量，而不是物理 DDR 的净流量（7.4.6 节）。

4.4.6 模型汇总

综合 4.2 至 4.4 节，三问共用的多核切图与调度模型为

$$\text{lex min}_{P \in F_X} (T_X(P), D_{added}^X(P)), X \in \{A, B, L\} \quad (4-20)$$

可行域由覆盖、唯一排布、联合无环和完整官方执行成功共同定义；必要的时序、容量、带宽与记账约束分别见式(4-2)至式(4-19)。

式(4-20)将方案目标与评价约束并列。其释放规则需按场景选用：A 使用式(4-11)至式(4-13)，B/L2 使用式(4-14)；边界记账分别使用式(4-18)、式(4-19)。这些必要约束不是独立于原版评价器的充分等价规划模型，实际排序、容量复用边与完整执行仍由评价程序决定。

4.5 问题的计算复杂性与下界

4.5.1 NP 难性

命题 4.1（计算调度抽象的 NP 难性）忽略搬运及启动开销，只保留相互独立、使用同一种计算 Pipe 的正整数时长操作时，两核最小完工时间问题包含 PARTITION 判定问题。

证明：设操作时长为 $p_1, \dots, p_n$ 。任意分配的完工时间等于两核负载和的较大者，存在完工时间不超过 $\frac{1}{2} \sum_j p_j$ 的分配，当且仅当这些整数可分为和相等的两组。PARTITION 为 NP 完全问题[14]（第 223 页）。因此，仅核心分配这一计算调度抽象就具有组合困难。这里不将“零字节 COPY”当作零耗时操作，也不声称该抽象归约已经证明固定官方程序的全部输入限制下具有同一复杂性结论。

复杂性分析说明穷举核心分配的规模风险，但不排除小实例精确求解。本文以有限候选搜索处理正式规模，再用下界判断具体方案还可能改进多少；下界与证书的有效性由下述资源和依赖推导独立保证。

4.5.2 与方案无关的计算下界

记 W_M 、 W_V 为两种计算 Pipe 的原始非负周期总和， L_{CP} 为只计原始计算周期的最长依赖路径。与源码一致，下界不使用零周期被提升为 1 后的有效周期；表 2-1 的有效周期统计另作输入描述。定义

$$LB_k = \max \left\{ \left\lceil \frac{W_M}{k} \right\rceil, \left\lceil \frac{W_V}{k} \right\rceil, L_{CP} \right\} \quad (4-21)$$

命题 4.2 对任意核数 k 下的任意可行方案 P ，三种评价下都有 $T(P) \geq LB_k$ 。

证明 每个核心只有一条 PIPE_M，同一核心的矩阵计算在其上串行（式(4-10)），全部 W_M 周期分布在 k 条 PIPE_M 上，至少有一条承担不少于 W_M/k 周期；周期为整数，故可取上整。 W_V 同理。沿任一依赖路径，计算操作须依次完成（式(4-9)），搬运耗时与各类等待均非负，故 Makespan 不小于 L_{CP} 。计算操作的实际耗时 $\max(1, \text{cycles})$ 不小于其周期数，下界仍然成立。□

记 r_v 为只计原始计算周期的最早开始时刻， q_v 为操作 v 完成后最长后继计算链的周期。对 $p \in \{M, V\}$ 与非负阈值 α, β ，令 $U(\alpha, \beta, p) = \{v : \text{pipe}(v) = p, r_v \geq \alpha, q_v \geq \beta\}$ 。仅当该集合非空时，这些操作都必须位于区间 $[\alpha, T - \beta]$ 内，且最多使用 k 条同类 Pipe，于是

$$T(P) \geq \alpha + \beta + \frac{1}{k} \sum_{v \in U(\alpha, \beta, p)} c_v \quad (4-22)$$

非空条件不可省略：空集合没有必须容纳的工作量，不能推出任意大的前后阈值之和小于完工时间。源码只在正周期操作对应的阈值上扫描。取零阈值可恢复负载项；将所有非空窗口界与计算关键路径取最大，得到全局窗口下界。

计算界及窗口界与具体划分、分核和核序无关，适用于对应核数下的全部方案。它们可用于总体间隙证书和运行时一致性检查，但在通信或等待占比较高时会偏松。未满足 3% 阈值不代表解差，只表明当前界不能认证该精度。

4.6 三个场景的关系

三个场景共用 4.2 至 4.5 节的全部结构，差别集中在 Task 的组织方式与由此引出的代价结构上。

表 4-2 三个场景的对照

维度	场景 A (问题一)	场景 B (问题二)	L2 场景 (问题三)
Task 组织	每个子图独立成 Task	每核全部子图合并为一个 Task	同场景 B
同核跨子图数据	必须经 DDR 中转	留在 L1/UB 中直接复用	同场景 B
跨核同步	前驱完成后 + 1000 cycles	写出完成后 + 500 cycles	同场景 B
主要代价	Task 边界搬运	核内驻留与容量溢出	缓存交互（命中与逐出）
评价配置	$Eval_A$	$Eval_B$	$Eval_B + 1 \text{ MiB}$ 只读 L2、250 bytes/cycle
求解策略差异	不使用局部微批	可用 Spill 触发的局部微批	同场景 B，另做配置效应与选解效应的分离分析

从 A 到 B 同时改变 Task 组织和同步规则，同核边界不再必然经 DDR，但容量溢出与跨核连接仍存在。B 到 L2 保持相同 Task 构造，仅增加只读缓存状态和独立读池。场景间均值对照因此是整体配置及选解变化的结果，不能直接作单一机制归因。

由此先划出两条边界，细节分别在第 6、7 章展开：场景 B 不能从场景 A 替换同步常数平移得到；L2 的收益必须把硬件配置效应与求解器选解效应分开报告。

4.7 求解框架总览

4.7.1 三层结构

本文的求解框架记为 R12，由三层构成。

候选生成层使用链块、依赖带、驻留组织和局部移动等结构信息；筛选层检查覆盖、联合无环、重复方案与适用下界；评价层调用原版程序，并按式(4-6)更新当前最好解。Treap 是候选构造的区间索引，不是独立的性能评价模型。

分层设计便于复用方案表示和择优规则，但不同模块仍通过当前解、剩余预算和官方时间线相互影响。替换某一模块后需要重新验证完整流程，不能仅凭接口相同就认定结果保持不变。

4.7.2 组件清单

各组件的设计依据与实现细节见 5.2、6.2、7.2 节，这里只交代职责。一次请求内，各组件按下列顺序运行，共用同一个软预算：

控制链：先运行基础构造器得到首个可行解；再尝试至多 6 个“减少活动核心”的候选；场景 A 随后生成依赖带候选（宽度 4、8、2、16）。依赖带候选由安全链收缩、依赖带弱连通分组与追加式分核构成，追加式分核沿统一的合法拓扑序推进，不会由构造自身引入等待环。

反馈重排：利用官方评价返回的时间线修正代理时长后重新安排。场景 A 为“划分 g 不变、按实测 Task 时长重新分核与排序”，划分不变意味着边界搬运结构不变；场景 B 与 L2 场景为沿官方时间线上关键链的至多 4 个局部移动。

分量家族：对活动核数 $m \leq k$ 与驻留组织参数枚举候选，至多评价 6 个新候选（场景 B 与 L2 场景的主要结构候选；场景 A 同样运行，但以 Task 激活下界剪枝）。

跨配置重评价（仅 L2 场景）：在同一请求内独立求解一个场景 B 方案，并按 L2 配置重新评价，成本计入该请求。

插入式候选：用确定性区间索引加速“最早可行位置”的查找。它只加快同一条插入规则的执行，不改变判定结果。

Spill 触发的局部微批：仅当当前解确有容量溢出时才诊断并重排（场景 B 与 L2 场景；场景 A 因不存在驻留复用收益而不使用）。

第 1 至 4 项的每个阶段开始前都检查近优认证条件式(4-23)（基础构造在评价每个候选之前检查），成立即跳过；第 5、6 项不受这一门控，只受剩余预算约束。每个组件产生的候选都走同一条处理链：覆盖与联合无环检查、哈希去重、下界剪枝、官方评价、字典序择优。三个场景各自的执行顺序与门控位置，分别画在 5.2.5 节、6.2.5 节与 7.2.4 节的流程图中；各组件的参数汇总于表 4-3，全部取自求解器源码，在 1400 个配置格的实验中保持不变。

表 4-3 R12 算法参数一览

模块	参数	取值	说明
全局	单请求软预算	600 s	case_087 的场景 A 四格补跑用 1800 s
全局	近优认证阈值	$T \leq 1.03 \cdot LB$	仅跳过受门控控制阶段；外层插入与微批仍可运行
控制链	基础构造的单次评价上限	120 s	同时做下界剪枝
控制链	减少活动核心的候选	至多 6 个	三个场景
控制链 (A)	依赖带宽度 w	4、8、2、16	四种粒度
控制链 (A)	分组软目标	2048 个操作	粒度控制参数，不是容量上限
反馈重排 (B/L2)	关键链局部移动	至多 4 个	仅用于不超过 10000 个操作的图
分量家族	活动核数 m ；驻留组织 target	$m \leq k$ ；0、512、2048	至多评价 6 个新候选，单次 30 s

模块	参数	取值	说明
插入式候选	生成时限；评价上限	30 s；120 s	场景 A 的日历间隔为 100
局部微批 (B/L2)	触发条件	Spill 新增>0；张量不 小于容量的 1/4；前后 使用距离不超过 8	见式(6-4)
局部微批 (B/L2)	窗口	4、8 个子图；至多 16 个窗口；每窗至多 128 个原计算操作； 至多 2 个候选	见式(6-5)
局部微批 (B/L2)	诊断时限；单候选评 价上限	40 s；45 s	诊断在独立进程中进行
跨配置重评价 (L2)	B 方案求解时限；评 价上限	至多 180 s；40 s	成本计入同一请求

4.7.3 停止准则与两条性质

近优判断与程序终止需要分开。令当前成功方案为 P^* ， $LB>0$ 为相应场景、核数下适用的全局计算界或窗口界。若

$$T(P^*) \leq 1.03 \cdot LB \quad (4-23)$$

记真正最优执行时间为 T_{opt} 。由 $LB \leq T_{opt} \leq T(P^*)$ ，可得 $0 \leq [T(P^*) - T_{opt}] / T_{opt} \leq T(P^*) / LB - 1 \leq 0.03$ 。这只是满足条件实例的主目标证书，不代表所有实例均达到 3%，也不认证同一完工时间下的最少搬运。实现据此跳过受门控的控制阶段；外层插入及微批仍可能使用剩余预算，不能写成全程序立即停止。

这套框架还有两条性质。其一是同次请求内不变差：候选只有通过官方评价且字典序严格更优，才会替换当前解，所以最终输出不会劣于流程起点的控制解。该性质成立于同一次请求、同一版本、同一机器、同一超时设置之下，不跨请求成立。

其二是确定性与可复现：索引的平衡优先级由固定的整数散列生成，候选按确定性名称排序，全流程不用随机种子，每个结果都与方案、官方结果和输入的 SHA256 哈希绑定。各阶段受墙钟预算约束，预算没有截断时，同一输入重复运行得到相同方案；某阶段若因预算或超时被截断，评价到的候选数可能随机器负载变化，最终方案也可能不同。本文全部结果都保留了实际运行的方案哈希，复查以存档方案为准。

4.8 小结

三问共用方案、可行性检查与字典序目标，以原版评价确定实际执行时间。全局下界用于认证，固定方案下界用于淘汰；代理优先级用于提出候选，三者不可混用。后续按场景说明 Task 粒度、驻留和缓存状态如何进入候选设计。

模型的保证包括特定构造的联合无环、核心归属不变时的边界记账不变，以及满足下界条件时的主目标间隙上界。一般性最优性、跨机器逐字节复现和测试集外性能均不在保证范围内。

按此框架，三个场景在五核下相对基准的平均加速比分别为 3.743、4.131、4.219，相对 C3 的逐图耗时降幅平均分别为 43.48%、34.49%、31.41%。这些结果的完整分布、代价分解、退化记录与边界条件，分别在第 5、6、7 章给出。

4.9 下界的适用域与可核验判定

4.9.1 同一个不等式为何不能承担所有职责

全局下界在固定图与核数下对全部合法方案成立，因此可以约束真正最优值。固定方案下界则只约束给定划分和核心归属的方案；改变归属后，各核负载和必需搬运都可能变化。将后者当作全局最优值的下界，会把“这个候选的资源很紧”误写成“所有方案都没有改进空间”。

设当前成功方案的时间为 T^* 。对于待评候选 P ，若已证明 $L(P) \leq T(P)$ 且 $L(P) > T^*$ ，则该候选不可能在主目标上胜出，可以跳过。若 $L(P) = T^*$ ，仍不能淘汰：它可能主目标持平而新增 COPY 更少。对活动核数至多为 m 的整个候选族，则须使用对该族全部方案成立的 LB_m ；其用途是类别淘汰，而不是仅对其中某一份方案的判断。

4.9.2 固定方案的乐观带宽界

设固定方案在 Spill 插入前的计划读入、写出量为 R 、 W 。不含 L2 时，全部这些工作均要经过共享 DDR，忽略释放时间和其他竞争只能使所需时间减少，因此总传输工作量给出下界。L2 场景中，所有写出仍必须经过 DDR；将所有读取乐观地视为可以自由分配到两个池，并忽略首次未命中、FIFO 淘汰及容量，可以得到更弱但安全的资源松弛。

$$L_{copy}^{A/B}(P) = \lceil \frac{R+W}{60} \rceil \quad (4-24)$$

$$L_{copy}^L(P) = \max \left\{ \lceil \frac{W}{60} \rceil, \lceil \frac{R+W}{60+250} \rceil \right\} \quad (4-25)$$

第一项来自写出只能使用 DDR；第二项来自两个独立池在任意持续时间内能够提供的总服务量上限。真实执行还要满足读池资格、Pipe 占用、跨核释放和取整规则，因而该式不是对实际命中率的估计。最终固定方案界还取各核计算 Pipe 负载、计算关键路径与带宽界的最大值。

4.9.3 非空窗口的推导与示例

对窗口集合 $U(\alpha, \beta, p)$ 中的任一操作，原依赖使它不能早于 α 开始；它完成后还至少有 β 的计算必须顺序接续。因此，该集合内全部计算只能占据长度为 $T - \alpha - \beta$ 的区间。 k 条同类流水线在该区间最多提供 $k(T - \alpha - \beta)$ 的计算容量，将集合工作量与这一容量比较即得式(4-22)。

作为代数示例，设两核下某个非空窗口的前缀和后缀阈值分别为 10 和 8 周期，窗口内同类计算总工作量为 25 周期，则任何可行执行至少需要 $10+8+\lceil 25/2 \rceil = 31$ 周期。这里的 25 不是图中某一次真实测量；它只演示“局部必需工作量加两端依赖”的计算方法。若集合为空，该例的工作量约束并不存在，不能直接把 10 和 8 相加作为新下界。

4.9.4 条件证书与程序路径

以 $LB > 0$ 表示对全部方案成立的全局界，则当前解与真正最优值之间的相对差距满足

$$0 \leq \frac{T(P^*) - T_{opt}}{T_{opt}} \leq \frac{T(P^*)}{LB} - 1. \quad (4-26)$$

例如，假设一个实例的全局界为 1000 周期、当前解为 1025 周期，则可认证的差距上限为 2.5%；若当前解为 1500 周期，则只能给出 50% 的上限。后一个界可能很松，不能据此判断实际解真的比最优值慢 50%。这两个数值例子均为条件演示，不计入 100 张图的实验结果。

代码中的近优门控只是跳过其所覆盖的控制阶段。外层插入和微批还有独立的触发与剩余预算检查，不能由证书成立推断程序已经退出。本稿不汇报未经逐请求日志确认的证书触发率；可核验对象是每次实际保存的界、成功方案和门控记录。

5 问题一：场景 A 下的多核切图与调度

场景 A 要求把计算图切成若干子图，每个子图独立成为一个 Task，再把 Task 分配到多个核心并确定核内次序。本章把官方评价器作为确定性的黑箱目标函数，给出“结构化候选生成一下界剪枝一整机评价一字典序择优”的求解框架，并在 100 张计算图、2 至 5 核共 400 个配置格上给出完整结果。五核相对整图单核的平均加速比为 3.743，中位数 4.130，最小值 1.202；相对固定构造对照基线 C3，五核逐图耗时平均下降 43.48%。

5.1 问题分析与数学模型

5.1.1 问题分析

场景 A 的主要权衡是 Task 粒度与放置。较细划分可能增加重复读入和启动次数，较粗划分可能压缩并行空间并加重单 Task 驻留压力。操作数均衡可以作为构造信息，但不是最终优化目标；候选必须同时考虑资源组成、依赖和通信。

本文按图结构构造有限候选，再调用官方评价，避免将静态时长代理直接作为最优性依据。精确规划或其他搜索方法并非原则上不适用；当前路线的选择受评价成本和实现预算制约。本章保留全部 400 个配置格的分布、COPY 分解、退化与预算例外。

5.1.2 场景 A 的模型

场景 A 的决策变量、可行域与目标完全沿用第 4 章：方案 $P=(g,a,\pi)$ 见式(4-1)，覆盖性、唯一排布与联合无环见式(4-2)、式(4-3)，目标为式(4-4)的 $T_A(P)$ ，择优按式(4-6)的字典序， F_A 为满足方案规则且官方执行成功的方案集合。场景 A 特有的约束是 Task 的释放规则式(4-11)至式(4-13)：同核前一 Task 完成后等待 100 cycles，跨核前驱完成后等待 1000 cycles，并且每个 Task 开始执行时核内缓存为空，其全部输入都要从 DDR 读入。问题一的模型因此是式(4-20)在场景 A 下的实例：

$$\text{lex min}_{P \in F_A} (T_A(P), D_{added}^A(P)) \quad (5-1)$$

场景 A：每个子图独立成为 Task，释放规则见式(4-11)至式(4-13)，边界记账见式(4-18)。

联合无环这一条在场景 A 中尤其要紧，因为一个核心上往往排着几十乃至上千个 Task。当核心 0 的队列写成 S_3 先于 S_0 时， $S_0 \rightarrow S_1 \rightarrow S_3 \rightarrow S_0$ 就形成了等待环，尽管每条数据依赖本身都没有问题（图 5-1 的反例，结构示意）。核序合法性必须在式(4-3)定义的并图上检验。




图 5-1 数据依赖与核心队列的联合无环约束（合法例与反例）

场景 A 在各 Task 内执行容量检查，核内顺序与 Spill 由官方阶段确定。算法仅控制划分、核心归属和核序。以官方程序评价能够保持报告口径一致，但不提供一般最优性保证；满足全局下界条件的实例另有第 4.7.3 节的间隙证书。

5.2 求解算法

5.2.1 求解路径与方法选择

先由链结构与依赖深度生成不同粒度，再沿合法拓扑次序追加分核，最后用官方反馈筛选与调整。受门控的控制阶段达到近优后跳过，外层索引插入仍可在剩余预算内执行。每次请求从原图开始，不读取历史优胜方案。

两端独占是本文采用的链收缩充分条件：若收缩后出现经过新块的环，则原 DAG 中存在绕过该边、连接其两端的另一条路径，与源端唯一后继或目标端唯一前驱矛盾。因此收缩保持商图无环。该证明只涉及结构；合并可能改变外部输入时点、容量压力和核内排布，不能推出 Makespan 必不增加，也不把该条件称为性能不劣的最弱条件。

5.2.2 安全链收缩与依赖带分带

沿拓扑序扫描两端独占边并合并为链块，直至遇到分支。每个非 COPY 操作恰好属于一个链块；后续候选以链块为基本单位。无环性由上述结构条件保证，性能由完整评价确认。

链块按依赖深度分带：

$$\text{depth}(C) = 1 + \max\{-1 \cup \{\text{depth}(C') : C' \in \text{Pred}(C)\}\}, \text{band}(C) = \lfloor \text{depth}(C)/w \rfloor \quad (5-2)$$


无前驱的链块深度为 0。宽度 w 依次取 4、8、2、16，生成四种粒度的候选。带内不是把整条带并成一个 Task，而是只沿同带链块之间的依赖做图遍历，求出带内的弱连通分量；过大的分量再按原链块拓扑顺序切成连续段，每段不超过 2048 个操作（粒度控制的软目标，不是物理容量上限）。

这样构造保证了三件事：跨带依赖只指向后续带，带内不同弱连通分量之间无依赖，连续拓扑段之间也只向前。图 5-2 以 $w=2$ 的概念例展示完整流程：带 2 含两个互不相连的分量，因此形成 S_2 与 S_3 两个独立子图而非一个（结构示意，示意规模不触发 2048 操作的软分组目标）。

(a) 安全链：源出度=1，目标入度=1



(b) 链块深度分带： $\text{band}(C) = \lfloor \text{depth}(C)/2 \rfloor$



(c) 子图结果：带内按弱连通分量合并，不把整带强行并为一个Task




图 5-2 安全链与依赖带如何形成子图（示意图）

5.2.3 追加式分核与反馈重排

得到子图之后，用一个与场景 A 规则一致的代理时长来决定分核。记子图 s 的矩阵、向量计算周期为 $W_M(s)$ 、 $W_V(s)$ ，子图内部只计计算周期的最长路径为 $L_{\text{int}}(s)$ ，从外部读入与向外写出的字节为 B_s^{in} 、 B_s^{out} ，则代理时长为

$$d_s = \max \left\{ W_M(s), W_V(s), L_{\text{int}}(s), \frac{B_s^{\text{in}} + B_s^{\text{out}}}{60} \right\} \quad (5-3)$$

取最大值而不是求和，对应的是核内 Cube、Vector 与搬运 Pipe 可以并行（4.4.1 节），题目提示的“两个计算单元之间的负载均衡”由此进入代理。子图的尾长定义为

$$\text{tail}(s) = d_s + \max \left(\{0\} \cup \{1000 + \text{tail}(s') : s' \in \text{Succ}(s)\} \right) \quad (5-4)$$

尾长用于就绪候选的优先级排序。统一加 1000 是跨核等待的代理处理，不是任意放下剩余时间的严格下界。选择尾长最大者后，对各核心估计最早开始时刻：

$$\hat{r}_c(s) = \max \left\{ \ell_c + 100 \cdot \mathbf{1}_{\{\pi_c \neq \emptyset\}}, \max_{p \in \text{Pred}(s)} \left(\hat{f}_p + 1000 \cdot \mathbf{1}_{\{a(p) \neq c\}} \right) \right\} \quad (5-5)$$

无前驱时式(5-5)内层最大值取 0。 ℓ_c 为核心队尾的估计完成时刻， $\hat{f}_p$ 为前驱估计完成时刻。算法将子图追加到估计完成最早的核心，平局按负载和编号确定。该构造使用与场景 A 释放规则相对应的代理，但实际时刻仍需官方评价。

命题 5.1 (追加式分核的联合无环性) 若划分 g 的子图依赖图无环（依赖带候选满足这一点，见 5.2.2 节），则按式(5-5)逐个追加得到的核序 π 满足联合无环条件式(4-3)。

证明 记子图的追加次序为 σ 。子图只在全部前驱都已放置后才进入就绪集合，所以每条子图依赖边 (s', s) 都满足 $\sigma(s') < \sigma(s)$ ；每个核心的队列按追加先后排列，所以每条核序边 (s, s^+) 也满足 $\sigma(s) < \sigma(s^+)$ 。并图中的每条边都指向 σ 值更大的顶点，沿任何路径 σ 严格增加，不可能回到起点，因此并图无环。□

反馈重排沿用同一追加过程，只替换代理时长，命题 5.1 对它同样成立；分量家族、插入式候选等其他构造不在命题范围内，仍逐个显式检查并图无环。

反馈重排保持划分不变，分别以核内排布时长或多核 Task 实测时长替换代理，再执行尾长排序和追加分核。由式(4-18)，Spill 前边界字节保持不变；负载、释放与争用时序仍会变化，反馈时长也不一定能原样迁移到新放置。因此重排后必须重新评价，不预先认定其改善。

5.2.4 插入式候选与 Treap 区间索引

剩余预算用于构造插入式候选。它以 5.2.2 节的安全链链块为子图，沿用静态 DAG 调度中“优先级排序+插入式最早完成”的构造规则[6]。链块 u 的优先级为

$$\text{rank}(u) = d_u + \max \left(\{0\} \cup \left\{ \sigma + \frac{2b_{uv}}{60} + \text{rank}(v) : v \in \text{Succ}(u) \right\} \right) \quad (5-6)$$

其中 d_u 按式(5-3)计算， σ 为跨核同步常数（场景 A 取 1000，场景 B 与 L2 场景取 500）， b_{uv} 为 u 流向 v 的张量字节， $2b_{uv}/60$ 估计一次写出加一次读入的 DDR 时间。链块按优先级从大到小依次放置：对每个核心，先由跨核前驱的完成时刻加 σ 与搬运估计求出就绪时刻 ready ，再在该核心的候选日历上找满足就绪时刻与持续时间的最早可行位置，最后放到完成最早的核心。场景 A 的日历在相邻 Task 之间保留 $\text{gap}=100$ 的切换间隔，场景 B 与 L2 场景取 0。在起点为 low 、终点为 high 的空闲区间中，判定式为


$$t = \max(\text{ready}, \text{low}), t + \text{duration} + \text{gap} \leq \text{high} \quad (5-7)$$

朴素做法是按时间顺序逐个扫描区间；当日历中区间数量增长时，这种扫描会反复检查大量明显放不下的短空隙。算法改用确定性 Treap[15]维护空闲区间，每个节点额外记录子树内的最大可用跨度 span 与最右边界 rightmost ，据此整体跳过不可能命中的子树：

$$\begin{aligned} \text{span} + 16 \text{ulp}(\cdot) &< \text{need} \text{ or} \\ \text{rightmost} + 16 \text{ulp}(\cdot) &< \text{ready} + \text{need}, \text{need} = \text{duration} + \text{gap}. \end{aligned} \quad (5-8)$$

浮点容差用于避免边界误剪枝，通过子树筛选后仍需按式(5-7)检查首个可行空隙。在精确算术下，正确维护索引得到的首个可行位置与顺序扫描一致；固定散列优先级不自动继承随机 Treap 的期望深度保证。图 5-3 仅说明虚拟日历查询，不能当作官方真实时间线。

(a) 同一候选日历: ready=5, duration=5, gap=1



(b) 增强索引: 用子树摘要排除不可能容纳任务的区间




图 5-3 Treap 区间索引: 相同插入规则, 更少无效搜索 (示意图)

场景 A 不启用本文的局部微批: 该模块以同核跨子图驻留复用为设计目标, 而场景 A 的相邻 Task 不保留此类驻留。细分仍可能改变其他执行因素, 但本文没有为场景 A 验证这一路线, 因此不将其列为已启用机制。

5.2.5 求解流程与停止准则

问题一的完整求解流程见图 5-4, 其中红色虚线框标出近优门控的作用范围: 减少活动核心、依赖带、反馈重排与分量家族四个阶段开始前都要检查当前解是否已被下界认证, 插入式候选则不受这一门控。与流程图对应的步骤如算法 5-1。




图 5-4 问题一（场景 A）的求解流程

算法 5-1 R12 场景 A 求解流程

输入：原图、固定配置、核心数和 600 秒软预算。输出：已成功评价的最好方案及其官方结果；无成功方案则输出失败状态。

- 1 运行基础构造和控制链，保存首个成功方案。
- 2 依次考虑减少活动核心、依赖带、反馈重排与分量家族；近优门控成立时跳过受控阶段。
- 3 对当前阶段的候选检查覆盖与联合无环，去重并计算适用的固定方案下界。
- 4 下界严格大于当前 Makespan 时剪枝；等于时仍保留次指标改善机会。
- 5 其余候选在剩余预算内运行完整官方评价；成功且字典序更优才更新。
- 6 控制阶段结束后，预算允许时构造 Treap 插入候选，并重复上述检查与评价。
- 7 输出两字段方案和来源记录；预算耗尽或全部可执行阶段结束后返回。

近优证书限制控制阶段，不直接终止第 6 步的外层插入。若没有成功方案，保留失败记录，不填零、不删图。

部分候选阶段还使用 Task 激活下界：将各 Task 的乐观时长代入必要释放约束，得到当前方案的完成时间下限。它用于淘汰当前候选，不作为全局最优值下界。现有程序另对适用的全局下界进行运行时断言；一次自检未触发不能替代独立的评价器实现。

5.2.6 结构性质、确定性与复杂度

先说三条结构性质。同一次请求内，候选只有通过官方评价且字典序严格更优才会替换当前解，所以最终输出不会劣于第 2 行的控制解；这一不变差性质只在同一次请求、同一版本、同一机器、同一超时设置下成立。

Treap 的平衡优先级由固定整数散列生成，候选按确定性名称排序，全流程不用随机种子；预算未截断时同一请求重复运行得到相同方案，受预算截断的阶段则可能随机器负载评价到不同数量的候选（4.7.3 节）。

允许空核心意味着增加配置核心数不强制使用新核心；在不改变其他规则的理想可行集比较中，旧方案可嵌入新配置。但各核数独立开展有限搜索，实际终点可能非单调，例如附录 A 中 case_039 的场景 A 四核至五核耗时增加。该现象与 case_062 相对 C3 的退化属于不同对照。

再看求解成本。一次请求的墙钟成本可分解为

$$C_{\text{solve}} = C_{\text{index}} + C_{\text{generate}} + C_{\text{bound}} + \sum_{j=1}^K C_{\text{official}}(G, P_j, A) + C_{\text{IO}} \quad (5-9)$$

链收缩和拓扑扫描为线性图遍历，带内分量分组另包含排序；追加式分核使用就绪堆并逐核扫描前驱。索引查询的最坏访问量仍可能达到全部区间数。随机 Treap 的期望对数深度[15]依赖随机优先级假设，本文固定散列实现不能直接据此获得逐输入最坏保证。总成本还需计入实际调用的完整官方评价。

$$O((|U|+|E|)\log|U|+k(|S|+|E_s|)+|S|\cdot q_m), q_m \leq m \quad (5-10)$$

其中 q_m 为单次插入查询访问的节点数。各部件的复杂度汇总于表 5-1。

表 5-1 R12 各部件的时间复杂度

部件	复杂度	说明
安全链收缩与链块深度	$O(U + E)$	沿拓扑序一次遍历、一次动态规划
带内弱连通分量与切段	$O(U + E + U \log U)$	同带图遍历，按拓扑秩排序后切段
尾长优先的追加式分核	$O(S \log S +k(S + E_s))$	就绪堆，逐核估计最早开始时刻
Treap 插入候选	$O(S \cdot q_m), q_m \leq m$	固定散列不自动保证随机模型的期望深度
下界计算	计算界线性；窗口维护 $O(n \log n)$	与方案无关，每请求算一次
官方评价	C_{eval} ，随图规模增长	主导项，一次请求共 K 次

不过，这些并不是求解的总复杂度。由式(5-9)，总成本由 K 次官方评价主导：每次官方评价都要对全部 Task 完整运行核内调度与多核事件模拟。 K 由剩余预算与单次评价上限共同决定，在预算固定时随单次评价成本反向变化。本测试集的非 COPY 操作数范围为 552 至 35705，大图评价一次就要消耗可观的预算，能试的候选数自然少；case_087 是这一机制的极端情形（5.5.5 节）。Treap 索引优化的是候选构造项，主导项是官方评价求和项，因此不能用某个子模块的复杂度代表整套算法。

5.3 实验设置

实验在题目给定的 100 张正式测试计算图上进行，核数取 2 至 5，共 400 个配置格。硬件参数全部使用官方配置（表 3-2），单次请求软预算 600 秒。加速比按式(4-7)以 REF 为分母逐图计算后取平均，单核加速比按定义为 1；相对 C3 的比较按式(4-8)逐图计算，C3 的定义与性质见 4.3.3 节，本章及后两章沿用。

5.3.1 对比实验的设计

本文从四个层次组织比较：题目固定参考、同输入构造基线、同请求阶段增量及跨场景结果。它们回答不同问题，但并非统计独立，也不能代替等预算强基线实验。各项结论按其比较范围解释。

(1) 题目基准 REF。即原版核内调度算法在整图单核上的结果，由题目指定，不含本文的任何设计，回答“与不做多核切分相比快了多少”。

(2) 固定构造对照 C3。该基线合并链结构、平衡就绪层负载，并按静态等待与边界代理分核。它可独立复现，适合比较相同输入下的终点方案质量；但没有等预算强基线实验，不能由“能独立运行”推出基线足够强。

(3) 同请求阶段记录。按控制链、插入后、微批后记录同一请求的方案质量，刻画既定执行顺序下的阶段增量。五核 B 控制阶段平均加速比为最终值的 98.6%，该比值不是因果贡献率，也不替代独立关闭模块的等预算消融。

(4) 跨场景对照。比较同一框架在场景 A、场景 B、L2 场景下的表现（7.6 节），回答代价结构改变时同一套方法如何响应。

5.4 主要结果

表 5-2 场景 A 逐核主结果（每格 100 图）

指标	2 核	3 核	4 核	5 核
平均加速比	1.855274	2.560587	3.197302	3.743282
中位加速比	1.963848	2.768124	3.459641	4.130239
最小加速比	1.045561	1.113337	1.171898	1.202340
均值新增 COPY/MiB	13.2023	14.5546	14.8736	14.7913
其中边界/MiB	11.9502	13.1640	14.4942	13.5574
其中 Spill/MiB	1.2521	1.3906	0.3794	1.2340
墙钟中位/s	25.6756	20.8955	18.8994	21.4839
墙钟 P95/s	376.9549	399.0524	465.8099	470.6481

注：加速比为逐图比值的算术平均；1 MiB = 1048576 bytes；P95 为经验最近秩；墙钟含候选构造、评价与 I/O。表中保留完整精度，正文取四位有效数字。

题目要求的 1 至 5 核平均加速比折线见图 5-5，一核点按定义取 1。平均加速比随核数单调上升，从两核的 1.855 增至五核的 3.743。每增加一核的边际增量在缩小，依次为 0.705、0.637、0.546，方向与共享带宽的物理限制一致；本章未做带宽敏感性实验，不把递减完全归因于带宽。




图 5-5 问题一：场景 A 下 1 至 5 核平均加速比折线图（R12 完整流程与 C3 基线）

中位数在各核数上都高于均值（五核 4.130 对 3.743），说明存在少数低加速比用例拉低均值；这些用例的最小值在 2 至 5 核都来自同一张图 case_064。最小加速比一列给出分布下沿：五核最差的一张图仍有 1.202，400 个配置格中没有出现比单核参考更慢的情况。

核数扩展趋势与 C3 的差距随核数拉大（图 5-5）。C3 曲线是相同输入与评分口径下的事后对照，两者搜索成本不同。

5.5 结果分析

5.5.1 与 C3 的逐例比较

平均曲线的差距需要落到逐例层面。按式(4-8)逐图计算耗时降幅，结果见表 5-3。

表 5-3 场景 A 相对 C3 的逐例对照（每格 100 图）

核数	加速比均值 T_{C3}/T_{R12}	逐图降幅均值	更快 / 持平 / 更慢	更快但 COPY 更高
2	1.398926	25.0121%	92 / 7 / 1	4
3	1.622964	32.9501%	91 / 7 / 2	2
4	1.828961	38.9334%	92 / 4 / 4	3
5	2.053093	43.4760%	93 / 5 / 2	2

注：C3 为同输入、同评分口径的事后对照，非等搜索预算消融；时间为官方 cycles，非求解墙钟。

五核逐图降幅均值 43.48%。这是逐图先算降幅再平均的结果，不是求解程序的墙钟下降率；依赖带、反馈重排、分量家族与插入式候选在同一次请求中共同竞争预算，该数值不能归因于其中某一个模块。

胜负分布比均值更有信息量：五核为 93 例更快、5 例持平、2 例更慢。平均优势不等于逐例必胜，这在任何核数上都成立。8.3 节对这组配对结果做了符号检验。

5.5.2 退化配置与 case_062

400 个配置格中有 9 个相对 C3 更慢：case_062 在 2 核为+22.97%、3 核为+40.94%；case_085 在 3 核为+0.997%；case_016、case_024、case_051、case_082 在 4 核分别为

+0.25%、+0.24%、+0.24%、+0.21%；case_028 与 case_090 在 5 核分别为 +0.60%、+0.16%。

除 case_062 外，另外 7 个相对 C3 退化配置的幅度均在 1%以内。case_062 的低核数退化明显更大，因此保留其粒度和记账明细，分别说明已确认的终点差异与尚未确认的搜索原因。

逐例数据可以部分检验这一现象的来源（表 5-4）。

表 5-4 case_062 在场景 A 各核数下的最终方案

核数	Makespan/ cycles	C3 Makespan/cy cles	Task 数	每 Task 操作数中 位	新增 COPY/ bytes	C3 新增 COPY/bytes
2	1976451	1607247	4361	8	13393920	13393920
3	1593547	1130638	4361	8	13393920	13393920
4	764940	889045	293	71	897024	13393920
5	619333	746374	293	71	897024	13393920

注：Task 数与每 Task 操作数来自最终方案；C3 的 Task 数未记录。

两组核数的最终方案属于完全不同的粒度。2 核与 3 核时 R12 选中的方案有 4361 个 Task，每个 Task 中位只有 8 个操作，新增 COPY 与 C3 完全相同；4 核与 5 核时选中的是 293 个 Task 的粗粒度方案，新增 COPY 降为 897024 bytes，只有前者的约十五分之一，并反过来比 C3 快。细粒度方案的代价可以从释放规则直接估出下限：2 核时最忙的核心至少排有 2181 个 Task，按式(4-11)仅同核切换等待就不少于 218000 cycles，约占该方案 Makespan 的 11.0%；293 个 Task 的方案在 4 核时这一下限只有 7300 cycles。

case_062 在低核数选择了 4361 个 Task 的方案，在高核数选择 293 个 Task 的方案。细粒度方案存在显著启动代价，但仅凭终点表不能确认低核数是否生成、评价或因预算截断而错过粗粒度候选，更不能证明粗粒度方案放在低核数必然更好。它与 C3 搬运总量相同也不代表内部划分相同，具体成因仍需候选阶段日志。

全部 400 格的对数比值热力图与 9 个退化配置的逐项定位见图 5-6；该图保留了完整色标与全部负例，避免用均值掩盖。




图 5-6 场景 A：全量性能变化与退化定位

5.5.3 新增搬运的构成

新增 COPY 由两个来源合成：切图产生的 Task 边界搬运，以及官方核内调度阶段因容量不足插入的 Spill，两者之和等于官方报告的新增 COPY 字节字段。

边界搬运在各核数上都是主导项，占比在九成以上。五核平均新增 14.79 MiB，其中边界 13.56 MiB、Spill 1.234 MiB。四核的 Spill 均值明显更低（0.3794 MiB），而边界均值在四核最高（14.49 MiB）。这一组合在数值上自洽：切分更细时单个 Task 的驻留压力下降，Spill 随之减少，代价是边界搬运上升。不过这只是四个观测点上的一次共变，样本不足以支撑一般性结论。

图 5-7 把两类来源分开堆叠，并统计各核数下实际发生 Spill 的图数：2 至 5 核分别为 25、25、20、26 张。Spill 不是普遍现象，而是集中在部分用例上，因此均值里那 1 MiB 多的 Spill 并不代表典型用例。




图 5-7 场景 A：新增 COPY 的来源

5.5.4 并行与搬运的权衡

字典序目标先比 Makespan 再比 COPY，意味着算法会接受“更快但搬运更多”的方案。五核下有 2 例在比 C3 更快的同时增加了官方 COPY 记账，因此不能把全部加速解释为通信量下降。

表 5-5 并行—搬运权衡案例（五核）

用例	Makespan/cycles	新增 COPY/bytes
case_002	58180	82944
case_005	69060	2483610

注：两例均比 C3 更快且 COPY 更高；展示的是最终选解的终点值，非控制单一变量的对照。

两例说明更快方案可能付出不同的新增搬运代价。跨图的时间与字节差异同时受到输入规模、依赖和方案变化影响，不能从两张图的终点值推出其中一张“必须”增加多少搬运才能加速。本文将其作为主次指标冲突实例，而不是受控因果比较。

5.5.5 预算例外

case_087 是唯一在 600 秒软预算内没有产生顶层成功结果的用例，A2 至 A5 四个配置全部如此；该组单独使用 1800 秒预算重跑后均告成功。

表 5-6 预算例外完整记录

用例	场景/核数	首次预算	补跑预算	补跑墙钟/s	Makespan/cycles
case_087	A2	600 s 首次无成功	1800 s	819.1333	2093249
case_087	A3	600 s 首次无成功	1800 s	752.9736	1483711
case_087	A4	600 s 首次无成功	1800 s	910.7309	1204070

用例	场景/核数	首次预算	补跑预算	补跑墙钟/s	Makespan/cycles
case_087	A5	600 s 首次无成功	1800 s	1036.1133	1038529

注：首次 600 秒的失败结果予以保留，不以补跑结果替换来源记录；仅本组使用 1800 秒预算。

四次补跑实际用时 753.0 至 1036.1 秒，均超过 600 秒。这说明存档流程在这些请求中未满足题面建议时效；没有不同负载下的重复试验，不能排除机器负载和候选阶段超时对首次失败的影响。图 5-8 展示补跑方案真实时间线，空白不自动归因于某一种瓶颈。




图 5-8 困难案例 case_087：五核执行时间线

五核 A 请求墙钟中位数 21.48 秒、P95 为 470.6 秒、最大 1036.1 秒，呈现长尾。除 case_087 的四格外，其余 396 个 A 配置在常规预算内得到结果。题面建议单例 5 至 10 分钟，不能将 600 秒写成对全部用例均已达到的时间保证。

5.5.6 校验范围

全部输出方案均通过官方评价器执行，并在覆盖性、周期数、核心归属、依赖关系、Pipe 占用与 COPY 记账等方面完成核查；全部 400 个结果均不低于式(4-21)的下界。本章未另行独立重建全部带宽与容量的活期状态，相关校验属于内部自检。

5.6 小结

联合选择 Task 粒度、核心归属与执行顺序，可以在全部 400 个配置格上取得稳定的多核加速：五核平均加速比 3.743、中位 4.130、最小 1.202，相对 C3 的逐图耗时平均下降 43.48%。三项决策必须联合选择，任何一项单独最优都不能保证总体执行时间最短。

算法以链收缩、依赖带和反馈重排生成候选，以官方评价择优；Treap 加速插入位置查找。近优证书只跳过受门控的控制阶段，外层插入仍按剩余预算决定是否运行。

平均收益不代表逐例必胜：400 格有 9 格慢于 C3，case_062 的低核数差异尚未完成阶段归因；五核有 2 图更快但新增 COPY 更多；case_087 的四格需要单列的 1800 秒补跑。全部结果保留原预算与来源，不将难例从均值中删除。

6 问题二：场景 B 下的同核驻留与多核调度

场景 B 合并同核全部子图，允许跨子图驻留复用，但跨核通信、同步与容量压力仍同时存在。本章区分边界 COPY 和 Spill，给出活动核数候选与实测 Spill 触发的局部微批。五核平均加速比 4.131，中位 4.447，最小 1.812；相对 C3 的逐图耗时平均降低 34.49%。

6.1 问题分析与建模差异

6.1.1 问题分析

同核 Task 合并取消了同核子图之间的强制 DDR 边界，却不取消容量约束。候选需要同时处理跨核连接、双 Pipe 负载与驻留次序。五核 B 的边界均值仍大于 Spill 均值，因此不能把该场景描述成完全由 Spill 主导。

C3 在单核 B 配置下的平均 REF 加速比为 0.9487，说明这一特定静态构造没有充分适配场景 B。该观察不证明所有场景 A 方法都会失效，而提示需要按新的 Task 组织重新评价候选。

我们保留第 5 章框架的后两层，即下界剪枝与官方评价择优，只在候选生成层增加两类针对驻留的机制：活动核数与驻留组织的候选族，以及以实际发生的 Spill 为触发条件的局部微批。本章给出 100 张图、1 至 5 核共 500 个配置格的完整结果，把新增 COPY 拆成边界与 Spill 两类来源，并在同一次请求内追踪三个阶段各自的收益。

6.1.2 沿用与替换

方案表示与可行性条件与场景 A 相同：仍记 $P=(g,a,\pi)$ ，三项决策的定义、覆盖性条件与联合无环条件见式(4-1)、式(4-2)、式(4-3)。固定参数 θ 同样包括 L1=524288 bytes、UB=131072 bytes 与全部核心共享的 60 bytes/cycle。目标函数形式不变，只换用场景 B 的评价算子 $T_B(P)$ (式(4-5))，择优仍按式(4-6)的字典序，可行集记为 F_B 。问题二的模型是式(4-20)在场景 B 下的实例：


$$\text{lex min}_{P \in F_B} (T_B(P), D_{added}^B(P)) \quad (6-1)$$

场景 B：同核子图合并成一个 Task，跨核同步见式(4-14)，边界记账见式(4-19)。

瞬时容量由官方展开过程与容量复用依赖控制，不能用于子图全部张量之和代替。合并 Task 后驻留窗口被显著拉长，这一区分在场景 B 比在场景 A 更关键。

6.1.3 Task 边界的消失与不消失

第一处实质差异在 Task 边界。设操作 u_0 产生 b 字节的中间张量、 u_1 消费它，无其他消费者且非最终输出。场景 A 中若两者分属不同子图，即便调度到同一核心也要一次写出加一次读入，共 $2b$ 字节；场景 B 中两者落在同核的同一个 Task 里，只要不发生 Spill，这 $2b$ 字节就不产生。图 6-1 并排给出两种情形（结构示意）：场景 B 消除的是“同核跨 Task”这一类边界搬运，前提是“驻留且无 Spill”，消除边界不等于容量足够。



相同片段： u_0 产生 b 字节中间张量， u_1 消费；无其他消费者、非最终输出

场景B消除该同核边界，不代表容量足够或不会Spill

图 6-1 同一计算片段在场景 A 与场景 B 下的 Task 边界（示意图）

跨核情形则按连接计费。按官方评估程序的实现（式(4-19)），场景 B 对每一对“生产核心→消费核心”的跨核连接各插入一次 COPY_OUT 与一次 COPY_IN。对单生产者、非最终输出的中间张量，设字节数为 b 、不同远端消费核心数为 r ，Spill 前的边界记账为

$$D_{\text{边界}}^B(t) = \begin{cases} 2rb, & r > 0 \\ 0, & r = 0 \end{cases} \quad (6-2)$$

即每个远端消费核心各对应一次写出与一次读入； $r=0$ 表示所有消费者都在生产核上，不产生这一项。同样的张量在场景 A 中若分布在 r 个其他 Task 上，计为一次写出加 r 次读入，即 $(r+1)b$ 。两者在 $r=1$ 时相同， $r \geq 2$ 时场景 B 的跨核扇出反而更贵，这可能是场景 B 的边界新增随核数上升较快（6.4.2 节）的原因之一。该特例不含 Spill、原始输入的重复读入与最终输出。

跨核传输另有一条时序约束式(4-14)：目标核的 COPY_IN 要在源核 COPY_OUT 完成 500 周期后才进入就绪判定。这是必要释放条件，目标操作还须满足 Pipe FIFO、本地前驱与内存申请次序，源端完成加 500 周期不等于目标端立即发射。


6.1.4 逻辑活期不等于物理驻留

只有实际驻留期间才占用私有缓存。张量从产生到最后使用的逻辑活期可以包含换出、暂存 DDR 与再次读入，因而不能将整个逻辑活期一律视为连续物理占用。

这里要区分两个概念：逻辑活跃指张量从产生到最后一次使用之间的区间，物理驻留指它实际占据缓存的字节。两个张量的逻辑活期重叠，不能直接换算成占用量或 Spill 量。320 KiB 与 256 KiB 两个张量各自都能放进 512 KiB 的 L1，合计 576 KiB 却超出容量，无法同时常驻（图 6-2，概念例）。容量冲突必须按活跃集合判断。

(a) 逻辑活跃区间：仍有后续使用

(b) 两者不能同时留在L1



逻辑活跃 ≠ 物理常驻：需换出再读入，或选择不同的合法顺序

此图仅解释容量冲突；不指定替换策略，不推断实测Spill字节数

图 6-2 逻辑活跃、物理驻留与容量冲突（示意图）

至此可以说清场景 B 能优化的是什么：核心归属，以及方案能够表达的操作顺序。“同核数据永不换出”则是一个不成立的假设。

6.2 求解算法

6.2.1 求解路径概述

场景 B 仍以基础构造取得可行解，再在近优门控和预算允许时考察活动核数、关键链移动与驻留组织。候选经结构检查、哈希去重和适用下界筛选后才进入官方评价。外层索引插入之后，仅当当前结果确有 Spill 才启动诊断和局部微批；这两个外层阶段不受控制链的近优门控直接限制。

6.2.2 活动核数与驻留组织候选

从原图得到当前可行解后，在剩余预算与质量界允许时枚举一族候选：

$$C_{family} = \{(m, target) : 1 \leq m \leq k, target \in \{0, 512, 2048\}\} \quad (6-3)$$

m 为活动核心数， $target$ 控制驻留排序的组织粒度；该扩展阶段最多评价六个新候选。

减少活动核心可能减少部分跨核连接，同时减少计算并行资源；由于会重新构造方案，两类变化都不保证单调。候选先经合法性、去重和下界筛选，未被淘汰者才进行完整评价，不免费把所有可能方案都送评。

6.2.3 Spill 触发的局部微批

第二类机制只在确有 Spill 时启动。仅当当前成功结果的 Spill 新增字节大于零，才进行微批诊断；诊断在独立子进程中观察原版 Step2 返回的 Spill 事件，并核对诊断中的搬运分解与成功结果一致，正式评分在未插桩的新进程中进行，不修改原版仿真。

诊断关注满足下列条件的大张量事件：


$$\text{size}(t_b) \geq 1/4 C_m, \text{dist}(s_{\text{before}}, s_{\text{after}}) \leq 8 \quad (6-4)$$

即张量大小至少为相应容器容量的四分之一，且前后两次使用所在子图的距离不超过 8。两个阈值是启发式候选规则。候选窗口参数为

$$w \in \{4, 8\}, |\{\text{窗口}\}| \leq 16 (\text{互不重叠}), |\{\text{原计算操作}\}| \leq 128 (\text{每窗口}) \quad (6-5)$$

窗口内细化到操作级子图，用稳定 Kahn 顺序[16]优先复用最近使用的大型外部输入，平局时沿原位置与 ID 确定；窗口外的顺序不改变。设计动机见图 6-3：四条 $A_i \rightarrow B_i$ 依赖链共享两份大输入 t_A 与 t_B ，交替顺序会让两份输入反复换入，成组顺序则让同一输入连续使用（结构示意）。窗口重排改变的只是同核内部的执行次序，中间张量的活期可能因此被拉长，实际收益仍须完整评价确认。


(a) 原依赖：每条链 A_i 在 B_i 之前，无跨链依赖



所有 A_i 读取同一大输入 t_A ；所有 B_i 读取同一大输入 t_B


(b) 交替顺序

核心0；横向为顺序，不是持续时间



(c) 同核局部重排

核心0；横向为顺序，不是持续时间



下排同输入连续使用；原始依赖与核心归属不变，但实际收益仍须完整评价

图 6-3 局部微批：依赖不变，共享输入成组使用（示意图）

6.2.4 微批的不变量：能推出什么，不能推出什么

微批重排满足核心归属不变式：

$$a_{\text{new}}(g_{\text{new}}(u)) = a_{\text{old}}(g_{\text{old}}(u)), \forall u \in U \quad (6-6)$$

场景 B 下每个核心只有一个 Task，核心归属不变意味着每个张量的生产核心集合与消费核心集合都不变，于是 Spill 前的边界 COPY 记账严格保持：

$$D_{partition,new}^B = D_{partition,old}^B \quad (6-7)$$

这条推论的适用范围需要划清，它是本章分析中最容易被误用的一步。式(6-7)只覆盖 Spill 前的边界 COPY；执行顺序改变了，Spill 量可以改变，Makespan 当然也可以改变。因此不能由它推出“微批不改变总时间”或“微批不改变总搬运”。该结论也不适用于场景 A：A 中一个核心上有多个 Task，核心归属不变并不保证 Task 边界集合不变。

同样，局部 Kahn 顺序只保证窗口内部的原依赖被满足；与窗口外顺序、跨核释放及内存复用边的组合是否合法，由完整方案检查与官方评价决定。只有完整成功且 (Makespan, 新增 COPY, 名称) 更优的候选才替换当前解。

6.2.5 求解流程与预算分配

问题二的完整流程见图 6-4。与问题一相比，控制链多了沿官方关键链的局部移动，依赖带与划分不变的重排不再运行，流程末尾多了一道“有没有实测 Spill”的判断，微批诊断与窗口重排只在判断成立时执行。对应的步骤如算法 6-1。




图 6-4 问题二（场景 B）的求解流程

算法 6-1 R12 场景 B 求解流程

输入：原图 G ；固定 B 配置 θ ；核心数 k ；单请求软预算 B （600 秒）

输出：通过原版评价的最佳已得方案 P^* ，及诊断与失败记录

- 1 从原图生成并评价控制链（基础构造、减少活动核心候选、沿官方时间线关键链的局部移动），保存当前最好解 P^* ；
- 2 if $T(P^*) > 1.03 \cdot LB$ then 按式(6-3)生成分量家族、活动核心数与驻留组织候选，去重、下界剪枝后至多评价 6 个；
- 3 用区间索引生成插入候选，完整评价后按字典序更新 P^* ；
- 4 if P^* 的 Spill 新增字节 $D_{\text{spill}}(P^*) > 0$ 且预算尚有剩余 then
 - 5 在独立进程中观察原版 Step2 的 Spill 事件，按式(6-4)筛选大张量事件；
 - 6 按式(6-5)生成至多两个固定窗口的微批候选，逐个检查合法性并送官方评分，按字典序更新 P^* ；
 - 7 end if
- 8 输出两字段方案；未产生成功方案则明确返回失败，不补 0、不删图以伪造完整均值。

各阶段共用总软预算 600 秒，其中快速生成上限 30 秒、插入候选评分 120 秒、Spill 诊断 40 秒、每个微批候选评分 45 秒，均受剩余预算约束，控制链已消耗的预算同样计入。

第 4 行的条件顺序决定了微批的触发面：它不是无条件执行的优化，而是“先看有没有 Spill，再决定是否诊断”，见 6.4.4 节。

场景 B 的候选构造复杂度与场景 A 同阶（式(5-10)）。新增的分量家族枚举为常数规模，该扩展阶段最多评价六个新候选；微批重排本身的规模由窗口参数式(6-5)限定（每份候选最多 16 个互不重叠的窗口、每个窗口不超过 128 个原计算操作），附加的构造成本很小；Spill 诊断需要在独立进程中运行一次带观测的核内调度，成本与一次核内排布同阶，并受 40 秒上限约束。总成本仍由官方评价次数主导。

6.2.6 与 C3 对照的可比性

C3 在场景 B 中的构造沿用 4.3.3 节的定义：合并安全链，按就绪层平衡计算负载，用场景 A 的等待与边界代理分核，再在场景 B 的真实规则下评价。两者输入与官方配置相同，搜索成本结构不同，终点性能比较不能解释为等成本下的算法效率比较。

6.3 实验设置与主要结果

6.3.1 口径：一核的两种含义

场景 B 的实验里“一核”出现两次，含义不同：标准参考曲线的一核点按原题定义取 1，是加速比的分母定义；优化 B1 则是把 R12 框架实际作用在单核配置上得到的结果，平均 REF 加速比 1.061。两者不可混用，也不能用后者替换曲线上的参考点。

6.3.2 逐核主结果

表 6-1 场景 B 逐核主结果（每格 100 图）

指标	1 核	2 核	3 核	4 核	5 核
平均加速比	1.061366	1.992522	2.801109	3.521046	4.131077
中位加速比	1.008872	1.994111	2.925982	3.724109	4.446792
最小加速比	1.000000	1.424760	1.355264	1.736104	1.811818
均值新增 COPY/MiB	8.7090	9.1437	8.7155	7.7976	8.2173
其中边界/MiB	0.0000	2.7091	3.9676	4.5703	5.5112
其中 Spill/MiB	8.7090	6.4346	4.7479	3.2273	2.7062

指标	1 核	2 核	3 核	4 核	5 核
有 Spill 图数	50	36	23	23	22
墙钟中位/s	13.8222	9.8964	10.1644	9.9414	7.9157
墙钟 P95/s	183.0985	105.6320	94.2155	86.0755	77.4654

注：“1 核”一列为优化 B1 的实测均值，标准参考曲线的一核点按原题定义为 1，两者不可混用；1 MiB = 1048576 bytes；P95 为经验最近秩；“有 Spill 图数”分母为 100。表中保留完整精度，正文取四位有效数字。

平均加速比从两核的 1.993 升到五核的 4.131，五核最小值 1.812，100 张图全部快于固定整图单核。五核请求墙钟中位 7.916 秒、P95 为 77.47 秒、最大 127.1 秒，全部 500 个请求在 600 秒预算内完成。

两处非单调需要指出。其一是最小加速比列：两核与三核的最小值都来自同一张图 case_064，它在三核下的加速比（1.355）低于两核（1.425），四核与五核的最小值换成了其他图并恢复上升。case_064 也是场景 A 全部核数下的最小值（5.4 节），是本测试集里最难并行化的一张图。其二是新增 COPY 总量列既不单调增也不单调减，成因见 6.4.2 节。

核数扩展趋势与 C3 的差距随核数扩大（图 6-5）；该图同时提示一核参考点按定义取 1、优化 B1 另行报告。




图 6-5 问题二：场景 B 下 1 至 5 核平均加速比折线图（R12 完整流程与 C3 基线）

6.3.3 优化 B1

单核配置下 R12 框架仍能在原版结果之上改进：平均 REF 加速比 1.061，其中 55 图改善、45 图相同，没有变慢的用例。中位数 1.009 显著低于均值，改善集中在少数图上而非普遍分布（图 6-6，纵轴为加速比超出 1 的幅度，不是耗时降低率）。




图 6-6 优化 B1：相对固定单核的逐图变化

单核是一个干净的对照点：此时不存在跨核边界，表 6-1 一核行的边界项为 0.0000，全部 8.709 MiB 新增 COPY 都来自 Spill。这从口径上确认了两类来源的划分是互斥的。

6.4 结果分析

6.4.1 与 C3 的逐例对照

逐图耗时降幅定义同式(4-8)，五核结果为

$$\bar{\rho}_B = \frac{1}{100} \sum_{i=1}^{100} \left(1 - \frac{T_{R12,i}}{T_{C3,i}} \right) = 34.4910\% \quad (6-8)$$

表 6-2 场景 B 相对 C3 的逐例对照（每格 100 图）

核数	加速比均值 T_{C3}/T_{R12}	逐图降幅均值	更快 / 持平 / 更慢	更快但 COPY 更高	C3 平均加速比 T_{REF}/T_{C3}
1	1.138380	10.8752%	82 / 18 / 0	15	0.948680
2	1.227637	16.3835%	90 / 10 / 0	20	1.670220
3	1.357801	22.6021%	92 / 7 / 1	11	2.163389
4	1.498911	28.1411%	93 / 7 / 0	5	2.514776
5	1.718822	34.4910%	94 / 5 / 1	4	2.668780

注：C3 为同输入、同评分口径的事后对照，非等搜索预算消融；时间为官方 cycles，非求解墙钟。

最后一列有一个现象值得单独说明：C3 在单核配置下的平均 REF 加速比为 0.9487，小于 1，它的固定构造在单核上平均比原版整图单核基准还慢。单核时不存在跨核边界，C3 按场景 A 代理切出的子图次序改变了核内的执行与驻留顺序，结果反而不如不切分。这一观察支持 6.1.1 节的判断：场景 B 不能靠替换同步常数从场景 A 平移过来。

五核下 R12 为 94 例更快、5 例持平、1 例更慢。“更快但 COPY 更高”一列在两核达到峰值（一核 15 例、两核 20 例），此后随核数递减（11、5、4），提示核数较多时主次目标的冲突较少；这是五个观测点上的趋势，未做机制层面的验证。

6.4.2 边界与 Spill 的反向变化

表 6-1 中两个分解项走向完全相反。边界项随核数单调上升：0、2.709、3.968、4.570、5.511 MiB；Spill 项随核数单调下降：8.709、6.435、4.748、3.227、2.706 MiB。总量因此非单调，在四核取到最低的 7.798 MiB。

在这批各核数独立选出的方案中，边界均值增加而 Spill 均值减少。较多核心可能分散驻留压力，也可能增加跨核连接，这为趋势提供了机制解释；但算法允许空核心，核数增加并不逻辑上必然导致这两种变化。具体因果贡献尚未通过固定方案或参数扫描分离。

发生 Spill 的图数同样随核数下降：50、36、23、23、22（表 6-1 末列，另见图 6-7 的字节分解）。这条计数与 Spill 字节的下降方向一致，说明减少的不只是溢出的量，也包括发生溢出的用例范围。




图 6-7 场景 B：边界 COPY 与 Spill 分解

6.4.3 Spill 的集中度

五核 B 的 100 张图中有 Spill 的只有 22 图，其余 78 图为零。在这 22 张图内部分布同样极不均匀：按 Spill 降序排列的前 10 图贡献了全部 Spill 字节的 93.84%。

五核有 78 张图的最终方案不发生 Spill，不能据此断言是“同核合并消除了这些图原来已有的 Spill”，因为该因果比较尚未构造。图 6-8 保留 22 个非零值，并用完整 100 张图定义累计贡献；平均 2.706 MiB 并不代表多数实例的典型溢出量。




图 6-8 五核 B：非零 Spill 细节与全量集中度

6.4.4 同次请求的阶段增量

为观察各机制各自保留了多少收益，记录同一次请求内三个阶段的方案质量：

$$\bar{S}_{\text{stage}} = \frac{1}{100} \sum_{i=1}^{100} \frac{T_{\text{REF},i}}{T_{\text{stage},i}}, \text{stage} \in \{\text{control}, \text{indexed}, \text{full}\} \quad (6-9)$$

表 6-3 五核 B 同次请求的三阶段结果

阶段	相对 REF 平均加速比 / 原始 cycles	较前阶段严格改善
控制	4.073198	(基准)
插入后	4.111995	12 / 100
微批后	4.131077	2 / 100
case_067 (明细)	15,255,427 → 13,798,191 → 13,054,159	—
case_073 (明细)	3,210,135 → 3,046,190 → 2,034,983	—

注：三阶段共享同一总软预算，不是等预算独立消融；未改善含相同、未触发或未完成三种情况。

严格改善的计数定义为

$$N_j = \left| \left\{ i : T_{\text{stage}_{j+1},i} < T_{\text{stage}_j,i} \right\} \right|, (N_{\text{插入}}, N_{\text{微批}}) = (12, 2) \quad (6-10)$$

控制阶段平均加速比 4.073198 与最终值 4.131077 之比为 98.6%。这是两个终点均值的比，不是控制链贡献的因果收益比例。插入和微批依次给出进一步改善，且只覆盖部分图；这些记录说明既定流程中的增量，而非独立组件效应。

改善面同样很窄：插入阶段 12/100，微批阶段 2/100（图 6-9，纵轴局部放大，标注的两段增量为+0.038797 与+0.019083）。“未改善”包含三种不同情况（候选评价后未更优、诊断条件未触发、预算耗尽未完成），因此 2/100 既不是触发率也不是成功率。三阶段共享同一总预算，后面的阶段用的是前面剩下的时间，这组数据不构成等预算的独立消融。




图 6-9 五核 B：同次请求的阶段增量

6.4.5 微批阶段的两个改善实例

微批阶段全部两个进一步改善的实例是 case_067 与 case_073（图 6-10 给出配对结果，其余 98 例未进一步改善）。case_067 从插入后到微批后耗时降低 5.39%、对该阶段加速比增量贡献 13.82%；case_073 对应为 33.20%与 86.18%。




图 6-10 微批阶段：两个实际改善案例的配对结果

微批阶段+0.019083 的平均增量中，86.18%来自 case_073 一张图。

表 6-4 开发诊断案例终点值（case_073，B 五核）

指标	数值
Makespan/cycles	2034983
边界新增/bytes	21712384

指标	数值
Spill 新增/bytes	15489024

R12 提出窗口排序的依据是“两份大输入交替使用可能造成反复换入”这一有源码依据的机制推测，case_073 正是一个 Spill 量级很高的实例。本章把它作为设计动机的来源记录下来，而不把这组终点值当作微批有效性的因果证据：要做因果论证需要等预算的独立消融，本章没有做。

6.4.6 退化配置

500 个 B 配置格中相对 C3 更慢的只有两个：case_089 在 3 核为+0.038%，case_062 在 5 核为+0.502%。两者幅度都在 1%以内，属于小幅退化。

case_062 在 A 的低核数相对 C3 明显退化，在 B 中仅五核慢约 0.502%。两种场景改变了 Task 组织、同步规则 and 实际选解，差异与同核边界代价有关的解释相容，但尚不能单独把差异归因于取消某一类等待。

6.4.7 主次目标的权衡

五核下有 4 图比 C3 更快而新增 COPY 更高（图 6-11 给出执行时间与 COPY 的散布关系）。主指标改善不等于逐例搬运下降，也不构成每个用例上的双目标 Pareto 支配。




图 6-11 五核 B：执行时间与 COPY 的权衡

更快但 COPY 更高的图数为 15、20、11、5、4，在两核达到峰值后下降。这描述了本批终点方案的主次指标冲突范围；其与 Spill 占比的共同变化不能代替逐事件或固定方案的机制分析。

6.4.8 求解成本与校验

表 6-1 显示墙钟 P95 随核数单调下降（183.1 → 105.6 → 94.22 → 86.08 → 77.47 秒），全部 500 个请求在 600 秒预算内完成，原图、配置与评分代码未作修改。这一形态与场景 A 相反：场景 A 的 P95 随核数上升且出现了需要 1800 秒补跑的例外（见表 5-2 与 5.5.5 节）。一个与数据相容的解释是场景 B 的候选空间更受约束：每核只有一个 Task，不需要在 Task 划分与 Task 间排序之间反复权衡。本章未做求解成本的分解实验，故不作为结论。

既有核查覆盖原操作计数、周期、核心归属、原依赖、Pipe 与 COPY 分解，并核对了官方记录的容量峰值；完整的动态容量与共享带宽未用第二套实现全量重建，相关校验属于内部自检。

6.5 小结

场景 B 的结论可以归为四点。

(1) 容量压力具有集中性。五核 78 张图无 Spill，另外 22 张中前 10 张占全部 Spill 字节的 93.84%。因此需要同时报告发生面、非零分布和全图平均值。

(2) 边界与 Spill 在本批选解中随核数反向变化。四核总新增量均值最低，不代表四核在每个实例上最省搬运，也不代表其完工时间最短。

(3) 精细优化的增量具有局部性。五核微批阶段在两张图上进一步改善，其中 case_073 占该阶段平均加速比增量的 86.18%。这为保留有条件触发机制提供了实例证据，不构成普遍有效或因果贡献率结论。

(4) 场景适配需要重评。C3 的单核 B 均值小于 1，说明该特定固定构造存在适配不足；不能据此推广为所有静态构造或其他路线都不可用。

全部结论限定在这 100 张图、题目给定的固定配置与 600 秒软预算之内。

7 问题三：共享只读 L2 下的调度与性能影响

问题三在场景 B 的硬件上加了一块 1 MiB 的共享只读 L2，读带宽 250 bytes/cycle，与 DDR 互不占用。

共享只读 L2 改变重复读取的服务路径。在本测试集上，五核同方案配置比均值 1.016766，中位数 1.000546，收益集中于部分图，另有少量退化。该量级是观测结果，不是由硬件结构预先决定的必然小收益。

本章先定义 FIFO 状态和双带宽池，再分别报告固定方案配置效应、独立选解变化和搬运记账。命中率与加速可以总体正相关而逐例不单调；计划 COPY 不扣除命中，因此不等于物理 DDR 净流量。求解沿用 B 的结构候选，并在条件允许时增加同请求内的跨配置重评价。

7.1 缓存模型

7.1.1 沿用与新增

方案表示、可行性条件、Spill 与驻留规则、跨核同步约束式(4-14)全部沿用场景 B（见 6.1 节）；每核的全部子图仍合成一个 Task，L1 与 UB 容量不变。本章新增的只有一条读路径与随之而来的状态规则。

记同一方案在无 L2、有 L2 两种配置下的官方 Makespan 分别为 $T_B(P)$ 与 $T_L(P)$ 。主目标是最小化 T_L ，主指标相同时比较新增 COPY。方案不增加任何额外的计算、复制、预热或等待指令，也不改变 FIFO 策略：能优化的仍然只有 (g, a, π) 。问题三模型为

$$\text{lex min}_{P \in F_L} (T_L(P), D_{added}^B(P)) \quad (7-1)$$

新增 COPY 的记账与场景 B 相同（假设 7），只读 Cache 只改变读取走哪一个带宽池。

7.1.2 FIFO 语义：命中在发射时，插入在完成时

令 $Q(t)$ 为按插入先后排列的逻辑张量 FIFO， $H(t)$ 为其字节占用：

$$H(t) = \sum_{\tau \in Q(t)} b_{\tau} \leq 1048576 \quad (7-2)$$

正字节且键有效的读入操作在发射时查询缓存：命中则进入独立 L2 读池，未命中进入 DDR 池；写出操作始终走 DDR。命中不刷新已有键的 FIFO 次序，即这是先进先出而非最近最少使用。

插入发生在完成时：每个读入完成都会尝试插入，若无键、超容量或键仍存在则不插入，否则逐出最早的键直至能够容纳。

两个时点的分离带来一个容易被忽略的情形：一次命中读取在途期间，其对应的键可能被别的插入挤出，等该读取完成时缓存里已无此键，于是它会重新插入。图 7-1 用每键 256 KiB、容量 1 MiB 的概念例走完整个过程： t_0 发射读取 A 时命中并进入 L2 读池， t_1 另一读取 E 完成并插入、最早的 A 被逐出， t_2 读取 A 完成时 A 已不在缓存，于是逐出 B 后重新插入 A（结构示意，按官方语义构造）。键被逐出不会撤销已发射读取的带宽池选择，这两个时点必须分开理解。

概念例：每个键 256 KiB；FIFO 容量 1 MiB；左端最早插入



$t_0 < t_1 < t_2$ 仅表示先后；缓存键被逐出，不撤销已发射读取的带宽池选择

图 7-1 FIFO 状态快照与在途读取（示意图）

逐图按字节命中率定义为

$$h_i = \frac{B_{hit,i}}{B_{hit,i} + B_{miss,i}} (B_{hit,i} + B_{miss,i} > 0) \quad (7-3)$$

零字节读取不进入正字节命中统计。本章报告的命中率均为 100 图逐图计算式(7-3)后的算术平均，不是把全部命中字节池化后计算的总体命中率。

7.1.3 两个互不占用的带宽池

$$\sum_{j \in A_p(t)} v_j(t) \leq B_p, B_{DDR} = 60, B_{L2} = 250 \text{ bytes/cycle} \quad (7-4)$$

$A_p(t)$ 为池 p 中的在途传输集合。每个池由全部核心共享，两池之间互不占用，这是 L2 可能带来收益的结构原因：命中的读取不再与未命中读取、写出争抢那 60 bytes/cycle。

忽略取整与并发时，单次搬运的理想参考延迟为

$$d_{\text{DDR}}^{\text{isolated}} = b/60, d_{L2}^{\text{isolated}} = b/250 \quad (7-5)$$

两者相差约 4.17 倍。这个比值只用于说明独立读池的量级：局部传输时间缩短不等于整图同比加速，关键计算、Pipe 占用、跨核释放与其他搬运都可能成为瓶颈。

7.1.4 未命中的三类来源

未命中至少有三类不同来源，终点统计无法区分它们：单条数据超过 1 MiB 容量，永远无法缓存；数据能够缓存，但在两次使用之间被其他张量挤出；多个核心在首次读取尚未完成时同时发射同一输入，此时缓存中还没有这个键，它们会全部未命中。

第三类的存在意味着低命中率既可能反映容量不足，也可能只反映并发时序。本轮实验固定了容量与带宽，未做参数扫描，因此识别的是该指定 L2 配置的联合净效应，无法为容量增加与带宽增加分别指定因果贡献。

7.2 实验设计：分离配置效应与选解效应

第一层固定 B 方案，比较两种配置；第二层比较各自在配置内选出的方案。两层共用分子、使用不同分母。后者包含重新搜索的变化，可能扩大也可能缩小配置收益，因此不预先认定混合报告必然高估。所有配置效应均指官方模拟语义下的结果，不是实体芯片实测。

7.2.1 两种比值

记图 i 在 k 核下由 B 场景与 L2 场景分别选定的方案为 $P_{B,i,k}$ 与 $P_{L,i,k}$ 。同方案配置比与分别选优综合比分别为

$$R_{\text{hw},i,k} = \frac{T_B(P_{B,i,k})}{T_L(P_{B,i,k})} \quad (7-6)$$

$$R_{\text{select},i,k} = \frac{T_B(P_{B,i,k})}{T_L(P_{L,i,k})} \quad (7-7)$$

前者分子分母是同一个方案，差异只来自配置；后者的分母换成 L2 场景自己选出的方案，含有选解变化，不能叫作纯硬件收益。两个比值共用同一分子而分母不同，互换会改变结论的含义。三项评价如何得到、两个比值如何构成，以及它们与求解流程的关系，一并画在图 7-2 中：左支是第 6 章的场景 B 求解，得到 P_B ；右支是只读 Cache 配置下的独立求解，得到 P_L ；“ P_L 在无 L2 配置下”这一格不参与本比较。




图 7-2 问题三的求解与“方案×配置”受控对照

7.2.2 分解恒等式及其使用边界

两个比值之间有一条逐例成立的恒等式：

$$R_{\text{select},i,k} = R_{\text{hw},i,k} \cdot \frac{T_L(P_{B,i,k})}{T_L(P_{L,i,k})} \quad (7-8)$$

右侧第二项即选解效应：同在 L2 配置下，换用 P_L 相对沿用 P_B 的比值。

恒等式逐例成立，但不能推广到均值。配置比的均值按

$$\bar{R}_{\text{hw},k} = \frac{1}{100} \sum_{i=1}^{100} R_{\text{hw},i,k} \quad (7-9)$$

计算，是 100 个逐图比值的算术平均；三个量各自取算术均值后不再满足乘积关系。因此不能用 $\bar{R}_{\text{select}}/\bar{R}_{\text{hw}}$ 去估计平均选解效应。本章严格避免这一操作，选解效应的量级另行用逐例配对数据给出（7.4.4 节）。同理，两条主性能曲线各自用同一个整图 REF 归一化，配置比则另行对 100 个逐图比值取平均，不能用两条均值曲线相除得到。

7.2.3 对照的构造

配置对照通过图、核数、配置、评估器与方案哈希五项匹配。500 对中 430 对的 B/L2 最终方案本来就相同；其余 70 对方案不同，其中 62 对复用了同哈希的既有候选评分，8

对只补做官方 L2 评分，均不重跑求解器。对照补评分不反向参与既有主方案的选型，主实验的选解来源保持不变，本章只新增读表分析。

一项与官方实现相符的观察可作交叉校验：固定 P_B 时，两个配置下的边界与 Spill 新增 COPY 字节完全一致。这是因为官方在事件模拟之前就完成了新增 COPY 的记账，缓存命中发生在模拟阶段，不会回减该量。

7.2.4 求解路径

L2 求解从原图生成基础可行解，尝试不同的活动核心数与驻留组织；预算允许时，在同一请求内独立求解一个场景 B 方案并按 L2 配置重新评价，这部分成本计入该请求，不免费读取另一批次已经选出的 B 方案。随后尝试快速插入与实际 Spill 触发的至多两个局部微批，按官方 Makespan 与新增 COPY 的字典序保留成功结果。流程的位置关系见图 7-2 右支，逐步描述如算法 7-1。

算法 7-1 R12 共享只读 L2 场景求解流程

输入：原图 G ；L2 配置 θ_L ；核心数 k ；单请求软预算 B （600 秒）

输出：L2 下选出的方案 P_L 及其官方评价结果

- 1 在 L2 配置下运行基础构造和控制链，保存当前成功方案。
- 2 门控与预算允许时，生成分量家族候选，经检查后至多评价 6 个。
- 3 预算允许且未被近优门控跳过时，在同一请求内求解 B 方案（至多 180 秒），再用 L2 配置评价（至多 40 秒）。
- 4 在剩余预算内生成索引插入候选（生成至多 30 秒，评价至多 120 秒）。
- 5 当前方案有实测 Spill 且预算允许时，诊断并评价至多两个微批候选。
- 6 每次仅以完整官方结果按 Makespan、COPY 和名称字典序更新，最后输出 L2 已得最好方案。

同次请求内的择优不变差性质不能推广到两个独立请求：两次请求的最终方案谁优谁劣没有保证，7.4.4 节给出了实例。

L2 请求可能增加同请求内的 B 方案求解及 L2 重评价。五核墙钟 P95 高于 B，与额外步骤方向一致；不过各实例的门控和预算截断不同，没有完整调用次数汇总就不能断言每个 L2 请求的评价次数都更多。

7.3 主要结果

7.3.1 本章五个五核指标的口径

本章涉及五个含义不同的五核数字，混用会得出相反结论，先集中辨析（表 7-1）。

表 7-1 本章五个五核指标的口径

指标	数值	含义
同方案配置比（均值/中位）	1.016766 / 1.000546	固定 P_B ，开关 L2 的耗时比，纯配置效应
分别选优比（均值）	1.027400	分母换成 P_L ，含选解变化
固定 P_B ，L2 相对 REF	4.187457	主性能曲线，方案固定
L2 独立选优相对 REF	4.218978	主性能曲线，方案可变

指标	数值	含义
固定 B 方案命中率均值	23.4614%	逐图字节命中率的算术平均，非独立选优方案

后两条曲线的定义为

$$\bar{S}_{L2}^{\text{fixed}} = \frac{1}{100} \sum_{i=1}^{100} \frac{T_{\text{REF},i}}{T_L(P_{B,i})} = 4.187457 \quad (7-10)$$

$$\bar{S}_{L2}^{\text{select}} = \frac{1}{100} \sum_{i=1}^{100} \frac{T_{\text{REF},i}}{T_L(P_{L,i})} = 4.218978 \quad (7-11)$$

关于数值精度：配置比这类贴近 1 的比值在本章保留六位小数，四舍五入到常规精度会抹掉退化记录之间的差别（如 0.999831 与 0.999991）。其余量按四位有效数字报告。

7.3.2 L2 独立选优的逐核主结果

表 7-2 L2 逐核主结果（每格 100 图，L2 独立选优方案）

指标	1 核	2 核	3 核	4 核	5 核
平均加速比	1.063807	2.002948	2.834798	3.581091	4.218978
中位加速比	1.011370	1.995712	2.939286	3.742978	4.470774
最小加速比	1.000000	1.424760	1.356033	1.815040	1.932301
均值新增 COPY/MiB	8.4131	8.1986	9.0377	8.2813	9.4032
其中边界/MiB	0.0000	2.7611	4.2787	4.6212	5.8467
其中 Spill/MiB	8.4131	5.4375	4.7590	3.6601	3.5565
墙钟中位/s	17.3699	18.9794	21.7490	22.2803	20.7454
墙钟 P95/s	193.1206	193.8599	201.4150	189.8324	197.7045

注：本表为 L2 配置下独立选优的结果，与“同一 B 方案开关 L2”的配置对照（表 7-3）口径不同。

一核没有跨核边界，新增 COPY 全来自 Spill。表 7-2 中边界均值随核数增加，Spill 均值由 8.4131 MiB 降至 3.5565 MiB；这是本批各核数独立选解的观测趋势，不是增加核心后的逐例单调保证。最小加速比在三核低于两核，也需要与全量分布一起阅读。

值得一提的是，两核最小加速比在场景 B 与 L2 场景下完全相同（均为 1.424760）。逐例数据确认两者来自同一张图 case_064，三核的最小值（B 为 1.355264，L2 为 1.356033）也来自该图，即同一张困难图在开启 L2 后几乎没有得到配置收益，三核回落是这一张图的现象而非普遍规律。case_064 同时是场景 A 全部核数下的最小值（5.4 节）。

7.3.3 三条方案曲线

图 7-3 左侧给出三条相对同一 REF 归一化的曲线：无 L2 的 P_B 、有 L2 的同一 P_B 、有 L2 另选 P_L ，五核值分别为 4.131、4.187、4.219。中间那条才是固定方案的配置效应，最上面那条已经包含了选解变化：两类平均收益不能混为纯硬件收益。三条曲线在 1 至 3 核几乎重合，从 4 核起才明显分离。右侧给出两种比值随核数的变化（纵轴围绕 1 局部放大）。




图 7-3 问题三：无 L2 与只读 Cache 两种配置下的 1 至 5 核平均加速比对比曲线 (a) 与两种配置比 (b)

7.3.4 逐核配置比与选优比

表 7-3 同核数 L2 配置比与选优比（每行 100 图）

核数	同方案配置比均值	同方案配置比中位	分别选优比均值	改善 / 相同 / 退化	固定 B 方案命中率均值	最终方案不同对数
1	1.001978	1.000000	1.002364	31 / 69 / 0	6.0886%	3
2	1.004765	1.000174	1.005591	57 / 39 / 4	16.0858%	5
3	1.011799	1.000210	1.013423	55 / 43 / 2	21.6492%	13
4	1.015729	1.000200	1.020292	55 / 45 / 0	19.6118%	21
5	1.016766	1.000546	1.027400	61 / 37 / 2	23.4614%	28

注：配置比与选优比口径不同，不可互换；一核配置比为实测值，不能强设为 1。

同方案配置比的算术均值在 1 至 5 核中依次增加，但各核数组固定的是各自 B 方案，并非同一个方案跨核扩展。共享输入和并发状态随核数及选解一起变化，不能单凭这五个均值推断单位时间卸载字节必然增加。

改善计数的分布值得单看：一核下 69 图完全没有变化，只有 31 图改善；即便到五核也仍有 37 图保持相同。在大多数核数下，超过三分之一的图对这块缓存没有任何可观测响应。

一核配置比是实测值 1.001978 而非按定义设定的 1：单核同样会发射重复读取，同样可能命中。这与加速比曲线的一核参考点（按原题定义取 1）性质不同。

7.4 结果分析

7.4.1 收益的分布形态

五核配置比均值 1.016766 与中位数 1.000546 均接近 1；相差较大的是各自超出 1 的部分，而不是两个比值本身相差一个数量级。超过一半实例的改善幅度很小，少量较大收

益拉高均值。图 7-4 保留全部 500 对及五核 100 对的完整分母，局部视窗不表示删去视窗外数据。




图 7-4 L2 收益：完整长尾与五核典型区间

表 7-3 的中位数一列进一步印证：五个核数的中位配置比全部贴近 1（最高者为五核的 1.000546）。只报均值会给出“普遍提速约 1.7%”的印象，只报中位数会给出“几乎没有效果”的印象：两个数字都真实，必须同时给出。

7.4.2 命中率的正相关与逐例非单调

命中率反映读池覆盖，不直接表示关键路径缩短量。这里区分固定 B 方案的命中率与 L2 独立选优方案的命中率，并区分总体相关和逐例单调性。

固定 B 方案的逐核平均命中率依次为 6.09%、16.09%、21.65%、19.61%、23.46%，四核较三核降低，而相应配置比均值上升。不同核数下的 B 方案也在变化，该现象不能单独识别命中率的因果作用。它表明跨组均值不能代替逐图同方案分析。

在 8 条退化记录中，case_090 两核的命中率为 36.29%，配置比为 0.995638；较高命中并未保证该例更快。五核全部 100 图的散点见图 7-5。按附录保留四位小数的命中率复算，Spearman 秩相关约为 0.655，支持总体正相关，同时不排除这些非单调实例。




图 7-5 五核：命中字节率与配置收益

机制上，命中改变服务路径后，会影响后续操作发射、FIFO 状态和池内并发。整图完成时间取决于这些变化在关键链上的叠加，因此单次读取变快并不能直接保证终点同比改善。该解释与观察相容，不代表已经完成逐事件因果追踪。

因此，命中率可以参与候选设计和诊断，但不能作为逐例加速保证，更不能直接承担未经证明的严格剪枝。本文的最终择优仍使用官方 Makespan 与新增 COPY 的字典序。

7.4.3 全部退化记录

表 7-4 全部同方案 L2 退化记录（8 条）

用例	核数	同方案配置比	同方案命中字节率
case_014	2	0.999863	23.8602%
case_049	2	0.999991	1.8294%
case_053	2	0.999831	11.6049%
case_090	2	0.995638	36.2899%
case_092	3	0.998346	11.1234%
case_094	3	0.999572	13.0478%
case_026	5	0.993980	16.4131%
case_092	5	0.997391	20.3016%

注：低于 1 表示退化。

500 对中有 8 对退化，最差为 case_026 在五核的 0.993980，相当于慢了约 0.6%。八条记录中有四条集中在两核，case_092 在三核与五核各出现一次。图 7-6 完整保留这八条记录并放大横轴：放大是为了读出小差异，不意味着退化幅度很大。




图 7-6 全部同方案 L2 退化记录

命中改变完成时刻后，后续发射、FIFO 状态和池内竞争可能随之改变，这是与局部退化相容的机制解释。现有终点数据没有逐事件分离这些路径，也不能排除事件推进和取整细节的影响；不对 8 条记录分别作未验证归因。

7.4.4 选解效应的量级

分别选优比与同方案配置比的算术均值之差随核数增加，最终方案不同的对数为 3、5、13、21、28。这是选解变化的描述性证据，但均值之差不等于单独定义的平均选解比，也不代表因果份额。

因此五核下 1.027400 与 1.016766 之间的差距不能全部记在 L2 头上：其中有 28 对的最终方案本身就换了。按 7.2.2 节的说明，这里也不能用两个均值相除来估计平均选解效应。

图 7-7 给出五核 28 对方案不同的配对结果：在同一 L2 配置中，另选方案较 P_B 有 26 例更快、1 例相同、1 例更慢。




图 7-7 五核：不同最终方案的选择效应

五核存在 1 例重新选解后反而较固定 B 方案更慢。两次请求的候选、门控和预算截断不同，同请求内保留最好解的性质不跨请求成立。该负例保留在完整配对结果中。

7.4.5 case_073：一个收益实例的事件轴

表 7-5 五核异质性案例

用例	无 L2 P_B /cycles	有 L2 同一 P_B /cycles	L2 独立选优/cycles
case_073 (5 核)	2034983	1806253	1805392
case_026 (5 核)	33518	33721	33721

注：case_026 为同方案配置比最小的五核用例。

两个案例形态完全相反。case_073 固定方案后开启 L2，Makespan 从 2034983 降到 1806253 cycles；再让求解器在 L2 下独立选优，只进一步降到 1805392，这一例的提升基本全部来自配置。case_026 则相反：开启 L2 后从 33518 升到 33721，而 L2 独立选优的结果与固定方案完全相同，说明求解器在该图上没有找到更好的替代方案。

case_073 完整 4252 条缓存事件 FIFO 占用与累计命中率演化见图 7-8：缓存占用在早期迅速逼近 1 MiB 容量上限后长期维持高位，共同观察窗口内出现最大的一次占用净降，即事件 e2428 (1143536 cycles) 处由 986880 降至 762624 bytes，净降 219 KiB。这里必须注明，占用的净变化不等于该次逐出的字节量。




图 7-8 case_073: 缓存事件与共同观察窗口

图 7-9 把同一方案在两个配置下的多核时间线并排（固定 P_B 时两配置 Makespan 分别为 2034983 与 1806253 cycles），L2 视图中读入通道的密集段整体前移；红线只是全局缓存日志的事件定位，不指定给核心 0 的任何具体操作，也不建立 Pipe 层面的因果关系。




图 7-9 case_073: 同方案时间线与缓存事件定位

选择 case_073 作展示，是因为它在第 6 章已作为微批机制的开发诊断案例出现过，Spill 量级较高、重复读取特征明显，用同一实例贯穿两章便于对照。两个案例合起来只能说明异质性的存在，不代替全部 100 图的分布。

7.4.6 新增 COPY 反而更高

表 7-6 五核 L2 独立选优的 COPY 与请求成本

五核 L2 独立选优指标	数值
平均新增 COPY/MiB	9.4032
其中边界/MiB	5.8467
其中 Spill/MiB	3.5565
请求墙钟中位/s	20.7454
请求墙钟 P95/s	197.7045
请求墙钟最大/s	423.6723

五核 L2 独立选优的平均新增 COPY 为 9.4032 MiB，高于 B 独立选优的 8.2173 MiB。这里比较的是两组不同选解；固定同一方案时开关 L2 的计划边界与 Spill 计账相同。因此不能写成缓存本身增加了同一方案的计划搬运。

原因有两层。一是计账时点：官方在事件模拟之前就完成新增 COPY 的计账，之后的缓存命中不会回减该量，所以这个数字反映的是计划中的搬运请求，不是物理 DDR 净流量。二是目标结构：字典序先比 Makespan，当 L2 使某些读取变得廉价时，求解器会接受那些搬运更多但时间更短的方案，这正是前两章反复出现的主次目标权衡，在这里以更明显的形式出现。

因此不能因为开了 L2 就说“搬运减少了”。要衡量物理流量，需要模拟阶段的实际 DDR 字节统计，本章没有这项数据。

7.4.7 相对 C3 的对照

表 7-7 L2 最终方案相对 C3 的逐例对照（每格 100 图）

核数	加速比均值 T_{C3}/T_{L2}	逐图降幅均值	更快 / 持平 / 更慢	更快但 COPY 更高
1	1.136025	10.6912%	81 / 19 / 0	14
2	1.222827	16.2115%	91 / 9 / 0	21
3	1.336165	21.8332%	92 / 7 / 1	16
4	1.454170	26.4412%	93 / 7 / 0	7
5	1.621458	31.4081%	94 / 5 / 1	7

注：C3 与 R12 的 L2 方案在本表中均按 L2 配置评价；C3 为同输入、同评分口径的事后对照，非等预算消融。

五核下为 94 例更快、5 例持平、1 例更慢，逐图降幅均值 31.41%，其中 7 个更快的实例 COPY 更高。

31.41% 低于场景 B 的 34.49%，但两组比较同时改变评价配置和方案，不能由差值推断算法能力下降或某类方案普遍受益。对 R12 自身的配置效应可用固定 B 方案对照；对 C3 的配置收益则需单独配对。两种分析的分母及问题不同。

7.4.8 求解成本与校验

L2 请求的墙钟 P95 在各核数上都接近 190 至 200 秒区间，五核最大值 423.7 秒，全部在 600 秒软预算内完成。这一水平高于场景 B（五核 P95 为 77.47 秒，见表 7-10），与 7.2.4 节的描述一致。

三问的选解与各类对照共检查 1470 组输出：1400 组为逐格选解（场景 A 的 400 格、场景 B 与 L2 场景各 500 格），另 70 组是最终方案与 L2 主方案不同的同方案对照（62 组复用同哈希的既有候选评分、8 组新补官方 L2 评分；其余 430 对两场景最终方案本来相同，无需另查）。核查覆盖执行计数、周期、原依赖、核心归属、Pipe 与 COPY 分解，全量结果与同方案对照保留了图、方案、官方结果及哈希绑定。本章未另写独立的缓存与带宽模拟器，相关校验属于内部自检。

7.5 测试覆盖、框架复用与适用边界

一个方法在给定测试集上表现好，还要追问它在多大范围内成立。本节从测试规模、框架结构与适用边界三个层次讨论。

7.5.1 测试集内的覆盖证据

100 张正式图覆盖全部要求的核数和场景，1400 个配置格不作筛选。它们提供测试集内的分布证据，不是从所有计算图随机抽样得到的外部泛化保证。同一图在多个配置重复出现，统计时必须按图配对。

表 7-8 三场景五核结果的分布形态

场景	五核加速比 均值 / 中位 / 最小	是否全部优于基准	退化配置数
A	3.743 / 4.130 / 1.202	是	9 / 400
B	4.131 / 4.447 / 1.812	是	2 / 500
L2	4.219 / 4.471 / 1.932	是	8 / 500（同方案配置对照）

注：退化配置的含义按场景而异：A、B 为相对 C3 更慢的配置格，L2 为同方案开启缓存后更慢的配置对；三者不可直接相加。

五核三场景最小加速比分别为 1.202、1.812、1.932；全部 1400 格最终结果不慢于 REF。这里的全量结果包含 case_087 的 1800 秒补跑，不等同于全部常规 600 秒请求成功。

五核中位数与最小值差异说明实例间收益不同。仅由最小值和中位数不能判断分布偏态方向，更不能给出测试集外性能下限；完整分布和预算例外应共同阅读。

7.5.2 框架层面的通用性

三问复用方案表示、合法性检查、下界与择优。场景 A 的依赖带和反馈分核主要处理 Task 粒度与释放；B/L2 的关键链移动和微批处理同核次序与驻留；跨配置重评价仅用于 L2。表 7-9 给出模块启用范围，不将启用本身等同于已证实的独立收益。

场景 A：独立 Task 的边界与释放 → 依赖带及追加式分核。

场景 B：同核驻留与容量压力 → 实测 Spill 触发的局部微批。

L2 场景新增缓存状态 → 引入跨配置候选重评价。

场景 A 不启用当前驻留型微批，属于与模块设计目标相匹配的取舍，并非证明所有操作级细分在场景 A 都无效。

表 7-9 框架部件与场景专属机制

#	部件	作用	A	B	L2	出处
1	决策变量与可行性	方案三元组及其覆盖、唯一排布、联合无环约束	●	●	●	式(4-1)、式(4-2)
2	字典序择优与下界	先 Makespan、相同时比新增 COPY；下界剪枝与 3%近优认证	●	●	●	式(4-6)、式(4-23)
3	安全链收缩	合并非分支链为链块，避免凭空增加边界	●	●	●	5.2.2
4	基础构造器	弱连通分量打包、链块波次；B/L2 另含链块迁移	●	●	●	4.7.2

#	部件	作用	A	B	L2	出处
5	依赖带分带	按链块深度分带成组，构造合理粒度	●	○	○	5.2.2
6	追加式分核	尾长优先、沿合法拓扑序追加，构造不引入等待环	●	○	○	5.2.3
7	反馈重排	用官方时间线修正代理：A 为划分不变重排，B/L2 为关键链局部移动	●	●	●	4.7.2、5.2.3
8	活动核数与驻留组织候选	枚举 $m \leq k$ 与驻留排序粒度，权衡跨核边界与并行度	●	●	●	式(6-3)
9	Treap 区间索引插入	加速最早可行位置的查找，不改变判定规则	●	●	●	5.2.4
10	Spill 触发局部微批	确有 Spill 时诊断并作窗口重排，A 不启用	○	●	●	式(6-4)、式(6-5)
11	跨配置候选重评价	同一请求内按 L2 配置重新评价 B 方案	○	○	●	7.2.4

注：● 启用；○ 未启用；● 经分析后不使用（5.2.4 节）。启用情况按求解器源码核对。

迁移到新平台时可复用方案表示和检查框架，但需重新核对通信、容量、同步、缓存及评价语义。原有下界必须重新证明适用，固定参数也需验证，不能直接沿用本测试集的性能数值。

7.5.3 通用性的边界

以下三点限制了结论的外推范围。

（1）测试集边界。全部结论基于题目给定的 100 张计算图，其非 COPY 操作数范围为 552 至 35705。对结构差异极大的计算图（例如深度远大于宽度的长链图，或分支因子极高的图），本文没有观测数据。

（2）参数边界。只读 L2 的容量（1 MiB）与读带宽（250 bytes/cycle）本轮固定未扫描，因此 7.4 节识别的是该指定配置的联合净效应。若容量或带宽变化，命中率与收益之间的关系可能改变。

（3）预算边界。常规 600 秒与 case_087 补跑 1800 秒必须分别记录；补跑预算约为五核 A 中位墙钟的 84 倍，只描述预算尺度差异，不是额外计算量或性能提升倍数。有限预算结果可能随机器负载和超时状态变化。

7.5.4 代理量、下界与目标的职责

时序系统的标量统计能够提供有用信息，但用途不同。工作量、复用跨度和命中率可用于构造候选；经证明成立的资源下界可用于安全淘汰；完整官方评价用于最终择优。不能把“相关但不单调”的统计直接当作下界，也不能将所有标量一概称为只能剪枝。

这一区分限定了本文可复用的部分：可以迁移评价与构造分工的思路，但具体代理、下界和停止门控仍须随问题重新验证。

7.6 小结与跨场景对照

表 7-10 跨场景五核对照 (A / B / L2)

场景	平均加速比	边界/MiB	Spill/MiB	墙钟 P95/s
A	3.743282	13.5574	1.2340	470.6481
B	4.131077	5.5112	2.7062	77.4654
L2	4.218978	5.8467	3.5565	197.7045

注：三场景常规单请求软预算均为 600 秒，A 的 case_087 四格单列 1800 秒补跑；各阶段时限和实际用时不同。C3 为同评价口径的终点对照，非等预算消融。

五核从 A 到 B 的边界均值降低，Spill 均值增加；从 B 到 L2 的独立选优中，两类计划新增量都增加而平均加速比仍提高。这些是场景配置及实际选解共同变化的描述。固定方案效应另由第 7.2 节的配对试验识别，不能把跨场景均值差全部分配给一条硬件规则。

本章自身的结论可归为三点。

(1) L2 带来的是正向但高度不均的收益。五核同方案配置比均值为 1.016766，中位数却只有 1.000546，超过三分之一的图没有可观测变化，500 对配置对照中还有 8 对反而更慢。

(2) 命中率具有描述价值，但不构成逐例单调性能代理。五核秩相关约 0.655，正相关与少量退化能够同时成立；不能用命中率独立替代 Makespan。

(3) 配置效应与选解效应必须分开报告。五核综合比 1.027400 中包含 28 对最终方案的变化，其中还有 1 例换了方案反而更慢。分解恒等式式(7-8)逐例成立，但不能用于均值相除。

全部结论限定在这 100 张图、1 MiB 与 250 bytes/cycle 的指定 L2 配置以及 600 秒软预算之内。本轮未做容量与带宽的参数扫描，识别的是该配置的联合净效应。

7.7 冻结结果的补充统计与分解

7.7.1 两类命中率的逐核核对

前文表 7-3 的命中率属于固定 B 方案开启 L2 的对照，不能直接写到 L2 独立选优方案名下。表 7-11 按附录的 100 个逐例百分比重新取算术平均，明确两种方案的区别；未进行新求解或新评分。命中率原表保留四位小数，复算也以该精度为基础。

表 7-11 固定方案与独立选优方案的命中率 (%)

核数	固定 B 方案	L2 独立选优	固定方案命中率—配置比秩相关
1	6.0886	7.7355	0.880
2	16.0858	16.2205	0.610
3	21.6492	21.2584	0.563
4	19.6118	21.3471	0.690
5	23.4614	25.3143	0.655

五核两类命中率分别为 23.4614%和 25.3143%。相关系数按同一图上的固定方案命中率与同方案配置比计算，不把两个方案的命中率混合。正相关表示在这批图中较高命中率通常伴随较大配置收益，不表示任意两张图都按命中率排序，也不排除开启缓存后个别方案更慢。

7.7.2 几何均值为何能够保留乘积关系

令逐例配置比、选解比与综合比分别为 x_i 、 y_i 、 $z_i = x_i y_i$ 。由于这些比值均为正，先取对数再平均可以保持加法关系；指数还原后得到几何均值的乘积分解：

$$G_x = \exp\left(\frac{1}{n} \sum_{i=1}^n \ln x_i\right), G_y = \exp\left(\frac{1}{n} \sum_{i=1}^n \ln y_i\right) \quad (7-12)$$

$$G_z = \exp\left(\frac{1}{n} \sum_i \ln(x_i y_i)\right) = G_x G_y. \quad (7-13)$$

表 7-12 配置、选解与综合比的几何均值

核数	配置效应	选解效应	综合比
1	1.001899	1.000381	1.002281
2	1.004521	1.000662	1.005186
3	1.011185	1.001572	1.012775
4	1.015211	1.004338	1.019615
5	1.016317	1.009934	1.026414

五核三个几何均值约为 1.016317、1.009934 和 1.026414，在未舍入值下严格满足乘积关系。几何均值是补充的乘性统计，不能替代题面要求的逐图加速比算术平均。正文主结果曲线、表 10-1 和逐例指标均保持题目口径。

算术均值的情况不同。定义以 n 为分母的经验协方差，则

$$\overline{xy} = \bar{x} \bar{y} + \frac{1}{n} \sum_i (x_i - \bar{x})(y_i - \bar{y}). \quad (7-14)$$

只有协方差恰为零等特殊情形下，算术平均的综合比才等于两个算术平均效应的乘积。因此，直接用 1.027400 除以 1.016766 不能作为平均选解比的计算方法。该区别是聚合口径问题，不是评价器或实验数据产生矛盾。

7.7.3 比值与时间降幅不可互换

对单例，时间降幅为 $d_i = 1 - 1/x_i$ ，而比值超出 1 的部分为 $x_i - 1$ ，两者在小幅变化时接近但并不相同。汇总时也有 $\bar{d} = 1 - \frac{1}{n} \sum_i 1/x_i$ ，不能直接将平均配置比代入单例公式得到平均时间降幅。本文保留比值、百分比及其分母定义，避免把“约 1.7% 的比值超额”写成所有图普遍节省 1.7% 的时间。

8 模型检验与算法分析

本章检验方案合法性、数值口径、相对对照的方向差异、核数变化和求解成本。原结构统计与组件来源继续使用存档记录，新增符号检验校正及扩核计数只读冻结表；不新增求解或硬件实验。AI 辅助范围与历史信息待核验项见附录 D。

8.1 检验框架与证据矩阵

表 8-1 把每一类检验的手段、覆盖范围、结果与尚存的缺口放在一起，便于逐项核对。

表 8-1 模型检验的证据矩阵

检验对象	手段	覆盖范围	结果	尚存缺口
方案合法性	官方评价器执行；覆盖、周期、核归属、原依赖、Pipe、COPY 分解核查	1400 格选解+70 组同方案对照，共 1470 组	全部通过	未用第二套实现重建带宽与容量活期
数值与来源一致性	方案、官方结果与输入的 SHA256 绑定；全文数字由存档数据重算核对	全部表、图与正文数字	一致	属作者自检
下界一致性	命题 4.2 的 LB_k 与官方 Makespan 比较；求解中的运行时断言	1400 格	0 格低于下界	下界不含带宽与等待项
相对对照的显著性	符号检验、Wilcoxon 符号秩检验	14 个场景-核数组	符号检验原始 $p < 10^{-22}$ ；14 组校正后最大约 1.226×10^{-21}	C3 不是等预算对照
稳健性	逐组最小值、退化计数、规模与平均并行度的秩相关	1400 格	归档结果均不慢于 REF；描述结构与性能的秩相关	测试集之外无数据
组件作用	最终方案来源的白盒统计	1400 格	改进阶段产生 35.6%至 40.0%的最终方案	不是等预算消融
预算灵敏度	首次失败与补跑、同请求阶段增量	case_087 四格；五核 B 三阶段	600 秒对 1 张图不足	无等预算消融
L2 配置效应	同方案配对、分解恒等式	500 对	8 对退化，全部列出	未扫描容量与带宽

8.2 加速比分布、并行效率与超线性现象

表 8-2 加速比分布与并行效率（每组 100 图）

场景-核数	平均加速比	并行效率 $\bar{S}_k/k$	最小（用例）	最大（用例）	加速比超过核数的图数
A2	1.8553	0.9276	1.0456 (case_064)	2.4751 (case_084)	26
A3	2.5606	0.8535	1.1133 (case_064)	3.2877 (case_084)	14
A4	3.1973	0.7993	1.1719 (case_064)	4.4784 (case_059)	14
A5	3.7433	0.7487	1.2023 (case_064)	5.5011 (case_059)	8
B1	1.0614	—	1.0000 (case_001)	1.9726 (case_044)	55
B2	1.9925	0.9963	1.4248 (case_064)	3.4125 (case_044)	40
B3	2.8011	0.9337	1.3553 (case_064)	3.5503 (case_083)	27
B4	3.5210	0.8803	1.7361 (case_069)	4.8234 (case_083)	20

场景-核数	平均加速比	并行效率 $\bar{S}_k/k$	最小（用例）	最大（用例）	加速比超过 核数的图数
B5	4.1311	0.8262	1.8118 (case_071)	5.9116 (case_092)	14
L2-1	1.0638	—	1.0000 (case_001)	1.9726 (case_044)	71
L2-2	2.0029	1.0015	1.4248 (case_064)	3.4128 (case_044)	43
L2-3	2.8348	0.9449	1.3560 (case_064)	3.7727 (case_090)	30
L2-4	3.5811	0.8953	1.8150 (case_064)	4.8234 (case_083)	21
L2-5	4.2190	0.8438	1.9323 (case_005)	5.8962 (case_092)	17

注：并行效率为平均加速比除以核数；最后一列统计加速比大于核数的图数（单核组即大于1的图数）。

并行效率定义为平均加速比与核数之比，

$$E_k = \frac{\bar{S}_k}{k} \quad (8-1)$$

E_k 是相对固定 REF 的平均加速比除以核数，不是“多加一核”的边际收益。三个场景 2 至 5 核的该指标均下降，反映平均扩核收益没有等比例增加。共享带宽可类比 Roofline 的资源上限[17]，等待可类比 Amdahl 分析中的非并行部分[18]；这些类比用于解释，本文没有拟合或验证一套独立 Roofline/Amdahl 性能模型。

表中有一部分图的加速比超过了核数：场景 A 两核有 26 张图超过 2，场景 B 五核有 14 张、L2 五核有 17 张超过 5，最大值为场景 B 五核 case_092 的 5.9116。这并不违背物理约束。加速比的分母 REF 是原版启发式核内调度在整图单核上的结果，并非单核最优；本文的单核方案在 55 张图上优于 REF，最多达到 1.9726 倍（case_044），可见 REF 离单核最优还有相当距离。多核加速比因此同时包含并行收益与相对原版调度的质量收益，个别图超过核数是两者叠加的结果。题目规定的加速比口径保持不变，这里只说明其构成。

12 个多核组中有 9 组最小加速比来自 case_064：该图 906 个非 COPY 操作，平均并行度 6.53、最大分层宽度 62。它在 A 的 2 至 5 核、B 的 2 至 3 核及 L2 的 2 至 4 核均为组内最小值。该现象与较低并行空间相容，但不能仅据组内排名给出所有瓶颈的唯一解释。

方案也不是简单均分。场景 A 最终方案的 Task 数中位数在 2 至 5 核依次为 8、10.5、33.5、27.5，最少的只有 2 至 3 个 Task，最多达 4361 个（图 8-1）。静态计算负载的不均衡度定义为




图 8-1 场景 A：最终 Task 粒度分布

$$B = \frac{\max W_c}{\frac{1}{k} \sum_{c=0}^{k-1} W_c}, W_c = \sum_{u: a(g(u))=c} \max(1, \text{cycles}_u) \quad (8-2)$$

$B=1$ 表示各核计算量完全均衡；它不计通信、双 Pipe 重叠与等待，不等于实际利用率。场景 A 最终方案的 B 中位数为 1.013 至 1.079，最大到 2.727（图 8-2）；五核时还有 7 张图的最终方案只用了不到 5 个核心。算法在不同图上选择了差别很大的粒度与放置，并行收益抵不过通信代价时会主动少用核心，而不是把图机械地切成 k 块。




图 8-2 场景 A：静态计算负载均衡

8.3 相对对照基线 C3 的配对检验

为描述终点方案的方向差异，对每个场景一核数组按 100 张图配对。精确符号检验剔除持平项，只使用更快与更慢计数；其参照假设为非零差异正负方向等概率。双侧概率为

$$p=\min\left(1,2^{1-n}\sum_{j=0}^m\frac{n!}{j!(n-j)!}\right) \quad (8-3)$$

其中 n_+ 、 n_- 为 R12 更快与更慢的图数。Wilcoxon 符号秩检验[19]还利用差异的大小：取 $d_i=\ln(T_{C3,i}/T_{R12,i})$ ，剔除 $d_i=0$ 后按 $|d_i|$ 取平均秩 rk_i ，式(8-3)中 $n=n_++n_-$ ， m 为 n_+ 与 n_- 的较小者。

$$W_+=\sum_{d_i>0}rk_i, z=\frac{W_+-n(n+1)/4}{\sqrt{n(n+1)(2n+1)/24-\sum_g(t_g^3-t_g)/48}} \quad (8-4)$$

n 为非零差异的配对数， t_g 为第 g 组并列值的个数。结果见表 8-3，逐组胜平负的全貌见图 8-3。




图 8-3 跨场景：相对 C3 的逐例胜平负

表 8-3 R12 相对 C3 的配对检验（每组 100 图）

场景-核数	更快/持平/更慢	符号检验 $\log_{10} p$	Wilcoxon z	有效配对数
A2	92/7/1	-25.72	8.29	93
A3	91/7/2	-24.05	8.28	93
A4	92/4/4	-22.06	8.47	96
A5	93/5/2	-24.64	8.45	95
B1	82/18/0	-24.38	7.87	82
B2	90/10/0	-26.79	8.24	90
B3	92/7/1	-25.72	8.37	93
B4	93/7/0	-27.69	8.37	93
B5	94/5/1	-26.31	8.46	95
L2-1	81/19/0	-24.08	7.82	81

场景-核数	更快/持平/更慢	符号检验 $\log_{10} p$	Wilcoxon z	有效配对数
L2-2	91/9/0	-27.09	8.28	91
L2-3	92/7/1	-25.72	8.37	93
L2-4	93/7/0	-27.69	8.37	93
L2-5	94/5/1	-26.31	8.46	95

注：符号检验为精确双侧检验，列出 $\log_{10} p$ ；Wilcoxon 检验取正态近似并做并列校正。

14 组精确符号检验的原始 p 值均小于 10^{-22} ，最大约为 8.758×10^{-23} 。按 14 次比较作 Bonferroni 校正后，最大校正值约为 1.226×10^{-21} ，方向差异仍明显。Wilcoxon 的原存档 z 值为 7.82 至 8.47；它需要非零差异分布等附加条件，本文保留统计口径而不把 z 值当作效应量。

显著性不等于强基线、等成本优势或外部泛化。C3 与 R12 搜索预算结构不同；14 组重复使用同一批图，不能将 p 值再按独立证据合并；正式图也不是从所有图中随机抽样。检验仅对既定参照假设下的方向差异提供补充，主结论仍需与降幅、退化幅度和时间成本共同判断。

8.4 稳健性分析：核数、规模与并行度

题目要求算法“在 2 至 5 核范围内均能稳定地、高效地生成高质量结果”。核数维度上有四条证据：1400 个配置格没有一格慢于 REF（表 8-2 最小值列）；场景 A 的最小加速比随核数单调上升，从两核的 1.0456 升到五核的 1.2023；每个组相对 C3 的更快图数都不少于 81 张，多核组都不少于 90 张；相对 C3 更慢的配置在场景 A 为 9/400、场景 B 为 2/500、L2 场景为 2/500，除 case_062 在场景 A 两核、三核外，幅度都在 1% 以内。求解成本方面，各组请求墙钟的中位数在 7.916 秒至 25.68 秒之间。

图的维度上，分别用非 COPY 操作数衡量规模、用平均并行度（表 2-2）衡量结构，计算它们与加速比、与求解墙钟的 Spearman 秩相关系数[20]，见表 8-4。

表 8-4 计算图规模、平均并行度与结果、成本的秩相关

场景-核数	规模与加速比	平均并行度与加速比	规模与求解墙钟
A2	0.107	0.683	0.901
A5	0.158	0.803	0.905
B2	-0.051	0.344	0.924
B5	0.192	0.691	0.879
L2-5	0.185	0.663	0.844

注：表中为 Spearman 秩相关系数，每组 100 张图；规模为非 COPY 操作数，平均并行度为全部操作周期之和与关键路径长度之比。

规模与加速比的 Spearman 系数在这几组中较小，而规模与求解墙钟为较强正相关。其与“较大图的完整评价成本较高”的解释相容，但相关性不能单独识别某一程序阶段的耗时贡献。

平均并行度较低的 11 图，五核 A、B、L2 平均加速比为 2.766、3.311、3.406；其余 89 图为 3.864、4.232、4.319。这说明依赖结构与加速在本测试集中有关联，不证明它是唯一决定因素；带宽、驻留、参数和候选覆盖仍共同影响最终结果。

8.5 白盒统计：最终方案由哪个组件产生

R12 在一次请求内按固定顺序运行多个组件（4.7.2 节）。每个配置格最终输出的方案，都能追溯到首次给出它的组件：该组件的候选在当时字典序最优，此后运行的组件都没有找到更优的候选。表 8-5 按场景统计了 1400 个配置格最终方案的来源。

表 8-5 最终方案的来源组件（配置格数）

产生最终方案的组件	场景 A（400 格）	场景 B（500 格）	L2 场景（500 格）
基础构造	240	322	311
减少活动核心	4	5	4
依赖带候选	39	—	—
反馈重排	97	52	49
分量家族	18	8	3
跨配置重评价	—	—	3
插入式候选	2	107	123
局部微批	—	6	7
改进阶段合计（占比）	160（40.0%）	178（35.6%）	189（37.8%）

注：场景 A 为 2 至 5 核，场景 B 与 L2 场景为 1 至 5 核；“—”表示该组件在此场景不启用。基础构造包括分量打包、链块波次、分量批次，场景 B 与 L2 另有链块迁移；反馈重排在场景 A 为划分不变的重排，在场景 B 与 L2 为关键链局部移动。来源按选中方案的官方结果文件所在的阶段目录判定；五核 B 中来源为插入式候选或局部微批的图，与 6.4.4 节同请求阶段记录中后两个阶段有改善的图逐一对应。

这是存档运行记录的读表统计。某组件产生了最终方案，说明它在该请求中给出了字典序更优的候选，但说明不了去掉它以后其余组件能否补上这一改进；它不能替代等预算消融。在这一限定下，表中可以读出四点。

第一，基础构造给出多数最终方案，改进阶段在 A、B、L2 中分别产生 160、178、189 格，占 40.0%、35.6%、37.8%。这是按来源目录和哈希判定的终点统计，不是关闭模块后的反事实结果。

第二，场景专属组件在各自的场景中都产生了最终方案。场景 A 中，反馈重排产生 97 格，约占四分之一；依赖带候选产生 39 格，在两核、三核分别为 7 格与 4 格，在四核、五核各为 14 格；插入式候选只产生 2 格，这与场景 A 的代价主要由 Task 粒度与放置决定（5.1.1 节）相符。场景 B 与 L2 场景中，插入式候选分别产生 107 格与 123 格，是最大的改进来源；关键链局部移动分别产生 52 格与 49 格；局部微批只产生 6 格与 7 格，与它只在确有 Spill 时启动的设计、以及 Spill 集中在少数图上的事实（6.4.3 节）一致。

第三，来源随核数变化。场景 B 的插入式候选在一核时产生 28 格，五核时只有 10 格；关键链局部移动则从一核的 0 格增至五核的 17 格。L2 场景的趋势相同，插入式候选从 27 格降到 15 格，关键链局部移动从 0 格增到 16 格。核数少时改进主要来自核内次序，核数多时越来越多地来自沿跨核关键链的调整。

第四，参数层面的观察。依赖带的四种宽度中，宽度 4、8、16 分别产生 18、14、7 格，宽度 2 没有产生任何最终方案；场景 A 的反馈重排有两种时长口径，按整机时间线实测时长重排的产生 70 格，按 Task 核内局部时长重排的产生 27 格。前者提示宽度 2 的

候选在本测试集上边际作用很小，后者与“计入等待和带宽争用的实测时长更能反映 Task 真实代价”的直觉一致。两条同样是来源统计，不是控制变量的参数扫描。

8.6 灵敏度分析：求解预算与求解成本

预算影响分为首次可行解时效和后续改进空间。图 8-4 保留各组墙钟长尾；常规预算是否足够，应结合失败记录而非只看中位数判断。




图 8-4 求解墙钟与预算长尾

case_087 的 A2 至 A5 在 600 秒内没有顶层成功结果，1800 秒补跑后实际用时 753.0 至 1036.1 秒。其余 1396 格在常规预算内得到结果。缺少阶段日志和重复计时，不能由这 4 格推断所有大图的最低搜索时间或断言失败完全由图规模决定。

五核 B 的控制阶段已获得平均加速比 4.073198，后续两阶段最终为 4.131077。该记录说明当前流程中先得到的方案已有较高终点质量，但不能据此推断缩短总预算后仍一定得到相同控制结果；阶段运行条件也可能随预算变化。

8.7 小结

综合来看，合法性自检、全量分布、终点配对比较和组件来源分别回答不同问题。相对 C3 的多数方向优势在校正后的符号检验中仍存在；全部最终方案不慢于 REF，但包含 4 格补跑。结构相关性和模块来源不作因果归因，等预算消融、外部图和 L2 参数扫描仍未完成。

8.8 核数扩展的逐例非单调检验

逐核平均曲线递增，不等于每张图增加一核都更快。利用附录中相邻核数的实际终点，按同一图计算 $T_{k+1} - T_k$ ，在 2 至 5 核的三个相邻转移上分别统计更快、持平和更慢。表 8-6 中每行仍为 100 张图，不把同一图跨核重复出现视为独立样本。

表 8-6 相邻核数扩展的逐例结果（每行 100 图）

场景	核数变化	更快/持平/更慢	最差增时/%	最差用例
A	2 → 3	97/3/0	0.0000	009
A	3 → 4	96/3/1	0.1862	048

场景	核数变化	更快/持平/更慢	最差增时/%	最差用例
A	4 → 5	90/6/4	0.8799	069
B	2 → 3	98/1/1	5.1278	064
B	3 → 4	97/3/0	0.0000	005
B	4 → 5	87/10/3	2.4817	035
L2	2 → 3	98/1/1	5.0682	064
L2	3 → 4	99/1/0	0.0000	044
L2	4 → 5	90/7/3	3.6685	035

最差增时以 $100(T_{k+1}/T_k - 1)$ 计算，正值表示更慢。增加核心理论上允许保留原有分配并添加空队列，但这里比较的是两次独立有限搜索得到的最终方案，不是把原方案无条件嵌入后重新选择；因此观测非单调不与“允许空核心”相矛盾。

这些记录与相对 C3 的退化是两类不同事件。前者比较本方法相邻核数的方案，后者比较同核数两种方法的方案。同一用例可以在一种比较中改善、在另一种比较中退化，不能相加作为统一失败率。case_062 的低核数对照问题以及 case_039 的 A 四核至五核变化，应分别沿各自比较轴诊断。

本检验只复用归档周期，既没有为非单调实例重新搜索，也没有将低核数优胜方案追加到高核数候选集。若后续采用跨核保底机制，需要重新定义预算、运行并报告全部受影响结果；不能只把附录中的高核数数值替换为较小值。

9 模型评价与推广

9.1 主要认识

把三个场景放在一起看，可以得到四条不依赖具体数字的认识。

(1) 粒度、核心归属与核序需要联合评价。case_062 的低核数和高核数终点采用不同 Task 粒度，产生明显不同的启动和搬运代价；终点表解释了差异形态，但尚未查明候选生成和截断的完整原因。

(2) 同核合并转移了容量代价，并没有消除它。从场景 A 到场景 B，五核平均边界新增由 13.56 MiB 降到 5.511 MiB，Spill 新增却由 1.234 MiB 升到 2.706 MiB，而且高度集中在少数图上（前 10 张图占五核 B 全部 Spill 字节的 93.84%）。优化的对象从“少切几刀”变成了“驻留谁、何时驻留”。

(3) 代理量不能混作保证。命中率和搬运量可以用于诊断或候选组织，只有具有证明的下界才能承担严格剪枝，最终择优以官方结果为准。正相关不意味着每个实例都加速。

(4) 图结构与收益有关，但不是已识别的唯一原因。平均并行度与五核加速比的秩相关较强，规模与加速比相关较弱；这些是给定测试集内的关联证据，不给出测试集外的加速上限。

9.2 模型的优点

评价口径一致。最终报告使用原版评估结果，候选代理不替代正式评价；仍需要检查图、方案、配置和程序版本的一致性。

下界用途明确。全局界支持满足条件时的近优认证，固定方案界支持候选淘汰；未触发证书的实例不作统一精度承诺。

搜索是结构化的。安全链收缩、依赖带分组、尾长优先分核、反馈重排、Treap 插入、Spill 触发微批各有明确的结构依据，追加式分核还有无环性的证明（命题 5.1）；候选数量有界，全流程无随机种子，结果与方案哈希绑定，可以复查。

实验全量、不作筛选。1400 个配置格与 500 对同方案对照全部保留，退化记录、预算例外、首次失败全部披露；相对 C3 的优势在 14 个组中都通过了配对检验。

测量方法可迁移。把 L2 的收益拆成同方案配置效应与选解效应，并给出逐例成立的分解恒等式，避免把求解器行为的变化记在硬件头上。

框架可复用。三个场景共用决策结构、择优规则与多数候选部件，场景专属机制只加在候选生成层，每一项都对应代价结构中一个明确的新增维度。

9.3 模型的不足

一般实例没有最优性保证。全局下界虽可给出有效的间隙上界，但在通信和等待较强时可能很松，证书未必达到实用精度；近优触发覆盖率尚未汇总。

组件来源和同请求阶段记录不是等预算消融。它们显示特定模块在既定顺序中产生过更优终点，不能唯一分配 43.48% 等总体降幅，也不能排除其余模块在删除该模块后补偿收益。

没有做 L2 的参数扫描。容量与带宽在全部实验中固定，第 7 章识别的是该配置的联合净效应，不能分别给容量与带宽分配贡献。

个别负例仍缺少完整机制诊断。case_062 的低核数粒度差异、case_026 等 L2 退化已确认终点事实，但尚未追踪候选覆盖、预算截断或逐事件因果链。

验证属于自检。全部核查由作者完成，没有用第二套独立实现重建带宽与容量的动态过程。

9.4 改进方向

做等预算的独立消融。固定预算，依次关闭依赖带、反馈重排、分量家族、插入与微批，把增量对照升级为可归因的比较；8.5 节发现依赖带宽度 2 从未产生最终方案，可以优先检验去掉它、把预算让给其余候选的效果。

收紧下界。在计算下界之外加入跨 Task 边界搬运的必然字节与跨核等待，得到高核数下更紧的下界，使剪枝与近优认证在更多实例上起作用。

按结构与规模分配预算待检验方向。规模与墙钟相关可以指导预算设计，但不能直接把相关关系当成新策略已经有效；需先保留困难实例的阶段计时和首个可行解时间。

L2 参数扫描与缓存感知的候选。对容量与带宽做二维扫描，分离两者的作用；在候选生成中考虑共享输入的首次读取时序，减少多个核心同时未命中的情况。

粒度候选应覆盖粗细两端，并记录哪些候选确已生成、评价和被截断。case_062 提示检查这一覆盖过程的必要性，尚不能据此保证加入某个粒度就一定改善。

9.5 模型的推广

本文的候选生成、下界筛选与真实评价分工，可供其他受资源争用影响的任务映射问题参考。迁移时需要重新明确评价语义、重证下界并验证候选参数，不能直接移植数值结论。对算子融合、切分及硬件特性评价，可以分别借鉴结构候选和同方案配对设计；这些是可研究的方向，尚未在题目以外的数据和平台上验证。

10 结论

本文围绕多核 NPU 的切图、分核和核序建立统一的仿真驱动模型，采用结构化候选、适用下界与官方评价相结合的 R12 流程。在 100 张正式图、1400 个场景一核数配置上保留全量结果。三问主要数值见表 10-1，逐例原始指标见附录 A。

表 10-1 三问核心结果汇总（每格 100 图，逐例比值的算术平均）

核数	问题一 场景 A	问题二 场景 B	问题三 无 L2 P_B	问题三 有 L2 P_L	同方案配置比 $\bar{R}_{hw}$	分别选优比 $\bar{R}_{select}$
1	1 (定义)	1 (定义)	1.0614	1.0638	1.001978	1.002364
2	1.8553	1.9925	1.9925	2.0029	1.004765	1.005591
3	2.5606	2.8011	2.8011	2.8348	1.011799	1.013423
4	3.1973	3.5210	3.5210	3.5811	1.015729	1.020292
5	3.7433	4.1311	4.1311	4.2190	1.016766	1.027400

注：问题一、问题二的一核点按题目定义为 1；问题三两条曲线的一核点为实测值（无 L2 列即优化后的 B1）。同方案配置比固定无 L2 下选出的方案 P_B ，分别选优比的分母换成 L2 下独立选出的方案 P_L 。

问题一采用链收缩、依赖带、追加式分核与反馈重排，在全部 400 个配置格上获得多核加速。五核平均 3.743、中位 4.130、最小 1.202，相对 C3 的逐图耗时平均降低 43.48%。9 个相对 C3 退化配置和 case_087 的补跑保留；主曲线见图 5-5，逐例结果见附录 A。

问题二同时权衡跨核边界、同核驻留与 Spill。五核平均加速比 4.131，相对 C3 的逐图耗时平均降低 34.49%；微批阶段在两张图上进一步改善。核心归属不变量只约束 Spill 前边界字节。主曲线见图 6-5，题设一核点为 1，优化 B1 的实测结果另列。

问题三用同方案配对区分配置变化与重新选解。五核 L2 独立选优平均加速比 4.219，同方案配置比均值 1.016766、中位 1.000546，综合比 1.027400。500 对中 8 对退化；命中率呈正秩相关但无逐例单调保证。三条方案一配置曲线见图 7-3，几何均值分解见表 7-12。

模型检验保留退化幅度、预算例外、组件来源及结构相关性。配对符号检验经 14 次比较校正后仍显示相对 C3 的方向差异，但不构成等预算或最强基线优势。正式结论包括测试集内的收益与不利结果，不将描述性相关改写为唯一机制。

本文的方法特点概括如下。

(1) 评价一致的建模与分层下界。统一刻画方案表示、资源约束和边界计账，区分计算/窗口全局界与固定方案界。仅对满足相应全局界条件的实例给出 3%主目标间隙证书，不作全量近优保证。

(2) 按代价结构组织的结构化候选族。场景 A 以安全链收缩、依赖带弱连通分组、尾长优先分核与划分不变的反馈重排控制边界搬运，追加式分核有联合无环性的证明；场景 B 与 L2 场景以驻留组织候选和只在确有 Spill 时启动的局部微批处理容量溢出，并以核归属不变式保证 Spill 前的边界 COPY 严格不变。

(3) 配置与选解的配对分解。分别定义同方案配置比和独立选优综合比，保留逐例恒等式，并补充几何均值的可乘分解；命中率相关、局部退化和计划搬运变化按不同口径报告，不把配置收益写成算法创新。

(4) 全量结果与可核验来源。逐例表、退化、补跑、组件来源及哈希记录保留。来源统计说明模块与最终方案的对应关系，不称为完成独立因果归因。

结论的适用边界是：限于这 100 张图、题目给定的固定配置与 600 秒软预算（case_087 的场景 A 四格为 1800 秒补跑）；C3 是事后同口径对照，不是等预算消融；L2 的容量与带宽没有分别扫描，报告的是指定配置的联合净效应。

参考文献

- [1] Sze V, Chen Y H, Yang T J, Emer J S , Efficient processing of deep neural networks: a tutorial and survey, *Proceedings of the IEEE*, 105(12): 2295-2329, 2017.
- [2] Chen Y H, Krishna T, Emer J S, Sze V , Eyeriss: an energy-efficient reconfigurable accelerator for deep convolutional neural networks , *IEEE Journal of Solid-State Circuits*, 52(1): 127-138, 2017.
- [3] 中国研究生数学建模竞赛组委会, “华为杯”第二十三届中国研究生数学建模竞赛 A 题: 通用神经网络处理器下的多核调度问题(赛题正文、附录与评估程序) , 2026.
- [4] Graham R L , Bounds on multiprocessing timing anomalies , *SIAM Journal on Applied Mathematics*, 17(2): 416-429, 1969.
- [5] Kwok Y K, Ahmad I, Static scheduling algorithms for allocating directed task graphs to multiprocessors, *ACM Computing Surveys*, 31(4): 406-471, 1999.
- [6] Topcuoglu H, Hariri S, Wu M Y , Performance-effective and low-complexity task scheduling for heterogeneous computing , *IEEE Transactions on Parallel and Distributed Systems*, 13(3): 260-274, 2002.
- [7] Chen T, Moreau T, Jiang Z, 等 , TVM: an automated end-to-end optimizing compiler for deep learning , 13th USENIX Symposium on Operating Systems Design and Implementation (OSDI 18) , 578-594, 2018.
- [8] Xing Y, Liang S, Sui L, 等 , DNNVM: end-to-end compiler leveraging heterogeneous optimizations on FPGA-based CNN accelerators , *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems*, 39(10): 2668-2681, 2020.
- [9] Zheng L, Li Z, Zhang H, 等 , Alpa: automating inter- and intra-operator parallelism for distributed deep learning , 16th USENIX Symposium on Operating Systems Design and Implementation (OSDI 22) , 559-578, 2022.
- [10] Shi Y, Yang Z, Xue J, 等 , Welder: scheduling deep learning memory access via tile-graph , 17th USENIX Symposium on Operating Systems Design and Implementation (OSDI 23) , 701-718, 2023.
- [11] Popp M, Schlag S, Schulz C, Seemaier D , Multilevel acyclic hypergraph partitioning , *Proceedings of the Symposium on Algorithm Engineering and Experiments (ALENEX 2021)* , 1-15, 2021.
- [12] Hong J W, Kung H T, I/O complexity: the red-blue pebble game, *Proceedings of the 13th Annual ACM Symposium on Theory of Computing*, 326-333, 1981.
- [13] Belady L A , A study of replacement algorithms for a virtual-storage computer , *IBM Systems Journal*, 5(2): 78-101, 1966.
- [14] Garey M R, Johnson D S , *Computers and Intractability: A Guide to the Theory of NP-Completeness*, San Francisco: W. H. Freeman, 223, 1979.

- [15] Seidel R, Aragon C R , Randomized search trees , *Algorithmica* , 16(4-5) : 464-497, 1996。
- [16] Kahn A B , Topological sorting of large networks , *Communications of the ACM*, 5(11): 558-562, 1962。
- [17] Williams S, Waterman A, Patterson D , Roofline: an insightful visual performance model for multicore architectures, *Communications of the ACM*, 52(4): 65-76, 2009。
- [18] Amdahl G M, Validity of the single processor approach to achieving large scale computing capabilities, *Proceedings of the AFIPS Spring Joint Computer Conference*, 483-485, 1967。
- [19] Wilcoxon F, Individual comparisons by ranking methods, *Biometrics Bulletin*, 1(6): 80-83, 1945。
- [20] Spearman C , The proof and measurement of association between two things , *The American Journal of Psychology*, 15(1): 72-101, 1904。

附录

附录 A 逐例结果（官方评估程序输出）

以下九张逐例表完整保留原归档数值，每表 100 个用例，共 900 行。Makespan 单位为 cycles，新增 COPY 单位为 bytes，命中率为按字节统计的百分比。用例编号 001 至 100 对应 case_001 至 case_100。A 的 case_087 四格为 1800 秒补跑，其余为 600 秒常规预算。为避免在小四字号下挤压数字，问题三表中的无 L2 时间和新增量复用表 A-3、A-4 的相应核数列，与表 A-5 至 A-9 按用例一一连接。

A.1 问题一：场景 A

表 A-1 问题一逐例 Makespan（REF 为整图单核基准）

用例	REF 单核	2 核	3 核	4 核	5 核
001	233110	116868	78545	58984	47502
002	261945	140236	98023	76865	58180
003	602212	393827	321535	287598	276507
004	392357	199074	134043	104188	88341
005	95618	80999	72553	70248	69060
006	82837	43033	30917	27895	27679
007	1012562	507494	338094	254398	203834
008	487605	244266	163359	123060	100603
009	153261	92198	92198	81530	73571
010	86969	45626	30856	27800	24563
011	184697	92646	69625	46880	46880
012	59088	30094	21894	17853	14212
013	263949	132198	88351	66982	54363
014	17698626	8759857	5865918	4447779	3614837
015	177362	92321	61168	51205	42955
016	7715523	4646180	3793761	3592965	3306411
017	162810	84055	58959	48848	35470
018	1004367	503411	339838	258063	202636
019	81144	43224	30852	24099	22228
020	532746	266580	177950	133704	107650
021	6567937	3156352	2106282	1550324	1250168
022	56780	28881	19370	14641	11813
023	122614	61424	41720	30522	24965
024	2555343	1539668	1256817	1189845	1095663
025	4863026	2434032	1624426	1219420	975282
026	99203	58112	41276	41219	41219
027	2363952	1120962	837049	559196	558753
028	43836040	20541851	14076015	10461460	8605530
029	37555	19740	12743	11028	9383
030	2808034	1394193	931629	698657	560814
031	1414369	706033	485202	392550	306307
032	41443	21706	15674	12763	10415
033	1774196	904907	607519	461610	373638

用例	REF 单核	2 核	3 核	4 核	5 核
034	842996	415383	287578	230925	184639
035	169571	95406	95406	90516	82052
036	931510	466068	311345	233584	187182
037	210001	105374	74038	53320	43800
038	1364555	681518	461018	345206	283932
039	1435262	708561	485565	392896	395297
040	253454	143799	110105	98759	93219
041	6003957	2965113	1976739	1484401	1192525
042	1686740	835375	571947	435238	363428
043	677656	355614	268777	261670	232286
044	154407	78699	78699	78699	78699
045	125614	63059	42601	31878	26164
046	276455	158876	142176	124612	124612
047	326508	245880	187273	171560	158050
048	222220	169359	145022	145292	145490
049	196276	148351	124128	115314	108297
050	149690	108121	85329	74902	70368
051	607628	367112	299245	282785	261214
052	180301	91267	65207	50125	43641
053	1472686	770010	546106	492232	492699
054	815051	515425	391890	331031	298043
055	118835	57941	43655	31823	26800
056	277285	213386	180659	166455	157566
057	59726	32042	21762	16879	14055
058	4539717	2200935	1532101	1184895	1004819
059	829473	369318	254768	185216	150782
060	888789	458745	308169	232466	185331
061	77191	39298	28342	27170	22059
062	2854809	1976451	1593547	764940	619333
063	1070397	558373	377834	290167	237375
064	19116	18283	17170	16312	15899
065	53068	26972	17918	14288	11235
066	359070	226476	185361	167785	159869
067	63834834	32438342	22543931	16545997	13961132
068	362095	260340	221224	197091	189541
069	25144	21197	19700	18866	19032
070	117300	58234	45660	34658	28840
071	18919	16232	14889	14434	14220
072	23897828	11713796	7870089	5945430	4779968
073	10081626	5304875	4427074	3646155	3315864
074	1682239	832726	548347	415984	345470
075	1441809	844156	639599	552334	506598
076	6185113	3046650	2033956	1526939	1230399
077	495320	250735	178739	144734	121081
078	2296143	1080972	763089	619540	536429
079	31052251	14738594	9939977	7495240	5998948

用例	REF 单核	2 核	3 核	4 核	5 核
080	292138	145926	100325	100325	100325
081	151795	76860	51943	39588	30943
082	721041	450921	355841	311867	290998
083	1057993	537673	414361	390026	370632
084	2507412	1013056	762658	629028	503472
085	3187899	2105594	1593477	1291419	1216812
086	118403	99674	92319	84701	83340
087	3974071	2093249	1483711	1204070	1038529
088	243623	173654	146818	131635	127073
089	693092	346832	243614	178160	147432
090	1178363	513438	397500	346678	346678
091	9186769	4529311	3036878	2288314	1857417
092	4815554	2498492	1841420	1465901	1384732
093	74205	37827	25103	19779	15876
094	94892	49398	39889	27461	23564
095	2084853	1042890	695775	524422	420852
096	84194	47089	30832	26980	26930
097	11491509	5161740	3577028	2626908	2102348
098	177430	89551	82660	69258	64165
099	1622999	811243	544403	405655	336496
100	151223	82771	57566	57566	51287

表 A-2 问题一逐例总额外数据搬运量 (bytes)

用例	2 核	3 核	4 核	5 核
001	1152	2304	3456	4608
002	82944	82944	82944	82944
003	6729464	6729464	6729464	6729464
004	110592	221184	331776	442368
005	2049178	2483610	2483610	2483610
006	56200	91264	664560	664560
007	27648	55296	82944	110592
008	0	0	0	0
009	0	0	928212	928212
010	48384	48384	715508	715508
011	180224	1081344	540672	540672
012	28800	20160	21888	31104
013	8192	16384	24576	32768
014	71556024	71375016	75533208	81189384
015	224536	290056	1081932	342528
016	119566328	119566936	119567544	119568152
017	161280	175104	260352	343296
018	2835456	4075904	4914944	5136384
019	27168	24576	51744	608920
020	0	0	0	0
021	5427200	6707200	4608000	11431936
022	6912	13824	13824	6912

用例	2 核	3 核	4 核	5 核
023	84096	196896	207552	197472
024	39331088	39331288	39331488	39331688
025	248832	304128	304128	110592
026	288	217872	217872	217872
027	1744896	3686400	3317760	5529600
028	99676800	98668800	103033728	105408000
029	0	0	0	0
030	7370752	8237056	9418752	10398720
031	4379136	7348224	14062336	8059392
032	6216	12360	129188	12360
033	6645792	6972480	12826272	7816320
034	1998336	2645504	6690304	3581952
035	0	0	469248	1007048
036	1152	2304	3456	4608
037	204800	1064960	614400	1925120
038	6790656	7045632	9295872	9667584
039	11067392	14323712	16388096	16388096
040	53760	0	2075814	2075814
041	22579200	25559040	26910720	28502016
042	6967584	8251680	7876896	8598528
043	556040	233480	5285512	5285512
044	2014560	2014560	2014560	2014560
045	0	0	0	0
046	6512800	4021280	4513952	4513952
047	3820950	3820950	3820950	3820950
048	853830	1253562	1253562	1253562
049	1784066	1784066	2743324	2743324
050	3456	1219726	1219726	1219726
051	9046218	9046264	9046310	9046356
052	102912	181248	259584	854016
053	7237216	5882944	6360992	6918912
054	6850874	6850874	6850874	6850874
055	57856	115712	115712	198656
056	2922520	2922520	2922520	2922520
057	70272	70272	70272	70272
058	43794432	32858112	45551616	32104448
059	360448	2748416	1081344	4325376
060	8150032	8150032	8150032	3641728
061	34560	43008	62208	382558
062	13393920	13393920	897024	897024
063	337920	337920	337920	337920
064	65662	65662	131982	131982
065	13968	27936	41760	55728
066	1953158	2890070	2890070	2890070
067	272726272	298754304	282468608	298754304
068	2598030	2598030	2598030	2598030

用例	2 核	3 核	4 核	5 核
069	532364	532364	532364	532364
070	129536	259072	360960	462848
071	375274	375274	375274	375274
072	99330848	177263132	177263132	177263132
073	98703232	100065536	144435968	102790144
074	5910536	7626752	7790592	8392712
075	8130090	8130090	8130090	8130090
076	33976320	33654784	33742848	35696640
077	57344	114688	172032	172032
078	15039360	15825792	15039360	15825792
079	47714304	43948032	44257280	45352960
080	2191360	3047424	3047424	3047424
081	0	0	0	0
082	4435418	8998170	9580494	10097280
083	13151840	14082240	15012640	15943040
084	30190464	30190464	0	0
085	40692846	43297606	42980512	46542906
086	2656640	2656640	3103172	3103172
087	35193224	35193224	35193224	35193224
088	1860972	1860972	1860972	1860972
089	238720	477440	716160	954880
090	4145280	6293760	8442240	8442240
091	56506336	55158080	59109376	61130752
092	56912480	57842880	58773280	59703680
093	8192	16384	24576	32768
094	106272	212544	318816	259200
095	0	0	0	0
096	66240	67392	719180	661824
097	14483456	29818880	14221312	21311488
098	0	1602190	1602190	2065850
099	7319552	8798208	9764864	9703424
100	763960	534528	534528	1877578

A.2 问题二：场景 B

表 A-3 问题二逐例 Makespan

用例	1 核	2 核	3 核	4 核	5 核
001	233110	116868	78545	58984	47502
002	261945	137089	94149	73120	59575
003	548159	315516	257302	234056	232588
004	392357	199074	134043	104188	88341
005	83323	60883	52655	52655	52655
006	76373	39367	29782	26251	24618
007	1012562	507494	338094	254398	203834
008	487605	244266	163359	123060	100603
009	147061	84436	63747	55563	52311
010	86057	42846	30856	26147	26147

用例	1 核	2 核	3 核	4 核	5 核
011	184697	92646	69625	46880	46880
012	51532	29730	18114	14886	12712
013	263949	132198	88351	66982	54363
014	17698626	8864262	5924867	4428315	3605387
015	158311	89331	58906	51503	39837
016	7715523	4026549	2876720	2238959	2087323
017	155189	86334	52489	42924	30495
018	1004367	498719	334784	255853	202778
019	74026	40392	28195	21744	18640
020	532746	266580	177950	133704	107650
021	6567937	3194570	2106848	1550324	1250168
022	56750	28851	19370	14574	11813
023	109495	58216	41720	30522	24793
024	2555343	1334769	953408	743027	694207
025	4863026	2431840	1622164	1217444	975282
026	90235	53208	41132	35520	33518
027	2363952	1118352	765280	559196	558753
028	41576363	20615674	13848390	10250099	8211965
029	37555	19740	12743	11028	9383
030	2808034	1403594	933857	700342	561102
031	1412792	732205	483567	394466	306307
032	34524	17554	11808	11164	10415
033	1774196	896676	602408	457602	369453
034	825894	440418	280681	252538	173032
035	162870	95406	71961	56936	58349
036	931510	466068	311345	233584	187182
037	210001	105374	74038	53320	43800
038	1364555	681518	459530	344898	283188
039	1435262	708561	483806	381106	381106
040	236131	140145	105923	95952	89745
041	6003957	2992480	1991992	1490603	1196379
042	1686740	840916	571947	435949	369780
043	644058	350868	267919	240597	240597
044	78274	45248	45248	45248	45248
045	125614	63059	42601	31878	26164
046	216726	109740	82826	79918	79918
047	291280	166394	136827	125959	119372
048	198369	125568	99835	97813	98572
049	181681	106107	84225	70510	64305
050	142450	78327	67318	59891	58897
051	607628	318674	227452	178386	168374
052	175278	86843	62309	45500	41994
053	1341846	728229	497437	425404	375096
054	815051	438618	316491	262542	240647
055	106616	56582	40063	31823	26183
056	258692	147688	117225	104605	97116

用例	1核	2核	3核	4核	5核
057	59056	30025	23294	20957	16538
058	4539717	2261085	1554831	1141608	1004819
059	738041	369318	254073	185216	150782
060	882690	474073	323843	240113	185331
061	77191	39298	28342	26678	22283
062	2854809	1572635	1083992	838854	703542
063	1070397	575202	396695	313176	255854
064	17184	13417	14105	10614	8333
065	44156	22021	16963	11769	9558
066	318124	190462	139098	123721	119141
067	63834834	31418001	21034535	16152614	13054159
068	328200	200719	167916	147382	141879
069	21597	16133	14920	14483	13698
070	110849	58234	43439	34658	25840
071	15824	12826	10782	10331	10442
072	23897828	11836023	7961454	5911772	4831103
073	9839163	5587533	4300595	2507770	2034983
074	1651943	803673	537857	406099	330183
075	1334897	728185	526421	425508	374967
076	6185113	3065214	2050028	1540201	1240011
077	495320	250735	178739	144734	121081
078	2095621	1051374	720770	568228	481517
079	31052251	15446486	10140755	7635624	6045667
080	292138	145926	100325	100325	100325
081	151795	76860	51943	39588	30943
082	718790	387499	263881	217255	195543
083	851601	433315	298003	219344	191867
084	2191327	1168951	836220	629028	503472
085	3187899	1810774	1228758	938020	822333
086	105557	67521	60328	55557	55557
087	3974071	1987606	1371815	1069325	885221
088	219593	134265	117498	98539	98539
089	659152	329430	229298	165616	133338
090	882630	454440	337795	295164	274650
091	9186769	4571759	3053553	2290698	1848187
092	4373417	2162750	1418789	1033609	814597
093	74205	37827	25103	19779	15876
094	84874	48430	35024	27182	20297
095	2084853	1042890	695775	524422	420852
096	75393	41837	30611	26984	25183
097	11491509	5617602	3660459	2626908	2102348
098	176171	89551	65715	52186	50844
099	1622999	811243	544403	405655	324321
100	141463	74200	54371	50324	47130

表 A-4 问题二逐例总额外数据搬运量 (bytes)

用例	1 核	2 核	3 核	4 核	5 核
001	0	1152	2304	3456	4608
002	0	562176	746496	841728	872448
003	24576	6408454	9518568	7733990	9723996
004	0	110592	221184	331776	442368
005	0	2190534	1728714	1728714	1728714
006	166044	614532	841742	913168	411656
007	0	27648	55296	82944	110592
008	0	0	0	0	0
009	327048	1236498	1616024	1890898	2008978
010	63892	471500	48384	778932	778932
011	0	180224	1081344	540672	540672
012	0	461572	20160	21888	31104
013	0	8192	16384	24576	32768
014	71010720	62154168	46130856	48577944	53128200
015	873464	1786394	208128	231168	317952
016	0	404192	12200	15864	214900
017	0	394974	175104	260352	343296
018	1970176	1377280	12853772	3755776	5054464
019	315392	814128	24576	359504	327032
020	0	0	0	0	0
021	4501504	3174400	4710400	4608000	11431936
022	0	6912	13824	13824	6912
023	1100056	1523296	196896	207552	197472
024	0	396848	4040	5256	202660
025	0	27648	55296	82944	110592
026	0	1301728	1491816	724704	491168
027	1400832	1449984	33890304	3317760	5529600
028	62779392	82416768	34820352	31777152	30147072
029	0	0	0	0	0
030	5519360	7644160	9242624	10404864	11479040
031	2251776	2139648	3462144	4922880	8059392
032	0	6216	12360	12360	12360
033	4592640	3391008	4180032	5251680	6509184
034	0	1459712	2341888	2979328	3532800
035	0	0	1735510	1675904	1602218
036	0	1152	2304	3456	4608
037	0	204800	1064960	614400	1925120
038	5627904	6790656	5534208	6950400	8558592
039	7929856	11067392	12414976	13320192	13320192
040	0	2475470	3308532	2473682	2634900
041	30898176	33490944	34879488	39164928	40630272
042	6629376	7262496	8251680	7059744	8045568
043	2867036	9505206	7959640	9832918	9832918
044	0	930400	930400	930400	930400
045	0	0	0	0	0

用例	1 核	2 核	3 核	4 核	5 核
046	0	930400	1860800	2791200	2791200
047	0	3012550	4387628	5012946	3409368
048	0	391302	1016076	1114512	1132628
049	27658	2803330	3516344	1739398	2125062
050	702996	1958198	1393486	1620642	1885008
051	0	393884	960	1252	198040
052	0	102912	181248	259584	333312
053	855054	5317152	7442990	11152366	12135050
054	0	8276074	6482640	7592222	8940968
055	282696	852212	115712	115712	198656
056	25618	3622398	1870000	3214102	3574548
057	0	416890	549116	288	27936
058	28696576	30621696	30400512	32284672	32104448
059	0	360448	2162688	1081344	4325376
060	1439748	1255552	3290252	3131648	3641728
061	0	34560	43008	62208	83712
062	0	10856448	10865664	10054656	10626048
063	0	3323904	3133440	3538944	3253248
064	0	95590	126220	152784	132948
065	0	13968	27936	41760	55728
066	75272	3937564	3077354	3938934	4419676
067	264449408	182202752	187518720	154190976	158705152
068	531976	3519186	3536102	4076226	4184738
069	0	233732	489770	503470	465362
070	0	129536	1523108	360960	462848
071	0	208452	235082	329486	317010
072	108613680	113724192	82414368	85994272	84918960
073	90447872	91806080	93164288	44120192	37201408
074	5255176	3747840	4923392	6230016	7118848
075	0	7124774	12146060	12171570	12788022
076	28280832	31095808	34332672	37442560	40553472
077	0	57344	114688	172032	172032
078	24576	2148480	8054016	6445440	12822528
079	32448512	31780864	33890304	30445568	31907840
080	548864	2191360	3047424	3047424	3047424
081	0	0	0	0	0
082	597130	3234278	2788460	6970608	5194934
083	262144	930400	1860800	2791200	3721600
084	29453952	28717440	0	0	0
085	0	9335690	29372396	29385842	22587672
086	155146	1185860	1851498	2269390	2269390
087	7902720	10142208	5465088	7133184	8050176
088	544128	2582030	2337262	2683862	2683862
089	0	238720	477440	716160	954880
090	0	2341200	4490496	6514560	8606208
091	53947008	57904096	33286976	35909280	39725056

用例	1 核	2 核	3 核	4 核	5 核
092	29294592	16642656	10675392	6788896	4606336
093	0	8192	16384	24576	32768
094	458752	106272	737860	318816	259200
095	0	0	0	0	0
096	107552	719692	67392	78336	623148
097	10584064	11796480	16031744	14221312	21311488
098	852332	0	852966	1249322	1517236
099	5484544	7319552	8798208	9764864	7065600
100	0	1161942	1640268	1961860	1112288

A.3 问题三：无 L2 与只读 Cache 两种配置

无 L2 方案记为 P_B ，其逐核 Makespan 和新增 COPY 见表 A-3、A-4。下列五表同时列出 L2 独立选优 P_L 的时间、新增量和命中率，以及固定 P_B 开启 L2 后的时间与命中率；无 L2 配置不存在缓存命中指标，记为不适用。表内所有数值均沿用原始逐例记录。

表 A-5 问题三逐例结果（1 核）

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
001	233110	0	0.0000	233110	0.0000
002	261945	0	0.0000	261945	0.0000
003	548159	24576	0.0000	548159	0.0000
004	392357	0	0.0000	392357	0.0000
005	83323	0	0.0000	83323	0.0000
006	76373	166044	6.4862	76373	6.4862
007	1012562	0	0.0000	1012562	0.0000
008	487605	0	0.0000	487605	0.0000
009	146683	327048	7.4819	146683	7.4819
010	86057	63892	0.0000	86057	0.0000
011	184697	0	0.0000	184697	0.0000
012	51532	0	0.0000	51532	0.0000
013	263949	0	0.0000	263949	0.0000
014	17689602	71010720	12.2910	17689602	12.2910
015	156783	873464	15.4479	156783	15.4479
016	7715523	0	0.0000	7715523	0.0000
017	155189	0	0.0000	155189	0.0000
018	1003110	1970176	34.3750	1003110	34.3750
019	74026	315392	4.7471	74026	4.7471
020	532746	0	0.0000	532746	0.0000
021	6558837	4501504	50.0597	6558837	50.0597
022	56750	0	0.0000	56750	0.0000
023	109032	1100056	19.1895	109032	19.1895
024	2555343	0	0.0000	2555343	0.0000
025	4863026	0	0.0000	4863026	0.0000
026	90235	0	0.0000	90235	0.0000
027	2359515	1400832	26.8939	2359515	26.8939
028	41555374	62779392	3.3815	41555374	3.3815

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
029	37555	0	0.0000	37555	0.0000
030	2807891	5519360	25.9868	2807891	25.9868
031	1412441	2251776	36.2137	1412441	36.2137
032	34524	0	0.0000	34524	0.0000
033	1774080	4592640	9.6277	1774080	9.6277
034	825894	0	0.0000	825894	0.0000
035	162870	0	0.0000	162870	0.0000
036	931510	0	0.0000	931510	0.0000
037	210001	0	0.0000	210001	0.0000
038	1363312	5627904	17.3617	1363312	17.3617
039	1435262	7929856	0.0000	1435262	0.0000
040	236131	0	0.0000	236131	0.0000
041	6001575	30898176	10.1637	6001575	10.1637
042	1675633	6629376	31.8692	1675633	31.8692
043	642964	2867036	2.2848	642964	2.2848
044	78274	0	0.0000	78274	0.0000
045	125614	0	0.0000	125614	0.0000
046	216726	0	0.0000	216726	0.0000
047	291280	0	0.0000	291280	0.0000
048	198369	0	0.0000	198369	0.0000
049	181681	27658	0.0060	181681	0.0060
050	141691	372270	12.8892	141872	10.4185
051	607628	0	0.0000	607628	0.0000
052	175278	0	0.0000	175278	0.0000
053	1341846	855054	0.0003	1341846	0.0003
054	815051	0	0.0000	815051	0.0000
055	105512	282696	11.0962	105512	11.0962
056	258692	25618	0.0077	258692	0.0077
057	59056	0	0.0000	59056	0.0000
058	4539717	28696576	0.0000	4539717	0.0000
059	738041	0	0.0000	738041	0.0000
060	882534	1439748	31.1384	882534	31.1384
061	77191	0	0.0000	77191	0.0000
062	2854809	0	0.0000	2854809	0.0000
063	1070397	0	0.0000	1070397	0.0000
064	17184	0	0.0000	17184	0.0000
065	44156	0	0.0000	44156	0.0000
066	318124	75272	0.0008	318124	0.0008
067	61875727	197050368	88.5588	63834834	0.0000
068	327848	531976	3.5140	327848	3.5140
069	21597	0	0.0000	21597	0.0000
070	110849	0	0.0000	110849	0.0000
071	15824	0	0.0000	15824	0.0000
072	23890756	108613680	2.6210	23890756	2.6210
073	8702659	90447872	95.4660	8702659	95.4660

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
074	1647335	5255176	23.4920	1647335	23.4920
075	1334897	0	0.0000	1334897	0.0000
076	6183098	28280832	13.3577	6183098	13.3577
077	495320	0	0.0000	495320	0.0000
078	2095621	24576	0.0000	2095621	0.0000
079	31052251	32448512	0.0000	31052251	0.0000
080	291826	548864	16.8614	291826	16.8614
081	151795	0	0.0000	151795	0.0000
082	717869	597130	8.7058	717869	8.7058
083	851601	262144	0.0000	851601	0.0000
084	2191327	29453952	0.0000	2191327	0.0000
085	3187899	0	0.0000	3187899	0.0000
086	105557	155146	0.0025	105557	0.0025
087	3969779	7902720	18.3368	3969779	18.3368
088	219539	544128	1.2106	219539	1.2106
089	659152	0	0.0000	659152	0.0000
090	882630	0	0.0000	882630	0.0000
091	9168820	53947008	10.5386	9168820	10.5386
092	4333631	66000096	79.3550	4358155	5.6952
093	74205	0	0.0000	74205	0.0000
094	84874	458752	3.4469	84874	3.4469
095	2084853	0	0.0000	2084853	0.0000
096	75393	107552	1.5394	75393	1.5394
097	11491509	10584064	0.0000	11491509	0.0000
098	175431	852332	12.3105	175431	12.3105
099	1618902	5484544	25.2355	1618902	25.2355
100	141463	0	0.0000	141463	0.0000

表 A-6 问题三逐例结果（2 核）

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
001	116868	1152	0.0000	116868	0.0000
002	137089	562176	0.0000	137089	0.0000
003	314363	6408454	6.1616	314363	6.1616
004	199074	110592	0.0000	199074	0.0000
005	60375	2190534	10.3340	60375	10.3340
006	39326	614532	26.9994	39326	26.9994
007	507494	27648	0.0000	507494	0.0000
008	244266	0	0.0000	244266	0.0000
009	84423	1236498	18.1690	84423	18.1690
010	42721	471500	29.6773	42721	29.6773
011	92646	180224	0.0000	92646	0.0000
012	29689	461572	11.9454	29689	11.9454
013	132198	8192	0.0000	132198	0.0000
014	8857863	51088824	23.1463	8865476	23.8602

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
015	87960	1786394	28.6870	87960	28.6870
016	4025717	404192	49.6535	4025717	49.6535
017	86028	394974	26.6336	86028	26.6336
018	498614	1377280	43.0650	498614	43.0650
019	40392	814128	8.4923	40392	8.4923
020	266580	0	0.0000	266580	0.0000
021	3193634	3174400	21.7778	3193634	21.7778
022	28851	6912	3.1354	28851	3.1354
023	57260	1523296	21.0907	57260	21.0907
024	1333937	396848	49.8848	1333937	49.8848
025	2431840	27648	0.0000	2431840	0.0000
026	51165	1301728	26.7505	51165	26.7505
027	1118352	1449984	0.0000	1118352	0.0000
028	20601621	82416768	3.5459	20601621	3.5459
029	19740	0	0.0000	19740	0.0000
030	1403449	7644160	46.3375	1403449	46.3375
031	732205	2139648	42.6581	732205	42.6581
032	17554	6216	2.1782	17554	2.1782
033	896372	3391008	35.7219	896372	35.7219
034	440340	1459712	36.0757	440340	36.0757
035	95319	1195418	20.6213	95406	0.0000
036	466068	1152	0.0000	466068	0.0000
037	105374	204800	0.0000	105374	0.0000
038	681309	6790656	27.1460	681309	27.1460
039	705615	11067392	37.0172	705615	37.0172
040	139995	2475470	15.9642	139995	15.9642
041	2987139	33490944	22.3048	2987139	22.3048
042	840258	7262496	41.2962	840258	41.2962
043	348941	9505206	12.5953	348941	12.5953
044	45244	930400	0.3432	45244	0.3432
045	63059	0	0.0000	63059	0.0000
046	109740	930400	0.0000	109740	0.0000
047	166346	3012550	7.2543	166346	7.2543
048	125568	391302	19.9076	125568	19.9076
049	106108	2803330	1.8294	106108	1.8294
050	76865	1958198	16.9776	76865	16.9776
051	317922	394076	49.9727	318334	49.9788
052	86703	102912	8.5805	86703	8.5805
053	728352	5317152	11.6049	728352	11.6049
054	438266	8276074	2.2547	438266	2.2547
055	55755	852212	20.7220	55755	20.7220
056	147676	3622398	4.5028	147676	4.5028
057	29987	416890	35.7464	29987	35.7464
058	2260689	30621696	8.8310	2260689	8.8310
059	369318	360448	0.0000	369318	0.0000

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
060	472697	1255552	29.8871	472697	29.8871
061	39272	34560	5.9731	39272	5.9731
062	1572635	10856448	0.0000	1572635	0.0000
063	575202	3323904	0.0000	575202	0.0000
064	13417	95590	9.6806	13417	9.6806
065	22021	13968	4.4528	22021	4.4528
066	189749	3937564	7.5765	189749	7.5765
067	30483124	148560256	79.4855	30544074	83.7261
068	198360	3519186	10.4518	198360	10.4518
069	16094	233732	20.4230	16094	20.4230
070	58234	129536	19.1047	58234	19.1047
071	12813	208452	28.4446	12813	28.4446
072	11826643	113724192	12.4176	11826643	12.4176
073	4270350	36216704	78.7759	4539269	80.9675
074	803065	3747840	25.8573	803065	25.8573
075	727824	7124774	6.7648	727824	6.7648
076	3063843	31095808	27.8782	3063843	27.8782
077	250735	57344	2.6082	250735	2.6082
078	1051374	2148480	0.0000	1051374	0.0000
079	15446486	31780864	0.0000	15446486	0.0000
080	145674	2191360	43.6000	145674	43.6000
081	76860	0	0.0000	76860	0.0000
082	387499	3234278	4.7322	387499	4.7322
083	433240	930400	43.9821	433240	43.9821
084	1168951	28717440	0.0000	1168951	0.0000
085	1810773	9335690	5.0074	1810773	5.0074
086	67520	1185860	11.4674	67520	11.4674
087	1984150	10142208	29.5515	1984150	29.5515
088	133573	2582030	10.9573	133573	10.9573
089	329430	238720	0.0000	329430	0.0000
090	456431	2341200	36.2899	456431	36.2899
091	4569395	57904096	17.9865	4569395	17.9865
092	2161490	16642656	0.8739	2161490	0.8739
093	37827	8192	0.0000	37827	0.0000
094	48430	106272	18.3989	48430	18.3989
095	1042890	0	0.0000	1042890	0.0000
096	40991	719692	17.5851	40991	17.5851
097	5617602	11796480	0.0000	5617602	0.0000
098	89551	0	0.0000	89551	0.0000
099	807032	7319552	44.1892	807032	44.1892
100	73335	1161942	30.0567	73335	30.0567

表 A-7 问题三逐例结果 (3 核)

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
001	78545	2304	0.0000	78545	0.0000
002	94149	746496	0.0000	94149	0.0000
003	247555	9518568	23.5742	247555	23.5742
004	134043	221184	0.0000	134043	0.0000
005	52396	1733514	18.7198	52401	18.7537
006	27859	841742	37.2060	27859	37.2060
007	338094	55296	0.0000	338094	0.0000
008	163359	0	0.0000	163359	0.0000
009	62869	1616024	27.0609	62869	27.0609
010	30856	48384	11.1880	30856	11.1880
011	69625	1081344	46.9697	69625	46.9697
012	18114	20160	3.9980	18114	3.9980
013	88351	16384	0.0000	88351	0.0000
014	5896850	57474216	22.4236	5914855	17.5900
015	58906	208128	19.0487	58906	19.0487
016	2876720	12200	0.1523	2876720	0.1523
017	52439	175104	24.6548	52439	24.6548
018	334589	12853772	26.5243	334589	26.5243
019	28195	24576	12.0572	28195	12.0572
020	177950	0	0.0000	177950	0.0000
021	2106355	4710400	45.2174	2106355	45.2174
022	19370	13824	6.0801	19370	6.0801
023	41357	1160938	26.4747	41720	31.2029
024	953408	4040	0.0506	953408	0.0506
025	1622164	55296	0.0000	1622164	0.0000
026	37376	1491816	26.6300	37376	26.6300
027	765280	33890304	15.6045	765280	15.6045
028	13848390	34820352	0.0000	13848390	0.0000
029	12743	0	0.0000	12743	0.0000
030	933236	9242624	54.6511	933236	54.6511
031	483567	3462144	50.2392	483567	50.2392
032	11808	12360	4.2399	11808	4.2399
033	602363	4180032	28.3169	602363	28.3169
034	280601	2341888	44.5326	280601	44.5326
035	71125	1735510	29.9945	71125	29.9945
036	311345	2304	0.0000	311345	0.0000
037	74038	1064960	61.5385	74038	61.5385
038	459314	5534208	44.5933	459314	44.5933
039	482552	12414976	31.8462	482552	31.8462
040	103722	3308532	26.3744	103722	26.3744
041	1991302	34879488	25.6151	1991302	25.6151
042	569347	29111164	19.7565	571429	48.0684
043	265912	8238192	29.1496	266191	29.0864
044	45244	930400	0.3432	45244	0.3432

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
045	42601	0	0.0000	42601	0.0000
046	82826	1860800	63.8267	82826	63.8267
047	134415	4387628	23.6383	134415	23.6383
048	99785	1016076	13.7738	99785	13.7738
049	80938	3516344	18.6046	80938	18.6046
050	64455	2735846	22.8307	67069	17.5362
051	227452	960	0.0117	227452	0.0117
052	61902	181248	15.8048	61902	15.8048
053	489248	7442990	19.8318	489248	19.8318
054	316308	6482640	13.1293	316308	13.1293
055	40063	115712	13.3973	40063	13.3973
056	116861	1870000	14.4754	116861	14.4754
057	20872	549116	42.2528	20872	42.2528
058	1554831	30400512	0.0000	1554831	0.0000
059	254073	2162688	55.1768	254073	55.1768
060	323606	3290252	46.8773	323606	46.8773
061	28316	43008	7.3262	28316	7.3262
062	1083992	10865664	0.0000	1083992	0.0000
063	396695	3133440	0.0000	396695	0.0000
064	14097	126220	20.0517	14097	20.0517
065	16963	27936	8.5260	16963	8.5260
066	137156	3077354	22.5103	137156	22.5103
067	20274197	150320896	78.4083	20361960	83.5511
068	160947	5172720	18.4923	165344	25.6883
069	14474	489770	23.2645	14474	23.2645
070	41101	1523108	29.0399	41101	29.0399
071	10460	235082	33.5518	10460	33.5518
072	7944880	82414368	14.6043	7944880	14.6043
073	3223907	93164288	87.8960	3223907	87.8960
074	537389	4923392	32.2975	537389	32.2975
075	524721	12146060	23.0935	524721	23.0935
076	2047868	34332672	33.6950	2047868	33.6950
077	178739	114688	2.5419	178739	2.5419
078	709786	8054016	38.2845	709786	38.2845
079	10140199	33890304	15.4802	10140199	15.4802
080	100325	3047424	0.0000	100325	0.0000
081	51943	0	0.0000	51943	0.0000
082	263832	2788460	17.3891	263832	17.3891
083	298003	1860800	30.5440	298003	30.5440
084	836220	0	0.0000	836220	0.0000
085	1224333	29372396	17.1512	1224333	17.1512
086	59919	1851498	18.1600	59919	18.1600
087	1371815	5465088	22.0609	1371815	22.0609
088	112104	4023768	19.8669	114232	27.2380
089	229298	477440	27.1191	229298	27.1191

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
090	312336	4409088	60.3885	324619	54.4626
091	3070819	64602944	24.4627	3044780	28.4675
092	1421140	10675392	11.1234	1421140	11.1234
093	25103	16384	0.0000	25103	0.0000
094	35039	737860	13.0478	35039	13.0478
095	695775	0	0.0000	695775	0.0000
096	30252	934048	26.4862	30611	24.2721
097	3660338	16031744	21.9721	3660338	21.9721
098	64144	1619618	31.0486	64713	31.6733
099	540586	8798208	51.0381	540586	51.0381
100	51556	1640268	36.4561	51556	36.4561

表 A-8 问题三逐例结果（4 核）

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
001	58984	3456	0.0000	58984	0.0000
002	73120	841728	0.0000	73120	0.0000
003	229275	7733990	24.0408	229275	24.0408
004	104188	331776	0.0000	104188	0.0000
005	50800	2224782	27.8088	52401	18.7537
006	24645	913168	33.7919	24645	33.7919
007	254398	82944	0.0000	254398	0.0000
008	123060	0	0.0000	123060	0.0000
009	52843	1890898	30.6073	52843	30.6073
010	24135	774836	38.1265	25518	38.0459
011	46808	704512	10.5357	46880	0.0000
012	14884	21888	4.3258	14884	4.3258
013	66982	24576	0.0000	66982	0.0000
014	4426698	48577944	30.3476	4426698	30.3476
015	51503	231168	17.7834	51503	17.7834
016	2238959	15864	0.3031	2238959	0.3031
017	42924	260352	32.4397	42924	32.4397
018	255632	3755776	52.6970	255632	52.6970
019	21598	359504	23.3655	21598	23.3655
020	133704	0	0.0000	133704	0.0000
021	1550324	4608000	0.0000	1550324	0.0000
022	14574	13824	6.0801	14574	6.0801
023	30522	207552	9.3655	30522	9.3655
024	743027	5256	0.1010	743027	0.1010
025	1217444	82944	0.0000	1217444	0.0000
026	34962	724704	30.2014	34962	30.2014
027	559196	3317760	0.0000	559196	0.0000
028	10250076	31777152	26.0089	10250076	26.0089
029	11028	0	0.0000	11028	0.0000
030	700156	10404864	59.6575	700156	59.6575

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
031	394388	4922880	40.4330	394388	40.4330
032	10764	12360	2.8348	10764	2.8348
033	457038	5251680	32.3248	457038	32.3248
034	252450	2979328	42.7956	252450	42.7956
035	54927	1675904	36.8000	54927	36.8000
036	233584	3456	0.0000	233584	0.0000
037	53320	614400	0.0000	53320	0.0000
038	344678	9295872	35.6060	344898	45.9622
039	368055	17604608	47.8212	380496	22.6741
040	90709	3717274	29.5439	94060	26.1551
041	1487676	39164928	34.3802	1487676	34.3802
042	435882	7059744	38.1425	435882	38.1425
043	227159	10019550	32.7617	227480	32.0638
044	45244	930400	0.3432	45244	0.3432
045	31878	0	0.0000	31878	0.0000
046	79918	2791200	0.0000	79918	0.0000
047	118989	5012946	27.0725	118989	27.0725
048	97321	1114512	19.2820	97321	19.2820
049	70332	1743366	21.3067	70450	21.2015
050	58829	1628226	21.1599	58841	21.4086
051	178386	1252	0.0234	178386	0.0234
052	45216	259584	14.6473	45216	14.6473
053	415932	11152366	23.6495	415932	23.6495
054	262300	7592222	12.5505	262300	12.5505
055	31823	115712	11.8780	31823	11.8780
056	103277	3214102	20.3623	103277	20.3623
057	18687	797094	45.8641	20957	0.0855
058	1136056	37580800	25.1019	1139266	18.0229
059	185144	1802240	33.2237	185216	0.0000
060	239861	3131648	38.3556	239861	38.3556
061	26678	62208	10.2612	26678	10.2612
062	838854	10054656	0.0000	838854	0.0000
063	313176	3538944	0.0000	313176	0.0000
064	10532	152784	32.1324	10532	32.1324
065	11769	41760	12.2291	11769	12.2291
066	120237	3943030	26.6901	120393	27.1509
067	15291889	154190976	78.6283	15291889	78.6283
068	138618	4065986	20.7584	138634	19.8884
069	12569	503470	33.1777	12569	33.1777
070	34658	360960	11.3440	34658	11.3440
071	9203	329390	31.0190	9237	27.9135
072	5901949	85994272	19.1622	5901949	19.1622
073	2194944	44120192	74.9185	2194944	74.9185
074	406017	6230016	28.4486	406017	28.4486
075	417743	12171570	23.0180	417743	23.0180

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
076	1536306	37442560	41.7145	1536306	41.7145
077	144734	172032	4.9578	144734	4.9578
078	568228	6445440	0.0000	568228	0.0000
079	7635624	30445568	0.0000	7635624	0.0000
080	90584	4190208	45.8333	100325	0.0000
081	39588	0	0.0000	39588	0.0000
082	210359	6970608	26.4094	210359	26.4094
083	219344	2791200	70.1874	219344	70.1874
084	629028	0	0.0000	629028	0.0000
085	923869	29385842	22.4863	923869	22.4863
086	51263	2266894	32.0400	52040	30.7162
087	1069325	7133184	22.9131	1069325	22.9131
088	91991	2712598	20.6292	94102	20.0603
089	165616	716160	0.0000	165616	0.0000
090	248631	6515328	46.5257	251921	46.5278
091	2307637	69360288	28.0418	2290222	24.6548
092	1018349	6788896	27.0236	1018349	27.0236
093	19779	24576	0.0000	19779	0.0000
094	26940	318816	39.7295	26940	39.7295
095	524422	0	0.0000	524422	0.0000
096	26984	78336	27.1438	26984	27.1438
097	2626908	14221312	4.1667	2626908	4.1667
098	50584	1806012	32.8177	50721	38.3945
099	403542	9764864	55.4526	403542	55.4526
100	45240	1961860	39.0025	45240	39.0025

表 A-9 问题三逐例结果 (5 核)

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
001	47502	4608	0.0000	47502	0.0000
002	59575	872448	0.0000	59575	0.0000
003	212297	9779292	31.0521	212880	31.0114
004	88341	442368	0.0000	88341	0.0000
005	49484	2547864	32.7884	52401	18.7537
006	21965	710016	28.8795	22707	37.7187
007	203834	110592	0.0000	203834	0.0000
008	100603	0	0.0000	100603	0.0000
009	46342	2008978	33.2497	46342	33.2497
010	24724	1011020	31.1386	25518	38.0459
011	46777	1622016	62.3106	46880	0.0000
012	12622	31104	6.0373	12622	6.0373
013	54363	32768	0.0000	54363	0.0000
014	3592432	53128200	30.9378	3592432	30.9378
015	39837	317952	26.4424	39837	26.4424
016	2086359	214900	33.1289	2086359	33.1289

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
017	30495	343296	27.1034	30495	27.1034
018	201337	4681728	61.4323	201472	54.2267
019	18640	327032	21.0548	18640	21.0548
020	107650	0	0.0000	107650	0.0000
021	1249380	11431936	56.9964	1249380	56.9964
022	11813	6912	3.1354	11813	3.1354
023	24793	197472	31.1289	24793	31.1289
024	693243	202660	33.2644	693243	33.2644
025	975282	110592	0.0000	975282	0.0000
026	33721	491168	16.4131	33721	16.4131
027	558753	5529600	4.4444	558753	4.4444
028	8209101	31031808	25.2734	8209252	27.4793
029	9383	0	0.0000	9383	0.0000
030	560897	11479040	59.5113	560897	59.5113
031	306307	8059392	54.7425	306307	54.7425
032	10391	12360	2.8348	10391	2.8348
033	367285	6509184	26.4588	367285	26.4588
034	171529	3532800	50.6998	171529	50.6998
035	56942	1602218	33.7165	56942	33.7165
036	187182	4608	0.0000	187182	0.0000
037	43013	1925120	64.2500	43013	64.2500
038	273759	8558592	47.7315	273759	47.7315
039	340476	20480000	37.0893	380496	22.6741
040	81272	3935920	28.2661	86832	27.2525
041	1193054	40630272	31.7719	1193054	31.7719
042	369723	8045568	42.8201	369723	42.8201
043	215630	11060460	34.5843	227480	32.0638
044	45244	930400	0.3432	45244	0.3432
045	26164	0	0.0000	26164	0.0000
046	79918	2791200	0.0000	79918	0.0000
047	114114	5402776	32.8906	117596	35.7046
048	98551	1132628	19.7987	98551	19.7987
049	63196	2123270	23.8340	63369	23.2890
050	54311	1885008	32.3691	54311	32.3691
051	167410	198040	33.3163	167410	33.3163
052	41587	333312	27.6295	41587	27.6295
053	362303	12135050	22.5096	362303	22.5096
054	237165	8940968	18.9723	237165	18.9723
055	26183	198656	12.3598	26183	12.3598
056	94490	3574548	26.9310	94490	26.9310
057	16538	27936	0.0790	16538	0.0790
058	1004819	32104448	0.0000	1004819	0.0000
059	150736	4325376	73.7879	150736	73.7879
060	184532	3641728	52.9842	184532	52.9842
061	22283	83712	12.3158	22283	12.3158

用例	L2 选优 时间	L2 选优 新增字节	L2 选优 命中率/%	固定方案 L2 时间	固定方案 命中率/%
062	703542	10626048	0.0000	703542	0.0000
063	255854	3253248	0.0000	255854	0.0000
064	8292	132948	30.0384	8292	30.0384
065	9558	55728	15.6782	9558	15.6782
066	110103	4610524	27.4677	113123	25.6030
067	12257518	158705152	76.4690	12257518	76.4690
068	130386	4177634	22.7867	130785	22.9230
069	12569	503470	33.1777	13071	36.0266
070	25840	462848	29.6978	25840	29.6978
071	9203	329390	31.0190	10229	30.1908
072	4817940	131343024	19.3648	4826576	16.5441
073	1805392	74410240	82.9390	1806253	63.4171
074	330183	7118848	26.2029	330183	26.2029
075	355004	12788022	34.0954	355004	34.0954
076	1232435	40553472	44.6061	1232435	44.6061
077	121081	172032	0.0000	121081	0.0000
078	452545	12822528	35.8494	452545	35.8494
079	6043668	31907840	23.3847	6043668	23.3847
080	86025	4571136	31.8786	100325	0.0000
081	30943	0	0.0000	30943	0.0000
082	187467	8565908	33.5699	194918	37.5612
083	190890	3721600	18.9588	190890	18.9588
084	503472	0	0.0000	503472	0.0000
085	813738	40853464	32.5884	817718	35.0246
086	51263	2266894	32.0400	52040	30.7162
087	885221	8050176	21.2111	885221	21.2111
088	91991	2712598	20.6292	94102	20.0603
089	133338	954880	0.0000	133338	0.0000
090	248631	6515328	46.5257	273577	4.6857
091	1848050	39725056	24.1690	1848050	24.1690
092	816728	4606336	20.3016	816728	20.3016
093	15876	32768	0.0000	15876	0.0000
094	20152	259200	12.0242	20152	12.0242
095	420852	0	0.0000	420852	0.0000
096	24363	623148	38.7532	24363	38.7532
097	2102250	21311488	24.5235	2102250	24.5235
098	46116	1533620	45.6206	46288	45.1468
099	327276	10698752	54.4487	324289	43.6942
100	38158	2170338	40.6034	41936	39.0883

附录 B 复现说明

程序入口。求解器入口为 reproduction/NPU_R12/round12_src/solve_round12.py (profile 固定为 full)，它在同一次请求内依次调用基础构造器、控制链各阶段 (R6、R7、R10) 与插入、微批模块；这些都是同一请求中的算法模块，不读取任何历史结果。官方评估程序与配置文件原样保存在 official/ 下，未作修改。

环境。求解器只依赖 CPython 标准库，已完成的实验使用过 Linux/WSL (Ubuntu 24.04, Python 3.12.3)。将 100 个原始 case_*.json 放入 reproduction/NPU_R12/official/data/ 后，单例命令为
python3 -B -S round12_src/solve_round12.py official/data/case_001.json -n 2 --scene A --profile full --budget 600 --out work/repro_case001_A2

--scene 取 A、B 或 L2，-n 取核数。输出目录中的 <case>_multicore_res.json 顶层只含 node_to_subgraph 与 core_schedules 两个字段，可直接交官方评估程序复核；report.json 记录各阶段候选、预算、失败与源码哈希。

问题三的同方案对照。对每个场景 B 最终方案 P_B ，用相同图、核数与配置分别运行问题 2 与问题 3 的评估程序，得到 $T_B(P_B)$ 与 $T_L(P_B)$ ；L2 独立选优方案 P_L 的结果另列。500 对中 430 对两场景最终方案相同，62 对复用哈希一致的已有候选评分，8 对补做了官方 L2 评分，补评分不反向参与选解。

可复现性的限度。求解受墙钟预算约束，并发与机器负载可能改变预算内评价到的候选数，因此不承诺跨机器每个请求都与存档方案逐字节相同；本文全部数值以存档方案及其官方结果为准，二者以 SHA256 绑定。

B.1 两种复现任务应分开

第一种任务是复核论文数值：读取归档的方案，用同一版本的官方评价器与固定配置重新评价，再对照 Makespan、新增 COPY 和缓存命中率。第二种任务是重新运行搜索：从原图生成新候选并受墙钟预算限制。前者检查既有结果与方案是否一致，后者检查求解流程能否再次产生可行方案；两者不是同一项测试。

B.2 输入、环境与失败记录

准备 100 张原始 case_*.json、固定 config.txt 及完整求解源码。原始图应来自题目材料，不以表格反推或合成替代。执行命令时工作目录切换到 reproduction/NPU_R12，使用全新或空输出目录，避免将另一请求的结果误作当前结果。运行期间保存解释器版本、平台、输入和配置哈希，以及各阶段实际状态。

常规请求仍使用 600 秒，case_087 的 A2 至 A5 分别保留首次失败和 1800 秒补跑目录。输出方案顶层仅保留题目规定的两个字段；日志、报告及哈希文件作为外部支撑材料保存。若缺少原始图、归档方案或程序版本，必须说明缺失，不能只凭同名文件认定复现成功。

B.3 表格与统计复算

新增统计只读表 A-1 至 A-9：逐图比值先计算再平均，命中率按已有四位小数记录复算；按用例编号连接无 L2 与 L2 表，断言 100 行编号完整、唯一且一一对应。几何分解

检验使用未舍入值核对乘积；相邻核数比较按原始整数周期计算。该流程验证的是表内算术与统计一致性，不替代完整事件模拟。

附录 C 支撑材料清单

表 C-1 支撑材料清单

材料	位置	说明
求解程序	reproduction/NPU_R12/	R12 求解器与官方评估程序、固定配置
逐例结果表	publication/tables/	Q1/Q2/Q3 逐例 CSV、汇总与 C3 对照
校验记录	publication/sources/closeout/results/	1470 组核查、下界字段、预算例外、方案哈希
图件	figures_v3/、paper_full_v1/figures/	全部图的 PDF、600 dpi PNG、SVG 与作图数据
依赖结构统计	paper_full_v1/并行度统计_20260926/	表 2-2 的复现脚本、逐例明细与汇总
论文数值核对	paper_full_v1/qa/	事实总表、全文数字溯源报告
统计、作图与排版脚本	paper_full_v1/code/	事实底座、生成表、流程图、合稿与 Word 排版

附录 D AI 工具使用说明

本附录记录能够确认的 AI 辅助使用范围，并保留参赛队尚须核实的信息。论文为核验稿，不能以本说明替代队员对全部历史工具、程序注释和最终文字的确认。

使用工具与信息状态。本轮论文扩展、科学表述核对、冻结表复算和排版使用 ChatGPT（开发机构：OpenAI）。具体模型版本与发布日期应以参赛队会话记录和可核验信息补全；此前用于求解、统计、图件及写作的其他工具信息尚待队员据实填写，不推定其未使用 AI。

使用范围。本轮读取原论文、官方格式规范、赛题以及仓库中的相关实现；辅助修改下界适用域、门控、比较与因果表述，编写文档生成及数值核对脚本。新增分析只读取冻结逐例表，不修改原始输入、官方评价器、求解器或已归档性能值，也不声称进行了新的全量实验。

数据分析与程序标注。本文第 2 章及第 8 章原有数据分析曾使用 AI 辅助脚本；第 7.7 节和第 8.8 节的补充统计由本轮 AI 辅助程序计算。提交时须按竞赛规定补全各阶段工具名称、版本、开发机构和日期，并在相关程序开头保留使用注释。历史代码是否全部标注仍需参赛队逐文件核实。

人工核查待办。参赛队需理解各公式的定义、证明条件和来源，核对统计脚本与冻结记录，检查实际方案和原版评价输出，并将最终文字以自身语言确认。是否存在未使用 AI 的核心环节，只能由队员根据真实过程说明，本稿不代作声明。

责任与提交状态。本稿未进行 AI 检测，也不承诺检测分值。对未核实工具信息不虚构名称或日期，对缺少的实验不补造结果。完成队员核验、历史披露及正式字体导出后，再决定是否作为最终参赛提交文件。