

2026 年中国研究生数学建模竞赛

“华为杯” 参赛论文研究长稿

共享带宽与核内复用约束下的多核 NPU 切图调度

参赛队号: _____

学校名称: _____

队员姓名: _____

A 题: 通用神经网络处理器下的多核调度问题

身份信息待团队填写; 本稿保留真实实验范围与复现来源。

共享带宽与核内复用约束下的多核 NPU 切图调度

基于安全分块、活动核心选择与局部微批的三问建模研究

摘 要

针对通用神经网络处理器的多核切图调度问题，本文围绕子图划分、核心分配与核上子图顺序建立受约束离散优化模型。操作依赖图描述可执行先后，张量生产—消费集合描述搬运及复用；以赛题原版评价器返回的总完成时间为首要目标，以新增搬运量作为同耗时下的次要指标，保持原计算量、硬件参数和输出接口不变。

问题一采用非分支链收缩和依赖带内连通分块，显式考虑完整 Task 结束后的激活门限，再在固定划分上利用实际时长反馈重排。问题二结合完整计算分量、双 Pipe 负载、张量通信增量、活动核心数及插入式顺序构造有限候选，并以空闲区间索引加速等价日历查询；对实际出现 Spill 且具有大输入复用窗口的方案，采用保持核心归属的局部微批细化。问题三严格遵守只读 FIFO 的发射查询、完成插入和独立读带宽语义，分别报告同方案资源对照与独立选解，避免把命中率或逻辑 COPY 量等同于总时间收益。

理论上给出安全分块与队列的无环性质、空核心嵌入性质、固定方案必要条件以及前驱—后继时间窗工作量下界。实验依据现存可追溯材料分版本报告：历史 R7.1 五核 A、B、L2 平均单核相对加速比分别为 3.7435、4.0690、4.1578；冻结 R12 五核 B 全 100 例均值为 4.1311，相对同次控制 2 例改善、98 例持平。case_073 总时间由 3046190 降至 2034983 周期，Spill 新增量由 87499776 降至 15489024 字节；case_067 亦取得改善。原、快日历在 100 例的最终候选哈希一致。

上述结果支持针对给定模型的可执行启发式及限定范围内的质量证书，不构成全局最优、未见图泛化或获奖保证。R12 全核数三场景矩阵尚未完成；历史曲线、R12 主批次、补充对照和证据重建分别标识。附录提供 100 例五核 B 逐例结果、历史分场景表、复现命令和数据来源说明。

关键词：多核调度；有向无环图；张量复用；局部微批；窗口工作量下界

目 录

1 问题重述与研究思路	
1.1 多核计算图调度的研究对象	4
1.2 三个子问题的共同目标与差异	5
1.3 为什么不能分开优化三个决策	6
1.4 技术路线与可复现研究单元	7
2 基本假设与符号	
2.1 硬件资源、存储层次与执行单位	8
2.2 计算图、张量关系与两种投影	9
2.3 决策变量、派生变量与符号表	10
2.4 评价函数、统计口径与比较对象	11
3 数据解析与结构特征	
3.1 输入合法性与索引构建	12
3.2 图规模与结构差异	13
3.3 关键路径、并行宽度与多 Pipe 负载	14
3.4 张量共享、复用距离与候选触发	15
4 统一优化模型	
4.1 划分与覆盖约束	16
4.2 依赖、核上队列与全局等待环	17
4.3 时间与 Pipe 资源约束	18
4.4 实际容量与 Spill 的派生机制	19
4.5 共享 DDR 与 L2 服务池	20
4.6 模型求解形式与代理函数的角色	21
5 问题 1：场景 A 的联合调度	
5.1 Task 级张量边界计数	22
5.2 非分支链收缩与完整分量候选	23
5.3 依赖带内连通分块	24
5.4 显式考虑 Task 启动时刻的列表调度	25
5.5 固定 Task 划分的反馈重分核	26
5.6 固定方案 Task 下界与安全筛选	27
5.7 两种相反的粒度调整与实验证据	28
6 问题 2：复用、归属与顺序	
6.1 核心级通信计数及其实现边界	29
6.2 双 Pipe 负载与完整分量保留	30
6.3 共享输入驻留代理与有限分批	31
6.4 精确张量增量驱动的链块迁移	32

目 录 (续)

6 问题 2: 复用、归属与顺序	
6.5 活动核心数的合法选择	33
6.6 插入式候选及次序保持	34
6.7 等价空闲区间索引加速	35
6.8 Spill 触发的局部微批与不变性	36
7 问题 3: 只读 FIFO 缓存	
7.1 FIFO 状态与发射时查询	37
7.2 重叠未命中、容量淘汰与因果边界	38
7.3 同方案对照与分别选解	39
7.4 L2 配置下的候选覆盖与真实成本	40
7.5 COPY 量、命中字节与实际 DDR 的区别	41
7.6 已验证 L2 局部结果与待完成范围	42
8 下界、正确性与最优性	
8.1 全局工作量与计算关键路径下界	43
8.2 前驱—后继共同时间窗下界	44
8.3 窗口界的高效计算与边界检验	45
8.4 固定归属的传输间隔下界	46
8.5 从上下界得到实例质量证书	47
8.6 微型精确枚举的作用与限制	48
9 实现、预算与复现	
9.1 冻结 R12 的完整求解流程	49
9.2 复杂度分解与不能省略的成本	50
9.3 来源、恢复文件与重跑元数据	51
9.4 独立复核与提交接口	52
10 实验设计与结果	
10.1 实验范围与版本分层	53
10.2 历史统一曲线与第三问数值口径	54
10.3 R11 与 R12 五核 B 的全样本变化	55
10.4 独立基线、消融与开发集限制	56
10.5 求解时间、失败与交付审计	57
11 模型讨论与研究结论	
11.1 适用范围、反例与剩余工作	58
11.2 三个子问题的结论与贡献归纳	59
参考文献	60
附录 A 100 个计算图规模记录	62
附录 B R12 五核 B 逐例结果	66
附录 C 历史 R7.1 逐例数据	71
附录 D 复现协议与证据边界	87

1 问题重述与研究思路

1.1 多核计算图调度的研究对象

本题研究的对象不是神经网络的训练精度，也不是重新设计处理器，而是给定细粒度计算图在同构多核平台上的执行组织。原图同时含操作节点与张量节点：操作定义计算或搬运，张量定义数据位置和字节数，边只表示生产与消费的依赖。计算操作、执行周期、张量大小及可用硬件资源均为输入事实，不能在求解时自由改变。[1-2]

需要提交的决策只有三个层次：把非 COPY 操作划入子图，为子图分配核心，确定每个核心的子图顺序。上述三个层次相互影响。划分越细，可能暴露更多并行，却也可能增加边界搬运与启动等待；同核聚合有助于数据复用，却可能扩大活跃工作集，增加换出与换入。因而，按节点数量平均分组不是本题目标的充分近似。

本文以官方评估器返回的总完成时间 Makespan 为主目标，将额外搬运量和缓存命中率作为机制分析与并列方案选择的辅助指标。通过结构化候选与固定评估器相结合，使所建数学模型、可执行输出与最终评价具有同一语义。文中所称周期均指题设模拟时钟周期；求解器运行秒数另行列示，不与实体 NPU 时延混淆。

研究采用“事实、证明、启发式、实验观察”四类陈述。事实来自题目与源码；证明说明所有满足前提的调度必须遵守的性质；启发式用于有限时间内构造候选；实验观察仅适用于实际完成的实例集合。明确这些层次，可以防止把一个有效案例扩写为普遍最优性或硬件性能保证。

一个便于理解的极端情形是：图中所有计算形成严格串行链。增加核心不能消除链上的先后关系，却可能让中间张量产生更多远端搬运。相反，若图由许多互不依赖的短分支组成，保留分支内部计算再分配到多核，能够在不切断内部边的条件下增加并行。两种情形说明，核心数量并不是唯一决定因素，图结构与数据复用必须一并进入决策。

本文所说的高质量解具有可检验含义：它先满足全部硬约束，再在统一评价下优于明确对照，或取得较紧的实例上下界。论文页数、方法名称与单个较大的提升比例都不是质量证明。对于尚未完成的配置，本稿给出复现任务与数据字段，不补写看似连贯的成绩。

表 1 多核计算图调度的研究对象

层次	给定内容或决策	本文处理
输入事实	操作、张量、依赖、周期	保持原值
可提交决策	子图、核心、核上次序	联合选择
派生执行	COPY、Spill、起止时刻	官方程序生成
主评价	所有任务完成时刻的最大值	最小化 Makespan

1.2 三个子问题的共同目标与差异

问题 1 采用场景 A：一个子图对应一个 Task。同核的不同 Task 之间也不保留核内数据，跨子图关系需要经过 DDR。任务粒度同时决定边界搬运数量和启动屏障，因而必须分析“整个前驱 Task 何时完成”，而不能只考察某个张量何时生产。问题 2 采用场景 B：同一核心的全部子图合成一个 Task，子图次序仍影响核内排列，但不再产生与 A 相同的 Task 切换语义。[1-2]

问题 3 在 B 的数据通路上加入共享只读 L2。其容量、读取带宽和 FIFO 替换规则固定。缓存只在读取发射时查询，未命中读取完成后才插入。两个核心几乎同时读取同一份尚未完成装入的数据，可能同时未命中。因此，不能把共享输入的数量直接解释为必然命中次数。

三问可共用图解析、张量关系索引、候选合法性检查、资源下界和结果保存框架，但候选代价必须分别计算。A 的跨核 Task 门限不能用于 B 的 COPY 释放；B 中的同核复用也不能用于 A。本文分别建模其变化，再将共同部分抽象为同一受约束离散优化问题。

评价结果分两层呈现。第一层是题目要求的多核性能和搬运指标；第二层是解释原因的运行轨迹与受控实验。性能比较本身不自动给出因果解释，尤其在共享带宽与固定核内启发式同时存在时，某个局部变化会重排多个后续事件。

场景 A 的子图边界具有执行屏障与数据中转的双重作用；场景 B 的子图边界主要是影响同核排序的组织信息。这意味着，同一条原依赖在 A 和 B 中的代价未必只差一个固定常数。若将 A 中两个同核 Task 合并，可能同时去除中转和切换；B 中同核 Task 已经合一，再合子图主要改变排列而不必减少 Task 数。

从问题递进角度看，第一问强调子图尺度，第二问强调数据放置与生命周期，第三问进一步引入共享只读数据的事件时序。三问的共同难点是性能不能通过某一个静态量完全预测。后续章节按此递进组织，避免把同一套公式仅更换参数后重复三遍。

表 2 三个子问题的共同目标与差异

机制	A	B	B+L2
Task 粒度	每子图	每核心	每核心
同核跨子图数据	DDR 中转	允许私有缓存保留	允许私有缓存保留
远端就绪门限	前驱 Task 结束 + 1000	COPY_OUT 结束 + 500	同 B
额外读取池	无	无	250 字节/周期 FIFO 读池

1.3 为什么不能分开优化三个决策

设一段计算链的中间张量很大。若只以核心负载均衡为目标，可能把相邻操作放到不同核心，从而使中间结果写回、同步和重新读入；若只以通信最小为目标，又可能把本可重叠的多个分支全部放在一个核心，导致计算资源闲置。类似地，固定核心分配后任意改顺序，可能让共享张量长时间驻留，或者推迟关键输入的最后一次使用。

这种耦合在 R11 的受控实验中得到直接体现：case_009 和 case_035 保持链块划分、核心归属与 COPY 量不变，仅改变同核顺序，完成时间分别由 52311 变为 85753、由 58349 变为 91744 周期。该观察说明，较好的分配应与其匹配的顺序共同保留。它不证明插入式顺序在所有计算图上最优。[16]

另一方面，case_078 的旧核心归属包含一个矩阵 Pipe 负载为 509472 周期的核心，而新方案耗时为 481517 周期。因为同核同 Pipe 必须串行，任何保持旧归属的方案都至少需要 509472 周期。这给出一个必要性结论：只重排旧归属，无法达到新方案的耗时，必须改变归属。

因此，本文采用互补候选而不是单一切法。先以完整分量保护数据复用，再以链收缩和分层释放内部并行；在 A 中改变 Task 粒度，在 B 中结合驻留调整，在实际成功结果上做有限反馈。每次接受变化都以完整评价为依据，而不是只根据某个代理分数降低。

把大张量尽量放在同核可以降低边界读写，但如果多个生产者过早执行、消费者很晚才使用，就会占住缓存。一个只最小化切边字节的方案可能得到低通信、高 Spill 的组合。另一个方案适度跨核后，虽然边界 COPY 增多，私有工作集却更平衡，整体反而更快。这里的可能性必须通过实际评价检验，不能作为必然规律。

因此，算法既要维护全局的计算资源信息，也要维护局部的张量关联与顺序。本文选择有限候选而不是把所有因素压进一个不可解释的大权重分数；每种候选针对一种有依据的失效模式，最后由相同官方模型进行比较。

$$T(P) \geq \max_{k,p} \sum_{v:a(v)=k, p(v)=p} c_v \quad (1)$$

1.4 技术路线与可复现研究单元

本文将一次求解定义为可复现研究单元：输入一个原图、一个可用核数、一个场景和明确的运行预算，输出一份成功方案及对应官方结果。程序不能把别的实验已经保存的最好方案作为免费输入；引用旧记录只用于结果复核或同协议恢复。这样可以区分算法能力与多轮人工挑选历史结果所得到的上包络。

完整流程包括输入合法性与索引构建、结构分析、构造互补候选、安全下界筛选、官方评价、保留成功当前解和结果导出。候选可因重复、下界不可能改善、生成超时或评价失败而被跳过。跳过不是成功评价，也不是输入非法证明。日志必须保留相应状态，避免只观察最终成功方案而忽略求解成本。

在证据层面，正文数字由逐例表汇总，逐例表又指向方案与官方结果。输入、固定配置、算法源码、运行协议以及结果文件均保留摘要哈希。哈希只能证明两个文件字节相同，不能替代正确性分析；完整轨迹一致性检查也不能替代官方带宽模拟或全局最优证明。

本稿采用已完成材料展开模型与论证。历史 R7.1 全配置数值、R10 与 R11 阶段验证、冻结 R12 五核 B 主批次和指定补充批次分开报告。自适应复用区间微批尚未完成独立收益验收，不列为正式 R12 默认算法。该范围限制影响最终答卷的完备性，但不应通过填入预测值或拼接不同版本的最好成绩掩盖。[14–18]

每个实验单元还需要记录“为什么停止”。因为预算耗尽、质量界达标、没有新候选和全部候选重复是不同情形；它们对性能解释与后续复现的意义也不同。对失败请求保留中间日志，有助于判断是输入结构、程序错误还是资源环境导致未返回结果。

从写作角度，正文重点呈现模型与机制，详细命令、逐例字段与恢复索引置于附录。历史开发过程只在解释必要的反例时引用，不将多轮版本日志直接拼接成论文。这样既保留真实来源，也使读者能够沿问题、模型、方法、证据的顺序理解结果。

读取 G、N、场景 q、预算 B，核对固定配置。
建立计算 DAG、张量生产消费索引和非分支链块。
构造完整分量、分层、Task 分块、插入式等适用候选。
检查合法性、去重，以安全下界筛除不可能改善者。
用未修改官方程序评价，在成功候选中按主指标择优。
在 B/L2 存在 Spill 时尝试有界局部微批，重新评价。
输出两字段方案、逐例指标、运行状态及来源索引。

2 基本假设与符号

2.1 硬件资源、存储层次与执行单位

平台由 N 个同构核心及共享主存构成。每核心具有矩阵计算 Pipe、向量计算 Pipe 和搬运资源，私有 L1 与 UB 分别约束不同位置的张量。相同核心、相同 Pipe 的操作不可重叠，不同 Pipe 在依赖允许时可以并行。操作为不可分割的非抢占执行单元，固定周期不随本文的切图或核心归属改变。[1-2]

容量约束必须基于实际生命周期。输入在相关操作完成前不能随意释放；输出占用和存储复用顺序由固定核内展开确定。一个子图累计涉及的数据量可以远大于私有缓存，而仍通过逐步计算、释放与必要 Spill 执行。因此，不能以子图全部张量大小之和直接判断是否可行。

共享 DDR 的 60 字节/周期属于所有核心读写共同竞争的总带宽，不是每核 60。增加核心既增加计算并行机会，也会改变 COPY 在途数量以及带宽分配。L2 是独立的共享读池，不能被解释为另增每核带宽。它改变的是部分读取的服务路径，原跨核同步前提仍须满足。

本文不引入未给出的能耗系数、实体设备频率或真实访存延迟。可报告模拟周期与算法运行秒数，但不能从模拟加速比推断实体 NPU 毫秒或节能百分比。所有参数均以用户提供的固定配置为准，不对正式成绩作硬件参数调优。

为防止单位混用，本文将 MiB 意义下的二进制容量直接以整数“字节”写出，不将 524288 近似为任意十进制 0.5MB 再用于计算。带宽与周期的乘积是字节服务量，计算工作量以操作固定周期累加；若采用取整下界，统一使用向上取整以保证必要服务时间不被低估。

硬件资源独立性也是模型前提的一部分。L1 与 UB 不是可任意互借的同一内存池；矩阵 Pipe 空闲不能替向量 Pipe 执行操作；L2 读池也不能处理所有 DDR 写回。允许核心闲置不等于允许将闲置核心的私有缓存借给其他核心。

表 3 硬件资源、存储层次与执行单位

资源或门限	固定值	单位
每核 L1	524288	字节
每核 UB	131072	字节
共享 DDR	60	字节/周期
只读 L2 容量	1048576	字节
L2 共享读取	250	字节/周期
A 同核/跨核门限	100 / 1000	周期
B/L2 跨核 COPY 门限	500	周期

2.2 计算图、张量关系与两种投影

记原始二部图为 $G=(O \cup T, E)$ ，其中 O 为操作节点， T 为张量节点； $U \subset O$ 表示全部非 COPY 计算操作。边从操作指向张量表示生产，从张量指向操作表示消费。对每个张量 τ ，记 $s\tau$ 为字节数， $Prod(\tau)$ 和 $Cons(\tau)$ 为其生产者与消费者集合。为避免误计费，这些关系在预处理阶段建立并重复使用。

从原二部图可得到计算依赖 DAG：若非 COPY 操作 u 生产的张量被非 COPY 操作 v 消费，则加入 $u \rightarrow v$ 。该投影适合做拓扑排序、链收缩和关键路径分析，但会丢失“多条依赖其实来自同一张量”的共享关系。因而，计算 DAG 不能独自承担精确通信计数。

第二种视图以张量为中心，把生产者和所有消费者视为一个关联集合。它类似有向超图思想，可描述一个输入被多个分量共享、一个中间结果被多个核心消费等情况。本文借鉴这一表达来实现题设通信规则，不把一般性的超图建模或无环划分思想声称为首创。[5]

两种视图的职责不同：计算 DAG 回答“哪些操作可以先做”；张量关联回答“某次分组需要读写多少份数据”。在局部修改中，前者用于检查顺序合法性，后者用于快速计算受影响张量的通信增量。二者共同避免只按操作边切割数量最小化的偏差。

当同一个张量连接一个生产者和多个消费者时，普通 DAG 投影会生成多条边。若消费者在同一个 Task 内，实际只需一次相应读入，而逐边累计会重复。若它们分散到不同 Task 或核心，去重单位又发生变化。因此，原张量 id 应贯穿解析、通信计数和缓存诊断，而不是在投影后丢弃。

对于多生产者关联，本文不自行猜测隐式归约语义，而是按附件的显式边与程序处理。若输入中出现未覆盖的关系类型，应优先由官方合法性检查与字段约束判定，不能仅因现实神经网络通常如此便对题目作额外假设。

$$E_c = \{(u, v) : \exists \tau, u \in Prod(\tau), v \in Cons(\tau), u, v \in U\} \quad (2)$$

$$G_c = (U, E_c) \quad (3)$$

2.3 决策变量、派生变量与符号表

记操作划分为 $P=\{S_1, \dots, S_m\}$ ，每个 S_j 非空、互不相交，且并集为 U 。 $a(S_j)$ 为子图所
属核心； π_k 是核心 k 上的子图序列。实际活动核心数 m_{act} 允许小于 N ，未使用核心对应
空序列。序列中每个子图必须恰好出现一次，不能遗漏、重复或跨核执行。

开始时刻 sv 、完成时刻 fv 、缓存驻留集合 $R_{k,p}(t)$ 、搬运带宽份额和 $L2$ 队列 $Q(t)$ 均为
方案经过官方展开后的派生量，而不是额外提交字段。数学模型可以用这些量描述约
束，但求解程序不能直接覆盖它们。这一区别决定了本文必须保留官方评价算子。

下界 L 用于约束可能的最佳耗时，上界 T 来自已经成功评价的可行方案。二者不可
混用：代理 J 可能高估或低估，不能据其数值剪去候选；有效下界则必须在相应适用域内
不大于任何可行结果。本文将全局下界与固定划分、归属或队列下界分别命名。

为减少符号歧义，字节数 D 与时钟周期 T 使用不同记号，求解程序的墙钟时间记为
 C_{wall} 。所有百分比均注明分母，尤其区分平均加速比的相对变化与逐例耗时下降比例的
平均，二者一般不相等。

同一记号在不同场景下的对象尺度必须明确。例如 P_τ 、 C_τ 在 A 通信式中代表 Task 集
合，在 B 式中代表核心集合；正文在转换处重新定义，代码中则使用不同变量避免混
用。报告中的“任务数”也区分子图数、每核心 Task 数和完整求解请求数，不以同一中
文词替代三个不同统计对象。

对空核心的处理保持显式：它没有原操作、不会产生新的 COPY 或缓存访问，也不
会引入一个有服务时间的虚拟任务。空列表只是声明可用资源的一部分，在求解与统计
中仍保留 N 个外层位置，使输出与题目核数一致。

表 4 决策变量、派生变量与符号表

符号	含义
U, E_c	计算操作集合、计算依赖边集合
$st, cv, p(v)$	张量字节数、固定计算周期、计算 Pipe
P, a, π	子图划分、核心归属、核上顺序
D_0, D_{pre}, D_{spill}	原 COPY、划分后 Spill 前 COPY、新增 Spill
$F_q(G, P, a, \pi)$	场景 q 的官方 Makespan
L, T, T^*	有效下界、可行解耗时、最优耗时
B, C_{wall}	求解预算、实际求解墙钟

2.4 评价函数、统计口径与比较对象

统一优化目标以官方返回值 F_q 为第一分量，新增 COPY 为第二分量，按字典序比较。只有在 Makespan 相等时，才优先选择额外搬运较小者；若仍相等，使用固定候选名等确定性规则。采用字典序可避免任意权重使较差主指标因副指标更小而被接受。

正式加速比的分母是题目规定的整图固定单核核内启发式结果，不是本文优化后的单核心方案。每个用例先计算比值，再对 100 个用例取算术平均。固定基准本身是启发式执行结果，因而某些多核方案出现相对该基准的超线性加速，并不能仅凭大于 N 就判断计算错误。[1]

多个版本的成绩必须以明示协议比较。历史统一矩阵可作为旧版本参考，新增 R12 结果只能填入其实际完成的配置范围。缺失、超时和程序错误不得填成 1 倍或在平均时悄悄剔除；不完整批次只能给出完成率与注明集合的子集统计。

相同预算上限也不意味着相同计算成本。本文同时记录候选生成次数、完整官方评价次数、实际墙钟、提前停止和超时。独立消融要求分别从原图启动；在同次完整运行中读取各阶段前缀，可作配对分解，但不能被称为全量独立消融。

例如两个用例的固定基准分别为 100 和 10000，新方案分别为 50 和 9000，则逐例加速比平均约为 $(2+1.111)/2$ ，而总时间相除约为 $10100/9050$ 。两者权重不同，后者让大图主导。这个纯算术示例说明必须遵守题目规定口径，不能在结果更有利时更换平均方式。

报告比例时还区分 $(T_{旧}-T_{新})/T_{旧}$ 与 $T_{旧}/T_{新}-1$ 。前者是耗时下降比例，后者是相对速度提升，两者在改进较大时数值差异明显。本文所有表格都为比例指定中文名称，避免读者将“平均加速比提高”误读为“平均耗时下降”。

$$\min_{P,a,\pi} (F_q(G, P, a, \pi), D_{pre} + D_{spill} - D_0) \quad (4)$$

$$\bar{S}_{q,N} = \frac{1}{100} \sum_{i=1}^{100} \frac{T_i^{single}}{T_{i,q,N}} \quad (5)$$

3 数据解析与结构特征

3.1 输入合法性与索引构建

原始数据由 100 个图文件及固定配置组成。预处理首先检查节点标识唯一性、操作与张量类别、必要字段、边端点存在性及有向无环性，再分离非 COPY 操作集合。随后为操作建立前驱、后继、输入张量、输出张量与 Pipe 周期索引，为张量建立生产消费列表。正式计算不依赖文件名编码的类型标签。

需要特别注意，原始 COPY 操作虽然不在 `node_to_subgraph` 中分配，仍是原图输入输出和 D0 统计的组成部分。剔除它们是为定义可提交决策集合，不能将对应数据搬运从基准成本中抹去。对于零字节张量和零周期操作，应遵循原程序的边界语义，不自行增加物理延迟。

拓扑排序采用确定性并列规则，使相同输入在相同程序下构建相同的初始顺序。确定性并不消除运行预算造成的差异：如果某候选在不同环境下超时，已完成候选集合可能不同。源码一致、方案一致和运行成本一致是不同强度的复现要求。

本稿的数据结构统计可由附录脚本直接读取原图重算；使用既有结果表时，保留其版本、场景与核数列。写作阶段生成统计图与附录表，不代表重新执行了全部历史官方评价。历史记录的来源限制在实验范围表中单独说明。

输入校验不应修改数据后再继续求解。例如图中字段缺失、边引用不存在节点或依赖成环，应记录拒绝原因，而不是删除边或补猜周期使其通过。相同地，损坏的历史 ZIP 不能用占位 JSON 补足文件数；需要实际恢复或重新运行，并保留新旧来源差异。

对写作阶段的数据整理，推荐将字段提取与统计公式单独实现，使用唯一配置键 (`case,N,scene,version`) 检测重复。对 100 例主批次，先核对用例集合恰为 001 至 100，再计算均值；行数等于 100 但用例重复仍不构成完整覆盖。

解析 JSON 并建立节点字典，检查重复 id 和边端点。

按原字段区分计算操作、COPY 操作与张量。

对每个张量收集 Prod、Cons、size、location。

由非 COPY 生产消费关系构建 Ec 并去除重复依赖。

执行确定性拓扑排序；失败则拒绝输入。

累计 WM、WV、原始 COPY 量，并生成只读索引。

3.2 图规模与结构差异

附件中的图规模跨度较大，不能假设小图上表现良好的构造成本会线性推广到最大实例。既有清点显示，非 COPY 操作数从 552 到 35705，原二部图边数从 1841 到 108272。100 个图中 93 个同时包含矩阵和向量计算，7 个仅含向量计算。这些统计描述输入结构，不直接给出并行效率。[14–17]

节点数量与求解难度之间并不存在唯一对应关系。多个独立短分量构成的大图可以先收缩为较少工作单元；一个节点数较少但长链密集、共享数据反复交错的图，可能对排序更敏感。因此，应同时观察分量数、链长度、分支与汇合、两种 Pipe 负载以及共享输入关系。

完整计算分量在计算依赖意义上互相独立，但可读取相同外部输入，并共同竞争 DDR 和 L2。这一事实解释了为什么分量分配仍需通信与驻留分析，不能只把每个分量当成没有相互作用的独立作业。

后续采用结构化算法组合，正是为了覆盖这些差异，而非对每种文件编号预设最优方法。若对全部图直接建立含划分、顺序、缓存状态和事件带宽的大型精确模型，会引入大量组合状态；本文保留精确评价但限制候选构造规模，以便在题目建议的时间内获得可执行结果。

表 5 图规模与结构差异

统计项	最小	最大
非 COPY 操作数	552	35705
全部操作数	766	38666
张量数	816	40287
原始边数	1841	108272




图 1 给定 100 个计算图的非 COPY 操作规模

3.3 关键路径、并行宽度与多 Pipe 负载

只计算原操作周期的最长依赖路径，给出忽略搬运和容量的全局下界。它描述不可并行的最短必要计算时长，但不包括资源冲突；各 Pipe 总工作量除以可用核心数则描述资源容量限制。两者取最大比单独使用总周期更能解释性能瓶颈。

对含矩阵与向量两种计算的图，保持负载向量(WM,WV)具有意义。若一组计算主要占用矩阵 Pipe，另一组主要占用向量 Pipe，将其放在同核可能实现重叠；直接累加总计算周期会忽略这种互补。但是否真正重叠，还受输入就绪、存储复用和核内固定序列约束。

并行宽度可用同层可就绪块数等描述性量估计，但不能把它当成实际每周期活跃核心数。依赖层只编码最少层数，不代表相同层操作同时就绪；共享 DDR 会推迟输入到达，长短任务也会形成不同的占用区间。

本文将上述量作为候选选择与解释工具：长关键链提示不宜盲目跨核，矩阵负载主导提示优先平衡对应 Pipe，独立分支丰富提示可保护分支内部复用后分配。实际归因仍需要读取官方时间线，防止根据输入特征直接宣称某个资源是唯一瓶颈。

在给定归属后，可计算每核每 Pipe 工作量下界，并与实际 Makespan 比较。若某核心的矩阵工作量已经接近整体时长，单纯减少非关键读取难以带来同量级收益；若计算工作量远小于实际时长，则依赖、同步、搬运与容量等待值得进一步检查。这个差距仅用于诊断方向，不给出可兑现收益保证。

$$CP(v) = c_v + \max_{u \in pred(v)} CP(u) \quad (6)$$

$$L_{compute} = \max \left\{ \left\lceil \frac{W_M}{N} \right\rceil, \left\lceil \frac{W_V}{N} \right\rceil, \max_v CP(v) \right\} \quad (7)$$




图 2 给定计算图的计算 Pipe 工作量结构

3.4 张量共享、复用距离与候选触发

共享输入关系可以从张量消费者集合中直接读取：一份外部输入被多少操作、多少链块或多少计算分量使用，取决于分析层次。在 A 中读取去重单位通常为 Task，在 B 中为核心。因此，同一份张量在两种场景下对不同粒度具有不同的成本。

局部复用距离可用同核顺序中相邻使用之间的操作数量、子图数量或累计数据量作为代理。代理用于发现潜在工作集冲突，但不能当作真实驻留时间：COPY 可能提前发射，输入会保持到操作结束，Pipe 重叠改变实际时间轴。应优先用真实 Spill 结果确认有问题，再用结构信息生成有限改动。

R12 对局部微批设置触发条件：场景为 B 或 L2，当前成功控制存在实际 Spill，且发现合适的大输入复用窗口。无 Spill 或没有合适窗口的图直接保留控制，避免为追求表面复杂度对所有图进行额外搜索。这种条件触发也决定了收益的适用范围。

case_073 提供了直观例子：两份 294912 字节的 L1 外部输入合计 589824 字节，大于 524288 字节容量。若多条链交替使用两份输入，就可能反复换入。使多个可就绪操作连续使用同一大输入，可以降低切换；但增加中间输出驻留也有风险，必须重新官方评价。[17]

微批触发应基于当前方案而不是图编号。即使两个图都存在相同大小输入，它们的消费者顺序、存储位置或同步结构不同，实际 Spill 也可能不同。使用图的客观属性和本次官方结果来触发，能够避免开发实例被特殊处理，也使不适用的输入自然回退到原成功方案。

表 6 张量共享、复用距离与候选触发

量	可直接确认	不能直接推出
消费者集合	谁使用张量	必然同时使用
静态使用跨度	给定顺序中的位置间隔	实际时间驻留
当前 Spill 量	当前方案换入换出工作量	全部可以消除
共享输入个数	潜在复用对象	L2 实际命中率

4 统一优化模型

4.1 划分与覆盖约束

子图划分必须完整且互斥。对每个非 COPY 操作 v ，引入归属函数 $g(v)$ ；所有操作恰好属于一个非空子图。对每个子图 S ，其核心归属 $a(S)$ 唯一，且仅出现在一条核心队列中。原始张量与 COPY 节点不写入归属映射，子图标签可以重新编号，但标签变化若影响确定性排序，必须遵循实际程序语义。

集合覆盖与结构合法性是不同的检查。一个方案即便每个节点恰好分配一次，也可能在子图层形成环。例如原计算链 $a \rightarrow b \rightarrow c$ 中，将 a 、 c 放进同一子图，将 b 单独划分，就得到 $S1 \rightarrow S2 \rightarrow S1$ 。原图无环并不保证任意聚合后的商图无环。

因此，构造时优先使用有结构保证的划分，如连续拓扑段或依赖带内连通分块；一般合并和局部迁移后则显式重建商图并判环。为了省时而跳过判环可能使后续核内展开产生难以解释的等待问题，不能依靠最终 JSON 字段齐全来代替合法性。

覆盖检查还应与官方结果进行独立对应：原计算操作在实际执行记录中恰好出现一次，周期与原图相同，核心符合方案归属，输入输出关系没有被默默改变。这类一致性检查为可行性提供补充证据，但不重写官方评分。

子图标识的连续化属于输出整理，不得将原操作归属或次序同时改变后仍称作纯重命名。对字节级复现，序列化键顺序、空白和排序规则也会改变文件哈希；应区分语义相同与原字节相同。本文用于硬件对照的要求采用完整计划哈希一致，避免遗漏细小但可能影响排序的结构差异。

$$\bigcup_{j=1}^m S_j = U, \quad S_i \cap S_j = \emptyset \ (i \neq j) \quad (8)$$

$$\sum_{k=0}^{N-1} \mathbf{1}\{S_j \in \pi_k\} = 1 \quad (1 \leq j \leq m) \quad (9)$$

4.2 依赖、核上队列与全局等待环

对划分形成的商图，每条跨子图生产消费关系构成 Task 或子图的依赖边。同核队列还会引入附加先后边：前一个子图不能在队列意义上被后一个越过。两类边必须一起检查。只保证每条核心队列内部无重复，不能排除跨核心循环等待。

一种安全的构造方式是就绪列表追加：只有所有前驱已经被安排的子图才能入队，每次将选中子图追加到某个核心尾部。全局安排顺序是商图的一条拓扑序，新增加的队列边同样沿这一顺序前进，因此两类边并图无环。后面的反馈列表分配保留这一性质。

插入式构造则依赖另一种证明。若每个块的虚拟服务时长严格为正，数据边及同核日历相邻边均要求虚拟开始时刻严格增加，则若存在有向环，将导出开始时刻严格小于自身的矛盾。这个证明覆盖虚拟日历结构，但不能替代官方核内展开后对内存复用和 Pipe FIFO 的组合检查。

B/L2 的实际阻塞不只来自原计算依赖，还可能来自存储额度复用、核内 FIFO 以及跨核 COPY 释放。本文在候选提交前做结构检查，在官方展开后做完整检查；这两个步骤互补，不能把前者通过说成后者必然通过。

一般图划分问题中，局部迁移一个节点看似只影响邻边，却可能改变商图的全局环性。对已经具有无环构造保证的方案做后处理时，同样不能假设保证自动继承。显式判环的成本通常远低于官方完整展开，因此应在每次结构修改后进行，不以性能代理更好为理由跳过。

$$G_{aug} = (\mathcal{P}, E_{data} \cup E_{queue}), \quad G_{aug} \text{ is acyclic} \quad (10)$$

从未安排子图中取全部前驱已安排者。

按剩余关键路径及固定并列规则选择一个子图。

比较不同核心的预计完成时间。

追加到所选核心队尾并更新就绪集合。

所有子图安排完毕后，对数据边与队列边并图判环。

4.3 时间与 Pipe 资源约束

对每个非 COPY 操作 v ，完成时间等于开始时间加固定计算周期。生产者必须先完成，消费者才能使用相应数据。对同一核心和同一计算 Pipe 上的两个操作，其执行区间不允许交叠。不同 Pipe 能否并行由输入与资源条件决定，不能只根据归属不同就假设完全重叠。

如果直接建立时序整数规划，同 Pipe 不重叠可由二元先后变量和大 M 约束表示；但本文实际输出不含这些先后变量，它们由子图和核上顺序间接影响官方核内排序。数学表达的用途是阐明可行集合，而不是宣称程序已经求解了一个覆盖全部执行状态的整数规划。

COPY 的持续时间不是固定的 $s/60$ 。在途访问数变化会改变每份访问分到的带宽，官方事件循环按工作量推进并进行整数周期结算。对一次搬运使用独占总带宽所需时间，只能作为乐观下界或时长代理；真实结束时刻需要完整事件模拟。

主目标 Makespan 包含全部必要计算和搬运的完成。某个核心的最后计算结束不必然是全图结束，最终结果写回仍可能在途。独立检查应将选中结果的最后完成时刻与报告 Makespan 对应，避免只以计算记录最大值替代完整官方结果。

同 Pipe 串行的区间采用半开形式 $[s, f)$ ，允许一个操作恰在前一操作结束时开始，避免把共享端点误判为重叠。对零周期操作，必须尊重原程序的事件顺序，不人为要求所有时间戳严格增加；结构证明中的正虚拟时长是候选日历的技术条件，与原图允许的零周期边界应区别。

$$f_v = s_v + c_v, \quad s_v \geq f_u \quad (u, v) \in E_c \quad (11)$$

$$[s_u, f_u) \cap [s_v, f_v) = \emptyset \quad \text{if } a(u) = a(v), p(u) = p(v) \quad (12)$$

$$T = \max_{o \in O_{expanded}} f_o \quad (13)$$

4.4 实际容量与 Spill 的派生机制

对每个核心 k 和存储位置 $p \in \{L1, UB\}$ ，时刻 t 的实际驻留集合 $R_{k,p}(t)$ 必须满足总字节数不超过容量 C_p 。输入尚未完成最后一次使用时不能凭空消失；输出需要先获得空间，存储复用边约束可用额度的释放。官方核内程序在不足时插入换出与换入，并保留相应执行依赖。[2]

同核复用存在两个相反影响。一方面，保留中间结果可以免去跨核写回与读入；另一方面，延长其生命周期会占用私有缓存，压缩后续操作的工作空间。故“同核边不发生边界 COPY”并不等于“该边零代价”。增加复用有时可能使其他数据 Spill 更多。

零 Spill 也不表示存储容量完全不起作用。程序可通过存储额度复用依赖推迟某些操作，使同一时间的占用不越界，而无需把数据写到 DDR。若只统计 Spill 字节，会漏掉这类存储引起的先后等待。具体瓶颈归因需要实际依赖链和时间线。

本文的驻留代理和局部微批只用于提出候选。case_006 曾出现静态 UB 代理峰值 150528 字节，高于容量，而实际 Trace 峰值 68614 字节且 Spill 为 0。该反例说明代理不构成严格容量判据。它可作为风险特征，但不能用于直接否决方案或宣称容量合法。[15–16]

真实峰值可在官方事件结束和开始边界处重建，输入保留、输出分配与释放顺序要与原程序一致。仅对所有操作的开始时刻采样可能漏掉同一周期内的分配峰值；仅对张量大小求和也可能重复统计逻辑别名。因此，容量审计优先复用原展开中的张量标识和释放事件，而不是猜测访问生命周期。

$$\sum_{\tau \in R_{k,p}(t)} s_{\tau} \leq C_p \quad \forall k, p, t \quad (14)$$

表 7 实际容量与 Spill 的派生机制

常见误判	正确处理
子图总数据超过容量即非法	检查实际峰值与必要 Spill
同核复用完全免费	考虑占用时间和额度复用
Spill 为 0 则容量无影响	仍可能存在存储等待边
代理峰值就是真实峰值	代理与 Trace 分别报告

4.5 共享 DDR 与 L2 服务池

在连续松弛意义下，任意时间区间内 DDR 完成的读写总服务量不能超过带宽乘以区间长度。若同一时刻有 $m(t)$ 个同池访问活跃，则公平共享模型中每个访问得到总带宽的 $1/m(t)$ 。当访问加入或结束时，其他访问的剩余服务速度改变，产生跨核心耦合。

设两份各 600 字节的读取同时启动，即使单份独占 DDR 只需要 10 周期，两份共享时也不能各在 10 周期完成；而若其中一份晚启动，又会改变另一份在独占阶段获得的服务。这一示意解释为什么单独估计每条边的 $s/60$ 再相加不能给出真实 Makespan。示意不是正式测试图的实验结果。

加入 L2 后，命中的读取进入 250 字节/周期的独立读池，未命中读取与写回仍竞争 DDR。两个池可以重叠服务。总 COPY 量仍包含逻辑上执行的读取，官方在事件模拟前得到的新增搬运字段不会因为后续命中而自动扣减；实际 DDR 分流与 COPY 计数是不同指标。

本文在筛选候选时采用乐观资源下界，在最后评价时使用官方事件模拟。对于 L2 场景，不可把全部 COPY 字节一概除以 60 作为固定候选下界，因为一部分读取可能走更快的池。对不同资源服务的放松必须保证乐观性，宁可较松，也不能错误剪掉好方案。

共享服务模型具有非局部效应。把某个核心上的读取提前，可能加剧另一个关键读取的争用；把它推迟，可能使该核心计算饥饿。局部 s/B 估计看不到这种相互影响，所以本文把带宽估计用于排序，把完整事件模拟用于接受。采用相同评估器也保证不同候选的比较具有统一口径。

$$\int_{t_1}^{t_2} \sum_j b_j(t) dt \leq B_{DDR}(t_2 - t_1) \quad (15)$$

$$b_j(t) = \frac{B_{DDR}}{m(t)} \quad \text{for active DDR transfers} \quad (16)$$

4.6 模型求解形式与代理函数的角色

将官方执行过程表示为算子 $F_q(G, P, a, \pi; \theta)$, θ 是固定配置。该算子包括 Task 构造、边界 COPY、核内排序、Spill 扩展和多核事件模拟。优化变量仍是提交接口允许的 P 、 a 、 π ; F_q 不是可随意调节的黑盒目标, 而是具有明确输入与执行规则的题设程序。

候选构造需要比完整官方评价更便宜的预测。本文使用双 Pipe 负载、计算关键路径、精确的划分 COPY 量、同步连接数和驻留代理等信息。它们组成启发式评分 J , 用来排序和筛选少量值得评价的候选。但 J 不等于 T , 不能仅因 $\Delta J < 0$ 就报告算法已经改善。

严格剪枝只使用被证明适用的下界 L 。若固定候选的下界严格大于当前成功结果, 就能确定它不可能胜出。若二者相等, 候选仍可能在额外搬运这一并列指标上更好, 不能只按主目标相等直接删除。下界过松只影响效率, 下界不安全则会破坏方法正确性。

最终求解是有限预算的确定性候选组合, 而非全域精确搜索。它没有对全部图给出统一近似比; 部分实例可通过上下界形成质量证书。算法选择的可解释性来自具体机制、受控实验和失败记录, 而不是对“智能优化”名称的依赖。

这类“评价器约束下的离散优化”并不意味着数学建模可以省略。可行域、约束来源、变量尺度和下界必须明确, 否则只能得到无法解释的试跑。本文将模型和可执行接口逐项对应, 并用受控反例说明代理可能失效的地方, 使算法的有效性可以被检验而不依赖黑盒名称。

$$T_q = F_q(G, P, a, \pi; \theta_{fixed}) \quad (17)$$

$$J = L_{load} + \frac{D_{pre}}{60} + \lambda \frac{500E_{remote}}{N} \quad (18)$$

表 8 模型求解形式与代理函数的角色

数值	用途	证据性质
F_q	正式评分	官方完整评价
J	候选排序	启发式, 可能失准
L_{global}	实例质量界	对全部可行归属有效
L_{fixed}	固定候选剪枝	只在明示归属/队列域有效

5 问题 1：场景 A 的联合调度

5.1 Task 级张量边界计数

在场景 A 中，通信读取的去重单位是消费 Task，而非消费操作。一个输入张量被同一 Task 内多个操作使用时，不应按操作依赖条数重复统计初始读入；被多个 Task 使用时，即使这些 Task 位于同一核心，也可能需要各自读入。计算图的普通切边计数因此可能严重高估或低估通信量。

对于只有一个计算生产者且不是最终输出的中间张量，若其源 Task 之外有 r 个消费 Task， $r > 0$ 时需要源端一次写回和 r 次读入，边界工作量为 $(r+1)s$ ； $r=0$ 时没有这一边界读写。一般情形需处理多个生产者、源 Task 兼消费者和最终输出，以官方实现的实际构造为准。

设 P_τ 为非 COPY 生产者所在 Task 集合， C_τ 为非 COPY 消费者 Task 集合， z_τ 表示原始 COPY_OUT 需要该张量。A 中每个没有本地生产者的消费 Task 需要读入；每个生产 Task 若有外部消费者或最终输出需求则需要写出。依次对张量求和即可得到 Spill 前的 COPY 工作量。[2]

将该计数函数用于候选对比，可以精确描述划分变化带来的逻辑搬运增量，但仍不能直接预测总耗时：搬运之间共享带宽，搬运与计算可能重叠，Spill 可能发生变化。因此，它是一项重要中间量，不是主目标的替代。

一个示意张量被三个消费者使用：如果三个消费者在同一外部 Task，则只需源写一次、该 Task 读一次；若分成三个外部 Task，则需要源写一次、三个 Task 各读一次。两者原计算依赖边数量相同，通信量却不同。这个例子说明切边数量不是传输量的可靠替代，必须使用消费集合的分组。

$$R_A(\tau) = |C_\tau \setminus P_\tau| \quad (19)$$

$$W_A(\tau) = \sum_{h \in P_\tau} \mathbf{1}\{z_\tau \vee (C_\tau \setminus \{h\}) \neq \emptyset\} \quad (20)$$

$$D_{pre}^A = \sum_{\tau} s_\tau (R_A(\tau) + W_A(\tau)) \quad (21)$$

5.2 非分支链收缩与完整分量候选

若计算依赖边 $u \rightarrow v$ 满足 u 出度为 1 且 v 入度为 1，则该位置没有直接可利用的分叉或汇合。把这类连续边收缩为链块，有助于保护内部数据复用并降低后续调度维度。链收缩只用于候选构造，不能改变原操作集合、周期或内部依赖。

完整弱连通分量候选则将存在计算依赖联系的操作保留在同一核心，以双 Pipe 负载进行分配。对由大量短独立分支构成的图，这种方法能在减少中间通信的同时利用核心间并行。对只有一个大型分量的图，它可能只使用一个核心，因而必须与内部并行候选互补。

链块图的规模和结构取决于实际依赖，不能将一个运算名称相同的集合直接合并。例如多个独立卷积操作不一定属于同一条链，强行合并会改变可并行结构。本文仅按图上的度条件收缩，再把块内操作保存在确定性拓扑顺序中。

整体保留与逐层切开分别对应复用优先和并行优先两个端点。需要寻找中间粒度时，引入依赖带内的连通划分，比对任意节点集合进行组合枚举更容易给出无环保证，也更便于控制生成复杂度。

串行链收缩不保证链块越长越好。它作为保守初始结构减少了无意义内部切割，但后续 B/L2 微批在明确 Spill 窗口内可以合法细化链块，以改变原绑定顺序。两者不矛盾：前者为一般候选降低维度，后者在实际失败机制上打开有限的新顺序空间。

$$\text{outdeg}(u) = 1, \text{ indeg}(v) = 1 \implies u, v \text{ may form one chain block} \quad (22)$$

构造非 COPY 计算 DAG 与入度/出度。

只沿唯一后继且目标唯一前驱的边扩展链。

保留链内拓扑顺序，汇总双 Pipe 工作量。

建立链块 DAG 并统计外部张量关联。

同时保留完整分量候选，避免单一细分方法强制替换。

5.3 依赖带内连通分块

对链块 DAG 定义深度：源块深度为 0，其他块为其前驱最大深度加 1。给定宽度 w ，把深度区间 $[hw, (h+1)w-1]$ 划为一个依赖带。每个带内按弱连通分量形成候选 Task，以保护相邻计算的内部复用，同时允许不同连通部分独立分配。

当某个带内分量过大时，沿其链块拓扑顺序切成连续段，使用 2048 个原计算操作作为软目标；单个链块不强拆。这里 2048 只控制组织粒度，不等于缓存容量，也不保证所有 Task 恰好相同规模。对每个宽度都重新计算边界张量与 Task 工作量。

冻结方法按固定次序尝试宽度 4、8、2、16，而非根据用例编号手工选择。较小宽度倾向暴露并行，较大宽度倾向减少边界与激活次数。不同图上的最佳宽度可能不同，通过实际评价选择，而不以“越粗越好”或“越细越好”预设结果。

该构造有明确的无环性质。跨带边的带编号严格增加；同带不同弱连通分量之间无边；同一分量分段后的边仅由较早拓扑段指向较晚段。因此每条跨 Task 边均沿一个统一偏序前进，商图不可能有环。后续核心队列仍需相容构造与完整校验。

依赖带中的弱连通划分与普通拓扑连续切片相比，更能避免将互不相关的同层支路合并成同一个 Task。合并互不依赖分支虽然结构合法，但可能让它们共享一个完成屏障并延长工作集；按带内连通部分分组保留了独立支路的调度自由度。软上限分段则防止单个巨大连通片形成过大的核内排序问题。

$$\ell(b) = \begin{cases} 0, & \text{pred}(b) = \emptyset \\ 1 + \max_{a \in \text{pred}(b)} \ell(a), & \text{otherwise} \end{cases} \quad (23)$$

$$\text{band}_w(b) = \left\lfloor \frac{\ell(b)}{w} \right\rfloor \quad (24)$$

5.4 显式考虑 Task 启动时刻的列表调度

构造 Task 之后，不宜只按总周期选择负载最小核心。场景 A 的 Task 必须同时满足数据前驱与核上队列的激活门限：远端前驱整个 Task 完成后加 1000 周期，已在本核心的前驱至少先完成，本核心前一 Task 结束后加 100 周期。多个门限取最大，不将所有前驱等待相加。[1–2]

对每个就绪 Task，计算剩余关键路径优先级，并在各核心上比较预计完成时刻。局部服务代理取矩阵工作量、向量工作量、内部计算关键路径和独占 DDR 读写工作量的最大值。该代理忽略部分流水细节，所以只用于选择，不作为最终耗时。

全局按照就绪顺序安排，每个 Task 追加到所选核心末尾，可以保证队列边与数据边共享一条拓扑序。某个 Task 被安排在核心日历较晚处，不等于引入新的显式空等操作：程序只提交次序，实际启动由原规则产生。

关键路径优先强调尽早释放决定全局完成时间的计算，而双 Pipe 负载强调资源均衡。两者可能冲突，例如关键 Task 更适合留在前驱核心，但该核心工作量已高。列表调度在代理完成时间中权衡此冲突，再由完整评价确定候选是否有优势。

当两个候选核心的预计完成时刻相同，应采用固定核心编号或另一明示确定性规则。不能在不同运行中由字典迭代、集合顺序或隐式随机状态决定，否则方案哈希难以复现。若确定性并列规则改变，应作为版本变化保存，而非假装只是日志调整。

$$R_j(k) = \max \left\{ \max_{h \in \text{pred}(j), a(h) \neq k} (F_h + 1000), \max_{h \in \text{pred}(j), a(h) = k} F_h \right\} \quad (25)$$

$$A_j(k) = \max\{F_{\text{prev}_k(j)} + 100, R_j(k)\} \quad (26)$$

$$\hat{F}_j(k) = A_j(k) + \hat{d}_j \quad (27)$$

5.5 固定 Task 划分的反馈重分核

初始代理无法完整表示共享带宽和固定核内启发式，因此在成功评价之后，可以利用得到的 Task 时长进行有限反馈。R7 分别以官方局部 `local_makespan` 和本次实际 `Task.duration` 为代理，保持每个 Task 的成员集合不变，重新做就绪列表分配与核上排序。

保持划分不变意味着 A 场景的切图 COPY 量不变，但实际同步等待、队列串行和带宽重叠会改变。旧 `Task.duration` 包含旧并发条件下的 DDR 竞争，不能当成新方案中精确不变的服务时间。两种反馈候选因此都需要完整重评，而不是把旧时长机械相加。

固定划分控制实验有较强解释力：它将性能变化限定为核心归属和队列安排，而不是混入 Task 成员变化。但仍不应将某条关键链的门限减少量直接解释为可兑现的总节省，因为新的关键链可能切换，Task 内部持续时间也可能变化。

此阶段保留原成功方案，最多生成有限反馈候选，不递归重排直到预算耗尽。对于本来已经接近全局计算下界的实例，可按明示质量界提前结束；对于下界较松者，是否值得反馈仍要综合生成和评价成本，而不能把差距当成保证的收益。

两类反馈时长各有偏差：`local_makespan` 接近忽略跨核带宽竞争的局部情况，实际 `Task.duration` 含当前竞争却可能过度反映旧布局。保留两份候选并分别评价，是承认代理误差而不是宣称其中一个是精确模型。若反馈未改善，原划分与安排继续作为有效结果保留。

表 9 固定 Task 划分的反馈重分核

保持不变	可能变化
每个 Task 的原计算操作集合	核心归属
原计算周期、张量大小	核上顺序与启动等待
A 场景边界 COPY 字节	Spill、带宽争用与实际 Task 时长
官方执行规则	最终 Makespan

5.6 固定方案 Task 下界与安全筛选

为了减少没有希望的完整评价，对每个 Task 构造必要服务时间下界：两类 Pipe 工作量、内部计算关键路径和 Spill 前必需 COPY 字节除以 DDR 带宽向上取整，取最大。任何合法 Task 执行时间都不小于该值，但实际值可因 Spill 或资源等待更大。

随后沿固定的数据依赖和核上队列，以准确的 100/1000 门限递推最早完成下界。因为各 Task 时长采用乐观值、每个激活条件采用必要条件，递推结果不超过该固定方案的真实 Makespan。如果下界严格高于当前成功方案，就可以安全跳过评价。

该界的“固定方案”限制必须强调。它使用当前 Task 划分和当前归属，不能约束另一种划分的最优值，也不能拿来给整个算法报告全局近似比。质量证书只使用不依赖当前划分的全局必要条件。

实现上需要处理源 Task、空核心、同核前驱及零工作量边界。无前 Task 时，其队列项取 0 而非额外 100；各前驱门限取最大而非相加。下界与真实值在小图上比较可发现实现错误，但正确性仍依赖前述乐观性证明。

剪枝的测试应包括“下界恰等于当前结果”的情况。若按大于等于直接跳过，可能漏掉主指标相同、搬运量更少的候选，破坏字典序目标。本文在严格大于时才排除；对于无副目标需求的实现，规则可以不同，但必须与正文目标一致。

$$d_j^{min} = \max \{W_M(S_j), W_V(S_j), CP(S_j), \lceil D_{pre}(S_j)/60 \rceil\} \quad (28)$$

$$F_j^{min} = \max \{F_{prev(j)}^{min} + 100, \max_{h \in pred(j)} (F_h^{min} + \delta_{hj})\} + d_j^{min} \quad (29)$$

5.7 两种相反的粒度调整与实验证据

场景 A 的已完成受控案例表明，减少 Task 和增加 Task 都可能提高性能。case_002 从 36 个 Task 变为 28 个，新增 COPY 由 1216512 降至 82944 字节，一条实际关键 Task 链的固定门限由 7100 降到 1500 周期，Makespan 从 75532 降至 58180 周期。该例主要体现保护强依赖段的收益。[14]

case_005 则从一个 Task 细分为 254 个 Task。它原本没有切图新增搬运，新方案增加 2483610 字节 COPY，一条关键 Task 链还出现 16400 周期固定等待，但 Makespan 从 95618 降至 69060 周期。新增边界的代价被释放出的并行机会抵消，说明以最少通信为唯一目标会错过有效方案。

实际关键链分解中的 Task 服务时间已经包含该时段的 DDR 争用与资源等待。固定门限与服务时间之和等于这条最终关键链的总长度，但不能把其中每一项下降视为互相独立、可以重复累计的反事实节省。

上述数字来自历史 R7 五核 A 的明示批次，不替换为 R12 全场景结果。R12 在 A 中仅加速插入候选生成，没有新增 B/L2 式局部微批。论文应分别报告算法机制的继承与新测试范围，避免借用历史成功案例声称新版全部核数均已复跑。

这些案例也说明主指标与次指标的适当关系。额外 COPY 不是必须单调下降的硬约束，而是辅助评价；任何以“改进后 COPY 增加”为由直接否定 case_005 的判定，都偏离了 Makespan 优先目标。反之，也不能只见 Task 更少就宣布 case_002 一定更快，必须保留其真实官方评价。

表 10 两种相反的粒度调整与实验证据

配置	Task 数旧→新	新增 COPY 旧→新	Makespan 旧→新
case_002/A/5	36 → 28	1216512 → 82944	75532 → 58180
case_005/A/5	1 → 254	0 → 2483610	95618 → 69060
case_006/A/5	5 → 51	63616 → 664560	31748 → 27679
case_010/A/5	5 → 57	145152 → 715508	31019 → 24563

6 问题 2：复用、归属与顺序

6.1 核心级通信计数及其实现边界

在 B 中，同核全部子图组合为一个 Task，因此张量通信的基本去重单位由 Task 改为核心。设 P_τ 为生产核心集合， C_τ 为消费核心集合。共同输入按实际消费核心数读取；跨核中间张量则依照附件的每个源核—目标核连接生成 COPY 对。该实现不应被擅自替换为一次写回广播给所有目标核。

对单生产者、非最终输出张量，若有 r 个远端消费核心，当前程序生成 r 对 COPY，工作量为 $2rs$ 。与 A 场景的单生产 Task 写一次、多消费 Task 读入不同，两者不能共用同一个普通切边权重。计算通信增量必须根据具体场景的构造规则。[2]

一般张量同时涉及原始输入、内部生产、最终输出和跨核消费时，应逐项判断而非直接套特例。本文的 `traffic_model` 按生产消费集合及原 COPY 需求统计 Spill 前 COPY，再与官方结果中的 `partition_added_copy_bytes` 核对。Spill 新增量独立计算，不由边界计数推断。

同核跨子图的数据无需边界 COPY，并不意味着永远不读 DDR。容量不足时，官方核内流程仍可能换出后再换入。同核复用与驻留成本的共同作用，是 B 与普通“通信边权最小划分”问题的重要区别。

若忽略不同场景构造语义，可能把一次写回与多个读取误算成每条边各一对，或者把多对源目标 COPY 误当成硬件广播。这些误差会同时影响候选排序、下界和论文章节。最稳妥的做法是以源码为操作性定义，对解析得到的张量集合计数逐例核对，再在文中注明特例公式的前提。

$$r_\tau = \sum_{h \in P_\tau} \sum_{k \in C_\tau} \mathbf{1}\{h \neq k\} \quad (30)$$

$$D_{pre}^B = \sum_{\tau} s_\tau (\mathbf{1}_{P_\tau=\emptyset} |C_\tau| + 2r_\tau + \mathbf{1}_{z_\tau \vee C_\tau=\emptyset} |P_\tau|) \quad (31)$$

6.2 双 Pipe 负载与完整分量保留

完整分量候选对每个弱连通计算分量统计(WM,WV)，按负载递减顺序选择核心，使各核心的主要 Pipe 工作量尽量均衡。一个分量不被拆开，减少内部中间结果的跨核通信。它不是按节点数量均分，也不假设两个 Pipe 工作量可以无条件完全重叠。

若图中含很多小独立分支，这种方法具有自然优势；若只有一个大型分量，它将无法释放内部并行。因此，完整分量保留必须与链块分层和插入式候选共同存在，而不是用一种方法覆盖全部结构。可用核心不必全部活跃，空队列保持合法。

将多个完整分量放在一个核心以后，还要选择它们的组织方式：全部合成一个大子图、一分量一子图或少量软分批。这些方式在 B 中仍属于一个核心 Task，但会影响核内访问顺序、共享输入的驻留和 Spill。布局相同不代表核内展开相同。

对完整分量之间的共享输入，使用张量关联做辅助分析，避免认为弱连通分量无计算依赖就没有资源耦合。分量之间既共享总带宽，也可能共享 L2 数据；某分量的读取时机能够改变另一核心的访问耗时。

在仅向量计算的图中，WM 为零，双 Pipe 负载退化为单 Pipe 均衡；算法不需要虚构矩阵工作量。含混合计算时，负载向量保留两个维度而非任意标量权重，可以更清楚地表达瓶颈切换。实际选择仍会受到输入和队列影响，不能据静态向量均衡直接宣称满流水。

$$W_p(C) = \sum_{v \in C, p(v)=p} c_v \quad (32)$$

$$L_{load}(a) = \max_{k,p} \sum_{C:a(C)=k} W_p(C) \quad (33)$$

6.3 共享输入驻留代理与有限分批

对某个核心接收的完整分量集合，预先统计每个外部共享输入还有多少未执行分量使用。安排一个分量后，减少对应计数，估计能够结束复用并释放的数据量，再优先选择使剩余活跃共享输入较小的分量。该方法试图把相关数据用完后再转向新工作集。

冻结实现采用一分量一子图以及 512、2048 个原操作的软批量等少量组织方式，不为凑数强行拆开完整分量。对每种组织方式重新调用固定核内展开，使潜在驻留改善转化为可测的 Spill 和总时长变化。

这种代理没有完整建模内部中间张量、预取、COPY 结束时刻和多 Pipe 重叠，所以不能写成精确内存峰值。R12 后续微批则进一步利用实际成功控制的 Spill 进行触发，降低无依据地重排所有分量的风险，但仍不等于求出了最优寄存/缓存分配。

case_014 四核 B 的历史控制实验保持核心分配和切图新增搬运 29628936 字节不变，组织排序使 Spill 从 60399504 降到 18949008 字节，Makespan 从 4551951 降至 4428315 周期。这支持组织影响驻留的结论；具体每一次 Spill 的因果位置仍需逐事件分析，不能从总量自动推断。[15]

驻留排序的一个实现风险是将所有共享张量都视为“已装入”。在实际执行中，某份输入可能尚未发射 COPY，另一些输入已经用完并释放。静态剩余使用计数只是访问顺序代理，不能把其所谓活跃集合直接代入真实容量公式。本文通过限定其用途并重新评价，避免该代理被过度解释。

$$H(\pi) = \sum_{\tau} s_{\tau} (pos_{last}(\tau) - pos_{first}(\tau)) \quad (34)$$

表 11 共享输入驻留代理与有限分批

代理目标	作用	限制
结束共享输入的最后使用	缩短局部驻留跨度	位置跨度不是时钟
限制组织软批量	避免大任务无差别聚合	不是容量上限
只接受官方真实改善	抵消代理误差	需要额外评价成本

6.4 精确张量增量驱动的链块迁移

链块迁移以完整非分支串行块为单位，优先尝试将其放到前驱或后继已经所在的核心。对受影响张量重新计算生产、消费核心集合，得到精确的 Spill 前通信变化 ΔD ；再结合双 Pipe 负载变化与跨核连接数变化形成候选评分。

此处“精确”只修饰给定核心集合下的边界 COPY 统计，不修饰整个完成时间。同步等待可以与其他计算重叠，部分传输未处在关键链，Spill 也会随顺序改变。即使 $\Delta D < 0$ ，Makespan 仍可能增加；通信增加的候选也可能因更好的并行而获胜。

冻结方法限制检查链块数量和接受代理改善的次数，再仅对少量形成完整方案的候选评价。迁移后重建合法的子图组织与核上序列，不允许仅移动一个映射条目却保留已经不相容的依赖顺序。

初始局部迁移与实际 Trace 驱动迁移具有不同信息来源：前者基于图结构代理，后者利用已完成控制方案的关键连接。后者只能指出当前执行中值得尝试的方向，不能证明删除某条旧关键边会产生等量全局收益。两者共同提供有限互补候选。

局部增量计算可只访问迁移块涉及的张量，而不必每次扫描全图所有关系。这降低候选生成成本，但要正确处理一个张量同时被块内与块外操作使用、迁出后源核心仍有消费者等去重情形。使用核心集合的引用计数比简单删除一条边更可靠，单元测试需包含这些边界。

$$\Delta J = \Delta L_{load} + \frac{\Delta D}{60} + \lambda \frac{500 \Delta E_{remote}}{N} \quad (35)$$

选取完整链块 b 及相邻核心 k 作为迁移提案。

只重算与 b 关联张量的生产/消费核心集合。

更新双 Pipe 负载和远端连接数，得到 ΔJ 。

检查子图与核上顺序合法性，形成完整候选。

用固定官方程序重新评价，不依据 ΔJ 直接接受成绩。

6.5 活动核心数的合法选择

题目允许 `core_schedules` 中出现空列表，因此给定 N 个可用核心时，算法可以只使用 $m \leq N$ 个活动核心。这不是减少原图工作量，而是在计算并行与通信、同步、重复输入读取之间选择更合适的布局。多个活动核数应与候选家族一起考虑。

可证明最优值具有单调性：任意 m 核可行调度可通过追加 $N-m$ 个空核心队列嵌入 N 核，原有资源与实际访问不变，因此可行域包含。这个性质描述的是最优可行集合，不保证一个有限预算程序每次运行输出都单调。候选排序和超时会改变实际被评价的集合。

R6/R7 低活动核数候选主要来自链块分层与迁移，R10 补入完整分量与驻留排序家族，R11 在请求核数下增加插入式候选。R12 加速生成器但保持其候选语义。本文不把已经存在的少核机制在每轮重新包装为新的独立算法。

case_044 的已验证反例说明其必要性：旧五核 B 结果 82823 周期，保留两核布局并追加空核心后为 45248 周期。旧结果因此确定非最优，但 45248 本身仍不具有全局最优证明。生成低核数候选的成本必须计入本次求解，不能读取别的批次结果当作免费预言机。

“更多核心不应使最优值变差”是可行域结论，无法直接转化为不同独立求解运行的结果单调性。如果程序在 N 核时选择的候选家族与 m 核时不同，或者 m 核的好候选没有在 N 核请求预算中生成，实际输出可能反而更慢。修正这类覆盖缺口需要计入额外生成成本，不能靠事后平滑曲线。

$$\mathcal{F}_m \subseteq \mathcal{F}_N \quad (m \leq N), \quad T_N^* \leq T_m^* \quad (36)$$

表 12 活动核心数的合法选择

配置声明	旧五核方案	两核布局嵌入五核
实际完成的原操作	相同	相同
活动核心数	5	2
Makespan	82823	45248
结论	已有更优反例	更优可行，未证最优

6.6 插入式候选及次序保持

插入式候选借鉴 HEFT 的向上优先级与最早完成位置思想，但适配本题的同构核心、双 Pipe 工作量、张量通信与固定评估器。它构造每个核心的虚拟日历，在满足前驱就绪的空闲区间中选择预计完成最早的位置，再保留该日历诱导的核上链块顺序。[4]

该方法不是原始异构硬件 HEFT 的逐参数复刻。块服务代理取双 Pipe 工作量、内部关键路径和局部 I/O 的乐观组合，跨核通信使用题设门限与张量字节代理。所有候选最后仍由未修改官方程序计分。与该适配单候选的比较只能支持本题和明示实现的结论。

R11 将该候选加入原 R10 组合，修复 case_009、035、078 三个失利点。受控比较显示，仅提取候选的核心归属而重新按层排序会显著变慢，因此程序应保留“归属+顺序”的整体。固定归属的 Pipe 下界又表明 case_078 不能只在旧归属上重排。

结构安全性利用严格正的虚拟块时长：每条数据边或核心相邻边均使开始时刻严格增长，所以并图不能形成环。但真实展开还包含存储复用与 COPY，仍需官方校验。插入日历扫描原实现最坏有二次项，后续 R12 通过等价空闲区间索引降低重复查找成本。

插入式日历可以利用已安排作业之间的空隙，因此它与只向核心队尾追加的列表法具有不同候选空间。其虚拟日历允许的空隙利用，不代表题目提交了操作绝对开始时刻；程序只保留由日历导出的核心顺序，真实执行仍由官方 Pipe 和存储规则产生。这个映射是适配算法时必须说明的接口差别。

$$rank_u(b) = \hat{d}_b + \max_{s \in succ(b)} (\hat{w}_{bs} + rank_u(s)) \quad (37)$$

表 13 插入式候选及次序保持

概念	本文含义
向上 rank	剩余依赖路径的代理优先级
插入位置	满足前驱就绪的核心空闲区间
虚拟时长	候选构造代理，不是官方 Makespan
最终次序	与归属一同保留的核心日历顺序

6.7 等价空闲区间索引加速

原插入式生成器对每个块寻找位置时反复扫描核心日历，已经不可能容纳任务的早期区间被多次访问。R12 改用空闲区间索引，保留优先级、就绪时间、各核心比较和并列处理规则，只跳过不可能满足请求的区间。目标是提高生成效率，而不是放宽计算图或评价约束。

对一个请求，需找到开始时刻不早于 r 、长度至少为 d 的最早可行空隙；其开始位置取空隙左端与 r 的最大值，若加 d 不超过空隙右端即有效。索引维护区间容量与顺序，使不会因跳过区间漏掉原算法本应选择的更早位置。浮点边界应保守处理，防止数值舍入改变并列选择。

全 100 例五核 B 的生成比较中，新方法 100 项均在 30 秒内成功；旧方法 96 项成功，双方成功项方案哈希全同。对旧 4 个超时图延长到 180 秒后，方案哈希也一致。因而完成了 100 例的结果等价核对，但不能宣称对所有未来输入的证明只靠这 100 例就充分。[17]

旧超时图的延长试验只用于核对等价性，不能回填成共同 30 秒协议成功。生成器耗时也不是完整求解耗时：这些大图候选后来可能被安全下界剪去，并未改变最终成绩。论文分别报告算法工程加速与调度性能收益，避免混淆。

比较加速前后的构造器时，应固定输入与候选规则，并把计时的包含范围写清楚。R12 记录包含图读取和结构校验，但不包含官方评分；原快调用顺序交替，仍来自共享环境。延长超时的等价性检查与首次共同上限测试分开统计，避免把更宽松预算下的旧方法成功算作原协议成功。

表 14 等价空闲区间索引加速

用例	旧生成器延长上限 后/秒	新区间索引/秒	方案哈希
014	62.900	2.415	一致
072	41.514	2.084	一致
076	53.706	1.957	一致
091	53.774	2.020	一致

6.8 Spill 触发的局部微批与不变性

R12 新增的性能机制不移动原操作的核心归属，而是在当前成功方案中寻找大输入复用窗口。原来粗链块把“先用 A、再用 B”的操作绑定在一起，多条链逐条执行时会交替换入；在有限窗口内细化操作级子图，可表达“先做几条链使用 A 的前段，再做使用 B 的后段”。

窗口以 4 或 8 个原子图为基本候选，最多选 16 个窗口，每窗口不超过 128 个原计算操作。窗口外顺序保持，窗口内仅从依赖已满足的操作中按大输入亲和性选择。这样限制变化范围，降低全局顺序被过度扰动的风险，但不提供精确容量峰值或最优复用保证。

B 场景每核心仍是一个 Task，原操作核心归属不变，因此划分边界 COPY 应保持一致；变化在于核内顺序、Spill 和共享带宽时序。候选若使中间输出驻留过多或关键计算推迟，即使共享输入复用变好，也应因真实 Makespan 较差而被淘汰。

case_067 与 073 分别从 13798191 降至 13054159、从 3046190 降至 2034983 周期；Spill 分别减少 44.962% 和 82.298%，切图 COPY 保持不变。收益集中在这两个开发实例，另外 98 例持平。该结果支持条件触发的局部机制，不支持普遍收益或全局最优结论。
[17]

局部细化后并非任意操作排列都合法。某个前段输出可能被窗口外消费者使用，窗口内的任务也可能依赖窗口外较晚位置。应在构造时检查这些关系，保证保留窗口外顺序仍相容；最终再对完整商图与扩展执行校验。微批允许表达新顺序，但没有放弃原图任何依赖。

表 15 Spill 触发的局部微批与不变性

项目	case_067	case_073
切图 COPY 保持值	66256384	21712384
Spill 旧→新	167973888 → 92448768	87499776 → 15489024
Makespan 旧→新	13798191 → 13054159	3046190 → 2034983
耗时下降	5.392%	33.196%

7 问题 3：只读 FIFO 缓存

7.1 FIFO 状态与发射时查询

在 B + L2 中，每个核心仍对应一个 Task，跨核目标 COPY_IN 仍需满足源 COPY_OUT 完成后 500 周期的就绪条件。L2 并不改变原图依赖，也不取消跨核同步。它只决定符合条件的读取从哪个共享服务池获得带宽。[1-2]

定义 $Q(t)$ 为按插入时间由旧到新排列的逻辑张量标识队列， $H(t)$ 为其占用字节。读取在发射时查询标识是否在 Q 中，命中则走 L2 池，否则走 DDR。命中不刷新 FIFO 顺序，未命中读取也不会立即把尚未完成的数据放入 Cache。

当未命中读取完成，若数据可容纳且此时尚未在缓存中，则从队首淘汰到剩余空间足够，再将它加入队尾。若其他读取已经把该标识插入，则不重复占空间，也不回头把本次未命中改为命中。超过容量的数据不缓存。

这组规则使访问的相对时机重要：相同核心分配、相同读取总量下，仅排列顺序变化，就可能改变在途未命中重叠与 FIFO 淘汰。本文因此既关注共享数据关系，也关注当前官方时间线，而不是只计算理论上可共享的字节数。

FIFO 与 LRU 的差别不只是名称。FIFO 按最早插入淘汰，即使某对象刚被命中，它也可能仍在队首；LRU 会刷新最近使用顺序。将命中刷新错误加入模拟会改变后续命中和成绩，因此本文不使用便于直觉分析的 LRU 替代官方 FIFO。

表 16 FIFO 状态与发射时查询

事件	Q 与 H 的更新	服务池
发射时命中	顺序与占用不变	L2 读池
发射时未命中	不立即插入	DDR 池
未命中完成且可容纳	必要淘汰后追加队尾	此次服务已结束
完成时标识已经存在	不重复插入、不刷新	不追溯更改命中
张量大于容量	不缓存	DDR 池

7.2 重叠未命中、容量淘汰与因果边界

未命中可以来自多种不同原因：首次访问、第一次读取尚未完成、此前缓存后被 FIFO 淘汰，或对象本身大于容量。只有区分这些类型，才能选择合适调整。若没有发生淘汰，却把未命中归因为容量冲突，将引导算法做无效甚至有害的工作集调整。

历史 Trace 对 case_005、006、010 的某些旧 L2 方案发现，没有 FIFO 淘汰，但存在 48、5、3 次同数据在途读取尚未完成的重复未命中。该观察只适用于这些明示方案，不可直接套到 R12 新结果。它解释了为何多核同时读取同一输入不必然产生“一核 DDR、其他核 L2”的效果。

减少重叠未命中可以考虑合法调整相关子图的顺序，但不能添加题目未允许的显式预热或空等指令。过度错开读取也可能串行化计算，节省带宽却延迟整体完成。因此，命中率增加只是机制观察，最后仍应比较 Makespan。

对某个时序中的关键访问进行改动，还会影响其他读取的带宽和后续就绪时刻。事后时间线可以确定事件发生顺序，却不能仅凭局部持续时间推导完整反事实收益。需要固定计划或受控调整后重新评价，才能把解释从猜测推进为可复核的实验。

一个容量足以同时存下全部相关数据的片段，也可能因首次读取重叠而产生多次未命中；一个顺序很紧密的片段，也可能因为单份数据超过容量而无法缓存。由此，容量总和、复用距离和在途完成顺序应分别诊断，不应只用一个“缓存友好度”分数取代事件机制。

表 17 重叠未命中、容量淘汰与因果边界

未命中类型	建议诊断	不能直接采用的结论
首次访问	检查首次完成时刻	共享数据必命中
在途重叠	检查各核心发射时刻	加空等即可最优
FIFO 淘汰	检查插入序列和字节占用	用 LRU 近似替换
容量不可容纳	对照固定容量	修改硬件容量计成绩

7.3 同方案对照与分别选解

设 PB 为 B 配置下选中方案，PL 为 L2 配置下选中方案。固定 PB 分别在 B 与 L2 下评价，可以观察增加只读缓存对同一布局的影响；分别评价 PB 与 PL，则包含硬件变化和方案选择变化。两种对照回答不同问题，必须分开呈现。

同方案要求完整提交文件哈希一致，而不仅是活动核心数或 Task 数量相同。即使原操作核心归属相同，不同子图组织与队列顺序也可能改变 L2 事件。匹配时应核对完整计划文件，不以“看起来相同”代替。

正式均值先对每个用例取比值，再对指定集合平均。两列平均单核加速比相除，一般不等于逐例 B/L2 比值平均。对 500 组 1~5 核硬件对照，缺失项必须标明，不可只取成功子集却称全 100 例曲线。

在固定方案下增加 L2 也可能使整体事件排列变化，不能把小于 1 的比值截为 1 或删除。若出现负收益，应先核对方案、配置和缓存语义，再分析资源时序。评价数据不因不符合直觉而被“平滑”成更好曲线。

同方案比较不必要求 B 与 L2 所有操作时刻相同，时刻变化正是被比较的结果；要求相同的是输入、计划与非 L2 配置条件。若计划本身不同，则资源变化和算法选择都参与了结果变化。两种设计都可以有价值，但必须在表头、公式与结论中使用一致名称。

$$R_N^{fixed} = \frac{1}{100} \sum_i \frac{T_{B,i,N}(P_B)}{T_{L2,i,N}(P_B)} \quad (38)$$

$$R_N^{selected} = \frac{1}{100} \sum_i \frac{T_{B,i,N}(P_B)}{T_{L2,i,N}(P_L)} \quad (39)$$

7.4 L2 配置下的候选覆盖与真实成本

L2 启发式搜索不保证选中在 B 中表现好的布局。若预算允许，R10 流程另外从原图运行同核数 B 求解，再把其选中方案按 L2 配置评价，作为补充候选。这不是把事后完成的另一个配置结果免费注入当前求解，而是同一次预算内实际生成并评价。

该阶段最多分配 180 秒给 B 求解，随后 L2 评价最多 40 秒，仍受总剩余预算限制。方案语义重复则去重；失败、超时或比当前 L2 成功方案更慢，则保留原解。不应因为候选在无 L2 环境更快，就推断其有 L2 表现一定更好。

R10 五核 L2 全 100 例中，这类扩展最终只有 1 例新增改善、99 例持平，均值由 4.157850 增至 4.157873，而完整求解墙钟中位数高于控制阶段。这个结果应如实报告，说明无选择增加 L2 候选的边际收益有限，而不是包装成显著突破。[15]

R12 则沿用有实际 Spill 的局部微批触发，没有把它改称新的 FIFO 专用算法。其 L2 补充配置中出现 3 项微批收益，见后文；这些是明示样本的结果，不代表 R12 全 100 例 L2 曲线。缓存专项新方法仍需独立事件依据与公平对照。

候选组合的一般风险是代价逐轮叠加。即使每个模块只新增少量尝试，完整链条也可能把预算花在大量重复方案上。因此，需要在规范化计划后去重，并用安全下界减少无用评价；但规范化不能改变核上顺序或字典插入语义，否则所谓去重可能错误合并两个不同执行候选。

表 18 L2 配置下的候选覆盖与真实成本

策略	成本计入	接受条件
L2 基础候选	本次总预算	官方 L2 结果成功
同核 B 候选重新生成	B 构造与求解+L2 重评	比当前 L2 更好
局部 Spill 微批	生成+最多两份完整评价	主指标改善
未验收自适应窗口	不进冻结主方法	另做独立扩展研究

7.5 COPY 量、命中字节与实际 DDR 的区别

官方新增搬运字段由 Task 构造和 Spill 扩展阶段产生，属于逻辑 COPY 工作量。后续模拟中的 Cache 命中不会反向修改这一字段。因此，两个方案的 `scheduled_copy_bytes` 相同，不意味着实际 DDR 服务字节必然相同；相同计划开关 L2 时，COPY 字节可不变而部分读服务转移到 L2。

字节命中率以可服务读取的命中字节占总读取字节计算，次数命中率则以读取次数计算。大张量和小张量分布不同时，两种比率差异可能较大，不能在表格中只写“命中率”却不注明定义。本文优先使用官方 `cache_stats` 的字节口径，并保留原字段。

降低 DDR 流量也未必同比缩短 Makespan。如果关键路径主要受矩阵计算或同步控制，非关键读取加速可能被其他工作掩盖。反过来，一次不大的关键读取收益也可能解除后续长链等待。性能解释应结合关键链，而非仅以总命中率高判断策略有效。

本文不自行把 `added_copy_bytes` 减去命中字节后覆盖官方成绩。需要分析实际 DDR 分流时，应另列命中字节、未命中字节及写回服务量，并明确该统计的时间线来源。正式评价、解释性派生统计和预测代理保持独立。

按字节统计的命中率更接近服务量分流，按次数统计更接近访问频率；两者都不是关键路径加速率。若命中的都是很小时非关键的读取，高次数命中仍可能只有微小总体收益。论文应保留必要的分母定义和单位，使“命中率较高但时间不变”的观察能够被合理解释而不是隐藏。

$$D_{added} = D_{pre} + D_{spill} - D_0 \quad (40)$$

$$h_{bytes} = \frac{\sum_{j \in COPY_IN, hit(j)} s_j}{\sum_{j \in COPY_IN, eligible(j)} s_j} \quad (41)$$

7.6 已验证 L2 局部结果与待完成范围

R12 的补充批次使用 067、073、009、014 四个预声明用例，分别在 3 核和 5 核的 A、L2 下运行，共 16 项。A 不采用 B 的局部微批；L2 采用同一实际 Spill 触发机制，但不新增预热、显式等待或 FIFO 替换规则。这个集合是诊断集合，不是随机代表性样本。
[17]

三项 L2 微批改善中，case_067 三核从 20394268 降到 20274197 周期，五核从 12374536 降到 12257518；case_073 五核从 1937165 降到 1805392。其他配置的持平与候选状态需要一并保留，不能只呈现胜出后暗示全部 L2 都有同等收益。

这些比较的控制是同一 R12 请求内的 indexed 阶段，并非将 R10 历史方案直接拿来免费输入。需要讨论日历加速与 Spill 微批的贡献时，二者应分别报告。控制内部新增插入候选相对更早版本的收益，不能再次算成微批收益。

本稿第三问因此提供完整的机制模型、评价口径及已完成局部证据，同时把 R7.1 历史 1~5 核汇总单独列示。R12 尚未完成全部核数的全 100 例 L2 主矩阵，不以填补缺失值的方式制造统一新曲线。剩余配置应使用同一冻结入口、预算与原版输出完成后再更新正式主表。

R11 三个开发案例的五核 B 与 L2 优胜计划哈希相同，周期分别为 009 的 52311 与 46342、035 的 58349 与 56942、078 的 481517 与 452545。它们提供独立于微批的同方案对照示例，但归属于 R11 而非 R12 新增收益。本文将这些记录按版本标识，避免一个改善在多轮演进中被重复计入。

表 19 已验证 L2 局部结果与待完成范围

用例	核数	indexed 周期	full 周期	耗时下降
067	3	20394268	20274197	0.589%
067	5	12374536	12257518	0.946%
073	5	1937165	1805392	6.802%

8 下界、正确性与最优性

8.1 全局工作量与计算关键路径下界

对于任意合法方案，全部矩阵 Pipe 工作量 WM 需要由 N 个核心的矩阵资源完成，因此 $T \geq \text{ceil}(WM/N)$ ；向量 Pipe 同理。计算依赖链中的操作必须依次执行，故 T 也至少为原计算 DAG 的最长固定周期链。将三者取最大得到与当前归属无关的全局计算下界。

该界忽略 COPY、同步、容量与 FIFO，所以是乐观的必要条件。它可以用于质量证书：已成功方案给出上界，下界给出不可突破的最低可能值。若上下界相等，才可证明该实例精确最优；接近只能说明近最优，而不是“算法已经全局最优”。

固定归属下可将每核每 Pipe 的工作量最大值纳入更强下界，但它仅约束保持该归属的方案。将固定归属界误用于全局最优性，会把某个不合理负载分配造成的下界错误当成所有方案的必然限制。case_078 的必要性诊断恰是正确使用固定归属界的例子。

同样，固定方案的边界搬运量可产生无 L2 资源下界，而该搬运量会随划分变化，不是全局不变常数。本文所有下界均注明依赖的条件，并在代码中保持不同命名，以防剪枝和质量停止的作用域混用。

总工作量除以 N 默认所有核心的相应 Pipe 可充分利用，实际任务不可抢占与依赖只会使结果更长，所以作为乐观下界是安全的。若某个场景允许改变原操作周期，这一证明就需要重审；本题固定周期使其直接成立。证明依赖的前提应显式写出，而不是仅凭“小图都满足”就认定下界正确。

$$L_0 = \max \{ \lceil WM/N \rceil, \lceil W_V/N \rceil, CP_{compute} \} \quad (42)$$

$$L_{fixed\ core} = \max_{k,p} \sum_{v:a(v)=k,p(v)=p} c_v \quad (43)$$

8.2 前驱—后继共同时间窗下界

传统总工作量界没有利用同一 Pipe 上一组操作被前驱与后继压缩在共同时间窗中的事实。令 r_v 为操作 v 最早可能开始时间， q_v 为 v 完成后到某个汇点还至少需要的最长计算路径时间。二者只使用原计算 DAG 与固定周期，不依赖子图、核心归属或缓存命中。

给定 a 、 b ，对某个计算 Pipe p ，取非空集合 $U_p(a,b)=\{v:p(v)=p,r_v\geq a,q_v\geq b\}$ 。其中所有操作都不能早于 a 开始；每个操作完成后还需至少 b 周期后继计算，所以必须不晚于 $T-b$ 结束。其全部工作量 W 因此落在区间 $[a,T-b]$ 内。

跨 N 个核心，同一 Pipe 最多同时处理 N 个操作单位的工作量，故 $W\leq N(T-a-b)$ 。周期为整数，整理得到 $T\geq a+b+\text{ceil}(W/N)$ 。取所有非空窗口的最大，并与 L_0 比较，即得到更强全局下界。这是必要条件，不要求这些操作按某个特定顺序执行。

非空条件不能省略。若集合为空， $a+b$ 本身不应被误作调度下界；后继长度也必须排除操作自身，否则会重复计算周期。实际实现用明确的前向、后向递推，避免索引定义的歧义。

共同时间窗条件对不同操作选择同一 a 、 b ，但各操作自己的 r_v 、 q_v 可以更大。因此它使用的是各生命周期的一个共同必要窗口，不要求存在恰好在 a 开始、 $T-b$ 结束的操作。取阈值出现点可以避免连续扫描无限实数，而不损失最大下界，因为集合只在阈值跨过某个 r_v 或 q_v 时改变。

$$r_v = \max_{u \in \text{pred}(v)} (r_u + c_u), \quad q_v = \max_{u \in \text{succ}(v)} (c_u + q_u) \quad (44)$$

$$U_p(a,b) = \{v : p(v) = p, r_v \geq a, q_v \geq b\} \neq \emptyset \quad (45)$$

$$T \geq a + b + \left\lceil \frac{W_p(a,b)}{N} \right\rceil \quad (46)$$

8.3 窗口界的高效计算与边界检验

只需检查 rv 和 qv 实际出现的阈值。对每个 Pipe 将操作按 rv 递减扫描，当前已加入的操作就是满足 $rv \geq a$ 者。对后继阈值 b 维护 $qv \geq b$ 的后缀工作量 $S(b)$ ，候选值可写成 $Nb + S(b)$ 。加入一个操作时，对所有 $b \leq qv$ 的候选值增加 cv 。

采用区间加与区间最大值结构，并标识已有非空集合的阈值，可在每组相同 rv 处理完后取得最大值。Fenwick 后缀和用于初始化或核对新激活阈值。每个核数的主要计算成本为 $O(|U|\log|U|)$ ， rv 、 qv 递推另需 $O(|U|+|Ec|)$ 。

实现检验包括：全部 rv 相同、全部 qv 相同、仅一个操作、不同 Pipe、零周期、无边图和长链图；将快速结果与直接双阈值枚举逐项比较。R10 已记录 100 个随机小图各 1~5 核共 500 组相等检查，以及微型可行结果不低于下界检查。这些实验用于发现实现错误，不替代数学证明。[15]

在正式 100 图×5 核数组合中，新界在 361 项上强化旧计算界。case_071 五核中， $a=393$ 、 $b=1106$ 、窗口工作量 7669，所以得到 3033 周期，旧界为 2507。增强的是最优值的必要条件，不是把当前执行时间缩短 20.98%。

若全部操作属于同一 Pipe 且没有依赖， rv 和 qv 均为 0，窗口界退化为总工作量界，不应凭空产生额外约束。若是严格串行链，关键路径通常已经很强，窗口界不一定继续提高。该退化行为既是理论一致性检查，也是单元测试应覆盖的最小情形。

$$L_{win} = \max \left\{ L_0, \max_{p,a,b: U_p(a,b) \neq \emptyset} (a + b + \lceil W_p(a,b)/N \rceil) \right\} \quad (47)$$

$$393 + 1106 + \lceil 7669/5 \rceil = 3033 \quad (48)$$

分别按 Pipe 收集(rv, qv, cv)，压缩 q 阈值坐标。

按 r 递减、相同 r 成组扫描操作。

加入操作时，对 $b \leq qv$ 的区间加 cv 并激活非空阈值。

查询 $\max(Nb + S(b))$ ，结合当前 a 取得窗口界。

跨两种 Pipe 和全部 r 组取最大，并与 L_0 比较。

8.4 固定归属的传输间隔下界

对 B 中一条确定跨核的张量依赖，消费者至少需要等待生产端写出、500 周期同步门限和目标端读入。若张量大小为 s ，按独占 DDR 给出每次搬运的最短服务时间，得到 $\text{ceil}(s/60)+500+\text{ceil}(s/60)$ 。该值忽略争用与 Spill，因而可用于给定归属下的必要间隔。

L2 场景为保持乐观性，可允许目标读取全部命中，将最后一项替换为 $\text{ceil}(s/250)$ 。这不宜宣称现实一定命中，而是在构造下界时放松约束。若把所有读取都当成 DDR 并加入过大的最低间隔，则可能错误剪枝有缓存收益的候选。

沿原计算 DAG 递推含必要间隔的最长路径，再与固定核心 Pipe 工作量和资源搬运界取最大，可以加强候选筛选。由于哪些边跨核由当前 a 决定，该界不是全局质量证书。用它拒绝当前固定候选合理，用它宣称所有核心分配都不可能更好则不合理。

多生产者、同核生产消费以及官方 COPY 对构造等情况需按实际依赖展开处理。只有能够确认属于同一必要依赖路径的间隔才能累计，不能把所有通信量与总计算量直接相加。全局共享带宽竞争仍留给官方事件模拟。

同步间隔的必要性来自源数据必须先写出，再经过固定延迟，目标读取完成后消费者才能使用；其他无关搬运可以重叠，因此不能把全图所有间隔串接。只有沿实际依赖路径累计，才不会将可重叠工作错误变成必然串行。多个前驱的完成约束取最大，也遵守同一原则。

$$\delta_B(s) = \lceil s/60 \rceil + 500 + \lceil s/60 \rceil \quad (49)$$

$$\delta_{L2}^{relax}(s) = \lceil s/60 \rceil + 500 + \lceil s/250 \rceil \quad (50)$$

8.5 从上下界得到实例质量证书

设某个成功方案的耗时为 T ，有效全局下界为 $L>0$ ，真正最优值为 T^* 。可行方案与必要条件共同给出 $L \leq T^* \leq T$ ，因此相对最优差距不超过 $T/L-1$ 。该证书针对具体图、核数与场景，不依赖人为选择的弱基线。

若 $T=L$ ，能证明该实例达到最优；若 $T/L-1$ 很小，可以证明接近最优；若已找到更快合法方案，则旧方案确定不是最优；若没有闭合界也没有反例，结论是最优性未定。不能把“当前候选中最好”与“所有可行方案最优”混为一谈。

case_014 四核 B 的历史记录为 $T=4428315$ 、计算下界 4306437，质量差距上界约 2.83%。该证书不依赖固定单核基准，补跑单核只影响报告加速比，不影响这组上下界论证。其余图的下界可能较松，不应把全部差距解释为可兑现收益。

求解器可在明确的质量阈值内提前结束后续搜索，但应报告停止规则及代价。提前停止是对已知可行结果足够接近全局下界的判断，不代表新候选无价值；关闭它的消融应比较实际额外时间与最终性能，而不是只统计触发次数。

质量界不使用固定单核基准作为最优值下界。固定单核是一份可行启发式结果，属于上界而非不可突破的最低值。相对单核加速 4 倍与距最优 2.83% 分别回答不同问题，不能用其一代替其二。论文同时报告性能与证书时，应保留这层逻辑区分。

$$0 \leq \frac{T - T^*}{T^*} \leq \frac{T}{L} - 1 \quad (51)$$

$$\frac{4428315}{4306437} - 1 \approx 0.0283 \quad (52)$$

表 20 从上下界得到实例质量证书

证据情况	可作结论
成功方案 T 等于有效全局 L	该实例最优
$T/L-1$ 较小	该实例具有近最优证书
存在更快合法方案	旧方案确定非最优
均未取得	最优性未定

8.6 微型精确枚举的作用与限制

正式图的组合规模较大，但微型图可枚举明确的提交域，作为算法与合法性规则的反证工具。R10 微型集合包含 3 个计算操作、8 种前向 DAG 边型、两种 Pipe 配置、2/3 核与 A/B/L2，共 96 个配置。枚举集合划分、连续标签置换、核心归属及各核心子图顺序，官方拒绝的方案不计为可行。[15]

该域还固定了输入映射的序列化方式，因而“枚举最优”严格指所说明的有限域，不自动包含任何任意 JSON 字典插入序可能诱导的排序差异。要对更大域给出严格最优结论，还需有效全局下界与成功方案相等。

已记录 19620 次合法官方评价中，R10 在 96 配置的 87 项达到域内最小，9 项未达到，最大相对差距约 0.324%。例如一个无依赖、两核向量 B 配置，R10 为 1021 周期，枚举最小 1019。这些小差距表明候选仍有遗漏，不应删除反例或沿用“微型全部最优”的过强说法。

微型实验主要用于检验覆盖、依赖、空核、Pipe、COPY 和下界边界，实现回归测试。它不能证明正式 100 图的全局最优，也不能将少数周期的微型改进自动转化为大图算法复杂化的理由。研究价值在于对方法提出可检验反问。

枚举任务也必须保留无效方案被拒绝的原因，防止把全体枚举数量当作可行域大小。计算图、张量大小、管线配置和标签序列化均随微型生成器固定；调整这些条件相当于改变枚举域，之前的最小值不能直接沿用。对失利实例，记录其最优域内方案有助于定位候选遗漏。

表 21 微型精确枚举的作用与限制

项目	已记录范围
原计算操作数	3
DAG/管线/核数/场景组合	$8 \times 2 \times 2 \times 3 = 96$
合法官方枚举评价	19620
R10 匹配枚举域最小	87
R10 未匹配	9
最大相对域内差距	约 0.324%

9 实现、预算与复现

9.1 冻结 R12 的完整求解流程

R12 的 reference 模式独立调用原 R11；indexed 模式使用原 R10 基础加快速插入候选，不做微批；full 模式在 indexed 成功结果上加入有界局部微批。模式差异用于独立对照，不能读取完整 full 运行已保存的最佳计划作为其他模式的免费输入。[17]

程序先校验固定配置并构建输入索引，运行适用的基础候选，以官方结果形成当前解；再生成插入式候选，检查结构、重复和安全下界，在剩余预算内评价。只有 B/L2 当前成功解实际 Spill 且符合窗口条件，才生成微批候选。

最终选择按 Makespan、新增 COPY 和确定性并列规则比较。若没有任何成功官方结果，返回明确失败，而不是输出未经评价的候选并标记成功。输出方案与日志分别保存，避免提交 JSON 混入评估指标或不可识别字段。

总预算是软截止而非硬实时保证，包含生成与评价阶段；I/O 和进程启动存在开销。微批、插入和基线阶段均使用明确上限，不能分别各用 600 秒却在报告中算成一次 600 秒请求。所有超时和异常保留独立状态。

在工程实现中，异常不能被宽泛捕获后默认返回零耗时或空结果。若选中方案丢失、原版输出解析失败或哈希不匹配，应标记失败并停止对应汇总；若仅新增候选超时而成功控制仍完整，则可以保留控制。两种情形的处理不同，必须在日志与状态机中区分。

输入 G、N、q 和 600 秒软预算，核对代码与配置。
从原图生成基础候选并官方评价，建立成功控制 P0。
用快速区间索引生成插入候选；安全检查与预算内重评。
若 $q \in \{B, L2\}$ 且控制有 Spill，构造 4/8 窗口局部微批。
保持原操作核心归属，重新校验每份微批候选。
只在成功官方结果中选优，导出两字段方案及日志。

9.2 复杂度分解与不能省略的成本

图解析和计算依赖拓扑分析通常为 $O(|U|+|Ec|)$ ，但 Ec 来自张量生产者与消费者展开，其规模不必等于原二部图边数。若一个张量连接多个生产者和消费者，展开成本包含相应关联组合，不能只引用原始边数忽略这一项。

完整分量与链块负载排序包含 $O(|U|\log|U|)$ 项；共享输入驻留贪心可能反复比较剩余分量，最坏具有二次扫描；插入日历原方法也可能存在 $O(B^2)$ 项。R12 区间索引减少实际重复查找，等价性与实际加速分别验证，不将经验加速误写成所有路径都严格对数。

窗口全局下界每核数 $O(|U|\log|U|)$ ，局部微批受到窗口数与窗口操作数硬限制。官方评价 C_{official} 则包括 Spill 扩展和并发服务事件循环，本文不宣称它线性。完整求解复杂度必须将每份实际评价的成本显式累加。

算法工程评价应同时给出生成耗时、完整求解墙钟、峰值内存或并发说明及失败状态。候选变快但最后被下界剪去，能节省求解成本却未必改变成绩；候选更优但成本增加，也应如实权衡。

候选数 K 虽然被固定上限约束，但每个候选的展开规模可能因 Spill 不同而变化，不能据 K 是常数就简单宣布整个求解器线性。批量实验还可能受到多个大图同时展开的内存压力影响。默认单工作进程有助于复现；提高并发前应单独测量峰值资源而不是只看 CPU 数量。

$$C_{\text{solve}} = C_{\text{index}} + C_{\text{generate}} + C_{\text{bound}} + \sum_{j=1}^K C_{\text{official}}(G, P_j, q) + C_{IO} \quad (53)$$

9.3 来源、恢复文件与重跑元数据

可复现证据至少包括输入图、固定配置、算法版本、求解协议、选中方案、官方输出和真实状态。报告与 CSV 只是这些对象的索引和汇总，不能代替原始结果。打包 CRC 通过也只说明 ZIP 结构完整，不能据此认定每个科学结论已经得到验证。

R12 曾有 4 个证据分包保存副本截短。补交先按原文件长度与 SHA-256 恢复 7095 项，再对缺失 1049 项补齐：165 项重跑后与原字节一致，884 项为本次真实运行的日志、时间和报告继承记录。原历史清单保持不变，新版清单明确每项的旧哈希、新哈希与来源。[18]

这一处理保证当前资料可读且可追溯，而不假装历史墙钟被恢复。确定性方案与仿真结果可以重得同哈希，包含进程号、路径和耗时的元数据通常应具有新哈希。补齐文件数量不等于扩大实验配置覆盖，8144 份证据也不是 8144 个不同用例。

论文在主表、历史表和附录中使用明确版本标签。重复控制、独立消融、候选、先导试验、恢复记录和新重跑分别计数。不得从一个状态 JSON 缺字段时填入默认零而宣称全部历史实验没有发生，也不得从旧口头完成声明推断原始文件仍然存在。

证据补齐视图可以按原路径组织，便于已有统计脚本读取，但若运行元数据已经变为新来源，就不应被当作原批次的断点直接恢复。新实验应使用新目录，并保留当前协议；文件相同的别名恢复只复制已校验字节，不是重新生成实验，也不应被计为新运行次数。

表 22 来源、恢复文件与重跑元数据

来源类型	计入方式
历史原件哈希匹配	原版本证据
真实重跑且结果字节相同	明示新运行，可比较旧值
真实重跑元数据不同	新来源与新哈希
仅有汇总、原件缺失	限制证据强度
文件补齐	不自动增加配置覆盖

9.4 独立复核与提交接口

求解器生成 `selected_plan.json`，并导出题目约定的 `<case>_multicore_res.json`，两者逐字节一致，仅含 `node_to_subgraph` 和 `core_schedules`。官方评价器应显式接收原图、方案路径和固定 `config`，避免省略位置参数时在原图目录寻找不存在的默认结果。

独立复核除官方重评外，检查所有原计算操作执行一次、固定周期、核心归属、同 Pipe 区间不重叠、原依赖满足、COPY 分解、容量和全局下界。该检查不另写一套“更快”的带宽模拟器，不用自己的评分代替题设程序。

已验证环境为 Linux、CPython 3.13.5、标准库与独立虚拟环境。进程树管理依赖 `/proc`，原生 Windows 或 macOS 未完成验收；Windows 可使用可用的 Linux/WSL 环境，但不能宣称所有版本都同耗时。环境条件与本题数学模型不同，应放在复现附录而不是当作硬件调度假设。

一次干净解压复跑只能证明对应配置能从实际包中运行，不能扩大成完整矩阵重新验证。R12 交付记录包含 A、B、L2 各一个配置复跑与 87 项测试；相应审计范围需与文件清单分开写明，避免空检查数组也被标记为科学验收成功。[17–18]

复现包应保留最小可运行核心与完整证据的明确分工。代码包足以从原图重新求解，结果包用于逐项回查既有实验；没有下载结果包时，不能说已拥有全部历史时间线。分包下载需检查字节数、ZIP 完整性和逐文件哈希，避免先前出现的文件截短被误判成算法运行问题。

解压代码与证据到同一 `NPU_R12` 根目录。

建立纯标准库虚拟环境，运行代码清单校验。

从新目录求解一个明示配置，保留所有日志。

独立调用原版 `problem_1/2/3` 重评选中方案。

比较 `Makespan` 与方案、结果哈希，执行一致性核查。

批量运行使用固定参数与新目录；同协议续跑才加 `--resume`。

10 实验设计与结果

10.1 实验范围与版本分层

本文汇集了同一项目不同阶段的模型与结果，但不把它们混成一套最终 R12 全矩阵。历史 R7.1 在 R8 逐例 CSV 中有 1400 行配置汇总，可用于旧方法曲线参考；R10、R11 和 R12 后续机制仅在各自明示范围内报告新结果。缺少原始证据的历史记录不因重新绘图而自动获得完整认证。

R12 正式主批次为 100 例五核 B，补充为 4 例 $\times$ 3/5 核 $\times$ A/L2 的 16 项，另有 reference 和 indexed 各 8 个独立请求。生成器比较的 100 例只是候选构造一致性与效率试验，不是 100 个额外完整性能配置。该范围定义防止把测试、候选和重复运行当成独立样本。

本稿写作重新整理现有数据、计算描述统计和生成图表，不声称重新运行全部原版评价。前述补齐版证据对 8144 项文件要求实现当前完整映射，其作用是修复数据交付，不是完成 R12 尚缺的 1084 项多核配置。

对于最终参赛答卷，仍需选定每问的正式方法并完成该方法对应的全要求范围，或明确采用已经完整验证的旧方法作为主结果。题目不要求三问共享同一版本编号，但正文方法、代码入口、参数和逐例结果必须能够对应。

主实验与诊断实验的采样逻辑也需区别。全 100 例主批次按题目集合完整覆盖，不因结果好坏选择；指定补充集合依据已有结构或失效模式选择，适合说明机制，却不代表总体。扩大采样后仍应先固定集合和预算，再运行，避免边看结果边挑选有利实例。

表 23 实验范围与版本分层

材料	实际覆盖	解释
历史 R7.1/R8	$100 \times 14 = 1400$ 行	历史统一汇总
R11 full	100 项 B5 + 24 项补充	不等于全矩阵
R12 full	100 项 B5 + 16 项补充	冻结主批次与诊断集合
R12 生成比较	100 项 B5 候选构造	非完整性能评价
补齐证据	8144 文件映射	文件完整性非配置覆盖

10.2 历史统一曲线与第三问数值口径

历史 R7.1 统一 CSV 的曲线按 100 个逐例比值平均重算。A 与 B 的 1 核点按题意为 1；L2 单核采用整图实际对照。该图展示旧版本在给定测试集合中的整体趋势，不将 R12 五核 B 的新点替换进来而称作统一新版性能。

同一历史版本中，场景 B 总体均值高于 A，与 B 允许同核子图保留数据、避免 A 类 Task 边界的机制相符。但由于两种场景分别选解，数值差异同时包含规则变化与方案选择，不能严格解释为仅改变某个门限造成的纯硬件收益。

第三问另列逐例 B/L2 比值平均。该值不同于两列平均加速比相除，来源为同一历史 CSV 的逐配置配对，解释为分别选解收益。若报告纯硬件作用，需要相同完整方案哈希的独立对照，不能根据此表宣称已经完成 R12 全部 500 组同方案重评。

历史表保留与最新代码不同的版本标签，附录给出读取字段、分组公式和逐例数据来源。对于当前未完成的新版本配置，不做插值，不用邻近核数或旧版数值填充；这是统计口径的必要限制，不是图表美化时可以省略的注释。

表 24 历史统一曲线与第三问数值口径

核数	历史 A	历史 B	历史 L2	逐例 B/L2 均值
1	1.000000	1.000000	1.008622	1.008622
2	1.860327	1.966007	1.971884	1.003221
3	2.572451	2.765531	2.787293	1.008737
4	3.197489	3.472848	3.533002	1.021384
5	3.743468	4.068966	4.157850	1.029314




图 3 历史 R7.1 汇总的平均单核相对加速比（不代表 R12 全矩阵）

10.3 R11 与 R12 五核 B 的全样本变化

R11 通过加入一个插入式候选，在 100 例五核 B 中 12 例改善、88 例持平，平均加速比由 R10 的 4.073198 提高到 4.111995。三个开发案例之外的 97 例还有 9 例改善，说明新增候选不仅修复已知反例；但这些仍是给定题目的测试图，不称为未见分布泛化。[16]

R12 的 indexed 控制由原 R10 与快速插入候选重建，其 100 例数值、方案和官方结果哈希与 R11 对应记录相同。full 新增微批后，2 例改善、98 例持平，平均加速比为 4.131077430。平均加速比相对变化约 0.464%，逐例耗时下降比例的平均为 0.385880%，两种指标不能互换。[17]

这 2 个改善恰为 067 与 073 两个开发实例。因此，虽然单例改善可达 33.196%，整体证据尚不支持普遍的微批收益。算法的价值在于条件触发下修复具体驻留冲突，并对不符合条件或未改善的图保留成功控制；适用范围必须明确。

平均指标之外还应检查改善分布、最差实例、Spill 和运行成本。某个图周期很长，不必然对平均加速比贡献最大；每例改善的贡献由其固定单核分母和旧新耗时共同决定。本文完整保留零收益点，不仅绘制两个胜出案例。

对于一个仅在两个开发实例触发改善的机制，合理结论是定位了某类工作集交替问题，并实现了有限修正。若希望主张更广适用性，需要更多不参与开发的高 Spill 结构、不同核数及 L2 配置验证。当前尚未取得这些完整证据时，报告局限比继续扩大文字中的适用范围更有说服力。

$$\Delta \bar{S}_i = \frac{T_i^{single}}{100} \left(\frac{1}{T_i^{new}} - \frac{1}{T_i^{old}} \right) \quad (54)$$




图 4 R12 五核 B 全部 100 例的配对耗时下降

10.4 独立基线、消融与开发集限制

独立对照的目标不是为组合算法选择一个容易战胜的基线。官方随机脚本仅示范接口，不能作为唯一性能基线。R10 按计算操作数量将 100 图分为 20 个五例区间，取各区间中间实例，独立构造 HEFT 风格适配候选并用相同官方程序评分。[1,4,15]

20 例配对中，R10 更快 16 例、持平 1 例、适配基线更快 3 例，失利实例 009、035、078 完整保留。R11 将该候选加入组合后，组合相对其中一个模块不再构成独立外部先进性比较；应称候选覆盖或组成模块对照，避免“吸收基线后战胜基线”被误写成新算法普遍优越。

R12 独立 reference 与 indexed 各 8 例，full 使用主批次独立请求。原 R11 与 indexed 在这些实例上结果一致，支持日历加速语义保持；067、073 的 full 更快支持微批局部效果。该集合包含开发例，不能称完全留出的测试集，100 例阶段前缀也不能冒充 100 例独立消融。

同预算是共同上限，不是相同实际算力。自然结束较快的基线如实记录，不人为耗满预算；超时应保留并注明配对可用范围。多核数同一图之间存在关联，不能把它们当作独立随机样本夸大统计显著性。

将一次完整运行中的 base、core、full 阶段分别取最小值，可以分析候选组合内部贡献，却不能回答“删去某模块后程序会如何分配剩余预算”。真正的模块消融需要重新执行该变体的控制流程，因此本文明确标识独立运行和阶段前缀，不把两者统计混合。

表 25 独立基线、消融与开发集限制

对照	实际范围	允许结论
HEFT 风格适配	R10 五核 B 分层 20 例	指定实现与集合的比较
R12 reference/indexed	各 8 独立请求	语义与成本对照
R12 full 阶段	100 例同次前缀	配对机制分解
微型枚举	96 明示配置	有限提交域的精确比较

10.5 求解时间、失败与交付审计

R12 五核 B 的 indexed 墙钟中位数 5.033 秒、P95 为 47.749 秒、最长 77.697 秒；full 分别为 5.146、47.796 和 83.468 秒，全部未超 600 秒软预算。这些来自共享 Linux 环境，不包含独立基线、生成器比较、证据审计与历史单核成本，也不构成其他机器速度保证。
[17]

生成器比较中 4 个旧方法超时，与完整求解中的候选评价超时属于不同层次。补充 A 场景还有内部候选评价超时，但最终保留其他成功候选给出解。最终请求成功不能被简化成所有内部尝试都成功；超时不等于不可行，也不等于更慢方案已被证明。

R12 记录 87 项测试通过，独立科学核查 936 组不同方案—原版结果对，涉及 5594045 次原计算操作执行记录。这些计数包含候选、控制和复核，不是相同数量不同节点或独立实验。独立检查范围为覆盖、固定周期、归属、Pipe、原依赖、COPY、容量、哈希和窗口界，不替代完整带宽模拟。

交付还需实际解压代码 ZIP 后运行，不只看工作区。固定结果可复读与从原图重新求解是不同验证层次；文档页码、公式字体和表格越界也独立检查。本文来源附录将代码、统计、历史资料和新增证据分开，便于队友检查每个数字的生成路径。

表 26 求解时间、失败与交付审计

五核 B 墙钟	indexed	full
中位数/秒	5.033	5.146
P95/秒	47.749	47.796
最长/秒	77.697	83.468
超过 600 秒	0	0




图 5 R12 五核 B 请求的墙钟统计（共享容器记录）

11 模型讨论与研究结论

11.1 适用范围、反例与剩余工作

本方法适用于给定操作周期、固定核内启发式与固定资源参数的计算图切分调度。优点是输出可执行、候选结构有解释、边界通信按张量计数、部分性质可证明，且原版评价保留共享带宽与缓存事件。局限是候选集合有限、驻留代理不精确，最佳粒度和顺序仍可能在搜索域之外。

实验中有多类反例需要保留：合法粗合并可能明显变慢；更低通信或 Spill 不一定更快；插入式好归属经过不匹配顺序重排会失去优势；增加核心可能使有限启发式输出退化；L2 命中改善不一定转化为全局时长下降；微型域内仍有未达到最小值的配置。

R12 主表尚未覆盖 100 图的 2~5 核三场景全部 1200 项。已验证范围为 100 项 B5 与 16 项诊断补充，不将测试、生成器或恢复文件计为额外正式配置。自适应复用区间微批尚未通过“重复固定窗口”公平对照，不进入冻结主算法。

后续优先工作是保持 R12 源码与协议，补齐各问最终采用方法的全要求配置及同方案 L2 数值；独立检查原始结果，再更新主表和附录。算法改动应另建版本。无需为了追求页数或奖项措辞增加未经验证的模型，也不能把文稿排版完成当成科学验收全部通过。

没有全局最优证明并不自动意味着题意未完成，题目要求合理时间内获得高质量可执行方案。但当前新版本覆盖缺口确实属于结果完备性问题，不能用少数近最优证书抵消。最终评价应将方法正确性、实验覆盖、质量优势与文稿格式分别审查，不以某一个“通过”替代全部。

表 27 适用范围、反例与剩余工作

边界	当前结论
最优性	有限启发式，部分实例有质量界
正式矩阵	R12 全 1200 项尚未全部确认完成
实体硬件	无实体 NPU 测量或能耗结论
外部领先性	有限适配对照，未证普遍领先
自适应扩展	待独立验收，不替换主成绩

11.2 三个子问题的结论与贡献归纳

问题 1 的关键在于将 Task 切分与完整 Task 启动门限共同考虑。非分支链保护内部依赖，依赖带内连通分块提供中间粒度，就绪列表调度处理 100/1000 周期门限，固定划分反馈进一步调整归属和核上顺序。减少边界与增加并行都可能正确，必须由真实 Makespan 决定。

问题 2 应以核心级张量生产消费集合计费，在双 Pipe 负载、同核复用和私有缓存驻留之间选择布局。完整分量、链块分层、通信增量迁移和插入式候选互补；活动核心数不必等于可用核数。R12 通过等价区间索引降低生成成本，再在高 Spill 局部窗口内细化链块，表达粗链块无法表达的复用顺序。

问题 3 保留 B 同步通路，采用发射查询、完成插入、命中不刷新与独立读取池的 FIFO 模型。分别选解与同方案硬件对照必须分开；命中率、逻辑 COPY 量和实际 DDR 服务不是同一指标。局部 Spill 微批在指定 L2 配置上有效，但不能据此宣称新的全 100 例 L2 主成绩。

理论贡献集中在题设适配的安全构造、固定方案必要条件、全局共同时间窗工作量界及其有效计算。工程贡献集中在确定性候选、预算内保留成功解、原版评价与来源追溯。性能证据来自明示批次，不把通用 DAG 划分、HEFT 思想或窗口容量思想声明为首次提出。

综上，本文形成可执行的三问建模方法和分版本实验证据，并说明哪些结论能够证明、哪些只是实验观察。作为研究长稿，它为团队独立复核与最终补齐提供完整组织；正式提交仍需完成未关闭的全配置结果、匿名模板字段、引用及 AI 辅助使用合规核查。

优秀建模论文的组织价值在于围绕问题提出清晰模型、给出可执行求解、用数据检验并说明边界，而不是复制既有论文的叙述或图表。本稿只借鉴公开优秀论文的章节与排版方式，技术内容、示例和统计均来自本题资料、明示推导与可追溯实验。

参考文献

说明：论文模板和往届论文仅用于版式与结构参考；赛题结果以原始附件和分版本实验记录为依据。引文不表示本文在外部硬件上复现了相关论文的成绩。

- [1] 中国研究生数学建模竞赛组委会. 2026 年中国研究生数学建模竞赛 A 题：通用神经网络处理器下的多核调度问题[Z]. 用户提供的原题正文与附录 A—D, 2026.
- [2] 赛题 A 官方附件 . config.txt 、 multicore_cut_evaluate_problem_1/2/3.py 、 schedule_step1/2/3.py 与配套说明[CP]. 本研究保持原文件字节不变.
- [3] Graham R L. Bounds for Certain Multiprocessing Anomalies[J]. Bell System Technical Journal, 1966, 45(9): 1563–1581. DOI: 10.1002/j.1538-7305.1966.tb01709.x.
- [4] Topcuoglu H, Hariri S, Wu M Y. Performance-Effective and Low-Complexity Task Scheduling for Heterogeneous Computing[J]. IEEE Transactions on Parallel and Distributed Systems, 2002, 13(3): 260–274. DOI: 10.1109/71.993206.
- [5] Popp M, Schlag S, Schulz C, Seemaier D. Multilevel Acyclic Hypergraph Partitioning[EB/OL]. arXiv:2002.02962, 2020. 用于有向无环划分相关工作定位，不引用其性能作为本题成绩.
- [6] Hong J W, Kung H T. I/O Complexity: The Red-Blue Pebble Game[C]//Proceedings of the 13th Annual ACM Symposium on Theory of Computing. 1981: 326–333. DOI: 10.1145/800076.802486.
- [7] Williams S, Waterman A, Patterson D. Roofline: An Insightful Visual Performance Model for Multicore Architectures[J]. Communications of the ACM, 2009, 52(4): 65–76. DOI: 10.1145/1498765.1498785.
- [8] Chen T, Moreau T, Jiang Z, et al. TVM: An Automated End-to-End Optimizing Compiler for Deep Learning[C]//13th USENIX Symposium on Operating Systems Design and Implementation. 2018.
- [9] Zheng L, Jia C, Sun M, et al. Ansor: Generating High-Performance Tensor Programs for Deep Learning[C]//14th USENIX Symposium on Operating Systems Design and Implementation. 2020.

参考文献（续）

- [10] Amdahl G M. Validity of the Single Processor Approach to Achieving Large Scale Computing Capabilities[C]//AFIPS Spring Joint Computer Conference. 1967: 483–485. DOI: 10.1145/1465482.1465560.
- [11] 中国研究生数学建模竞赛组委会. “华为杯”第二十三届中国研究生数学建模竞赛论文模板[Z]. 2026. 本稿格式据可读取的模板及其镜像核对；具体提交以组委会最终要求为准.
- [12] jirouvan. GMCM2026-LaTeX: FORMAT-CHECK.md, gmcmthesis.cls[CP/OL]. 2026. 社区版式实现及模板镜像，非组委会独立授权认证；检索日期 2026-09-25.
- [13] hiyouga. HuaweiCup2021-MCM-ProblemE: paper.pdf, README.md[CP/OL]. 2021. 仅参考公开参赛论文的章节组织、图表编号和附录形式，不使用其题目结果.
- [14] 本项目. R7.1 场景 A 分块优化与验证报告、R8 历史 1400 项逐例结果[DS]. 历史方法结果，正文与 R12 新结果严格分列.
- [15] 本项目. R10 三个子问题研究答案、实验统计及有限微型枚举[DS]. 20 例适配基线、96 个微型配置等范围以原记录为准.
- [16] 本项目. R11 诊断优化与全 100 例验证报告及五核 B 逐例结果[DS]. 五核 B 与指定补充配置独立标识，不宣称 R11 完整多核矩阵.
- [17] 本项目. R12.0 优化执行报告、METHOD_R12.md、round12_src 与配套结果[CP/DS]. 100 例五核 B、16 项补充与独立控制；原记录及代码属于本文直接依据.
- [18] 本项目. R12-EVIDENCE-REBUILD-1 补齐清单、逐项来源映射与交付核查记录[DS]. 2026-09-24. 8144 项文件要求补齐，165 项重跑字节一致、884 项为真实新元数据；不等于 R12 全 1200 配置完成.

附录 A 100 个计算图规模记录 (1/4)

本表根据随代码包提供的原始 JSON 读取，不改变节点、张量或边。非 COPY 操作与全部操作区分；未能由字段确认的单元格以“—”表示，不推断填充。

编号	计算操作	张量数	矩阵工作量 / 周期	向量工作量 / 周期
001	600	1,202	232,800	30,400
002	1,798	2,595	240,000	35,928
003	13,455	13,868	438,792	325,189
004	777	1,116	385,614	47,952
005	4,113	4,298	63,882	60,930
006	678	982	18,660	69,000
007	3,885	5,556	979,020	253,080
008	864	1,836	250,128	237,168
009	5,671	6,376	65,160	119,992
010	667	889	44,610	55,496
011	688	1,056	184,448	25,536
012	972	1,555	35,572	32,237
013	1,968	4,190	263,712	43,296
014	35,705	40,287	17,225,748	1,651,424
015	1,013	1,501	94,980	101,497
016	17,995	18,020	0	7,714,975
017	1,373	2,015	110,600	67,202
018	2,727	3,717	971,320	112,731
019	647	854	48,436	40,276
020	7,008	7,872	0	532,608
021	3,920	4,900	6,192,000	783,360
022	1,356	1,705	4,484	54,087
023	1,011	1,336	63,384	69,558
024	5,959	5,984	0	2,554,795
025	18,662	26,666	4,702,824	1,215,696

数据源：official/data/case_001.json—case_100.json。规模统计脚本及字段校验记录随文稿源文件提供。

附录 A 100 个计算图规模记录 (2/4)

本表根据随代码包提供的原始 JSON 读取，不改变节点、张量或边。非 COPY 操作与全部操作区分；未能由字段确认的单元格以“—”表示，不推断填充。

编号	计算操作	张量数	矩阵工作量 / 周期	向量工作量 / 周期
026	636	871	40,992	70,768
027	1,424	2,160	2,229,120	287,232
028	19,584	20,151	38,974,608	1,975,536
029	861	1,281	0	37,485
030	10,070	11,940	2,776,480	406,822
031	6,135	7,365	1,334,492	221,025
032	827	1,186	10,150	33,995
033	3,465	4,572	1,728,108	192,042
034	3,745	5,144	749,160	194,956
035	3,857	4,538	62,192	143,909
036	2,400	4,802	931,200	121,600
037	780	1,160	209,600	28,880
038	5,907	7,649	1,325,000	167,776
039	5,250	6,612	1,377,880	98,420
040	3,083	3,647	111,972	185,751
041	16,594	19,210	5,895,240	607,750
042	4,733	5,853	1,599,076	226,026
043	9,309	10,140	517,752	343,841
044	1,364	1,497	74,404	9,988
045	1,651	1,855	0	125,476
046	992	1,116	209,248	18,400
047	13,710	14,259	153,760	259,370
048	1,728	2,069	139,536	120,060
049	4,303	4,609	95,464	165,715
050	4,555	4,969	51,968	133,411

数据源：official/data/case_001.json—case_100.json。规模统计脚本及字段校验记录随文稿源文件提供。

附录 A 100 个计算图规模记录 (3/4)

本表根据随代码包提供的原始 JSON 读取，不改变节点、张量或边。非 COPY 操作与全部操作区分；未能由字段确认的单元格以“—”表示，不推断填充。

编号	计算操作	张量数	矩阵工作量 / 周期	向量工作量 / 周期
051	1,416	1,441	0	607,080
052	1,008	1,606	141,528	62,595
053	11,670	12,377	1,212,726	344,076
054	15,751	16,484	574,216	440,672
055	1,236	1,641	61,796	69,049
056	7,678	8,157	131,016	245,953
057	865	1,180	14,062	47,565
058	16,575	18,942	4,358,970	310,080
059	2,752	3,520	737,792	102,144
060	5,281	6,752	720,232	273,539
061	1,115	1,709	71,456	27,572
062	19,636	28,361	2,618,400	392,688
063	7,360	10,629	981,600	147,168
064	906	1,034	7,308	15,744
065	704	1,067	28,260	29,518
066	5,962	6,362	269,694	170,683
067	8,804	9,117	58,915,232	2,360,608
068	5,351	6,260	249,101	154,696
069	1,032	1,110	16,674	15,288
070	1,191	1,630	91,832	47,214
071	741	816	12,534	10,954
072	29,666	32,624	22,928,094	1,708,199
073	4,836	5,053	8,160,672	428,064
074	3,609	4,833	1,579,424	198,420
075	7,410	7,953	1,107,520	644,660

数据源：official/data/case_001.json—case_100.json。规模统计脚本及字段校验记录随文稿源文件提供。

附录 A 100 个计算图规模记录 (4/4)

本表根据随代码包提供的原始 JSON 读取，不改变节点、张量或边。非 COPY 操作与全部操作区分；未能由字段确认的单元格以 “—” 表示，不推断填充。

编号	计算操作	张量数	矩阵工作量 / 周期	向量工作量 / 周期
076	32,528	36,815	6,061,644	947,248
077	4,486	5,208	415,406	136,672
078	1,024	1,156	2,037,888	103,296
079	18,720	21,252	29,424,384	3,760,128
080	1,098	1,674	289,044	20,520
081	3,485	5,185	0	151,725
082	4,113	4,298	567,936	359,766
083	3,844	4,037	810,836	71,300
084	8,616	18,309	1,266,552	1,240,704
085	19,737	20,240	2,565,216	1,724,706
086	5,274	5,462	79,182	78,060
087	27,556	29,569	3,593,280	882,784
088	3,309	3,811	173,608	99,744
089	5,120	5,348	589,120	109,760
090	1,664	1,811	840,528	59,280
091	31,554	34,927	8,981,360	931,710
092	17,608	18,134	3,714,152	326,600
093	552	1,181	73,968	12,144
094	647	895	70,944	36,616
095	3,696	7,854	1,069,992	1,014,552
096	1,198	1,476	40,144	53,130
097	6,592	8,320	10,303,488	1,331,712
098	1,365	1,700	17,296	162,701
099	6,296	7,610	1,595,484	144,720
100	1,394	1,825	62,556	102,007

数据源：official/data/case_001.json—case_100.json。规模统计脚本及字段校验记录随文稿源文件提供。

附录 B R12 五核 B 逐例结果 (1/5)

版本：R12.0 full；5 个可用核心，场景 B。基准为固定整图单核；indexed 为同次控制。新增 COPY 与 Spill 取官方统计口径，单位为字节。此表不代表其他核数及场景已经完成。

编号	固定单核	indexed	R12	加速比	新增 COPY	Spill
001	233,110	47,502	47,502	4.9074	4,608	0
002	261,945	59,575	59,575	4.3969	872,448	0
003	602,212	232,588	232,588	2.5892	9,723,996	0
004	392,357	88,341	88,341	4.4414	442,368	0
005	95,618	52,655	52,655	1.8159	1,728,714	0
006	82,837	24,618	24,618	3.3649	411,656	0
007	1,012,562	203,834	203,834	4.9676	110,592	0
008	487,605	100,603	100,603	4.8468	0	0
009	153,261	52,311	52,311	2.9298	2,008,978	0
010	86,969	26,147	26,147	3.3262	778,932	0
011	184,697	46,880	46,880	3.9398	540,672	0
012	59,088	12,712	12,712	4.6482	31,104	0
013	263,949	54,363	54,363	4.8553	32,768	0
014	17,698,626	3,605,387	3,605,387	4.9089	53,128,200	17,894,232
015	177,362	39,837	39,837	4.4522	317,952	0
016	7,715,523	2,087,323	2,087,323	3.6964	214,900	0
017	162,810	30,495	30,495	5.3389	343,296	0
018	1,004,367	202,778	202,778	4.9530	5,054,464	372,736
019	81,144	18,640	18,640	4.3532	327,032	0
020	532,746	107,650	107,650	4.9489	0	0

来源：NPU_R12_B5.csv 及补齐版 R12_B5_Complete_Index.csv。完整方案、原版结果及来源哈希见电子证据；未在本文生成虚构运行日志。

附录 B R12 五核 B 逐例结果 (2/5)

版本：R12.0 full；5 个可用核心，场景 B。基准为固定整图单核；indexed 为同次控制。新增 COPY 与 Spill 取官方统计口径，单位为字节。此表不代表其他核数及场景已经完成。

编号	固定单核	indexed	R12	加速比	新增 COPY	Spill
021	6,567,937	1,250,168	1,250,168	5.2536	11,431,936	2,011,136
022	56,780	11,813	11,813	4.8066	6,912	0
023	122,614	24,793	24,793	4.9455	197,472	0
024	2,555,343	694,207	694,207	3.6810	202,660	0
025	4,863,026	975,282	975,282	4.9863	110,592	0
026	99,203	33,518	33,518	2.9597	491,168	0
027	2,363,952	558,753	558,753	4.2308	5,529,600	0
028	43,836,040	8,211,965	8,211,965	5.3381	30,147,072	11,882,496
029	37,555	9,383	9,383	4.0025	0	0
030	2,808,034	561,102	561,102	5.0045	11,479,040	4,015,104
031	1,414,369	306,307	306,307	4.6175	8,059,392	1,810,944
032	41,443	10,415	10,415	3.9792	12,360	0
033	1,774,196	369,453	369,453	4.8022	6,509,184	0
034	842,996	173,032	173,032	4.8719	3,532,800	0
035	169,571	58,349	58,349	2.9062	1,602,218	0
036	931,510	187,182	187,182	4.9765	4,608	0
037	210,001	43,800	43,800	4.7945	1,925,120	0
038	1,364,555	283,188	283,188	4.8185	8,558,592	0
039	1,435,262	381,106	381,106	3.7660	13,320,192	712,704
040	253,454	89,745	89,745	2.8242	2,634,900	0

来源：NPU_R12_B5.csv 及补齐版 R12_B5_Complete_Index.csv。完整方案、原版结果及来源哈希见电子证据；未在本文生成虚构运行日志。

附录 B R12 五核 B 逐例结果 (3/5)

版本：R12.0 full；5 个可用核心，场景 B。基准为固定整图单核；indexed 为同次控制。新增 COPY 与 Spill 取官方统计口径，单位为字节。此表不代表其他核数及场景已经完成。

编号	固定单核	indexed	R12	加速比	新增 COPY	Spill
041	6,003,957	1,196,379	1,196,379	5.0184	40,630,272	22,609,920
042	1,686,740	369,780	369,780	4.5615	8,045,568	758,784
043	677,656	240,597	240,597	2.8166	9,832,918	0
044	154,407	45,248	45,248	3.4125	930,400	0
045	125,614	26,164	26,164	4.8010	0	0
046	276,455	79,918	79,918	3.4592	2,791,200	0
047	326,508	119,372	119,372	2.7352	3,409,368	0
048	222,220	98,572	98,572	2.2544	1,132,628	0
049	196,276	64,305	64,305	3.0523	2,125,062	0
050	149,690	58,897	58,897	2.5416	1,885,008	0
051	607,628	168,374	168,374	3.6088	198,040	0
052	180,301	41,994	41,994	4.2935	333,312	0
053	1,472,686	375,096	375,096	3.9262	12,135,050	0
054	815,051	240,647	240,647	3.3869	8,940,968	0
055	118,835	26,183	26,183	4.5386	198,656	0
056	277,285	97,116	97,116	2.8552	3,574,548	0
057	59,726	16,538	16,538	3.6114	27,936	0
058	4,539,717	1,004,819	1,004,819	4.5179	32,104,448	13,721,600
059	829,473	150,782	150,782	5.5011	4,325,376	0
060	888,789	185,331	185,331	4.7957	3,641,728	200,704

来源：NPU_R12_B5.csv 及补齐版 R12_B5_Complete_Index.csv。完整方案、原版结果及来源哈希见电子证据；未在本文生成虚构运行日志。

附录 B R12 五核 B 逐例结果 (4/5)

版本：R12.0 full；5 个可用核心，场景 B。基准为固定整图单核；indexed 为同次控制。新增 COPY 与 Spill 取官方统计口径，单位为字节。此表不代表其他核数及场景已经完成。

编号	固定单核	indexed	R12	加速比	新增 COPY	Spill
061	77,191	22,283	22,283	3.4641	83,712	0
062	2,854,809	703,542	703,542	4.0578	10,626,048	1,363,968
063	1,070,397	255,854	255,854	4.1836	3,253,248	18,432
064	19,116	8,333	8,333	2.2940	132,948	0
065	53,068	9,558	9,558	5.5522	55,728	0
066	359,070	119,141	119,141	3.0138	4,419,676	0
067	63,834,834	13,798,191	13,054,159	4.8900	158,705,152	92,448,768
068	362,095	141,879	141,879	2.5521	4,184,738	0
069	25,144	13,698	13,698	1.8356	465,362	0
070	117,300	25,840	25,840	4.5395	462,848	0
071	18,919	10,442	10,442	1.8118	317,010	0
072	23,897,828	4,831,103	4,831,103	4.9467	84,918,960	45,498,368
073	10,081,626	3,046,190	2,034,983	4.9542	37,201,408	15,489,024
074	1,682,239	330,183	330,183	5.0949	7,118,848	0
075	1,441,809	374,967	374,967	3.8452	12,788,022	0
076	6,185,113	1,240,011	1,240,011	4.9880	40,553,472	24,255,488
077	495,320	121,081	121,081	4.0908	172,032	0
078	2,296,143	481,517	481,517	4.7686	12,822,528	0
079	31,052,251	6,045,667	6,045,667	5.1363	31,907,840	8,658,944
080	292,138	100,325	100,325	2.9119	3,047,424	0

来源：NPU_R12_B5.csv 及补齐版 R12_B5_Complete_Index.csv。完整方案、原版结果及来源哈希见电子证据；未在本文生成虚构运行日志。

附录 B R12 五核 B 逐例结果 (5/5)

版本：R12.0 full；5 个可用核心，场景 B。基准为固定整图单核；indexed 为同次控制。新增 COPY 与 Spill 取官方统计口径，单位为字节。此表不代表其他核数及场景已经完成。

编号	固定单核	indexed	R12	加速比	新增 COPY	Spill
081	151,795	30,943	30,943	4.9056	0	0
082	721,041	195,543	195,543	3.6874	5,194,934	0
083	1,057,993	191,867	191,867	5.5142	3,721,600	0
084	2,507,412	503,472	503,472	4.9802	0	0
085	3,187,899	822,333	822,333	3.8767	22,587,672	0
086	118,403	55,557	55,557	2.1312	2,269,390	0
087	3,974,071	885,221	885,221	4.4894	8,050,176	1,069,056
088	243,623	98,539	98,539	2.4724	2,683,862	0
089	693,092	133,338	133,338	5.1980	954,880	0
090	1,178,363	274,650	274,650	4.2904	8,606,208	0
091	9,186,769	1,848,187	1,848,187	4.9707	39,725,056	13,811,712
092	4,815,554	814,597	814,597	5.9116	4,606,336	884,736
093	74,205	15,876	15,876	4.6740	32,768	0
094	94,892	20,297	20,297	4.6752	259,200	0
095	2,084,853	420,852	420,852	4.9539	0	0
096	84,194	25,183	25,183	3.3433	623,148	0
097	11,491,509	2,102,348	2,102,348	5.4660	21,311,488	4,272,128
098	177,430	50,844	50,844	3.4897	1,517,236	0
099	1,622,999	324,321	324,321	5.0043	7,065,600	0
100	151,223	47,130	47,130	3.2086	1,112,288	0

来源：NPU_R12_B5.csv 及补齐版 R12_B5_Complete_Index.csv。完整方案、原版结果及来源哈希见电子证据；未在本文生成虚构运行日志。

附录 C.1 历史场景 A: Makespan (1/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	2 核	3 核	4 核	5 核
001	116,868	78,545	58,984	47,502
002	140,236	98,023	76,865	58,180
003	393,827	321,535	287,598	276,507
004	199,074	134,043	104,188	88,341
005	80,999	72,553	70,248	69,060
006	43,033	31,151	27,895	27,679
007	507,494	338,094	254,398	203,834
008	244,266	163,359	123,060	100,603
009	92,198	92,207	81,530	73,571
010	45,626	30,856	27,800	24,563
011	92,646	69,625	46,880	47,287
012	30,094	21,894	17,853	14,212
013	132,198	88,351	66,982	54,363
014	8,759,857	5,865,918	4,411,966	3,603,683
015	92,321	61,168	51,205	42,955
016	4,646,180	3,793,761	3,592,965	3,306,411
017	84,055	58,959	48,848	35,470
018	503,411	339,838	258,063	202,636
019	43,224	30,852	24,099	22,228
020	266,580	177,950	133,704	107,650
021	3,156,352	2,106,282	1,550,324	1,250,168
022	28,881	19,370	14,641	11,813
023	61,424	41,720	30,522	24,965
024	1,539,668	1,256,817	1,189,845	1,095,663
025	2,431,840	1,622,164	1,217,444	975,282

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.1 历史场景 A: Makespan (2/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	2 核	3 核	4 核	5 核
026	58,112	41,655	41,555	41,699
027	1,120,962	837,049	559,196	558,753
028	20,541,851	14,076,015	10,461,460	8,605,530
029	19,740	12,743	11,028	9,383
030	1,394,193	931,629	698,657	560,814
031	706,033	485,202	392,550	306,307
032	21,706	15,674	12,763	10,415
033	904,907	607,519	461,610	373,638
034	415,383	287,578	230,925	184,639
035	95,406	95,424	90,516	82,052
036	466,068	311,345	233,584	187,182
037	105,374	74,038	53,320	43,800
038	681,518	461,018	345,206	283,932
039	708,561	485,565	392,896	411,686
040	143,799	110,105	98,759	93,219
041	2,965,113	1,976,739	1,484,401	1,192,525
042	835,375	571,947	435,238	363,428
043	355,614	268,777	261,670	232,286
044	78,699	78,699	78,699	78,699
045	63,059	42,601	31,878	26,164
046	166,578	142,176	124,612	131,039
047	245,880	187,273	171,560	158,050
048	169,359	145,022	145,292	145,490
049	148,351	124,128	115,314	108,297
050	108,121	85,329	74,902	70,368

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.1 历史场景 A: Makespan (3/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	2 核	3 核	4 核	5 核
051	367,112	299,245	282,785	261,214
052	91,267	65,207	50,125	43,641
053	759,981	546,106	492,232	492,699
054	517,960	391,890	331,031	298,043
055	57,941	43,655	31,823	26,800
056	213,386	180,659	166,455	157,566
057	32,042	21,762	16,879	14,055
058	2,200,935	1,532,101	1,157,363	1,004,819
059	369,318	254,768	185,216	150,782
060	458,745	308,169	232,466	185,331
061	39,298	28,342	27,170	22,059
062	1,486,029	1,005,836	764,940	619,333
063	558,373	377,834	290,167	237,375
064	18,283	17,170	16,312	15,899
065	26,972	17,918	14,288	11,235
066	226,476	185,361	167,785	159,869
067	32,438,342	22,543,931	16,545,997	13,961,132
068	260,340	221,224	197,091	189,541
069	21,197	19,700	18,866	19,032
070	58,234	45,660	34,658	28,840
071	16,232	14,889	14,434	14,220
072	11,713,796	7,870,089	5,945,430	4,779,968
073	5,304,875	4,427,074	3,646,155	3,315,864
074	832,726	548,347	415,984	345,470
075	844,156	639,599	552,334	506,598

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.1 历史场景 A: Makespan (4/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	2 核	3 核	4 核	5 核
076	3,046,650	2,033,956	1,526,939	1,230,399
077	250,735	178,739	144,734	121,081
078	1,095,068	763,089	653,532	536,429
079	14,738,594	9,939,977	7,495,240	5,998,948
080	145,926	100,325	111,314	113,455
081	76,860	51,943	39,588	30,943
082	450,921	355,841	311,867	290,998
083	537,673	414,361	390,026	370,632
084	1,013,056	762,658	629,028	503,472
085	2,105,594	1,593,477	1,291,419	1,215,271
086	99,674	92,319	84,701	83,340
087	1,971,637	1,378,263	1,070,453	886,089
088	173,654	146,818	131,635	127,073
089	346,832	243,614	178,160	147,432
090	513,438	397,500	346,678	346,678
091	4,529,311	3,036,878	2,288,314	1,857,417
092	2,498,492	1,841,420	1,465,901	1,384,732
093	37,827	25,103	19,779	15,876
094	49,398	39,889	27,461	23,564
095	1,042,890	695,775	524,422	420,852
096	47,089	30,832	26,980	26,984
097	5,161,740	3,594,815	2,626,908	2,102,348
098	89,551	82,660	69,258	64,165
099	811,243	544,403	405,655	336,496
100	82,771	57,811	58,086	51,287

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.2 历史场景 B: Makespan (1/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	2 核	3 核	4 核	5 核
001	116,868	78,545	58,984	47,502
002	138,076	94,704	73,655	61,028
003	352,887	262,953	234,056	232,588
004	199,074	134,043	104,188	88,341
005	62,432	52,655	52,655	52,655
006	40,683	30,427	26,535	24,618
007	507,494	338,094	254,398	203,834
008	244,266	163,359	123,060	100,603
009	92,198	87,391	77,811	77,811
010	42,846	30,856	26,147	26,147
011	92,646	69,625	46,880	47,287
012	30,006	18,114	14,886	12,712
013	132,198	88,351	66,982	54,363
014	8,877,755	5,924,867	4,428,315	3,605,387
015	90,626	58,906	51,503	39,837
016	4,038,048	2,894,404	2,401,458	2,108,654
017	86,334	52,489	42,924	30,495
018	498,719	336,467	255,853	202,778
019	41,720	28,195	21,744	18,640
020	266,580	177,950	133,704	107,650
021	3,194,570	2,106,848	1,550,324	1,250,168
022	28,851	19,370	14,574	11,813
023	60,468	41,720	30,522	24,793
024	1,337,969	960,205	798,205	702,252
025	2,431,840	1,622,164	1,217,444	975,282

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.2 历史场景 B: Makespan (2/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	2 核	3 核	4 核	5 核
026	56,135	41,655	35,520	33,518
027	1,120,962	837,049	559,196	558,753
028	20,623,497	13,848,390	10,250,099	8,211,965
029	19,740	12,743	11,028	9,383
030	1,403,594	933,857	700,342	561,102
031	732,205	483,567	394,466	306,307
032	17,554	11,808	11,164	10,415
033	896,676	602,408	457,602	369,453
034	440,418	280,681	252,538	173,032
035	95,406	92,586	80,143	76,678
036	466,068	311,345	233,584	187,182
037	105,374	74,038	53,320	43,800
038	681,518	459,530	344,898	283,188
039	708,561	483,806	381,106	386,470
040	143,299	110,105	95,952	89,745
041	2,992,480	1,991,992	1,490,603	1,196,379
042	840,916	571,947	435,949	369,780
043	352,392	267,919	240,597	240,597
044	45,248	45,248	45,248	45,248
045	63,059	42,601	31,878	26,164
046	109,740	82,826	79,918	79,918
047	191,143	151,200	131,895	119,372
048	125,568	114,005	108,527	107,144
049	111,003	84,440	70,510	64,305
050	86,016	67,318	59,891	58,897

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.2 历史场景 B: Makespan (3/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	2 核	3 核	4 核	5 核
051	318,674	230,322	193,062	171,363
052	86,843	62,309	45,500	41,994
053	728,229	497,437	425,404	375,096
054	441,825	316,491	262,542	240,647
055	57,720	40,063	31,823	26,183
056	156,328	117,225	104,605	97,116
057	30,932	23,862	20,957	16,538
058	2,266,331	1,554,831	1,141,608	1,004,819
059	369,318	254,073	185,216	150,782
060	474,073	323,843	240,113	185,331
061	39,298	28,342	26,678	22,283
062	1,588,095	1,086,396	838,854	703,542
063	580,468	396,695	313,176	255,854
064	17,093	15,301	10,614	10,347
065	22,021	16,963	11,769	9,558
066	195,838	139,098	123,721	119,141
067	32,171,803	23,066,543	17,926,926	15,255,427
068	205,310	167,916	147,382	141,879
069	16,133	14,920	14,483	13,698
070	58,234	45,501	34,658	25,840
071	12,826	10,782	10,331	10,442
072	11,836,023	7,961,454	5,911,772	4,831,103
073	5,587,533	4,300,595	3,619,516	3,210,135
074	803,673	537,857	406,099	330,183
075	744,040	562,373	430,548	390,508

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.2 历史场景 B: Makespan (4/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	2 核	3 核	4 核	5 核
076	3,065,214	2,050,028	1,540,201	1,240,011
077	250,735	178,739	144,734	121,081
078	1,051,374	788,293	568,228	549,089
079	15,446,486	10,164,789	7,635,624	6,045,667
080	145,926	100,325	111,314	113,455
081	76,860	51,943	39,588	30,943
082	394,203	263,881	219,168	195,543
083	433,315	298,003	219,344	191,867
084	1,168,951	836,220	629,028	503,472
085	1,810,774	1,275,250	948,126	822,333
086	67,521	60,328	55,557	55,557
087	1,987,606	1,371,815	1,069,325	885,221
088	140,347	117,498	98,539	98,539
089	329,430	229,298	165,616	133,338
090	454,440	337,795	295,164	274,650
091	4,571,759	3,053,553	2,290,698	1,848,187
092	2,162,750	1,418,789	1,033,609	814,597
093	37,827	25,103	19,779	15,876
094	48,430	35,024	27,182	20,297
095	1,042,890	695,775	524,422	420,852
096	46,840	30,611	26,984	25,183
097	5,617,602	3,660,459	2,626,908	2,102,348
098	89,551	65,715	52,186	50,844
099	811,243	544,403	405,655	324,321
100	84,410	57,811	50,659	47,130

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.3 历史 L2 配置：Makespan (1/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	1 核	2 核	3 核	4 核	5 核
001	233,110	116,868	78,545	58,984	47,502
002	261,945	138,076	94,704	73,655	61,028
003	602,212	351,922	260,056	229,275	212,297
004	392,357	199,074	134,043	104,188	88,341
005	95,618	62,391	52,396	50,800	49,484
006	82,837	40,683	28,788	24,958	21,965
007	1,012,562	507,494	338,094	254,398	203,834
008	487,605	244,266	163,359	123,060	100,603
009	153,261	92,198	86,442	75,551	72,863
010	86,969	42,721	30,856	24,135	24,724
011	184,697	92,646	69,625	46,880	46,777
012	59,088	30,006	18,114	14,884	12,622
013	263,949	132,198	88,351	66,982	54,363
014	17,689,602	8,857,863	5,896,850	4,426,698	3,592,432
015	177,362	90,626	58,906	51,503	39,837
016	7,715,523	4,037,708	2,894,404	2,401,458	2,108,196
017	162,810	86,028	52,439	42,924	30,495
018	1,003,110	498,614	336,362	255,632	201,337
019	81,144	41,720	28,195	21,598	18,640
020	532,746	266,580	177,950	133,704	107,650
021	6,558,837	3,193,634	2,106,355	1,550,324	1,249,380
022	56,780	28,851	19,370	14,574	11,813
023	122,614	60,468	41,357	30,522	24,793
024	2,555,343	1,337,629	960,205	798,205	701,716
025	4,863,026	2,431,840	1,622,164	1,217,444	975,282

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.3 历史 L2 配置：Makespan (2/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	1 核	2 核	3 核	4 核	5 核
026	99,203	55,517	40,736	35,431	33,721
027	2,359,515	1,120,962	837,049	559,196	558,753
028	43,836,040	20,607,201	13,848,390	10,250,076	8,209,101
029	37,555	19,740	12,743	11,028	9,383
030	2,807,891	1,403,449	933,236	700,156	560,897
031	1,414,159	732,205	483,567	394,388	306,307
032	41,443	17,554	11,808	10,764	10,391
033	1,774,080	896,372	602,363	457,038	367,285
034	842,733	440,340	280,601	252,450	171,529
035	169,571	95,406	91,872	78,792	73,621
036	931,510	466,068	311,345	233,584	187,182
037	210,001	105,374	74,038	53,320	43,013
038	1,363,312	681,309	459,314	344,678	273,759
039	1,435,262	705,615	482,552	368,055	340,476
040	253,454	143,298	110,105	94,060	86,832
041	6,001,575	2,987,139	1,991,302	1,487,676	1,193,054
042	1,675,633	840,258	571,429	435,882	369,723
043	677,656	352,392	265,912	227,159	215,630
044	107,814	45,244	45,244	45,244	45,244
045	125,614	63,059	42,601	31,878	26,164
046	244,994	109,740	82,826	79,918	79,918
047	326,508	191,140	151,124	131,365	117,510
048	222,220	125,568	114,004	108,233	107,016
049	196,276	111,003	84,340	70,332	63,196
050	149,690	85,990	67,069	58,829	54,311

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.3 历史 L2 配置：Makespan (3/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	1 核	2 核	3 核	4 核	5 核
051	607,628	318,334	230,322	193,062	170,944
052	180,301	86,703	61,902	45,216	41,587
053	1,428,109	728,352	489,248	415,932	362,303
054	815,051	441,822	316,308	262,300	237,165
055	118,835	57,720	40,063	31,823	26,183
056	277,285	156,324	116,861	103,277	94,564
057	59,726	30,932	23,080	18,687	16,538
058	4,539,717	2,266,202	1,554,831	1,136,056	1,004,819
059	815,938	369,318	254,073	185,216	150,736
060	887,801	472,697	323,606	239,861	184,532
061	77,191	39,272	28,316	26,678	22,283
062	2,854,809	1,588,095	1,086,396	838,854	703,542
063	1,070,397	580,468	396,695	313,176	255,854
064	19,116	17,092	15,261	10,532	10,218
065	53,068	22,021	16,963	11,769	9,558
066	359,070	195,649	137,156	120,237	110,103
067	63,834,834	31,225,165	21,181,144	16,221,979	13,166,108
068	362,095	204,710	164,713	138,618	130,386
069	25,144	16,094	14,474	12,569	12,569
070	117,300	58,234	45,501	34,658	25,840
071	18,919	12,813	10,460	9,203	9,203
072	23,890,756	11,826,643	7,944,880	5,901,949	4,817,940
073	10,081,626	4,539,269	3,223,907	2,664,667	2,277,715
074	1,678,120	803,065	537,389	406,017	330,183
075	1,441,809	744,035	561,958	429,847	385,788

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.3 历史 L2 配置：Makespan (4/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	1 核	2 核	3 核	4 核	5 核
076	6,183,098	3,063,843	2,047,868	1,536,306	1,232,435
077	495,320	250,735	178,739	144,734	121,081
078	2,296,143	1,051,374	788,293	568,228	527,173
079	31,052,251	15,446,486	10,164,160	7,635,624	6,043,668
080	291,826	145,674	100,325	90,584	86,025
081	151,795	76,860	51,943	39,588	30,943
082	721,041	394,200	263,832	218,918	194,468
083	946,145	433,240	298,003	219,344	190,890
084	2,507,412	1,168,951	836,220	629,028	503,472
085	3,187,899	1,810,773	1,275,347	947,690	817,718
086	118,403	67,520	60,080	51,263	51,263
087	3,969,779	1,984,150	1,371,815	1,069,325	885,221
088	243,623	139,420	113,413	91,991	91,991
089	693,092	329,430	229,298	165,616	133,338
090	1,178,363	456,431	312,336	248,631	248,631
091	9,168,820	4,569,395	3,070,819	2,307,637	1,848,050
092	4,333,631	2,161,490	1,421,140	1,018,349	816,728
093	74,205	37,827	25,103	19,779	15,876
094	94,892	48,430	35,039	26,940	20,152
095	2,084,853	1,042,890	695,775	524,422	420,852
096	84,194	46,840	30,611	26,984	24,363
097	11,491,509	5,617,602	3,660,338	2,626,908	2,102,250
098	177,430	89,551	64,949	50,721	46,116
099	1,618,902	807,032	540,586	403,542	327,276
100	151,223	84,410	57,530	48,028	41,936

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.4 历史 L2 配置：字节命中率 (1/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	1 核	2 核	3 核	4 核	5 核
001	0.000%	0.000%	0.000%	0.000%	0.000%
002	0.000%	0.000%	0.000%	0.000%	0.000%
003	0.000%	13.005%	20.273%	24.041%	31.052%
004	0.000%	0.000%	0.000%	0.000%	0.000%
005	0.000%	8.631%	18.720%	27.809%	32.788%
006	2.928%	25.089%	36.547%	39.770%	28.879%
007	0.000%	0.000%	0.000%	0.000%	0.000%
008	0.000%	0.000%	0.000%	0.000%	0.000%
009	0.000%	0.000%	25.874%	29.322%	32.042%
010	0.000%	29.677%	11.188%	38.127%	31.139%
011	0.000%	0.000%	46.970%	0.000%	62.311%
012	0.000%	5.615%	3.998%	4.326%	6.037%
013	0.000%	0.000%	0.000%	0.000%	0.000%
014	12.291%	23.146%	22.424%	30.348%	30.938%
015	16.927%	11.045%	19.049%	17.783%	26.442%
016	0.000%	49.730%	0.151%	0.302%	33.196%
017	4.040%	26.634%	24.655%	32.440%	27.103%
018	34.375%	43.065%	42.699%	52.697%	61.432%
019	0.000%	12.614%	12.057%	23.365%	21.055%
020	0.000%	0.000%	0.000%	0.000%	0.000%
021	50.060%	21.778%	45.217%	0.000%	56.996%
022	0.000%	3.135%	6.080%	6.080%	3.135%
023	0.000%	16.228%	26.475%	9.366%	31.129%
024	0.000%	49.910%	0.050%	0.101%	33.287%
025	0.000%	0.000%	0.000%	0.000%	0.000%

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.4 历史 L2 配置：字节命中率 (2/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	1 核	2 核	3 核	4 核	5 核
026	0.000%	19.605%	27.196%	30.201%	16.413%
027	26.894%	8.904%	43.037%	0.000%	4.444%
028	0.000%	9.356%	0.000%	26.009%	25.273%
029	0.000%	0.000%	0.000%	0.000%	0.000%
030	25.987%	46.337%	54.651%	59.658%	59.511%
031	26.059%	42.658%	50.239%	40.433%	54.742%
032	0.000%	2.178%	4.240%	2.835%	2.835%
033	9.628%	35.722%	28.317%	32.325%	26.459%
034	30.905%	36.076%	44.533%	42.796%	50.700%
035	0.000%	0.000%	33.571%	36.664%	43.213%
036	0.000%	0.000%	0.000%	0.000%	0.000%
037	0.000%	0.000%	61.538%	0.000%	64.250%
038	17.362%	27.146%	44.593%	35.606%	47.732%
039	0.000%	37.017%	31.846%	47.821%	37.089%
040	0.000%	19.492%	0.000%	26.155%	27.253%
041	10.164%	22.305%	25.615%	34.380%	31.772%
042	31.869%	41.296%	48.068%	38.143%	42.820%
043	3.321%	26.156%	29.150%	32.762%	34.584%
044	81.999%	0.343%	0.343%	0.343%	0.343%
045	0.000%	0.000%	0.000%	0.000%	0.000%
046	75.303%	0.000%	63.827%	0.000%	0.000%
047	0.000%	13.632%	19.502%	26.872%	36.033%
048	0.000%	19.908%	12.563%	17.229%	22.197%
049	0.000%	4.867%	14.368%	21.307%	23.834%
050	0.000%	19.525%	17.536%	21.160%	32.369%

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.4 历史 L2 配置：字节命中率 (3/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	1 核	2 核	3 核	4 核	5 核
051	0.000%	49.979%	0.012%	0.023%	33.322%
052	0.000%	8.580%	15.805%	14.647%	27.630%
053	62.487%	11.605%	19.832%	23.650%	22.510%
054	0.000%	3.024%	13.129%	12.550%	18.972%
055	10.014%	8.464%	13.397%	11.878%	12.360%
056	0.000%	7.984%	14.475%	20.362%	26.894%
057	21.868%	41.489%	43.997%	45.864%	0.079%
058	0.000%	6.750%	0.000%	25.102%	0.000%
059	61.004%	0.000%	55.177%	0.000%	73.788%
060	42.314%	29.887%	46.877%	38.356%	52.984%
061	0.000%	5.973%	7.326%	10.261%	12.316%
062	0.000%	0.000%	0.000%	0.000%	0.000%
063	0.000%	0.000%	0.000%	0.000%	0.000%
064	0.000%	4.718%	18.875%	32.132%	31.769%
065	0.000%	4.453%	8.526%	12.229%	15.678%
066	0.000%	14.654%	22.510%	26.690%	27.468%
067	0.000%	81.059%	72.905%	68.613%	80.300%
068	0.000%	20.579%	25.426%	20.758%	22.787%
069	0.000%	20.423%	23.264%	33.178%	33.178%
070	0.000%	19.105%	7.541%	11.344%	29.698%
071	0.000%	28.445%	33.552%	31.019%	31.019%
072	2.621%	12.418%	14.604%	19.162%	19.365%
073	0.000%	80.967%	87.896%	71.923%	71.781%
074	16.680%	25.857%	32.297%	28.449%	26.203%
075	0.000%	13.191%	27.578%	28.336%	33.260%

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 C.4 历史 L2 配置：字节命中率 (4/4)

本表来自历史 R7.1 统一汇总 CSV，保留其版本归属，仅作已有全核数记录与方法演进参考，不与 R12 改善点拼接。时间单位为周期；命中率为比例×100%。原始文件恢复范围与新实验范围分别核验。

编号	1 核	2 核	3 核	4 核	5 核
076	13.358%	27.878%	33.695%	41.715%	44.606%
077	0.000%	2.608%	2.542%	4.958%	0.000%
078	0.000%	0.000%	57.903%	0.000%	40.497%
079	0.000%	0.000%	11.095%	0.000%	23.385%
080	16.861%	43.600%	0.000%	45.833%	31.879%
081	0.000%	0.000%	0.000%	0.000%	0.000%
082	0.000%	11.199%	17.389%	27.870%	37.148%
083	79.587%	43.982%	30.544%	70.187%	18.959%
084	0.000%	0.000%	0.000%	0.000%	0.000%
085	0.000%	5.007%	22.427%	21.657%	35.025%
086	0.000%	11.467%	17.900%	32.040%	32.040%
087	18.337%	29.552%	22.061%	22.913%	21.211%
088	0.000%	20.236%	27.680%	20.629%	20.629%
089	0.000%	0.000%	27.119%	0.000%	0.000%
090	0.000%	36.290%	60.389%	46.526%	46.526%
091	10.539%	17.987%	24.463%	28.042%	24.169%
092	79.355%	0.874%	11.123%	27.024%	20.302%
093	0.000%	0.000%	0.000%	0.000%	0.000%
094	0.000%	18.399%	13.048%	39.729%	12.024%
095	0.000%	0.000%	0.000%	0.000%	0.000%
096	0.000%	23.957%	24.272%	27.144%	38.753%
097	0.000%	0.000%	21.972%	4.167%	24.523%
098	0.000%	0.000%	32.740%	38.394%	45.621%
099	25.235%	44.189%	51.038%	55.453%	54.449%
100	0.000%	2.741%	39.725%	27.555%	39.088%

来源：NPU_R8_1400 项逐例结果.csv。数字可复算不等于全部历史原始输出在当前附件中已被重新执行。

附录 D.1 运行环境与首次复现

核心复现环境为 Linux、CPython 3.13.5 和 Python 标准库。进程树清理依赖/proc，原生 Windows 及 macOS 未完成同等验收；Windows 队员宜在已有 Linux/WSL 环境运行。无需 GPU、NPU、AI 接口密钥或在线模型服务。文稿构建工具不是求解器依赖。

解压 NPU_R12_Code.zip 得到 NPU_R12 目录，保持其余依赖目录与 official 完整。不要只复制 round12_src。首次运行用新建或空输出目录，并先核对包清单。若文件不匹配，应定位来源，不通过修改清单绕过检查。

单例完成后，selected_plan.json 与 <case>_multicore_res.json 应逐字节一致，且只含题目规定两个字段。报告与候选日志独立存放。不能从预先写入的参考数值选方案；参考值只用于事后断言。

常用命令：

```
cd NPU_R12
python3 -m venv --without-pip .venv
.venv/bin/python -S round12_tools/verify_package.py
.venv/bin/python -S -m unittest discover -s round12_tests -v
.venv/bin/python -S round12_src/solve_round12.py \
  official/data/case_073.json -n 5 --scene B \
  --budget 600 --out work/case073_B5
```

附录 D.2 官方重评与多核矩阵

官方重评直接读取刚生成的两字段方案，不读取求解器报告中的最终耗时作为评分输入。场景 A、B、L2 分别调用 problem_1、problem_2、problem_3。显式提供方案路径，避免评估器在原图目录寻找默认文件。

完整多核矩阵是 100 例 $\times$ 2/3/4/5 核 $\times$ A/B/L2，共 1200 项。本文并未将这条命令的存在描述为矩阵已经运行完成。每个 600 秒是单请求软预算，不是整个批次的总预算。

续跑必须保留相同参数、源码和输入，增加--resume 并让程序核对状态；版本或参数改变必须使用新目录。失败与超时保留为不同状态，不将缺失行填成 1 倍加速，也不只报告成功子集而称完整 100 例均值。

```
.venv/bin/python -S official/code/multicore_cut_evaluate_problem_2.py \  
  official/data/case_073.json \  
  work/case073_B5/case_073_multicore_res.json \  
  --config official/data/config.txt -o work/case073_B5/rechecked.json  
.venv/bin/python -S round12_src/run_matrix.py --cases all \  
  --cores 2 3 4 5 --scenes A B L2 --workers 1 \  
  --budget 600 --out work/final_R12
```

附录 D.3 证据补齐、三类对照与失败留痕

补齐版覆盖原清单 8144 项文件要求。其中 7260 项保留或复得原历史字节，884 项是本次真实重新运行的元数据与日志，不应当具有旧墙钟或旧路径。原 EVIDENCE_MANIFEST.json 不改；REBUILT_MANIFEST.json 与 COMPLETION_MAP.json 记录新旧哈希和来源映射。[18]

局部微批扩展应比较同一 R12 成功方案 P0、不再调整的 P0、从 P0 再次运行原固定窗口、从 P0 运行新自适应窗口。后三者不能串行接力：新自适应不得从已优化的固定窗口结果出发却声称公平。此项自适应试验尚未形成通过验收的正式结果，未纳入本稿主方法。

固定单核、优化单核和多核控制有不同职责。固定单核必须由题目指定整图入口产生，不能用优化后的一核时间替代。L2 纯资源对照需要完整方案哈希相同，且独立选解对照不得混用。

审计至少核对操作守恒、计算周期、同 Pipe 不重叠、原始依赖、核心归属、COPY 分解、容量峰值、结果哈希与下界。这样的独立一致性检查不等于第二个完整共享带宽模拟器，不构成大图最优性证明。

```
.venv/bin/python -S evidence_completion/verify_completion.py \  
--hydrate --output evidence_completion/local_verification.json
```

附录 D.4 交付清单与结论边界

论文交付应含 Word、PDF、可编辑正文、公式源、生成图表的数据、逐例 CSV 以及本稿构建脚本。求解器代码和大体积原始证据分别以已核对的小包提供。复杂公式以排版图插入 Word，配套保留可编辑 LaTeX 源，避免转换缺符号。Word 声明宋体、黑体和 Times New Roman 样式；本次 PDF 环境以 Noto Serif/Sans CJK 和 Liberation Serif 作兼容替代，不声称与官方样本逐字逐像素一致。字体文件不随稿分发。

本稿是按用户要求扩展的研究长稿，不将 80—100 页误写为竞赛规定页数。学校、队号、成员与签字由团队自行填写，不伪造身份或承诺。正式参赛时，应按照当届官方模板、匿名要求、AI 辅助使用规则和最终提交要求独立核验。

可支持结论：三问具有机制一致的模型与可执行方法；历史全核数汇总与 R12 限定主批次分列；局部微批在两个明确高 Spill 实例有效，快速日历在 100 例候选比较中保持相同性；若可行解接近有效全局下界，可给出该配置的质量证书。

不可支持结论：R12 已经完成全部 1200 项新矩阵；自适应微批已经优于等预算重复固定窗口；全部大图全局最优；所有历史日志都恢复原字节；已经达到某一奖级或名次。后续应以同版本全题验证和队友干净复现关闭这些交付缺口，而非用更长篇幅代替证据。